

SAM

Segment Anything

<https://arxiv.org/pdf/2304.02643>

Abstract

- Meta는 Segment Anything (SA) 프로젝트를 소개함.
- 새로운 작업, 모델, 데이터셋을 제안.
- 총 11백만 장의 이미지, 10억 개 이상의 마스크로 구성된 **사상 최대 규모의 분할 데이터셋 (SA-1B)을 제작.
- 이 모델은 프롬프트 기반 분할이 가능하며, 제로샷 전이 성능이 매우 뛰어남.
- Segment Anything Model 과 데이터셋은 모두 공개되어 연구용으로 사용 가능함

Introduction

1.1 배경

- NLP 분야에서는 웹 규모 데이터로 훈련된 **대규모 언어 모델**이 제로샷·퓨샷 학습을 통해 큰 성과를 거두고 있음.
- 이와 유사한 **"Foundation Model"** 개념을 컴퓨터 비전(CV)에도 도입하려 함.
- 기존 CV에서는 CLIP, ALIGN 등이 텍스트-이미지 쌍을 활용하여 제로샷 일반화를 가능하게 했지만, **이미지 분할** 분야에서는 아직 대규모 기반 모델이 부족함.

1.2 목표

- **이미지 분할 분야의 Foundation Model**을 만드는 것이 목표.
 - 이 모델은 다음 조건을 만족해야 함:
 1. 프롬프트 기반 분할이 가능하고
 2. 다양한 다운스트림 작업에 적용 가능하며
 3. 새로운 데이터 분포에도 일반화가 가능해야 함.
-

2. 주요 구성 요소

Task: 프롬프트 기반 분할

- 사용자가 입력한 **프롬프트(예: 점, 박스, 텍스트)**에 따라 마스크를 출력하는 작업.
 - 프롬프트가 모호한 경우에도 합리적인 결과 마스크를 출력해야 함.
 - 이 작업 자체가 사전 학습(pre-training) 목적이자, 다양한 분할 작업에 활용될 수 있는 기반이 됨.
-

Model: Segment Anything Model (SAM)

- SAM은 세 가지 주요 컴포넌트로 구성됨:
 1. 이미지 인코더: 이미지 특징 임베딩 추출.
 2. 프롬프트 인코더: 사용자의 입력(점, 박스 등) 임베딩.
 3. 마스크 디코더: 임베딩을 조합해 마스크 예측.
 - 분할 속도는 빠름 (브라우저에서 약 50ms).
 - 하나의 프롬프트에 대해 다중 마스크 예측도 가능 → 모호함 대응
-

Data: 데이터 엔진 (Data Engine)

- 기존 웹에는 분할 마스크가 부족하므로, 자체적으로 데이터셋 구축.
- 3단계 전략으로 구성된 데이터 엔진을 사용함:
 1. 보조 수동 수집: 사람이 SAM의 도움을 받아 마스크 생성.
 2. 반자동 수집: SAM이 일부 객체 자동 분할, 나머지만 사람이 보완.
 3. 완전 자동 수집: 그리드 포인트 기반 자동 분할 → 이미지당 약 100개의 마스크

SA-1B 데이터셋

- 11백만 장의 이미지, 10억 개 이상의 마스크 포함.
 - 기존 어떤 분할 데이터셋보다 약 400배 규모 큼.
 - 마스크의 품질과 다양성 모두 우수함.
 - 공개되어 향후 연구 기반으로 활용 가능.
-

Responsible AI

- 지역·경제적으로 다양한 국가에서 이미지를 수집.
 - SAM은 다양한 인구 그룹에서 유사한 성능을 보임.
 - 모델 및 데이터셋 카드 제공.
-

실험 결과

- 23개 이상의 분할 벤치마크에서 프롬프트 한 개만으로도 매우 높은 품질의 마스크 생성.
- 다양한 다운스트림 작업에 제로샷으로 강력한 성능을 보임:
 - 엣지 감지
 - 객체 제안
 - 인스턴스 분할
 - 텍스트-마스크 예측 등
- 여전히 발전의 여지는 존재함.

1. 핵심 아이디어: Promptable Segmentation

- NLP에서의 프롬프트 학습처럼, 이 모델은 이미지 분할에 프롬프트 개념을 도입함.
 - 프롬프트는 점, 박스, 마스크, 텍스트 등 다양한 방식으로 무엇을 분할할지 지시할 수 있음.
 - 목표는 주어진 프롬프트에 대해 항상 유효한 분할 마스크를 반환하는 것 (프롬프트가 애매하더라도).
 - 이를 통해 다양한 분할 문제에 **제로샷 전이(zero-shot transfer)**가 가능.
-

2. Segment Anything Model (SAM) 구조

- 세 가지 주요 컴포넌트로 구성됨:
 1. 이미지 인코더: ViT 기반 대형 모델. 이미지를 한 번 처리해 임베딩 생성.
 2. 프롬프트 인코더: 점, 박스, 텍스트, 마스크 등 다양한 프롬프트를 임베딩.
 3. 마스크 디코더: 이미지 및 프롬프트 임베딩을 입력으로 받아 마스크 예측.
 - 속도: 이미지 임베딩을 사전에 계산하면, 나머지는 웹 브라우저에서 50ms 내에 실시간 동작 가능.
-

3. 앰비규어스(모호한) 프롬프트 처리

- 하나의 프롬프트가 여러 객체를 나타낼 수 있으므로, SAM은 **3개의 마스크와 신뢰도 (점수)**를 출력.
 - 훈련 시, 예측된 마스크 중 가장 손실이 낮은 것에 대해서만 역전파 수행.
-

4. 데이터셋 구축: SA-1B

총 11억 개의 분할 마스크를 만든 대규모 데이터 수집 파이프라인을 구축함.

3단계로 구성:

1) 수동 보조 단계 (Assisted Manual)

- 사람이 SAM과 브라우저 도구를 활용하여 분할 마스크를 그리는 단계.
- 점 클릭, 브러시, 지우개 등 사용 가능.
- 약 4.3M 마스크 수집.

2) 반자동 단계 (Semi-automatic)

- SAM이 미리 객체를 분할하고, 사람은 남은 객체만 추가로 주석.
- 더 복잡한 객체를 타겟으로 함.
- 약 5.9M 마스크 추가 수집 (총 10.2M 마스크).

3) 완전 자동 단계 (Fully Automatic)

- SAM이 스스로 마스크를 생성.
 - 데이터가 충분히 수집되자 모델 정확도가 높아져 이 단계가 가능해짐.
-

5. SAM의 활용

- 제로샷으로 다양한 분할 작업에 적용 가능:
 - 예: 텍스트 기반 분할, 박스 기반 객체 인스턴스 분할, 반응형 툴 등에 적용.
 - CLIP처럼 다른 시스템의 구성 요소로도 사용 가능.
 - 실제로 SAM은 기존의 고정된 멀티태스크 모델과 달리 새로운 작업에도 적응 가능.
-

5. Segment Anything Dataset (SA-1B)

- SA-1B 구성:

총 1,100만 장의 고해상도 이미지와 11억 개의 분할 마스크로 구성된 데이터셋.

 - 이미지 해상도는 평균 3300×4950이며, 얼굴과 차량 번호판은 블러 처리됨.
 - 실제 공개 데이터는 한쪽 면을 1500픽셀로 줄여 제공.
- 마스크 품질:
 - 전체 마스크의 99.1%는 자동으로 생성됨.
 - 전문가가 수정한 마스크와 비교했을 때, 94%는 IoU가 90% 이상, 97%는 75% 이상으로 매우 높은 일치도를 보임.
 - 이전 데이터셋 간 주석자 간 일치도는 85~91%로, SA-1B의 자동 마스크는 전문가 수준임이 확인됨.
- 기존 데이터셋과 비교:
 - SA-1B는 Open Images보다 11배 많은 이미지, 400배 많은 마스크 보유.
 - 이미지당 평균 마스크 수는 Open Images보다 36배, ADE20K보다도 3.5배 많음.
 - 작은 객체, 복잡한 형태의 마스크도 많이 포함됨.
- 지리적 분포:
 - 전 세계 50개국 이상에서 촬영된 이미지 포함.
 - 유럽과 아시아 이미지 비중이 높음.
 - 모든 지역에서 최소 1,000장 이상, 아프리카도 2800만 개 이상의 마스크 포함.

6. Responsible AI (RAI) 분석

- 지역 및 소득 불균형 분석:
 - SA-1B는 중간 소득 국가에서 더 많은 데이터를 포함하고 있음.
 - 아프리카, 라틴 아메리카, 저소득 국가는 여전히 모든 데이터셋에서 부족함.
 - 그럼에도 불구하고, SA-1B는 아프리카에서도 2800만 개 이상의 마스크 포함.
- 공정성 평가 (성별/연령/피부색):
 - 성별 인식 기반 성능: 여성과 남성 모두 비슷한 성능 (mIoU 약 54~55%)
 - 연령 인식 기반 성능: '노년층' 인식 그룹에서 가장 높은 성능
 - 피부색 기반 성능: 6단계 피부 톤 모두에서 유사한 성능, 큰 차이 없음

- 모든 그룹 간 성능 차이는 통계적 신뢰구간이 겹치지며 공정한 성능을 보여줌