

FCN

<https://arxiv.org/pdf/1411.4038>

Fully Convolutional Networks for Semantic Segmentation

Abstract

본 연구에서는 완전 합성곱 신경망(FCN)을 이용해 의미론적 분할(semantic segmentation) 성능을 향상시켰다. 기존 분류 모델(AlexNet, VGGNet, GoogLeNet)을 FCN으로 변환하고 전이 학습을 적용하여 픽셀 단위 예측을 수행했다. 깊고 거친 특징과 얇고 세밀한 특징을 결합하는 구조를 도입해 정밀도를 높였으며, PASCAL VOC, NYUDv2, SIFT Flow에서 SOTA를 달성했다.

1. Introduction

CNN은 이미지 인식뿐만 아니라 객체 탐지, 키폰트 예측 등 다양한 분야에서 성능을 향상시키고 있다. 의미론적 분할은 픽셀 단위로 객체 클래스를 예측하는 문제로, 기존 연구들은 CNN을 활용하였으나 한계를 지녔다. 본 연구는 기존 복잡한 전·후처리 없이 FCN을 활용하여 더 효율적이고 정확한 분할을 가능하게 했다. 또한, 깊은 특징과 얇은 특징을 결합하는 skip 구조를 적용해 위치 정보와 의미 정보를 효과적으로 통합했다.

2. Related Work

기존 연구에서는 이미지 분류 모델을 변형하여 의미론적 분할에 활용했으나, 대부분 복잡한 후처리 과정을 포함하거나 패치 단위 학습을 수행했다. 본 연구는 완전 합성곱 신경망(FCN)을 활용하여 효율적이고 직접적인 의미론적 분할을 가능하게 한다. 기존 방식들과 달리 엔드 투 엔드 학습을 수행하며, 패치 기반 학습이나 후처리 없이 전체 이미지를 한 번에 학습하고 예측할 수 있다.

(기존) cnn을 활용한 밀집 예측

- Ning et al. [27], Farabet et al. [8], Pinheiro & Collobert [28]은 의미론적 분할을 수행
- Ciresan et al. [2]는 전자현미경 경계 예측, Ganin & Lempitsky [11]는 자연 이미지의 경계 예측

- Eigen et al. [5, 6]는 이미지 복원과 깊이 추정

→ 사용한 기법

- 모델 크기 제한 및 좁은 수용 영역
- 패치 단위 학습 방식
- 후처리 과정(초픽셀 적용, 랜덤 필드 정규화, 필터링, 지역 분류)
- 다중 해상도 피라미드 처리
- 특정 비선형 활성화 함수 사용
- 앙상블 기법 적용

⇒ 본 연구에서는 이러한 복잡한 기법 없이 FCN 활용하여 전체 이미지를 학습하고 예측하도록 함.

3. Fully convolutional networks

3-1. Adapting classifiers for dense prediction

일반적인 분류 신경망(LeNet, AlexNet 등)은 고정 크기의 입력을 받아 공간 정보를 버리고 분류 결과를 출력한다. 그러나 완전연결층을 **특정 영역 전체를 덮는 합성곱 층**으로 변환하면, 입력 크기에 상관없이 **공간적 출력을 생성하는 Fully Convolutional Network (FCN)**으로 만들 수 있다.

➡ 즉, 기존 분류 모델을 **FCN으로 변환하면 밀집한 예측을 수행할 수 있도록 확장할 수 있음.**

3.2. Shift-and-stitch is filter rarefaction

출력이 다운샘플링된 경우, 원본 크기의 예측을 복원하는 기법. OverFeat 모델이 제안한 방식으로, 입력을 여러 번 **좌우 및 상하로 이동**(패딩 추가)하고 각 경우의 출력을 결합하는 방식.

➡ 하지만 필터를 확대하는 방식으로 동일한 효과를 얻을 수 있어 FCN에서는 이 방법을 사용하지 않음.

3.3. Upsampling is backwards strided convolution

- 업샘플링 = 역합성곱

출력을 원래 해상도로 변환하려면 **업샘플링**이 필요.

업샘플링은 **일반적인 보간(예: bilinear interpolation)** 대신,

역합성곱(deconvolution, transposed convolution)을 사용하여 **학습 가능한 업샘플링 필터**를 적용하는 것이 효과적.

➡ FCN에서는 **업샘플링 계층을 학습**하여 정밀한 예측을 수행하도록 함.

3.4. Patchwise training is loss sampling

기존 방식: 작은 패치를 무작위로 샘플링하여 학습

FCN 방식: **전체 이미지를 한 번에 학습**

➡ FCN이 더 효율적이며, 패치 단위 학습을 적용하지 않아도 성능 저하 없이 빠른 학습이 가능함.

4. Segmentation Architecture

4-1. From classifier to dense FCN

분류기 → 밀집 FCN 전환

- AlexNet, VGGNet, GoogLeNet을 FCN 구조로 변환.
- 최종 분류기 레이어를 제거하고, 완전 연결층을 합성곱 레이어로 변환.
- 1×1 합성곱층을 추가해 PASCAL VOC 클래스별 점수를 예측.
- 업샘플링을 위한 디컨볼루션 레이어 추가.
- VGG16 기반 FCN(FCN-VGG16)이 가장 높은 성능(56.0 mean IU)을 기록.

결론: FCN-VGG16이 가장 뛰어난 성능을 보이며, GoogLeNet 기반 FCN은 성능이 상대적으로 낮음.

4.2. Combining what and where

특징 정보와 위치 정보를 결합

- 기존 FCN은 최종 예측 레이어의 32픽셀 스트라이드로 인해 출력이 조악함.
- 해결책: 낮은 층(pool4, pool3)의 정보를 최종 층과 결합하는 스킵 연결 사용.

- FCN-16s: pool4의 출력을 conv7과 결합하여 2배 업샘플링.
- FCN-8s: pool3을 추가 결합하여 더 정교한 예측 수행.
- 결과적으로 FCN-16s가 62.4 mean IU, FCN-8s가 62.7 mean IU로 성능 향상.

결론: 낮은 층과 높은 층을 결합하는 스킵 네트워크가 더 정밀한 세그멘테이션 결과를 제공.

4.3. Experimental framework

- **최적화 방법:**
 - SGD(확률적 경사 하강법) 사용, momentum 0.9 적용.
 - 학습률: FCN-AlexNet(10^{-3}), FCN-VGG16(10^{-4}), FCN-GoogLeNet(5×10^{-5}).
 - 정규화: 가중치 감쇠(weight decay) 사용(5×10^{-4} 또는 2×10^{-4}).
 - 클래스 예측을 위한 합성곱층은 0으로 초기화.
- **파인튜닝:**
 - 전체 네트워크를 백프로파게이션으로 미세 조정(fine-tune).
 - 최종 레이어만 학습하면 성능이 70% 수준에 그침.
 - 학습 시간: FCN-32s(3일), FCN-16s/FCN-8s(각 1일).
- **패치 샘플링:**
 - 전체 이미지에서 여러 패치를 샘플링하여 학습 진행.

결론: 전체 네트워크를 파인튜닝하는 것이 가장 효과적이며, 학습에는 다일 이상의 시간이 필요.

5. Results

우리는 FCN(Fully Convolutional Network)을 사용하여 의미론적 분할(semantic segmentation)과 장면 해석(scene parsing)을 테스트했다. PASCAL VOC, NYUDv2, SIFT Flow 데이터셋을 사용하였으며, 객체와 영역을 구분하는 기존 접근 방식과 달리 모든 픽셀을 예측 대상으로 처리했다.

평가 지표 (Metrics)

다음 4가지 평가 지표를 사용했다.

- **픽셀 정확도 (Pixel Accuracy):** 모델이 올바르게 분류한 픽셀의 비율

- **평균 정확도 (Mean Accuracy):** 각 클래스별 정확도의 평균
- **평균 IoU (Mean Intersection over Union, IU):** 클래스별로 교집합/합집합 비율의 평균
- **빈도 가중 IoU (Frequency Weighted IU, f.w. IU):** 클래스 빈도를 고려한 IoU

결론: FCN은 PASCAL VOC, NYUDv2, SIFT Flow 데이터셋에서 기존 방법보다 **높은 정확도와 빠른 속도**를 보였다. 특히, PASCAL VOC에서는 기존 최고 성능 대비 **20% 성능 향상**, 추론 속도 **286배 향상**을 기록했다. NYUDv2에서는 RGB와 깊이 정보를 결합한 RGB-HHA 모델이 가장 우수했고, SIFT Flow에서도 의미론적 및 기하학적 분할 모두에서 **최고 성능**을 기록했다.

6. Conclusion

완전 합성곱 신경망(FCN, Fully Convolutional Networks)은 현대적인 분류 기반 합성곱 신경망(CNN)의 확장된 형태로 볼 수 있는 풍부한 모델 클래스이다. 이러한 사실을 인식하고 기존 분류 네트워크를 세분화(Segmentation) 문제로 확장하며, 다중 해상도 계층 결합 방식을 개선하면, 학습과 추론 과정을 단순화하고 속도를 높이는 동시에 기존 기술 대비 성능을 크게 향상시킬 수 있다.

- FCN(완전 합성곱 신경망은 분류 CNN을 세분화 문제로 확장한 강력한 모델로, 성능을 크게 향상하면서도 학습 및 추론 속도를 높인다.
- 다양한 다운샘플링 실험을 통해, 픽셀 단위의 정확성이 반드시 높은 평균 IU로 이어지는 않음을 확인했다.
- PASCAL-Context 데이터셋 실험에서 기존 SOTA 기법인 CFM 대비 FCN-8s 모델이 11% 향상된 평균 IU를 기록했다.
- 연구의 개선 사항과 실험 결과는 arXiv 버전에서 지속적으로 업데이트된다.