

ELMo

deep contextualized word representation


1) 단어 사용의 복잡한 특성(syntax and semantic)

ex. present 단어 뜻 - 선물, 현재 등..

2) 이러한 단어 사용이 언어적 맥락에서 얼마나 다양한지를 모델링 한 것!

ex. 문맥에 따라 present의 의미가 달라져야 함. ("Here is your b-day present" vs "Live in present not past")

▼ Word Embedding



Word Coordinates			
	Gender	Age	Royalty
man	1	7	1
woman	9	7	1
boy	1	2	1
girl	9	2	1
king	1	8	8
queen	9	7	8
prince	1	2	8
princess	9	2	8


Word Embedding의 최종 목표

어떻게 하면 각 단어를 효과적으로
수치화 할 수 있을까?



다양한 임베딩 모델로의 발전
각 모델 내에서 학습을 통해 표현 방식 최적화

ELMo 이전에 등장했던 Word Embedding 방식들



[Word2Vec]



	the	quick	brown	fox	jumps
the	0	1	1	0	0
quick	1	0	0	1	0
brown	1	0	0	0	0
fox	0	1	0	0	1
jumps	0	0	0	1	0

[Glove]

Limitation

She's wearing a dress like mine

Do you like their new house?



기존 Word2Vec과 Glove의 한계

단어가 각 문장에서 쓰이는 문맥이 다르더라도,
같은 단어는 무조건 한 개의 고정된 벡터로 표현
문법구조나 다의어에 따른 의미의 변형을
포착하기 어렵다는 문제점

ELMo 제안

양방향 LSTM을 활용하여 전체 문장의
문맥적 특성을 각 위치의 단어 임베딩 벡터에 반영
같은 단어라도 서로 다른 의미를 가지면,
다른 벡터로 표현함으로써 문제 해결

1 Sparse Representation

대부분 0이므로 Sparse Representation임

예시 1: One-Hot Encoding (원-핫 인코딩)

- 단어를 벡터로 표현할 때, 해당 단어의 위치만 1, 나머지는 0
- 예를 들어, ["cat", "dog", "fish"] 3개 단어의 원-핫 인코딩 (3차원 벡터):

cat → [1, 0, 0]

dog → [0, 1, 0]

fish → [0, 0, 1]

✓ Sparse Representation의 특징

- ✓ 해석이 쉬움 (각 차원이 명확한 의미를 가짐)
- ✓ 고차원 표현 가능 (정보량이 많음)
- ✗ 메모리 사용량이 큼 (매우 많은 0이 존재)
- ✗ 계산 효율이 낮음 (희소 행렬 연산이 느릴 수 있음)

2 Dense Representation (밀집 표현)

📌 개념

- 대부분의 값이 0이 아닌 표현 방식
- 벡터 차원이 상대적으로 작지만, 각 차원이 의미 있는 정보를 내포
- 학습을 통해 최적화된 연속적인 값으로 표현됨

◆ 예시 1: Word Embedding

- Word2Vec, FastText, GloVe 같은 기법으로 학습된 단어 벡터
- 단어 간의 의미적 유사성을 반영한 저차원 벡터 표현
- 예: `cat`, `dog`, `fish` 의 밀집 벡터 (차원 축소 예시)

cat → [0.8, -0.2, 0.5]

dog → [0.9, -0.3, 0.6]

fish → [0.1, 0.4, -0.8]

◆ 예시 2: BERT의 단어 표현

- Transformer 모델이 학습한 단어 임베딩 벡터는 **고차원 정보가 내포된 Dense Representation**임
- 문맥(Context)을 반영하여 같은 단어라도 문맥에 따라 다른 벡터값을 가짐

✓ Dense Representation의 특징

- ✓ 메모리 효율적 (낮은 차원에서도 많은 정보 표현 가능)
- ✓ 연산 효율적 (GPU/TPU에서 최적화됨)
- ✓ 의미적 유사성 표현 가능 (비슷한 단어끼리 벡터 거리가 가까움)
- ✗ 해석이 어려움 (각 차원의 의미를 명확히 알기 어려움)

◆ 1 문맥(Context)에 따라 변하는 동적(Dynamic) 임베딩

- 기존 Word2Vec, GloVe는 단어별 고정된 벡터를 사용했지만,
- ELMo는 문맥(Context)에 따라 단어 벡터가 다르게 표현됨.
 - 예) "bank"
 - "I went to the bank to withdraw money." → 은행 의미
 - "He sat on the bank of the river." → 강둑 의미
 - 같은 단어라도 문맥에 따라 다른 벡터 값 제공!

◆ 2 깊은 양방향 언어 모델 (Deep BiLM) 사용

- ELMo는 BiLM(Bidirectional Language Model) 기반
 - 앞쪽(Forward)과 뒤쪽(Backward) 문맥을 모두 고려

- 예측 기반 학습으로 더 풍부한 의미 정보 반영
- Transformer 대신 **LSTM 기반**의 다층 언어 모델 사용

◆ 3 사전 학습된 모델을 활용 (Pre-trained on Large Corpus)

- 대량의 코퍼스(Wikipedia, 뉴스, 책 등)로 사전 학습(Pretraining)
- 특정 태스크(Sentiment Analysis, NER 등)에 맞춰 추가 미세 조정(Finetuning) 가능

◆ 4 여러 층(레이어)의 정보를 조합한 벡터 제공

- ELMo 벡터 = 여러 층의 Hidden States의 가중합(weighted sum)
 - 낮은 층: 형태학적(Morphological) 정보 포함 (예: 어휘, 문법)
 - 높은 층: 문맥적(Contextual) 의미 포함
- 필요에 따라 가중치를 조정하여 원하는 정보 추출 가능