

YOLO

<https://arxiv.org/pdf/1506.02640>

You Only Look Once: Unified, Real-Time Object Detection

1. Introduction

YOLO(You Only Look Once)는 객체 탐지를 단순한 회귀 문제로 재정의하여, 이미지에서 한 번만 예측을 수행하는 방식이다. 기존의 R-CNN이나 DPM 같은 복잡한 탐지 모델과 달리, YOLO는 하나의 합성곱 신경망을 통해 객체의 위치와 클래스 확률을 동시에 예측한다.

이 방식의 주요 장점은 다음과 같다.

1. **속도:** Titan X GPU에서 초당 45 프레임, 빠른 버전은 150 FPS 이상을 처리할 수 있어 실시간 탐지가 가능하다.
2. **전체 이미지 기반 학습:** YOLO는 이미지 전체를 학습하고 분석하기 때문에 배경과 객체를 더 잘 구별할 수 있다.
3. **일반화 성능:** 다른 데이터셋에서도 높은 성능을 유지하며, 기존 탐지 방법보다 예기치 않은 입력에 더 잘 대응한다.

하지만 작은 객체의 위치를 정확하게 찾는 데는 어려움이 있다. 전체 학습 및 테스트 코드는 오픈 소스로 제공되며, 사전 학습된 모델도 다운로드할 수 있다.

2. Unified Detection

YOLO는 이미지를 $S \times S$ 격자로 나누고, 각 격자 셀에서 B개의 바운딩 박스와 신뢰도 점수를 예측한다. 각 바운딩 박스는 (x, y) 좌표, 너비(w), 높이(h), 신뢰도(confidence) 값을 포함하며, 신뢰도는 예측된 박스와 실제 정답 박스 간의 IOU(Intersection over Union)를 반영한다.

이 모델은 전체 이미지를 한 번만 보고(Global Reasoning) 탐지하기 때문에 빠른 속도를 유지하면서도 높은 정확도를 제공한다. YOLO의 네트워크 아키텍처는 GoogLeNet을 기반으로 하지만, 1×1 컨볼루션 레이어를 사용해 특징 차원을 줄이고, 3×3 컨볼루션을 활용하는 방식으로 설계된다.

모델 학습 과정에서는 ImageNet 데이터셋을 사용해 사전 학습한 후, PASCAL VOC 데이터셋을 이용해 추가 학습한다. 손실 함수는 객체가 존재하는 셀과 존재하지 않는 셀에 각각

다른 가중치(λ_{coord} , λ_{noobj})를 적용하는 방식으로 설계된다.

3. Comparison to Other Detection Systems

1. **전통적 탐지 방식:** 기존 객체 탐지 시스템은 이미지에서 특징을 추출한 후, 분류기나 지역화 모델을 사용해 객체를 탐지한다. 대부분 슬라이딩 윈도우 방식이나 영역 제안 방식을 사용한다.
2. **DPM (Deformable Parts Model):** DPM은 슬라이딩 윈도우 방식으로 객체를 탐지하지만, YOLO는 단일 신경망으로 모든 탐지 과정을 통합해 속도와 정확성을 높인다.
3. **R-CNN 및 변형 모델:** R-CNN은 Selective Search로 영역을 제안한 후, CNN을 통해 특징을 추출하고 SVM으로 분류하는 복잡한 파이프라인을 가진다. 반면, YOLO는 그리드 기반으로 바운딩 박스를 예측하며, 제안된 박스 수를 크게 줄여 속도를 개선한다.
4. **Fast/Faster R-CNN:** R-CNN을 개선해 속도를 높였지만, 여전히 실시간 성능에는 미치지 못한다. YOLO는 탐지 파이프라인을 없애고 처음부터 빠른 속도로 설계되었다.
5. **Deep MultiBox:** MultiBox는 CNN을 사용해 관심 영역을 예측하지만, 완전한 탐지 시스템이 아니며 추가적인 이미지 패치 분류가 필요하다. YOLO는 단독으로 탐지를 수행할 수 있다.
6. **OverFeat:** CNN을 활용해 지역화를 수행하지만, 탐지 성능을 최적화한 것이 아니라 후처리가 필요하다. YOLO는 전체 맥락을 고려해 탐지 성능을 높인다.
7. **MultiGrasp:** YOLO는 MultiGrasp에서 영감을 받아 그리드 기반 바운딩 박스 예측을 수행하지만, MultiGrasp는 단일 객체의 잡을 수 있는 영역을 찾는 단순한 작업인 반면, YOLO는 여러 객체의 경계 상자와 클래스 확률을 예측한다.

결론: YOLO는 기존 탐지 모델들의 복잡한 파이프라인을 제거하고, 하나의 CNN으로 빠르고 효율적인 객체 탐지를 수행하는 통합된 시스템이다.

4. Experiments

이 장에서는 YOLO와 다른 실시간 객체 탐지 시스템을 비교한다.

- **PASCAL VOC 2007 성능 비교:** YOLO는 63.4% mAP를 기록하며, 기존 실시간 탐지 모델보다 두 배 이상 정확하다.
- **속도 비교:** YOLO는 45 FPS로 실시간 성능을 유지하며, Fast YOLO는 155 FPS로 가장 빠르다.

- **VOC 2007 오류 분석:** YOLO는 객체의 위치를 정확하게 찾는 데 어려움을 겪지만, 배경을 잘못 탐지하는 오류는 Fast R-CNN보다 적다.
- **YOLO + Fast R-CNN 결합:** YOLO를 이용해 Fast R-CNN의 배경 오류를 줄이면 성능(mAP)이 75.0%로 향상된다.

5. VOC 2012 Results

YOLO는 VOC 2012 데이터셋에서도 강력한 성능을 보이며, 최신 모델과 비교했을 때 경쟁력을 가진다.

- YOLO 단독 성능: 57.9% mAP
- Fast R-CNN + YOLO 결합: 70.7% mAP
- 최상위 모델(MR CNN MORE DATA): 73.9% mAP

YOLO는 최상위 모델보다는 낮은 성능을 보이지만, 속도 면에서는 압도적인 이점을 갖고 있다.

6. Generalization

YOLO는 다른 탐지 모델보다 새로운 도메인에서의 일반화 성능이 뛰어나다.

- **Artwork 데이터셋 테스트:** YOLO는 PASCAL VOC에 맞춰 학습했음에도 불구하고, 미술 작품과 같은 새로운 데이터셋에서도 좋은 성능을 보인다.
- **자연 이미지 외에도 강한 성능:** 기존 탐지 모델은 특정 데이터셋에 과적합되기 쉽지만, YOLO는 다양한 환경에서도 강한 탐지 성능을 유지한다.

YOLO는 빠르고 범용적인 객체 탐지 모델로, 다양한 환경에서도 뛰어난 성능을 발휘할 수 있음을 입증한다.