

Faster R-CNN

<https://arxiv.org/pdf/1506.01497>

Faster R-CNN: Towards Real-Time Object
Detection with Region Proposal Networks

1 Introduction

- **R-CNN 계열 모델:** R-CNN은 계산이 많이 필요했지만, Fast R-CNN은 성능을 크게 개선해 실시간에 가까운 속도로 동작할 수 있다. 그러나 여전히 **Region Proposal** 단계에서 시간이 많이 걸린다.
- **Region Proposal 방법들:** Selective Search는 너무 느려서 2초씩 걸리고, EdgeBoxes는 비교적 빠르지만 여전히 시간이 많이 소요된다. GPU를 사용하면 속도가 개선될 수 있지만, 탐지 네트워크와 계산을 공유하지 않아 효율적이지 않다.
- **Region Proposal Networks (RPN):** 이 논문에서 제안하는 방법은 **Region Proposal Networks(RPN)**이다. RPN은 기존의 탐지 네트워크와 같은 합성곱 계층을 공유하여 제안 계산의 비용을 줄인다. RPN은 각 위치에서 지역 경계와 객체 가능성 점수를 예측하며, **End-to-End**로 학습할 수 있다.
- **성능:** RPN은 다양한 크기와 비율의 스케일을 처리할 수 있다. 전통적인 방식들과 비교했을 때, 이 방법은 **속도와 정확도** 모두에서 뛰어난 성능을 보인다. 또한, **Selective Search**의 계산 부담을 거의 없애고, 제안 생성 시간이 10밀리초로 매우 빠르다.
- **통합 학습 방식:** RPN과 Fast R-CNN을 통합하여 학습하는 방식이 제안된다. 이 방식은 **빠른 수렴**을 보이며, 두 작업을 위한 특징을 공유할 수 있다.
- **실제 시스템 적용:** RPN과 Faster R-CNN은 다양한 대회에서 좋은 성적을 거두었으며, 상용 시스템에도 적용되어 사용자의 참여도 개선에 기여했다.

2 RELATED WORK

- **객체 제안 방법:** 객체 제안 방법에 대한 연구가 많으며, 주요 방법으로는 슈퍼픽셀 그룹화 방식(예: Selective Search, CPMC, MCG)과 슬라이딩 윈도우 방식(예: Objectness in windows, EdgeBoxes)이 있다. 이 방법들은 객체 탐지기와 독립적으로 외부 모듈로 사용된다.
- **딥 네트워크를 이용한 객체 탐지:** R-CNN은 CNN을 사용해 객체 범주와 배경을 분류하고, 주로 분류기 역할을 한다. 객체 경계 예측은 하지 않으며, 제안된 영역의 성능에 따라 정확도가 달라진다. 여러 논문에서는 딥 네트워크를 사용해 객체의 경계를 예측하는 방법을 제시했다. 예를 들어, OverFeat은 완전 연결층을 사용해 박스 좌표를 예측하고, MultiBox는 다수의 클래스에 상관없는 박스를 예측한다.
- **공유된 합성곱 계산:** 합성곱 계산을 공유하는 방식이 효율적인 시각적 인식을 위해 중요해지고 있다. OverFeat은 이미지 피라미드를 사용하여 분류, 로컬라이제이션, 탐지를 수행하며, Fast R-CNN은 공유된 합성곱 특징을 활용해 빠르고 정확한 객체 탐지를 가능하게 한다.

3 FASTER R-CNN

3.1. 지역 제안 네트워크 (RPN)

RPN은 이미지를 입력받아 객체가 있을 법한 사각형 영역을 제안하고, 각 제안에 대해 "객체성 점수"를 계산한다. 이 과정은 완전 합성곱 신경망을 통해 이루어진다. 제안된 영역은 작은 네트워크를 통해 생성되며, 이 네트워크는 합성곱 특징 맵에서 슬라이딩 윈도우 방식을 사용해 작동한다.

3.1.1. 앵커 (Anchors)

각 슬라이딩 윈도우 위치에서 여러 개의 지역 제안을 동시에 예측한다. 각 위치에서 제안하는 박스들은 "앵커"라는 기준 박스를 기반으로 하며, 앵커는 다양한 비율과 크기를 가진다. 이 방법은 이동 불변성(translation invariance)을 갖추어, 객체가 이미지에서 이동해도 동일한 제안이 생성된다. 이로 인해 모델 크기가 줄어들고, 작은 데이터셋에 대해서도 과적합(overfitting)을 방지할 수 있다.

3.1.2. 손실 함수 (Loss Function)

RPN의 학습을 위해 각 앵커에 대해 객체 여부를 이진 분류하여 레이블을 할당한다. 학습 과정에서 각 앵커의 클래스와 위치를 예측하는 손실 함수는 Fast R-CNN의 다중 작업 손실 함수(multi-task loss)를 따른다. 이 손실 함수는 객체 탐지의 정확성을 높이기 위해 분류와 회귀 손실을 결합한다.

핵심 아이디어

- **RPN**은 기존의 이미지 피라미드나 슬라이딩 윈도우 방식을 사용하지 않고, 하나의 이미지에서 여러 크기와 비율의 앵커를 통해 효율적으로 지역 제안을 생성한다.
- **앵커**는 이동 불변성을 보장하여, 객체가 이동해도 동일한 제안이 생성될 수 있게 한다.
- **손실 함수**는 객체의 존재 여부와 위치를 동시에 예측하여 정확도를 높인다.

4 EXPERIMENTS

4.1 Experiments on PASCAL VOC