

사전 지식

Attention – 입력 데이터의 중요한 부분에 집중 하는 기법, 특히 자연어 처리 (NLP)에서 시퀀스 변화 작업에 자주 사용

Abstract

Sequence transduction 모델들은 Encoder와 Decoder를 포함하는 복잡한 RNN 또는 CNN에 기반한다. 가장 성능이 뛰어난 모델은 Encoder와 Decoder를 attention 메커니즘을 통해 연결한다.

문제 상황 : 위 구조는 복잡한 구조

제안 : 순환과 합성곱을 완전히 배제하고 어텐션 메커니즘 기반으로 하는 Transformer

1. Introduction

순환 신경망의 한계 : 본질적으로 순차적인 특성 때문에, 훈련 데이터에서 병렬화를 수행하기 어렵고 특히 시퀀스 길이가 길어질수록 메모지 제한으로 인해 배치 크기가 제한되면서 연산이 더욱 비효율적

휠어텐션 메커니즘 등장 – 다양한 시퀀스 모델링 및 변환 작업에서 중요한 역할을 하여, 입력 또는 출력 시퀀스에서 거리와 무관하게 의존성을 모델링 but 기존 attention 메커니즘은 대부분 순환 신경망

새로운 접근 방식 – Transformer 순환구조를 완전히 제거하고, 오직 Attention 메커니즘만을 활용하여 입력과 출력간 전역적인 의존성을 모델링하는 Transformer 아키텍처

➔ 기존보다 높은 병렬화 성능 제공

2. Background

순차적 연산을 줄이려는 목표는 Extended Neural GPU, ByteNet 그리고 ConvS2S의 기반을 형성. 모두 CNN을 기본 구성 요소로 사용 BUT 먼 위치에 있는 단어들 간의 의존성을 학습하는 것을 더 어렵게 만들.

Self-attention : 단일 시퀀스 내의 서로 다른 위치를 연결하며, 해당 시퀀스의 표현을 계산하는 메커니즘. Transformer는 RNN 또는 합성곱을 전혀 사용하지 않고, 오직 self-attention만을 입력과 출력이 표현을 계산하는 최초의 모델

3. Model Architecture

Encoder – 입력 시퀀스 $(x_1, \dots, x_n)$ 을 연속적인 표현 $z=(z_1, \dots, z_n)$ 매핑

Decoder – 이 z 를 기반으로 출력 시퀀스 $(y_1, \dots, y_n)$ 를 한 번에 한 요소씩 생성




Figure 1: The Transformer - model architecture.

3.1. Encoder and decoder Stacks

인코더 N=6개의 동일한 레이어로 구성. 각 레이어는 두 개의 서브 레이어로 이루어짐.

1. Multi-head self-attention

2. 간단한 위치별 완전 연결 피드 포워드 네트워크

각 서브레이어는 잔차 연결을 적용한, 레이어의 정규화 수행. 각 서브 레이어의 출력 $\text{LayerNorm}(x_{\text{sublayer}}(x))$


디코더 N=6개의 동일 레이어. 디코더의는 세번째 서브 레이어를 추가 포함.

인코더 스택의 출력에 대해 멀티헤드 어텐션을 수행 but 디코더 스택 내의 자기 어텐션 서브레이어는 시퀀스에서 현재 위치 이후의 정보를 참조하지 못하도록 수정


3.2. Attention

Attention 함수는 쿼리와 키-값 쌍 집합(vector)를 출력(vector) 매핑

Scaled Dot-Product Attention



Multi-Head Attention



3.2.1. Scaled Dot-Product Attention

Scaled Dot-product Attention은 쿼리, 키, 값의 내적을 계산한 후 루트(dk)로 나누고 softmax를 적용해 가중치를 구함

Dot product Attention은 가산 어텐션보다 더 빠르고 메모리 효율적

dk가 커지면 softmax가 kwr은 그래디언트 영역으로 밀리는 문제가 발생 -> $1/\sqrt{dk}$ 로 스케일링

3.2.2 Multi-Head Attention

Multi-Head Attention은 쿼리, 키, 값을 h개의 서로 다른 선형 변환을 통해 d_k, d_k, d_v 파원으로 투영한 후, 병렬적으로 attention을 수행하고 최종적으로 연결하여 다시 투영하는 방식 -> 단일 헤드보다 강력한 표현력을 가짐

3.2.3 Applications of Attention in our Model

The Transformer uses multi-head attention in three different ways

1. 인코더-디코더 어텐션: 디코더는 쿼리를 이전 디코더 레이어에서, 키와 값을 인코더 출력에서 가져와 입력 시퀀스 전체를 참조한다.
2. 인코더 자기어텐션: 쿼리, 키, 값이 모두 이전 인코더 레이어의 출력에서 생성되며, 각 위치가 모든 위치를 참조할 수 있다.
3. 디코더 자기어텐션: 각 위치가 이전 위치까지의 정보만 참조하도록 마스킹 (masking)을 적용해 미래 정보가 흐르지 않도록 한다.

3.3. Position-wise Feed-Forward Networks

트랜스포머와 각 인코더 레이어는 두개의 선형 변환과 ReLU로 구성된 피드 포워드 네트워크를 포함. 입력 차원 512, 내부 레이어 차원 2048

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

3.4. Embeddings and Softmax

입력과 출력 토큰을 d_{model} 차원 벡터로 변환하는 임베딩과 예측된 토큰 확률을 위한 softmax를 사용하여, 두 임베딩 레이어와 pre-softmax 변환에서 동일한 가중치 행렬을 공유

3.5. Positional Encoding

Transformer는 recurrence나 convolution이 없기 때문에 모델이 시퀀스 순서를 이용 할 수 있도록 토큰의 상대적 또는 절대적인 위치 정보를 주입해야 함.

➔ 인코더와 디코더 스택의 하단에 위치 인코딩을 입력 임베딩에 추가

4. Why Self-Attention

Self-attention이 recurrent와 convolutional layer에 비해 장점

1. 계산 속도가 빠르고 병렬화 용이
2. 장기 의존성 학습 유지
3. 모델 해석 가능성이 높고, 효율성이 뛰어난 계산을 제공하여, self-attention 과 feed-forward 레이어의 조합은 분리 가능한 convolution보다 효율적

5. Training

This section describes the training regime for our models.

5.1. Training Data and Batching

Training Data : WMT 2014 영어-독일어 AND 영어-프랑스어 데이터셋

Batching : 바이트 페어 인코딩과 워드 feeword 어휘로 문장 인코딩, 각 훈련 배치에 25,000개의 소스와 target 토큰 포함

5.2. Hardware and Schedule

(논문 원본)

We trained our models on one machine with 8 NVIDIA P100 GPUs. For our base models using the hyperparameters described throughout the paper, each training step took about 0.4 seconds. We trained the base models for a total of 100,000 steps or 12 hours. For our big models,(described on the bottom line of table 3), step time was 1.0 seconds. The big models were trained for 300,000 steps (3.5 days).

5.3. Hardware and Schedule

(논문 원본)

We used the Adam optimizer [20] with $\beta_1 = 0.9$, $\beta_2 = 0.98$ and $\epsilon = 10^{-9}$. We varied the learning rate over the course of training, according to the formula: $\text{lr} = \text{d}^{-0.5} \cdot \min(\text{step_num}^{-0.5}, \text{step_num} \cdot \text{warmup_steps}^{-1.5})$ (3) This corresponds to increasing the learning rate linearly for the first warmup_steps training steps, and decreasing it thereafter proportionally to the inverse square root of the step number. We used warmup_steps = 4000.

5.4. Regularization

Three types of regularization during training 진행

6. Results

6.1. Machine Translation

영어-독일어

영어-독일어 번역 작업에서, 대형 모델은 이전에 보고된 최고 성능 모델(양상블 포함) 보다 BLEU 점수가 2.0 이상 더 높음 -> 28.4 BLEU 점수. 기존 모델보다 모든 기존 단일 모델 및 양상블을 능가하며, 경쟁 모델들보다 훨씬 적은 훈련 비용 사용

영어-프랑스어

Bleu 점수 41.0을 기록, 이전 최고 성능 단일 모델을 능가했으며, 훈련 비용은 기존 최고 성능 모델의 1/4 수준

6.2. Model Variations

	N	d_{model}	d_{ff}	h	d_k	d_v	P_{drop}	ϵ_{ls}	train steps	PPL (dev)	BLEU (dev)	params $\times 10^6$		
base	6	512	2048	8	64	64	0.1	0.1	100K	4.92	25.8	65		
(A)					1	512	512			5.29	24.9			
					4	128	128			5.00	25.5			
					16	32	32			4.91	25.8			
					32	16	16			5.01	25.4			
(B)					16					5.16	25.1	58		
					32					5.01	25.4	60		
(C)	2									6.11	23.7	36		
	4									5.19	25.3	50		
	8									4.88	25.5	80		
		256			32	32					5.75	24.5	28	
		1024			128	128					4.66	26.0	168	
			1024									5.12	25.4	53
			4096									4.75	26.2	90
(D)							0.0			5.77	24.6			
							0.2			4.95	25.5			
								0.0		4.67	25.3			
								0.2		5.47	25.7			
(E)	positional embedding instead of sinusoids									4.92	25.7			
big	6	1024	4096	16				0.3	300K	4.33	26.4	213		

6.3. English Constituency Parsing

33

Parser	Training	WSJ 23 F1
Vinyals & Kaiser et al. (2014) [37]	WSJ only, discriminative	88.3
Petrov et al. (2006) [29]	WSJ only, discriminative	90.4
Zhu et al. (2013) [40]	WSJ only, discriminative	90.4
Dyer et al. (2016) [8]	WSJ only, discriminative	91.7
Transformer (4 layers)	WSJ only, discriminative	91.3
Zhu et al. (2013) [40]	semi-supervised	91.3
Huang & Harper (2009) [14]	semi-supervised	91.3
McClosky et al. (2006) [26]	semi-supervised	92.1
Vinyals & Kaiser et al. (2014) [37]	semi-supervised	92.1
Transformer (4 layers)	semi-supervised	92.7
Luong et al. (2015) [23]	multi-task	93.0
Dyer et al. (2016) [8]	generative	93.3

7. Conclusion

Transformer는 완전히 Attention 메커니즘에 기반한 최초의 시퀀스 변환 모델로, 기존 인코더-디코더 아키텍처에서 흔히 사용되던 순환 신경망을 self-attention으로 대체

Transformer는 순환 신경망이나 합성곱 신경망 기반 아키텍처보다 훨씬 빠르게 수행하고 BLEU 점수도 상승

향후 텍스트 이 외 다양한 입력 및 출력 형식을 포함하는 문제로 확장 In this work, we presented the Transformer, the first sequence transduction model based entirely on attention, replacing the recurrent layers most commonly used in encoder-decoder architectures with multi-headed self-attention. For translation tasks, the Transformer can be trained significantly faster than architectures based on recurrent or convolutional layers. On both WMT 2014 English-to-German and WMT 2014 English-to-French translation tasks, we achieve a new state of the art. In the former task our best model outperforms even all previously reported ensembles. We are excited about the future of attention-based models and plan to apply them to other tasks. We plan to extend the Transformer to problems involving input and output modalities other than text and to investigate local, restricted attention mechanisms to efficiently handle large inputs and outputs such as images, audio and video. Making generation less sequential is another research goals of ours. The code we used to train and evaluate our models is available at <https://github.com/tensorflow/tensor2tensor>. 할 예정이다.