

Attention Is All You Need : Transformer

📅 작성일시	@2025년 3월 6일
📍 강의 번호	BASE
📌 유형	논문리뷰
📎 자료	https://arxiv.org/pdf/1706.03762
☑️ 복습	☐

Abstract

복잡한 순환(recurrent) 및 합성곱(convolution) 구조 없이도, 순수한 attention 기제를 활용하여 기계 번역 등 다양한 자연어 처리 과제를 효과적으로 해결할 수 있다는 내용을 핵심으로 한다. 구체적으로, 이 접근법은 인코더-디코더 구조를 기반으로 하지만, 반복구조나 합성곱 대신 어텐션만으로 모든 상호작용을 처리함으로써 병렬화가 용이하고 학습 효율을 높인다. 실험 결과, 이 방법은 기존 모델보다 더 빠르고, 정확도 향상됨을 보여주며, 특히 기계 번역 작업에서 우수한 성능을 입증한다. 이를 통해 어텐션 메커니즘이 시퀀스 처리에서 본질적인 역할을 할 수 있음을 강조한다.

Introduction

주로 기존의 시퀀스 변환 모델들이 RNN이나 CNN 구조를 사용해왔다는 점을 짚으며, 이로 인한 병렬화 한계와 비용 문제를 지적한다. 이를 해결하기 위해 저자들이 고안한, 순수한 어텐션 기제만을 이용한 **Transformer** 모델을 제안하며 주요 내용은 다음과 같다.

1. RNN/ CNN 기반 접근의 한계

- 자연어 처리, 특히 기계 번역 분야에서 RNN과 CNN이 일정 성과를 보여주었으나, 내부 구조상 여러 단계에 걸쳐 시퀀스를 순차적으로 처리하거나 (순환구조), 필터를 적용해야하는 (합성곱 구조) 특성이 있어 병렬화가 제한적이고 계산량이 커진다.
- 긴 의존 관계 (long-range dependency)를 효과적으로 다루기 위해서는 더 깊은 모델이 필요하며, 이는 학습 과정이 복잡해지고 느려지는 결과를 초래한다.

2. 순수 어텐션 기제의 가능성

- Transformer는 입력 시퀀스의 각 위치가 모든 위치와 직접 어텐션을 통해 상호작용을 한다.
- 반복 구조나 합성곱 없이도, 어텐션 만으로 단어 간의 상관관계를 포착할 수 있다고 주장한다.
- 이 방식은 시퀀스의 모든 위치가 병렬적으로 연산될 수 있어 기존 방법들보다 훨씬 빠르고 효율적이다.

3. Transformer의 장점

- 병렬화 효율 : 모든 시퀀스 위치에 대해 동시에 어텐션을 계산하기 때문에, RNN 기반 모델에 비해 훨씬 빠른 학습이 가능하다.
- 학습 성능 : 실제 기계 번역 과제에서, 기존모델 대비 뛰어난 BLEU 점수를 기록함을 보였다.
- 확장성 : 모델 구조가 단순(모듈식)하여 다양한 변형과 확장이 용이하다.

Model Architecture

이 모델은 전형적인 시퀀스-투-시퀀스(sequence-to-sequence) 방식의 **인코더-디코더(Encoder-Decoder)** 구조를 따르지만, **순수 어텐션 기제**만으로 시퀀스를 처리한다는 점이 특징이다. 주요 내용은 다음과 같다:




Figure 1: The Transformer - model architecture.

1. 전체 구조(Encoder-Decoder)

- Encoder와 Decoder는 각각 여러 층(layer)으로 구성된 스택(stack) 형태를 취한다.
- 각 층은 멀티-헤드 어텐션(Multi-Head Attention)과 피드-포워드 신경망(Feed-Forward Network, FFN)으로 이루어지며, 잔차 연결(Residual Connection)과 층 정규화(Layer Normalization)가 적용된다.

2. 인코더(Encoder) 구조

- 인코더는 동일한 구조의 층이 N번 반복된다.
- 각 층은
 1. 셀프-어텐션(Self-Attention): 입력 시퀀스 내의 모든 위치가 상호 참조해 문맥 정보를 추출
 2. 피드-포워드 신경망: 각 위치별로 독립적인 완전연결 레이어(주로 2개의 Dense 레이어)로 구성된다.

3. 디코더(Decoder) 구조

- 디코더 역시 N개의 동일한 층으로 구성되지만, 인코더와 차별화되는 서브-레이어가 존재한다.
- 각 층은
 1. 마스크드(masked) 셀프-어텐션: 미래 토큰을 보지 못하도록 다음 위치의 정보가 가려짐

2. 인코더-디코더 어텐션: 인코더가 추출한 출력 표현(컨텍스트)에 대해 어텐션 적용
3. 피드-포워드 신경망로 이루어진다.
4. 멀티-헤드 어텐션(Multi-Head Attention)




Figure 2: (left) Scaled Dot-Product Attention. (right) Multi-Head Attention consists of several attention layers running in parallel.

- 어텐션 기제를 여러 개 병렬로 적용해(헤드(head)라 부름), 각 헤드가 서로 다른 부분의 의미나 상관관계를 학습하게 만든다.
 - 모든 헤드의 출력을 합친 뒤, 선형 변환을 통해 최종 어텐션 출력을 생성한다.
5. 포지셔널 인코딩(Positional Encoding)
 - RNN이나 CNN처럼 순차적·위치 정보를 자연스럽게 반영하지 않기 때문에, 단어 임베딩에 위치 정보를 더하기 위해 사인 및 코사인 함수 기반의 포지셔널 인코딩을 사용한다.
 - 이를 통해 모델은 입력 시퀀스 내 단어의 순서 정보를 학습할 수 있다.
 6. 잔차 연결(Residual Connection)과 층 정규화(Layer Normalization)
 - 각 서브-레이어(어텐션, 피드 포워드 등)의 입력과 출력을 더해주는 잔차 연결을 적용해 학습 안정성과 정보 흐름을 개선한다.
 - 잔차 연결 후에는 층 정규화를 거쳐 학습을 더욱 원활하게 만든다.

Transformer 모델의 “인코더-디코더 구조 + 멀티-헤드 어텐션 + 피드-포워드 신경망”의 조합으로, RNN이나 CNN 없이도 시퀀스 상의 의존 관계를 효율적으로 학습할 수 있는 구조를 제시한다. 위치 정보를 담기 위해 **포지셔널 인코딩**을 활용하며, **잔차 연결** 및 **층 정규화** 같은 기법이 모델 학습을 안정적으로 이끈다.

4. Why Self-Attention

1. 병렬화와 효율성(Parallelization & Efficiency)

- RNN은 순차적으로 시퀀스를 처리해야 하므로 병렬화가 어려우며, CNN도 필터 적용에 따라 병렬화가 제한적이다.
- 반면에 **Self-Attention**은 동일 시퀀스 상의 모든 위치에 대해 동시에(병렬로) 어텐션을 계산할 수 있어 연산 속도가 훨씬 빨라진다.

2. 긴 의존 관계(Long-Range Dependencies) 처리

- RNN/CNN 구조에서 먼 위치의 단어 간 관계를 포착하려면 여러 계층이나 타임스텝을 거쳐야 하므로, 정보 전달 경로가 길고 학습 난이도가 높아진다.
- Self-Attention은 모든 위치가 직접 서로를 참조할 수 있어, 시퀀스의 길이에 관계없이 멀리 떨어진 단어 간의 관계도 단 한 번의 어텐션으로 반영 가능하다.

3. 연산 복잡도 및 메모리 사용량

- 셀프 어텐션은 시퀀스 길이를 n 이라 할 때, 각 계층(layer)당 대략 $O(n^2)$ 의 연산 복잡도를 가진다(모든 토큰 쌍에 대해 어텐션 계산).
- CNN/RNN도 멀리 떨어진 의존 관계를 파악하려면 복잡도가 커지므로, 실질적으로는 Self-Attention이 효율적이며, 심층 모델 구성 시 병렬 처리 장점을 극대화할 수 있다.

4. 해석 가능성(Interpretability)

- 어텐션 가중치는 모델이 각 토큰을 어떻게 참조하고 있는지 직관적으로 보여준다.
- 이는 CNN의 필터나 RNN의 은닉 상태보다 모델 내부 작동 방식을 비교적 쉽게 해석·분석할 수 있게 해준다.

Training

1. 최적화 기법(Optimizer) 및 학습률(Learning Rate) 스케줄

- Adam 옵티마이저를 사용하며, 논문에서는 로 설정했다.
 $\beta_1=0.9, \beta_2=0.98, \epsilon=10^{-9}$
- 학습률 스케줄은 워밍업(warm-up) 단계를 거쳐 이후 형태로 감소하는 방식이다.
 $\text{step}^{-0.5}$
- 구체적으로, 일정 스텝 수(예: 4,000)까지는 학습률을 선형적으로 증가시킨 뒤, 그 이후엔 스텝 수의 역제곱근에 비례해 감소시킨다.

2. 배치 및 모델 하이퍼파라미터

- 논문에서는 토큰 단위로 배치를 구성한다(예: 한 번의 업데이트에 처리할 최대 토큰 수를 기준으로 삼음).
- 임베딩 차원, 피드포워드 레이어 차원, 레이어 수 등은 Base 모델(작은 모델)과 Big 모델(큰 모델)로 구분해 제시되며, 큰 모델일수록 더 많은 파라미터와 넓은 차원을 사용한다.

3. 정규화 기법: 드롭아웃(Dropout) 및 레이블 스무딩(Label Smoothing)

- Dropout을 각 어텐션 서브레이어와 피드-포워드 서브레이어 입력 등에 일정 비율(논문에서는 0.1)로 적용해 오버피팅을 방지한다.
- Label Smoothing(보통 0.1 정도로 설정)을 도입해, 정확한 정답 토큰만 1로 두지 않고 주변 라벨에도 작은 확률을 부여함으로써 모델이 정답 토큰에 과도하게 수렴되는 현상을 완화한다.

4. 학습 리소스 및 효율

- 대규모 데이터를 학습하기 위해 GPU(또는 TPU) 분산 학습을 활용한다.
- Self-Attention 기반 구조 덕분에 병렬화가 용이해, 같은 시퀀스 길이라면 RNN 기반 모델보다 학습 속도가 빠르다.

5. 모델 변형(Scaling)과 일반화

- Base 모델보다 빅 모델(Big model)은 더 많은 층 수, 더 큰 임베딩 차원, 더 큰 피드포워드 차원을 사용하며, 이를 통해 성능을 추가로 높일 수 있다.
- 그러나 더 큰 모델은 학습에 더 많은 계산량과 시간이 소요되므로, 논문에서는 Base/Big 모델 둘 다 제시해 사용자가 필요에 맞게 선택할 수 있도록 한다.

Result

Table 2: The Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French newstest2014 tests at a fraction of the training cost.

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	41.29	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	$3.3 \cdot 10^{18}$	
Transformer (big)	28.4	41.8	$2.3 \cdot 10^{19}$	

1. WMT 2014 영어→독일어(En→De)와 영어→프랑스어(En→Fr) 번역 실험

- Transformer 모델을 Base와 Big 두 가지 버전으로 평가했다.
- 독일어 번역에서는 이전 최고 성능과 유사하거나 더 나은 BLEU 점수를 달성했으며, 특히 Big 모델이 높은 성능을 기록했다.
- 프랑스어 번역에서도 마찬가지로 우수한 결과를 보이며, RNN 기반 SOTA 모델을 능가하거나 대등한 성능을 냈다.

2. 학습 속도 및 효율성

- 같은 데이터셋 기준으로 RNN/CNN 기반 모델 대비 학습 시간이 크게 단축되었다.
- 병렬화가 가능해 GPU/TPU 등으로 분산 학습 시 매우 빠른 속도를 확보할 수 있음을 강조한다.

3. 파라미터 수에 따른 성능 차이

- Base 모델 대비 Big 모델이 더 많은 파라미터와 더 깊은/넓은 신경망 구조를 사용해 더 높은 BLEU 점수를 달성한다.
- 하지만 연산량과 학습 시간이 늘어나는 트레이드오프가 있으므로, 데이터 크기나 리소스에 맞춰 선택할 수 있다.

4. 아블레이션 스터디(Ablation Study)

- 모델의 주요 구성 요소(예: 멀티-헤드 어텐션, 포지셔널 인코딩, 레이블 스무딩 등)를 제거하거나 변형했을 때 성능이 어떻게 달라지는지 확인했다.
- 이 연구를 통해 셀프-어텐션과 포지셔널 인코딩이 Transformer 성능에 핵심적임을 입증했다.

5. 추가 실험 결과

- 인코더-디코더 각각의 층 수, 헤드(head) 수, 피드포워드 차원 등의 하이퍼파라미터에 따른 성능 변화를 제시하며, 모델 확장에 따라 성능 향상이 가능함을 보여준다.
- 번역뿐 아니라 다른 시퀀스 변환 작업에서도 적용 가능성을 시사한다.

시사하는 점과 생각해볼 만한 점

1. 어텐션(Attention)의 중요성 부각

- RNN/CNN이 아닌 어텐션만을 사용한 모델이 충분히 강력하다는 점을 입증했다.
- 시퀀스의 모든 위치가 직접 상호작용할 수 있어 긴 의존 관계(Long-Range Dependency)를 효과적으로 처리한다.

2. 병렬화에 의한 학습 효율성

- Self-Attention 구조는 시퀀스 내 모든 위치를 한 번에 계산 가능하므로, 병렬 처리가 용이해 학습 시간이 크게 단축된다.
- 특히 대규모 데이터나 긴 시퀀스를 다룰 때 훈련 속도 측면에서 큰 이점을 제공한다.

3. 단순하고 모듈화된 구조

- CNN/RNN의 복잡한 계층 대신, "어텐션 + 피드포워드(Feed-Forward) + 잔차 연결 및 정규화"만으로 구성된 단순한 구조를 제안했다.
- 이러한 구조는 구현이 직관적이고, 다양한 변형·확장이 쉬워 범용성을 높인다.

4. 모델 확장 및 일반화 가능성

- NLP 분야 외에도, 음성 인식, 시계열 데이터 분석, 컴퓨터 비전(예: Vision Transformer), 멀티모달 처리 등 여러 도메인으로 확장되어 큰 성공을 거두었다.
- 특히 포지셔널 인코딩(Positional Encoding)을 어떻게 정의하느냐, 어텐션을 어떤 식으로 변형하느냐에 따라 다양한 파생 모델들이 출현했다.

5. 추가 고려 사항

- 연산 복잡도가 $O(n^2)$ 로, 시퀀스 길이가 매우 길 경우 메모리 사용량과 계산량이 커지는 한계가 있다. 이를 개선하는 Sparse/Linear Attention 기법들이 등장했다.
- 학습을 안정적으로 진행하기 위해서는 정규화(Layer Normalization), Label Smoothing, Dropout 등 다양한 기법들이 필수적으로 사용된다.
- 자기회귀 방식(autoregressive)을 유지하면서도, decoder 구조를 어떻게 디자인할지, 그리고 마스킹 방식에 따라 성능과 해석 가능성이 달라질 수 있다.