

Abstract

BERT : 최근의 언어 표현 모델들과 달리 라벨이 없는 텍스트로부터 심층 양방향 표현을 사전 학습하도록 설계 -> 왼쪽과 오른쪽 문맥을 동시에 조건화

1. Introduction

사전 학습된 언어 표현을 하위 작업에 적용하는 두 가지 방법

1. 특성 기반 접근법
2. Fine - tuning

-> 언어 문맥을 양방향으로 활용x

BERT는 양방향 언어모델로 이 문제를 해결

미세 조정 기반 접근법을 개선할 것

2. Related Work

2.1 Unsupervised Feature-based Approaches

단어 표현을 학습하는 방법으로 왼쪽-오른쪽 언어 모델링과 문맥을 고려한 특징 추출이 사용되며, ELMo는 왼쪽과 오른쪽 문맥을 결합해 성능을 향상시켰다.

2.2 Unsupervised Fine-tuning Approaches

초기 연구는 단어 임베딩을 사전 학습했지만, 최근에는 문맥 기반 토큰 표현을 학습하여 하위 작업에 미세 조정하는 방식이 발전




Figure 1: Overall pre-training and fine-tuning procedures for BERT. Apart from output layers, the same architectures are used in both pre-training and fine-tuning. The same pre-trained model parameters are used to initialize models for different down-stream tasks. During fine-tuning, all parameters are fine-tuned. [CLS] is a special symbol added in front of every input example, and [SEP] is a special separator token (e.g. separating questions/answers).

2.3 Transfer Learning from supervised Data

대규모 데이터 셋을 활용한 지도 학습 작업에서도 효과적인 전이 학습이 가능함이 입증

3. BERT

BERT는 사전 학습과 미세 조정의 두 단계로 구성되며, 사전 학습된 모델을 하위 작업에 맞게 미세 조정한다. 모든 하위 작업은 동일한 사전 학습된 모델을 초기화로 사용하지만, 각각 별도로 미세 조정된다. BERT의 주요 특징은 다양한 작업에 적용할 수 있는 통합된 아키텍처로, 다층 양방향 Transformer 인코더를 기반으로 한다. BERT는 두 가지 크기로 제공되며, BERTBASE(110M 파라미터)와 BERTLARGE(340M 파라미터)로 구성된다. OpenAI GPT와 달리, BERT는 양방향 자기 주의를 사용하여 문맥을 보다 효과적으로 학습한다.

BERT는 단일 문장과 문장 쌍을 하나의 입력 시퀀스로 표현할 수 있도록 설계되었으며, WordPiece 임베딩(30,000개 어휘)을 사용한다. [CLS] 토큰은 분류 작업을 위한 전체 시퀀스 표현으로 활용되며, 문장 구분을 위해 [SEP] 토큰과 문장 구분 임베딩이 추가된다. 각 토큰의 최종 입력 표현은 토큰, 세그먼트, 위치 임베딩의 합으로 구성된다.

3.1. Pre-training BERT

Task 1 (Masked LM): 입력 토큰의 15%를 무작위로 마스킹하고 해당 단어를 예측하도록 학습하여 양방향 문맥을 반영한 언어 모델을 만든다.

Task 2 (Next Sentence Prediction, NSP): 두 문장이 실제 순서대로 연결된 것인지 예측하는 이진 분류 작업을 통해 문장 간 관계를 학습한다.

Pre-training data : BERT는 BooksCorpus(8억 단어)와 영어 위키백과(25억 단어)에서 문서 수준의 텍스트를 사용하여 사전 학습

3.2. Fine-tuning BERT

BERT는 자가 주의 메커니즘을 활용해 다양한 downstream 작업을 통합적으로 모델링하며, 모든 매개변수를 끝까지 미세 조정한다. 미세 조정은 비교적 비용이 적으며, 단일 TPU에서는 1시간 내, GPU에서는 몇 시간 내에 수행할 수 있음.

3.3 Task-specific input transformations

언어 이해 작업을 위한 반지도 학습 접근 방식을 제안

사전 훈련된 모델을 사용해 다양한 작업에 맞춰 적응하며, 구조화된 입력에 대해서는 순차 처리 방식으로 모델링을 수정. 텍스트 함의, 유사도, 질문 응답, 상식 추론 작업에 대해 구분자 토큰을 추가하고, 입력 시퀀스를 적절히 변환하여 모델이 처리할 수 있도록 한다. 이러한 방식은 모델 아키텍처에 최소한의 변경만으로 다양한 작업에 적용 가능




Figure 2: BERT input representation. The input embeddings are the sum of the token embeddings, the segmentation embeddings and the position embeddings.

4. Experiments

4.1 GLUE

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	Average -
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.8	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	87.4	91.3	45.4	80.0	82.3	56.0	75.1
BERT _{BASE}	84.6/83.4	71.2	90.5	93.5	52.1	85.8	88.9	66.4	79.6
BERT _{LARGE}	86.7/85.9	72.1	92.7	94.9	60.5	86.5	89.3	70.1	82.1

Table 1: GLUE Test results, scored by the evaluation server (<https://gluebenchmark.com/leaderboard>). The number below each task denotes the number of training examples. The “Average” column is slightly different than the official GLUE score, since we exclude the problematic WNLI set.⁸ BERT and OpenAI GPT are single-model, single task. F1 scores are reported for QQP and MRPC, Spearman correlations are reported for STS-B, and accuracy scores are reported for the other tasks. We exclude entries that use BERT as one of their components.

4.2 SQuAD v1.1

SQuAD v1.1(Stanford Question Answering Dataset v1.1) : 위키백과 문서를 기반으로 한 10만 개의 질의응답 데이터셋으로, 주어진 질문에 대해 문서 내 정답 구간을 예측하는 과제

BERT는 질문과 문서를 하나의 시퀀스로 인코딩하고, 시작 및 종료 벡터를 활용해 정답 범위를 예측하도록 미세 조정된다. BERT는 기존 최상위 모델보다 높은 F1 점수를 기록하며, 단일 모델로도 앙상블 모델을 능가하는 성능을 보였다.

System	Dev		Test	
	EM	F1	EM	F1
Top Leaderboard Systems (Dec 10th, 2018)				
Human	-	-	82.3	91.2
#1 Ensemble - nlnet	-	-	86.0	91.7
#2 Ensemble - QANet	-	-	84.5	90.5
Published				
BiDAF+ELMo (Single)	-	85.6	-	85.8
R.M. Reader (Ensemble)	81.2	87.9	82.3	88.5
Ours				
BERT _{BASE} (Single)	80.8	88.5	-	-
BERT _{LARGE} (Single)	84.1	90.9	-	-
BERT _{LARGE} (Ensemble)	85.8	91.8	-	-
BERT _{LARGE} (Sgl.+TriviaQA)	84.2	91.1	85.1	91.8
BERT _{LARGE} (Ens.+TriviaQA)	86.2	92.2	87.4	93.2

Table 2: SQuAD 1.1 results. The BERT ensemble is 7x systems which use different pre-training checkpoints and fine-tuning seeds.

4.3 SQuAD v2.0

SQuAD v2.0 : SQuAD v1.1의 문제 정의를 확장하여, 주어진 문단에 정답이 존재하지 않을 가능성을 포함한 보다 현실적인 질의응답 데이터셋

BERT는 정답이 없는 경우 [CLS] 토큰을 정답 범위로 간주하는 방식으로 확장되었으며, 정답 여부를 결정하는 임계값(τ)을 개발 데이터셋에서 최적화하여 적용했다. 이 접근 방식으로 기존 최고 성능 모델 대비 F1 점수를 +5.1 개선하는 성과를 거뒀다.

System	Dev		Test	
	EM	F1	EM	F1
Top Leaderboard Systems (Dec 10th, 2018)				
Human	86.3	89.0	86.9	89.5
#1 Single - MIR-MRC (F-Net)	-	-	74.8	78.0
#2 Single - nlnet	-	-	74.2	77.1
Published				
unet (Ensemble)	-	-	71.4	74.9
SLQA+ (Single)	-	-	71.4	74.4
Ours				
BERT _{LARGE} (Single)	78.7	81.9	80.0	83.1

Table 3: SQuAD 2.0 results. We exclude entries that use BERT as one of their components.

4.4 SWAG

SWAG (Situations With Adversarial Generations) : 113,000개의 문장 쌍 완성 예제로, 상식적 추론 능력을 평가하는 데이터셋이다. 주어진 문장에서 가장 그럴듯한 연속 문장을 네 개의 선택지 중 하나로 고르는 작업.

BERT는 SWAG 데이터셋에서 3 에폭을 학습하여, 각 선택지에 대해 [CLS] 토큰의 표현과 벡터를 내적해 점수를 계산한다. BERT_{LARGE}는 기존 모델들보다 성능이 +27.1% 향상되었고, OpenAI GPT보다 8.3% 더 우수한 성과를 보였다.

System	Dev	Test
ESIM+GloVe	51.9	52.7
ESIM+ELMo	59.1	59.2
OpenAI GPT	-	78.0
BERT _{BASE}	81.6	-
BERT _{LARGE}	86.6	86.3
Human (expert) [†]	-	85.0
Human (5 annotations) [†]	-	88.0

5. Ablation Studies

5.1. Effect of Pre-training Tasks

BERT의 깊은 양방향향성의 중요성을 평가하기 위해, 두 가지 전처리 목표를 비교

1. NSP 없이 "masked LM"만 사용하는 모델(No NSP)
2. "Left-to-Right" 모델 오른쪽 context가 없는 모델

NSP 작업을 제거하면 QNLI, MNLI, SQuAD 1.1에서 성능이 크게 저하된다. 또한, LTR 모델은 MLM 모델보다 모든 작업에서 성능이 낮고, 특히 SQuAD에서 토큰 예측에 어려움을 겪는다. 결과적으로, 양방향 모델이 LTR 모델보다 더 우수한 성과를 보인다.

5.2. Effect of Model Size

모델 크기를 키우면 작은 데이터셋에서도 정확도가 향상된다. BERTBASE(1.1억 파라미터)와 BERTLARGE(3.4억 파라미터)는 기존 모델보다 성능이 뛰어나며, 더 큰 모델이 매우 작은 작업에서도 유리하다. 이 연구는 사전 훈련된 대형 모델이 작은 데이터셋에 큰 영향을 미친다는 것을 입증

5.3. Feature-based Approach with BERT

BERT의 두 가지 접근법인 fine-tuning과 feature-based 방식을 비교한 결과, fine-tuning은 성능이 우수하지만 feature-based 접근법도 경쟁력 있는 성과를 보였다. 특히, BERTLARGE는 NER 작업에서 최신 방법들과 비슷한 성능을 기록했다. BERT는 두 방식 모두에서 효과적으로 작동함을 보여주었다.

System	Dev F1	Test F1
ELMo (Peters et al., 2018a)	95.7	92.2
CVT (Clark et al., 2018)	-	92.6
CSE (Akbik et al., 2018)	-	93.1
Fine-tuning approach		
BERT _{LARGE}	96.6	92.8
BERT _{BASE}	96.4	92.4
Feature-based approach (BERT _{BASE})		
Embeddings	91.0	-
Second-to-Last Hidden	95.6	-
Last Hidden	94.9	-
Weighted Sum Last Four Hidden	95.9	-
Concat Last Four Hidden	96.1	-
Weighted Sum All 12 Layers	95.5	-

Table 7: CoNLL-2003 Named Entity Recognition results. Hyperparameters were selected using the Dev set. The reported Dev and Test scores are averaged over 5 random restarts using those hyperparameters.

6. Conclusion

이 연구는 **심층 양방향** 아키텍처를 활용해 사전 훈련된 모델이 다양한 NLP 작업을 성공적으로 수행할 수 있음을 보여준다.