

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

0. Abstract

- BERT(Bidirectional Encoder Representations from Transformers)는 양방향 트랜스포머(Bidirectional Transformer) 를 활용한 사전 학습 모델
- 기존의 단방향 언어 모델과 달리 양방향 문맥(Bidirectional Context) 을 고려하여 문장을 이해
- Masked Language Model(MLM) 과 Next Sentence Prediction(NSP) 을 활용하여 사전 학습을 수행
- 다양한 자연어 처리(NLP) 태스크에서 최신 성능(SOTA, State-of-the-Art) 을 달성

1. Introduction

- 기존 NLP 모델들은 단방향 언어 모델(Unidirectional Language Model) 을 활용하여 문맥을 학습
- 하지만 이러한 방식은 양방향 문맥 정보를 반영하지 못해 한계가 있음
- BERT는 양방향 문맥을 고려하는 사전 학습 모델로 이를 해결
- 사전 학습(Pre-training) 후, 다양한 NLP 태스크에 미세 조정(Fine-tuning) 을 적용하여 높은 성능을 달성

2. Related Work

2.1 Unsupervised Feature-based Approaches

- 사전 학습된 단어 임베딩(Word Embeddings)을 NLP 태스크에 적용하는 접근법
- Word2Vec, GloVe, FastText 등의 방법이 대표적

2.2 Unsupervised Fine-tuning Approaches

- 사전 학습 후, 특정 태스크에 맞춰 미세 조정(Fine-tuning)을 수행하는 접근법
- ULMFiT, OpenAI GPT 등이 대표적

2.3 Transfer Learning from Supervised Data

- 지도 학습(Supervised Learning) 데이터를 활용한 전이 학습(Transfer Learning) 접근법
- 특정 태스크에서 학습한 모델을 다른 태스크로 확장하여 활용

3. BERT

서론

- BERT는 Transformer의 인코더(Encoder) 구조만을 활용한 모델
- 양방향 문맥 학습 을 가능하게 하여 기존 NLP 모델의 한계를 극복

3.1 Pre-training BERT

- BERT는 두 가지 주요 학습 기법을 사용하여 사전 학습 수행
 - **Masked Language Model (MLM)**: 입력 문장에서 랜덤으로 단어를 마스킹하고, 이를 예측하도록 학습
 - **Next Sentence Prediction (NSP)**: 두 문장이 실제 연속된 문장인지 여부를 예측하도록 학습

3.2 Fine-tuning BERT

- 사전 학습된 BERT 모델을 다양한 NLP 태스크에 맞춰 미세 조정(Fine-tuning)
- 입력 형식(Input Format)을 태스크에 맞게 변환하여 적용
- GLUE, SQuAD, SWAG 등의 태스크에서 뛰어난 성능을 보임

4. Experiments

4.1 GLUE

- General Language Understanding Evaluation(GLUE) 벤치마크에서 평가
- 자연어 추론(NLI), 문장 유사도 측정, 문법 오류 감지 등 다양한 태스크 포함

4.2 SQuAD v1.1

- 질의응답(QA) 태스크 에서 평가
- 사전 학습된 BERT가 기존 모델을 뛰어넘는 성능을 기록

4.3 SQuAD v2.0

- 답변이 없는(No Answer) 경우까지 포함 한 질의응답 데이터셋
- 기존 QA 모델보다 높은 정확도를 달성

4.4 SWAG

- 상황 기반 문장 완성(Task of Commonsense Inference) 태스크에서 평가
- 주어진 문맥에서 가장 적절한 후속 문장을 예측

5. Ablation Studies

5.1 Effect of Pre-training Tasks

- MLM과 NSP가 모델의 성능에 미치는 영향을 분석
- MLM과 NSP를 함께 사용할 때 성능이 가장 우수

5.2 Effect of Model Size

- BERT의 크기에 따른 성능 차이를 비교
- BERT-Base(110M parameters) vs BERT-Large(340M parameters)
- 모델 크기가 커질수록 성능이 향상됨을 확인

5.3 Feature-based Approach with BERT

- 사전 학습된 BERT를 피쳐 기반 접근 방식(Feature-based Approach)으로 활용 가능
- 예를 들어, 특정 태스크에서 BERT 임베딩을 추출하여 별도의 모델에서 활용 가능

6. Conclusion

- BERT는 양방향 트랜스포머(Bidirectional Transformer) 를 기반으로 사전 학습과 미세 조정을 결합한 모델
- 기존 단방향 모델과 비교해 더 강력한 문맥 이해 능력을 보유
- 다양한 NLP 태스크에서 최신 성능(SOTA) 을 기록
- 향후 연구 방향: 더 큰 모델, 더 긴 문맥, 더 다양한 태스크로 확장