



BERT

이름	홍준기
대학교	동국대학교
학과	산업공학과
날짜	2025년

Abstract

Abstract

1. Introduction

기존 언어 모델 사전 학습 기법:

기존 접근법의 한계:

기존 연구와의 Differentiation(BERT):

2. Model Architecture

2.1. 모델 구조 (Model Architecture)

입력 표현 (Input Representation)

2.2. Pre-training BERT model

Task 1: Masked Language Model, MLM

Task 2: Next Sentence Prediction, NSP

2.3. Fine-tuning BERT

3. Experiments

3.1. Unsupervised pre-training

3.2. Fine-tuning

4. Results

5. Ablation studies

5.1. 사전 학습 태스크의 효과 (Effect of Pre-training Tasks)

5.2. 모델 크기의 효과 (Effect of Model Size)

5.3. Feature-based vs Fine-tuning (Feature-based 접근법 비교)

BERT (Bidirectional Encoder Representations from Transformers)는

양방향(Deep Bidirectional) 언어 표현 학습 모델로, 기존 단방향 모델 (ELMo, OpenAI GPT)과 차별화되어 문맥을

좌우 양방향으로 고려하는 사전 학습을 통해 다양한 자연어 처리(NLP) 작업에서 SOTA(State-of-the-Art) 성능을 달성하였

1. Introduction

기존 언어 모델 사전 학습 기법:

- **Unsupervised Feature-based 방식:** ELMo처럼 사전 학습된 표현을 특정 작업에 맞춰 추가적으로 활용
 - 사전 학습된 단어 임베딩(word embeddings)은 NLP 시스템에서 필수적인 요소임을 GloVe에서 언급
- **Unsupervised Fine-tuning 방식:** OpenAI GPT처럼 사전 학습 후 특정 작업을 위해 미세 조정
 - 사전 학습된 언어 모델을 최소한의 수정만을 가하는 방식임
- **Transfer Learning from Supervised Data 방식:** 대규모 데이터셋을 활용한 지도 학습도 효과적인 전이 학습 방식으로 활용됨

- 컴퓨터 비전에서도 **ImageNet**을 활용한 사전 학습 및 전이 학습이 일반적으로 쓰여
- 기계 번역(Machine Translation) (McCann et al., 2017)

기존 접근법의 한계:

- 단방향(Left-to-Right or Right-to-Left)으로 학습된 언어 모델은 문맥 정보를 온전히 활용하지 못함
 - ELMo (Peters et al., 2018a)는 좌에서 우(LTR)와 우에서 좌(RTL)를 독립적으로 학습 후 결합
- 단방향 모델은 문장 단위 작업에서는 어느 정도 효과적이거나, 질문 응답(QA)과 같은 토큰 단위 작업에서는 성능이 저하될 가능성이 높음

기존 연구와의 Differentiation(BERT):

- Transformer 기반의 다층 인코더(Encoder) 모델 사용
 - 기존 GPT는 단방향 Transformer, ELMo는 좌-우 독립적 학습 후 결합, BERT는 양방향으로 모든 레이어에서 학습하는 방식을 사용함

2. Model Architecture

2.1. 모델 구조 (Model Architecture)

- Transformer 기반의 다층 인코더(Encoder) 모델 사용
- 두 가지 주요 모델 크기:
 - **BERT BASE**: L=12, H=768, A=12 (총 110M 파라미터)
 - **BERT LARGE**: L=24, H=1024, A=16 (총 340M 파라미터)
 - **L (레이어 수, Layers)**: Transformer 블록의 개수
 - **H (히든 크기, Hidden Size)**: 각 층의 차원 크기
 - **A (어텐션 헤드 수, Attention Heads)**: 다중 헤드 자기-주의(Multi-head self-attention) 개수

입력 표현 (Input Representation)

- **WordPiece 토큰화** (30,000개의 단어 사전)
- 입력 토큰 시퀀스 구성:
 - **[CLS]** Classification token: 문장 전체의 대표 벡터 역할이자 분류(Classification) 작업에 사용됨
 - **[SEP]** Sentence pair representation: 문장 간 구분을 위한 특별 토큰이자 질문-응답(Question-Answering), 문장 관계 예측(Next Sentence Prediction, NSP)에서 사용됨
- 임베딩:
 - 토큰 임베딩(Token Embeddings) + 세그먼트 임베딩(Segment Embeddings) 어느 문장에 속하는지 + 위치 임베딩(Position Embeddings) 을 합산으로 임베딩을 함




Figure 2: BERT input representation. The input embeddings are the sum of the token embeddings, the segmentation embeddings and the position embeddings.

- 문장 하나 또는 두 개를 입력으로 받을 수 있도록 설계되었음

2.2. Pre-training BERT model

Task 1: Masked Language Model, MLM

- 일반적인 언어 모델은 다음 단어를 예측하는 방식을 사용하여 단방향(uni-directional) 학습
 - 양방향 학습을 수행하려면 토큰이 미래 단어를 미리 보지 못하도록 해야 함
- BERT의 해결책: Masked Language Model (MLM)
 - 주요 특징:
 - 입력 문장에서 일부 토큰(15%)을 무작위로 [MASK]로 변환.

- 이 [MASK] 토큰의 원래 단어를 예측하는 방식으로 학습

→ Transformer 모델이 모든 레이어에서 **좌우 문맥 정보를 활용 가능**

- But, Fine-tuning 시 [MASK] 토큰이 등장하지 않는 문제가 있음
 - 실제 응용 예제에서는 [MASK] 토큰이 포함되지 않은 문장이 입력되고, Pre-training 과정은 [MASK] 가 포함된 데이터를 기반으로 학습했기 때문에, Fine-tuning 시 모델이 다르게 동작할 가능성이 있음
 - MLM은 특정한 학습 패턴을 학습할 위험이 있고, BERT가 [MASK] 토큰이 등장할 때만 중요한 정보(문맥)를 적극적으로 활용하는 패턴을 학습할 가능성을 배제할 수 없음
 - 이 문제를 해결하기 위해 **MLM 훈련 시 [MASK] 를 100% 사용하지 않고, 일부 변형된 방법을 도입하였음**
 - **80% 확률로** 해당 단어를 [MASK] 로 변경 ($15\% \times 80\% = 12\%$)가 [MASK] 로 대체)
 - **10% 확률로** 해당 단어를 랜덤한 다른 단어로 변경
 - **10% 확률로** 해당 단어를 변경하지 않고 그대로 유지
- 사전 학습할 때 일부 단어를 원래 단어로 유지하면, Fine-tuning 시 자연스러운 문장을 처리하는 능력이 향상될 수 있


Task 2: Next Sentence Prediction, NSP

- 일부 중요한 NLP 작업(QA, NLI)에서는 두 개의 문장 간 관계를 이해하는 것이 중요함
 - 일반적인 언어 모델은 이러한 관계를 직접적으로 학습하지 않음
 - BERT의 해결책: **NSP 태스크 방식**
 - **50%의 확률로** 문장 A와 B가 실제 연속된 문장(**IsNext**).
 - **50%의 확률로** 문장 B를 임의로 선택(**NotNext**).
 - BERT는 이를 **이진 분류(Binary Classification)** 태스크로 학습
- 문장 수준에서 문맥적 관계를 학습할 수 있

2.3. Fine-tuning BERT

- Fine-tuning 단계에서는 각 작업별 입력과 출력을 BERT에 맞게 조정 후 학습함

- 기존의 사전 학습을 활용하여, 미세 조정에 많은 리소스가 필요하지 않다고 함



3. Experiments

3.1. Unsupervised pre-training

- **BooksCorpus** (약 7,000권의 책)
 - 긴 문맥을 포함하는 데이터셋으로, 모델이 **장기 의존성(Long-range Dependency)**을 학습하는 데 유리하다고 함
 - cf) **1B Word Benchmark**는 문장을 단위로 섞어서 사용했기 때문에 문맥 학습이 어려움
- 모델 설정:
 - **Transformer 기반 12-layer 디코더(Decoder)-only 모델** 사용 (768차원, 12개의 어텐션 헤드)
 - **토큰 임베딩(Token Embedding)** 및 **위치 임베딩(Position Embedding)** 적용
 - **Byte-Pair Encoding (BPE)** 기반의 **40,000개 단어 사전** 사용
 - Adam 옵티마이저(Cosine schedule 적용)
 - 100 epoch (batch size: 64, sequence length: 512)

3.2. Fine-tuning

- Pre-training과 동일한 설정 유지 (dropout: 0.1).
 - 미세 조정 시 , **batch size: 32, 3 epochs** 만으로도 충분한 성능 도달
 - 학습률은 **warm-up 후 선형 감소 (linear decay schedule)** 적용

4. Results

- 자연어 추론 (Natural Language Inference, NLI):
 - **GPT 모델이 5개 중 4개 데이터셋에서 기존 최고 성능을 경신함**
- 질의응답 (Question Answering, QA)
 - 긴 문맥을 이해하는 데 강점을 보이며, 기존 모델보다 뛰어난 성능을 달성함
- 문장 유사도 (Semantic Similarity)
 - 유사도 태스크에서도 GPT가 최고 성능을 달성함
- 텍스트 분류 (Text Classification)
 - 문법적 판단(CoLA)에서 큰 성능 향상을 거둠

5. Ablation studies

5.1. 사전 학습 태스크의 효과 (Effect of Pre-training Tasks)

- 실험 목표:
 - BERT의 **양방향 학습(bidirectionality)**의 중요성을 평가하는 실험
- 실험 방법:
 - BERT-BASE와 동일한 **사전 학습 데이터, Fine-tuning 방식, 하이퍼파라미터**를 사용하여 두 가지 실험을 수행함
 1. No NSP (Next Sentence Prediction 없음)
 - 양방향 모델을 유지하지만 NSP 없이 "Masked Language Model (MLM)"만
 2. LTR & No NSP (Left-to-Right 모델 & NSP 없음)

- 단방향(left-to-right) 모델로만 학습함
- 기존 MLM 대신 일반적인 좌에서 우(Left-to-Right, LTR) 방식의 언어 모델을 사용함
- 실험 결과:
 - NSP를 제거하면 QNLI, MNLI, SQuAD 1.1의 성능이 크게 하락함
 - 양방향 학습이 단방향 학습보다 성능이 우수함을 확인함
 - LTR 모델이 SQuAD 같은 토큰 단위 작업에서 매우 부적합함을 밝힘
 - 각 Transformer 레이어가 유용한 기능을 학습하고 있으며, 이를 유지할수록 성능이 좋아진다는 방증임
 - 사전 훈련된 레이어를 많이 활용할수록 전이 학습(Transfer Learning) 성능이 향상

5.2. 모델 크기의 효과 (Effect of Model Size)

- 실험 목표:
 - BERT 모델 크기가 미세 조정(Fine-tuning) 성능에 미치는 영향을 평가
- 실험 방법:
 - 다양한 레이어 수, 히든 크기, 어텐션 헤드 수를 가진 여러 BERT 모델을 학습하였음
- 실험 결과:
 - 모델 크기가 커질수록 성능이 꾸준히 향상됨
 - GLUE 벤치마크에서 모든 작업에서 일관된 성능 향상을 보임
 - 특히 MRPC (3,600개의 작은 학습 데이터)를 포함한 소규모 작업에서도 성능이 향상됨을 확인함

모델 크기 확장과 NLP 성능

- 기계 번역과 언어 모델링에서 모델 크기 증가가 성능 향상을 이끄는 것은 잘 알려져 있었지만, 이 연구는 처음으로 모델 크기 확장이 작은 데이터셋에서도 유효함을 입증하였음

즉,

- 모델 크기가 클수록 NLP 성능이 향상됨.
- 특히 작은 데이터셋에서도 사전 학습된 표현이 큰 모델의 성능 향상에 기여할 수 있음.

5.3. Feature-based vs Fine-tuning (Feature-based 접근법 비교)

- BERT는 대부분 **Fine-tuning** 방식으로 활용되지만, Feature-based 방식(고정된 임베딩 활용)도 가능, Feature-based 방식은 fine-tuning 대비 비용 절감 효과가 있기 때
- 실험 방법: **Named Entity Recognition (NER)** 즉, **CoNLL-2003 NER** 작업에 대해 Fine-tuning 방식과 Feature-based 방식을 비교 실험
 - 이때, **Feature-based** 방식은,
 - 사전 학습된 BERT의 특정 레이어 출력을 추출한 후, **BiLSTM**을 추가하여 태깅 모델을 학습함
 - 다양한 레이어의 출력을 비교함:
 - 마지막 4개 레이어의 출력을 결합하면 Fine-tuning과 유사한 성능을 달성하였음
- 실험 결과:
 - BERT-LARGE의 Fine-tuning 방식이 SOTA를 보였지만, **Feature-based** 방식도 거의 동일한 성능을 보임
 - 마지막 4개 레이어를 결합하는 방식이 **Fine-tuning**보다 단 **0.3 F1** 낮은 성능을 보였음

→ 이는, Feature-based 방식도 BERT의 사전 학습된 표현을 효과적으로 활용 가능하다는 점을 보여주는 연구

6. Conclusions

- 최근 연구들은 사전 학습된 언어 모델을 활용한 전이 학습(Transfer Learning)이 NLP 시스템에서 중요한 역할을 한다는 것을 입증하였
- 기존 단방향(Unidirectional) 모델을 양방향(Bidirectional)으로 확장 → 사전 학습된 모델이 다양한 NLP 작업에서 효과적으로 활용될 수 있음을 입증하였음

- **Fine-tuning 방식과 Feature-based 방식 모두에서 강력한 성능을 보임 → 낮은 리소스로도 높은 성능을 낼 수 있음**
- 모델 크기를 키우면 작은 데이터셋에서도 성능이 향상됨을 확인함