

BERT

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

<https://arxiv.org/pdf/1810.04805>

0. Abstract

기존의 언어 모델은 한 방향만 고려했지만, 양방향 인코딩을 사용하여 레이블이 없는 텍스트에서 양쪽 문맥을 동시에 고려해 사전학습 진행하는 BERT를 소개함.

1. Introduction


- **양방향 사전 학습:** 기존의 단방향 언어 모델과는 달리, BERT는 양방향 문맥을 학습하여 성능을 향상시킴.
- **태스크 특화 아키텍처의 필요 감소:** BERT는 사전 학습된 모델을 파인튜닝만으로 다양한 작업을 해결할 수 있어, 복잡한 아키텍처 변경 없이 높은 성능을 달성함.
- **성능 향상:** BERT는 11개의 자연어 처리 작업에서 기존의 최첨단 기술들을 능가하는 성과를 거둠.

2. Related Work

- **Unsupervised Feature-based Approaches:**
 - 이 접근법은 주로 단어 임베딩을 학습하는 데 사용되며, 왼쪽에서 오른쪽으로 가는 언어 모델을 활용하여 단어를 예측합니다.
 - 기존 연구에서는 문장, 단락 임베딩을 위해 여러 방법들이 사용되었습니다.
 - **ELMo**와 그 전신 모델들은 양방향 언어 모델을 사용하여 문맥에 따른 특성(특히 왼쪽-오른쪽, 오른쪽-왼쪽 언어 모델)을 추출합니다. 이는 **BERT**와 비교할 때는 여전히 독립적인 단방향 모델에 기반한 특징으로 간주됩니다.
- **Unsupervised Fine-tuning Approaches:**
 - **OpenAI GPT**와 같은 모델들은 텍스트로부터 임베딩을 사전 학습한 후, 이를 세부 작업에 맞게 fine-tuning합니다. 이 접근법은 학습해야 할 파라미터 수를 줄여주어

유리합니다.

- GPT는 문장 수준 작업에서 뛰어난 성과를 보였으며, 왼쪽에서 오른쪽으로 가는 언어 모델링을 사용합니다.



→ BERT 모델은 출력 레이어를 제외한 동일한 아키텍처가 사전학습과 미세 조정에 모두 사용됨. 동일한 사전 학습된 모델 파라미터가 다운스트림 작업을 위한 모델을 초기화하는 데 사용됨. [CLS] - 입력 시퀀스의 시작을 알림, [SEP] - 질문과 답변을 구분하는 특수 구분자 토큰

• Transfer Learning from Supervised Data:

- 큰 데이터셋을 이용한 감독학습에서 효과적인 전이 학습을 보여주는 연구들도 있습니다. 예를 들어, 자연어 추론 및 기계 번역에서의 작업들이 있습니다.

3. BERT

- 1) 사전 학습 - 레이블이 없는 데이터로 사전 학습 작업 진행
- 2) 파인 튜닝 - 사전 학습된 파라미터로 초기화한 후, 다운스트림 작업에 맞는 레이블이 있는 데이터를 사용하여 모든 파라미터를 조정함.

모델 아키텍처

BERT는 다층 양방향 Transformer 인코더 아키텍처를 기반으로 하고, 두 가지 모델 크기로 제공됨.

- **BERTBASE:** L=12, H=768, A=12, 파라미터 수: 110M

- **BERTLARGE**: L=24, H=1024, A=16, 파라미터 수: 340M

BERT는 양방향(self-attention)을 사용하여 문맥을 이해하는 반면, GPT는 단방향(left-to-right) self-attention을 사용함.

3.1 사전 학습 (Pre-training)

BERT는 전통적인 왼쪽에서 오른쪽 또는 오른쪽에서 왼쪽 언어 모델을 사용하지 않고, 두 가지 비지도 학습 작업을 사용하여 학습됨.

- **작업 #1: 마스킹된 언어 모델 (Masked LM)**

BERT는 입력 시퀀스에서 일부 토큰을 마스킹하고 그 마스킹된 토큰을 예측하는 방식으로 학습함. 예측은 소프트맥스를 통해 이루어짐. 이 방식은 양방향 모델을 학습할 수 있게 해주며, 토큰은 무작위로 15%가 마스킹됨.

- **작업 #2: 다음 문장 예측 (Next Sentence Prediction, NSP)**

많은 다운스트림 작업에서는 두 문장의 관계를 이해하는 것이 중요함. BERT는 문장 쌍에 대해 50% 확률로 실제 다음 문장 또는 임의의 문장을 예측하는 작업을 통해 문장 관계를 학습함.

사전 학습 데이터

BERT는 **BooksCorpus**와 **영어 위키백과**를 사용하여 사전 학습을 진행함. 위키백과에서는 목록, 표, 제목 등을 제외하고 텍스트만 사용함. 이는 문서 수준에서 긴 연속된 텍스트를 추출하는 데 중요함.

3.2 미세 조정 (Fine-tuning)

미세 조정은 상대적으로 간단하며, BERT의 self-attention 메커니즘 덕분에 많은 다운스트림 작업을 수행할 수 있다. 작업에 맞는 입력과 출력을 BERT에 삽입하고, 모든 파라미터를 end-to-end로 파인 튜닝함. 예를 들어, 질문-답변, 텍스트 분류, 순서 태깅 등 다양한 작업을 처리할 수 있음.

4. Experiments

5. Ablation Studies

BERT의 여러 요소들에 대해 실험을 진행하여 각 요소들의 상대적인 중요성을 파악하고자 한다.

5.1 Pre-training Tasks의 영향

BERT의 양방향 학습의 중요성을 평가하기 위해 두 가지 프리트레이닝 목표를 비교했다. 이를 위해 동일한 프리트레이닝 데이터, 파인튜닝 방식, 하이퍼파라미터를 사용했다. "No NSP" 모델은 마스크드 LM만 사용하고 NSP 작업 없이 훈련되며, "LTR & No NSP" 모델은 왼쪽에서 오른쪽으로 훈련된 언어 모델을 사용한다.

- **NSP의 영향:** NSP를 제거하면 QNLI, MNLI, SQuAD 1.1에서 성능이 크게 저하된다.
- **양방향 학습의 영향:** "No NSP"와 "LTR & No NSP"를 비교했을 때, LTR 모델은 모든 작업에서 성능이 낮고, 특히 MRPC와 SQuAD에서 성능이 크게 떨어진다. SQuAD에서 LTR 모델은 오른쪽 문맥을 사용하지 않기 때문에 토큰 예측 성능이 낮아진다.
- **BiLSTM 추가:** LTR 모델에 BiLSTM을 추가하면 SQuAD에서 성능이 개선되지만, 여전히 양방향 모델보다 성능이 떨어진다. BiLSTM은 GLUE 작업에서 성능을 저하시킨다.

5.2 모델 크기의 영향

모델 크기가 파인튜닝 성능에 미치는 영향을 분석하기 위해 여러 BERT 모델을 실험했다. 여기서는 레이어 수, 은닉 유닛 수, 주의 헤드 수를 다르게 하여 모델을 훈련했다.

- **결과:** 모델이 커질수록 성능이 지속적으로 개선된다. 특히 MRPC와 같은 작은 데이터셋에서도 성능이 향상된다. 이는 충분히 프리트레이닝된 모델에서 작은 데이터셋을 다룰 때도 유의미한 개선을 가져온다는 점에서 중요하다.

5.3 BERT의 Feature-based 접근법

지금까지 BERT의 결과는 모두 파인튜닝 접근법을 사용했다. 하지만 BERT를 이용한 feature-based 접근법은 계산 효율성과 특정 과제에서의 이점을 제공한다.

- **NER 태스크에서의 비교:** BERT를 CoNLL-2003 Named Entity Recognition(NER) 태스크에 적용하여 feature-based 접근법과 파인튜닝 접근법을 비교했다.
 - **결과:** BERTLARGE 모델은 상태-최고 방법들과 경쟁할 수 있는 성능을 보였다. 파인튜닝을 할 경우와 동일한 성능을 내지는 않지만, 마지막 네 개의 숨겨진 레이어를 연결한 방식이 가장 좋은 성능을 보였다.

