

BERT, GPT

[language_understanding_paper.pdf](#)

[BERT.pdf](#)

GPT

Abstract

Generative (생성형) 사전 학습을 통해서, 세부적인 Task를 모두 잘 하는 모델을 만들자.

→ Huge unlabeled data로 pretrain, 그 후 task에 맞는 fine tuning

기존의 접근과 달리, Fine tuning 시 input을 task-aware한 transformation을 진행했음 → 모델의 구조는 거의 변화하지 않음

→ 이 부분 찾아봐야 할듯

→ GPT를 활용 시, Encoder를 활용하지 않고 Decoder만을 활용하게 되는데, 이를 다른 task에 어떻게 적용할 지 그 부분을 유심히 봐야 함

12개의 natural language understanding task 중 9개에서 SOTA 달성

Introduction

Language Pretrain을 활용한 Embedding 생성은 효과적이라는게 당시에 이미 알려짐 (EIMo),

but, Language Pretrain은 2가지 문제가 있음

1. Embedding 생성 시 학습의 목표를 정하기 애매함 (범용적인 task를 잘하는 임베딩을 만들기 위해서는, 뭐를 최적화해야 하는가?)
2. 세부 task에서 Transfer learning을 진행할 때의 gold standard가 없음
→ task에 맞게 모델을 수정함

gpt는, 1번의 문제점에서는 범용적인 task를 잘하기 위해 generative pretraining을 하였고, 2번의 문제점 해결을 위해 모델 수정을 최소화하고, Input을 수정하는 식으로 문제 해결

GPT는 baseline arch를 transformer로, input adaptation의 경우 traversal style approach로 하였음 (순회)

Method

Framework

Unsupervised pretraining

objective : 대량의 corpus를 통해서, 효과적인 task agnostic한 language model을 생성하자

Loss function

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

일반적인 language modeling과 똑같음

→ k = context window

Q/ k 값을 어떻게 하나에 따라 어떤 결과가 있을 지 궁금 하네

Task specific fine tuning

objective : 특정 task에 맞게, **model을 최소한의 수정을 거쳐서 학습**

Loss function

$$P(y|x^1, \dots, x^m) = \text{softmax}(h_l^m W_y).$$

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y|x^1, \dots, x^m).$$

transformer 마지막 레이어에 Linear layer 붙이고, CE loss

Finetuning 시, 우리가 도입하는 파라미터는 오직 마지막 Linear layer W_y 와, delimiter token에 대한 임베딩 뿐이다. 이게 이 논문의 포인트

Auxillary Objective

개념 : fine tuning 시, 다른 loss를 더한 값을 보조적인 학습 목표로 삼는 것

Objective : 수렴을 빠르게 하고, generalization 능력을 향상시킴

→ gpt 논문에서는, 독특하게 특정 task를 위한 fine tuning 시 language modeling loss를 더해주면 학습이 잘됨

Delimiter Token

Delimiter Token은, 구분자 토큰으로 맥락을 구분해주는 역할을 수행

GPT paper에서는, 모델을 최소한으로 변경하기 위해 delimiter token을 활용하였다

Input Transformation - Task specific




Figure 1: **(left)** Transformer architecture and training objectives used in this work. **(right)** Input transformations for fine-tuning on different tasks. We convert all structured inputs into token sequences to be processed by our pre-trained model, followed by a linear+softmax layer.

Objective : 모델의 구조 (transformer decoder)를 거의 안바꾸고, 여러 Task를 수행하게 하는게 목표

→ 왜 이렇게 해야함? 기존의 pretraining을 최대한 활용하기 위해. 새롭게 도입되는 파라미터는 오직 linear layer와 delimiter밖에 없음

Linear layer를 뒤에 붙인 구조는, sentence classification에는 다이렉트하게 적용 가능, but Q/A에 대해선 어떻게 적용해?

→ 이를 이해하기 위해서는, 기존 모델이 Transformer의 Decoder = autoregressive하다는 점을 이해해야 함.

Transformer의 Decoder는, 2개의 어텐션을 수행하는데, 본 경우 encoder가 결여되어 있으므로 Masked self attention만을 수행.

즉, 병렬적이게 문장을 다루지 않으므로, Q/A task에서 input = Q, answer = A 이런식으로 구성할 수가 없음.

→ 그렇기에 document = z, question = q, possible answers = a_k 라고 할때, [z; q; \$; a_k] 이런식으로 input으로 넣어서 autoregressive하게 answer를 예측하는 식으로 학습한다.

Results

12개 중 9개의 Task에서 SOTA 달성

Analysis

1. transfer된 layer의 수에 대한 성능 증가 분석

→ 예상대로, layer가 많이 transfer될 수록 성능 증가
유의미한 정보를 담고 있다 !

- Textual Entailment Task

→ 문장들간의 함의 (Entailment) 관계를 파악하는 Task

→ 전제 문장이 참이면, 가설 문장도 참이어야 함

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

Abstract

개념적으로 단순하고, 경험적으로 powerful한, 사전학습 임베딩 생성 기법

Bidirectional transformer = Transformer Encoder를 활용한다는 점에서 GPT와 구분됨

GLUE score에서 abs 7.7%가 상승하였다. (General Language Understanding Evaluation)

- GLUE score (General Language Understanding Evaluation)

→ 일반론적인 언어 이해 task에 대한 벤치마크로, 여러가지 언어 이해 task를 수반 (NLU = Natural language understanding)

→ 여러가지 언어 이해 task의 평균 점수 (acc, matthews correlation coef..)

1. Textual Entailment(문장 함의 분석)

- a. 문장 2개의 관계가 함의 / 모순 / 중립인지 분류하는 task

2. Sentiment Analysis

- a. 문장 감정 분석 → 긍정 / 부정 / 중립

3. Paraphrase Detection

- a. 문장 2개가 같은 말을 하는지 분류

4. Question Answering

- a. 질답

5. Semantic Similarity (STS-B)

- a. 문장 두개가 의미론적으로 얼마나 유사한지 분석 → 점수 (0~5)
- b. Spearman correlation으로 평가

6. Natural Language Inference (CoLA)

- a. 문장이 얼마나 문법적으로 올바른지 판별
- b. MCC 활용하여 평가

Introduction

Pretraining을 활용한 전이학습은 성능 증가에 효율적임이 알려짐

이러한 전이 학습에서는, 2가지 전략이 있음

1. Feature-based

- a. ELMo를 활용한 전이학습처럼, 특정 task를 수행하기 위해 기존의 임베딩을 고스란히 가져오고 task를 위해 새로운 모델을 학습 (기존 사전학습 모델의 embedding이 필요)

2. Fine tuning

- a. GPT를 활용한 전이학습처럼, 특정 task를 수행하기 위해 기존 모델을 조금만 수정하여 가중치를 학습 (기존 사전학습 모델이 임베딩을 제공하지 않고,

모델만 있을 때 활용)

BERT의 문제 의식 → Fine tuning approach는, 모델의 변화를 최소화 하기 때문에, 상당히 성능을 제한하는 경향이 있음

ex. GPT는 unidirectional하게 (left2right) 추론하기 때문에, 이는 sentence level task에서는 suboptimal할 수 있다.

→ sentence sentiment analysis task에서는, 문장 전체를 보고 판별하는데 gpt를 활용하면 문장을 단방향으로 처리하는 식으로 진행 (마지막 토큰에 감정은? = 긍정 / 부정) 이런식으로 추가해서


그래서 BERT는, cloze task에서 영감을 받아서 토큰에 마스킹을 하고, 단어를 맞추는 식으로 학습을 진행한다. (MLM)

또한, text 들 간의 관계를 학습하기 위해 Next sentence prediction task를 진행한다

→ MLM + NSP

Method

BERT



BERT 역시 pre-training과 fine tuning으로 구성,

BERT는 모델이 임베딩 역할을 하기 때문에, 앞서 언급한 feature-based와 fine-tuning 방법 중 finetuning 방식에 속한다

→ 위의 예시는 Pretraining BERT를, Q/A task에 finetuning할 때의 모델 구조의 예시

BERT는 encoder를 활용하기 때문에, 문장들 내의 토큰들의 self-attention을 수행, → Q/A task의 경우 Question과 answer를 delimiter = [SEP] 토큰으로 concat하여 Input으로 넣는다

BERT의 경우, bidirectional encoder를 활용하기 때문에 sentence A 인지 sentence B인지 구분하는 역할이 중요

→ 물론 positional encoding이 어느정도 기능을 하겠지만, 한계가 있기 때문에 sentence A, B에 해당하는 토큰들에 특정한 학습된 벡터를 더하고, [SEP] 토큰으로 구분한다

MLM (masked language modeling)

특정 수의 토큰을 마스킹하고, [Mask] 토큰으로 대체

그 이후, Mask 토큰을 softmax 에 넣어서 무슨 단어인지 맞추게 함

15%의 토큰을 마스킹했다

→ 본 접근법의 단점은, Pre-training과 fine-tuning에서 구조가 바뀐다는 것. 왜냐면 [MASK] 토큰이 없으니까.

→ 이를 해결하기 위해 15%의 토큰들의 80%는 마스크 토큰으로 바꾸고, 10%는 random, 10%는 unchange 했다.

NSP (next sentence prediction)

objective

문장들 간의 관계를 파악하기 위해

→ Q/A, Natural language inference (명제 함의 판단)의 경우 문장들의 관계가 중요

method

50%는 sentence A 뒤에 sentence B가 오는 진짜 다음 문장이고, 50%는 sentence A 뒤에 sentence B가 이어지지 않는 문장임.

→ 그 이후 class token을 활용해서 다음 문장인지 판별

Conclusion

unidirectional한 fine tuning 방식의 한계를 극복하고, bidirectional하게 풍부한 정보를 포착해내는 방식이 독특

fine tuning 방식을 채택하여, 동일한 사전학습 모델이 광범위한 자연어 모델에서 SOTA 달성

