

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

24기 분석 조희선

Abstract

- BERT는 "Bidirectional Encoder Representations from Transformers"의 약자로, 양방향 문맥을 모두 활용하는 사전학습 모델.
- 기존 모델(OpenAI GPT 등)은 왼쪽에서 오른쪽으로만 문맥을 고려했지만, BERT는 좌우 문맥을 동시에 학습함.
- 사전 학습된 BERT는 추가적인 출력층만으로 다양한 자연어 처리(NLP) 작업에 최첨단 성능을 달성.
- 11개 NLP 과제에서 새로운 최고 성능 달성 (예: GLUE, SQuAD 등).

1. Introduction

- 기존 언어 모델들은 특징 기반(feature-based) 방식과 파인튜닝(fine-tuning) 방식으로 나뉘었음.
- ELMo: feature-based 접근 (양방향 정보 사용하긴 하지만 얇음)
- OpenAI GPT: fine-tuning 접근 (왼쪽에서 오른쪽으로만 처리)

기존 모델들의 문제점:

- 대부분 단방향(unidirectional) 학습만 수행
- 문맥 정보를 제한적으로 사용하여 문장 수준 작업에서 비효율적
- BERT는 Masked Language Model (MLM)과 Next Sentence Prediction (NSP)이라는 새로운 사전학습 방식을 통해 양방향 학습을 가능하게 함.

2. 관련 연구 (Related Work)

2.1 비지도 특징 기반 접근법

기존의 단어 임베딩(Word2Vec, GloVe 등)은 문맥에 둔감.

ELMo는 양방향 LSTM을 사용하여 문맥에 따른 단어 임베딩 제공.

2.2 비지도 파인튜닝 접근법

OpenAI GPT: 왼쪽-오른쪽 언어 모델을 기반으로 파인튜닝하여 다양한 과제에서 높은 성능을 보였음.

2.3 감독 학습 기반 전이학습

자연어 추론(NLI)과 기계번역 등 감독학습 데이터에서 전이학습하는 사례가 많아짐.

3. BERT 모델 (The BERT Model)

✓ 구조 (Architecture)

양방향 Transformer 인코더 사용

두 가지 모델 크기:

BERTBASE: 12층, Hidden size 768, Attention head 12개 (110M 파라미터)

BERTLARGE: 24층, Hidden size 1024, Attention head 16개 (340M 파라미터)

✓ 입력 표현 (Input Representation)

WordPiece 임베딩 사용 (30K 토큰)

[CLS]: 문장 전체를 대표하는 토큰 (분류 작업에 사용)

[SEP]: 문장 구분자

입력 = 토큰 임베딩 + 세그먼트 임베딩 + 포지션 임베딩

4. BERT 사전 학습 방법 (Pre-training BERT)

✓ Task 1: Masked Language Model (MLM)

입력 문장에서 15% 토큰을 무작위로 마스킹하고 이를 예측

기존 왼쪽-오른쪽 방식과 다르게 양방향 문맥 활용 가능

✓ Task 2: Next Sentence Prediction (NSP)

두 문장이 실제로 연결되는지 예측 (50% 연결 / 50% 랜덤)

문장 관계 이해가 필요한 질의응답(QA), 자연어 추론(NLI)에 유리

5. 파인튜닝 (Fine-tuning BERT)

사전학습한 BERT에 task-specific 출력층만 추가하고, 전체 파라미터를 함께 학습

다양한 과제에 간단하게 적용 가능:

단일 문장 분류, 문장 쌍 관계 분류, 시퀀스 태깅 등

파인튜닝 시간은 짧고 효율적임 (Cloud TPU 기준 최대 1시간)

6. 실험 결과 (Experiments)

✓ GLUE 벤치마크

BERTLARGE: 11개 과제 모두에서 최고 성능 달성

기존 모델 대비 평균 4.5% ~ 7% 정확도 향상

✓ SQuAD v1.1/v2.0

SQuAD v1.1: F1 점수 93.2 (기존 대비 1.5점 향상)

SQuAD v2.0: F1 점수 83.1 (기존 대비 5.1점 향상)

✓ SWAG 데이터셋

상식적 추론 평가에서 OpenAI GPT보다 8.3% 더 높은 정확도 기록

7. 분석 및 추가 실험 (Ablation Studies)

NSP와 양방향 학습이 성능에 큰 기여

모델 크기 증가가 작은 데이터셋에도 큰 효과가 있음

Fine-tuning과 Feature-based 접근 비교 → 둘 다 강력하지만, Fine-tuning이 일반적으로 더 우수함

8. 결론 (Conclusion)

BERT는 기존 언어모델이 가지던 한계(단방향성)를 극복하고, 깊은 양방향 사전학습을 통해 다양한 NLP 작업에 최첨단 성능을 제공

저자들이 공개한 코드와 사전학습 모델은 다양한 응용이 가능하게 만들어졌음