

word2vec

1. 정의

- 단어를 벡터(수치)로 변환하여 의미를 반영하는 모델
- 연산량을 최소화하고, Skip-gram과 CBow의 두 모델로 단어의 분산 표현을 학습
- +) 기존 one-hot encoding 기반 모델은 단어 유사도를 반영하지 못함 -> 해결 위하여 등장한 모델

2. 주요 구조

- 대용량 데이터 학습을 위해 DistBelief 프레임워크 사용
- 연산량 줄이고 병렬 처리 가능한 모델 탐색

(1) CBOW

- 문맥을 기반으로 현재 단어를 예측, 은닉층이 없어서 연산량 적고 빠름
- 단어 순서를 고려하지 않음

(2) Continuous Skip-gram

- 현재 단어를 사용하여 주변 단어 예측
- 예측 범위를 늘릴수록 단어 벡터 품질 향상되지만, 연산량 증가
- > Hierarchical Softmax를 사용하여 연산량 감소시킬 수 있음

3. 학습 및 적용 방식

- 신경망을 활용한 CBOW와 Skip-gram이 단어 간 의미를 효과적으로 학습 가능
- 단어 간 관계 학습이 가능해져, 유사 단어 탐색 및 NLP 성능 향상