

Word2vec, Elmo

ELMo와, Word2vec 모델은 둘 다 임베딩 모델이다. 임베딩 모델이란, 비정형 데이터인 자연어를 벡터화 하여 벡터들 끼리의 유사도나, 연산을 가능케 하는 것이다.

ELMo는 Word2vec보다 이후에 나온 논문인 만큼, word2vec의 한계를 극복한다. 기본적으로 word2vec의 경우 skip-gram이나 cbow 방식으로 단어를 임베딩하는데, 이는 동음이의어에 대한 문제를 전혀 해결하지 못한다.

→ 이를테면, 사람의 눈과 하늘에서 내리는 눈은 완전히 다른 의미를 가지고 있으며, 맥락에 따라 의미가 결정되지만 word2vec 방법론에서는 이를 처리하지 못한다는 것이다.

이러한 word2vec의 한계를 극복한 논문이 ELMo이다. ELMo는 contextualized word embedding model로, 맥락에 따라 **개별 단어의 임베딩이 달라진다**.

맥락에 따라 개별 단어의 임베딩이 달라지는 것을, 어떻게 ELMo논문에서 가능케 하는가?

→ biLSTM 아키텍처를 통해서 가능해진다. LSTM은 RNN과 유사하게, time series를 다룰 수 있는 아키텍처로, 어떠한 한 단어를 임베딩하는 과정에서 이전 timestep에서의 hidden state를 고려한다. 이는 word embedding의 관점에서, **맥락**을 고려하는 역할을 하게 된다.

ELMo의 학습방법은, **독립적으로 매개변수를 공유하지 않는**, 두개의 LSTM 모델을 학습시키는 과정을 포함한다.

→ 한개의 모델은, 정방향으로 다음 단어를 예측하며, 한개의 모델은 역방향으로 이전 단어를 예측한다.

학습하는 손실 함수의 경우, 두 모델의 log likelihood를 선형으로 1:1의 가중치로 단순합하는 식으로 진행한다.

ELMo의 학습 방법과 BERT의 학습 방법을 어느정도 비교해볼 수 있다. 공통점과 차이점을 기반으로 이해해보자.

공통점

ELMo와 BERT는 모두 bidirectional 한 관계를 고려한다. 즉 한 문장에서, 특정 단어 이전과 이후의 토큰에 의해 모두 임베딩이 달라질 수 있다는 의미이다. → 이는 sentence classification, word classification 등의 task에서 중요하다

차이점

ELMo는 sequential한 데이터를 처리하는, LSTM을 기반으로 만들어졌고 BERT는 병렬적으로 처리할 수 있는 transformer를 기반으로 만들어졌다는 것이다.

transformer는 LSTM과 달리, inductive bias가 높지 않다. 이 말은 즉, positional embedding이 없다면 transformer는 단어의 어순을 완전히 무시한다는 것이다.

그렇기에 ELMo는 두개의 LSTM 모델이 있어야 양방향의 관계를 모델링 할 수 있고, BERT는 유일한 transformer 모델 하나로 임베딩이 가능한 것이다.