

LLaMA

Open and Efficient Foundation Language Models

Introduction

결론: GPT3보다 10배 작은 LLAMA가 gpt3와 경쟁할 정도의 모델이 되고

데이터는 오픈소스로 사용한다.

- 오직 공개 데이터만 사용
- 트랜스포머 아키텍처에서 어떤 변경을 했는지
- 다른 llm과 비교해서 어떤 벤치마크 성능을 보이는지

OPT	30B	26.1
GLM	120B	44.8
PaLM	62B	55.1
PaLM-cont	62B	62.8
Chinchilla	70B	67.5
LLaMA	65B	63.4
OPT-IML-Max	30B	43.2
Flan-T5-XXL	11B	55.1
Flan-PaLM	62B	59.6
Flan-PaLM-cont	62B	66.1
LLaMA-I	65B	68.9

Table 10: **Instruction finetuning – MMLU (5-shot).** Comparison of models of moderate size with and without instruction finetuning on MMLU.

Pre-training Data


- 다른 llm에서 사용한 데이터를 재사용함
- 그 중에서도 공개적으로 사용이 가능한, document가 작성된 데이터만 사용
- 이러한 데이터들로 tokenizing 해보면 1.4T 토큰을 얻음
- 학습할 때 거의 한 번씩만 사용되었고, Wikipedia(위키페디아)나 책 같은 경우에는 2 epoch을 돌아서 이것만 두 번 토큰이 학습됨
- Tokenizer: BPE

Dataset	Sampling prop.	Epochs	Disk size
CommonCrawl	67.0%	1.10	3.3 TB
C4	15.0%	1.06	783 GB
Github	4.5%	0.64	328 GB
Wikipedia	4.5%	2.45	83 GB
Books	4.5%	2.23	85 GB
ArXiv	2.5%	1.06	92 GB
StackExchange	2.0%	1.03	78 GB

Table 1: **Pre-training data.** Data mixtures used for pre-training, for each subset we list the sampling proportion, number of epochs performed on the subset when training on 1.4T tokens, and disk size. The pre-training runs on 1T tokens have the same sampling proportion.

Architecture

- Standard 트랜스포머의 decoder (그림)
 - Few-shot learning과 PaLM과 유사
- 1) Pre-normalization - input에 Normalization을 함 [GPT-3]
 - 2) SwiGLU activation function 사용 [PaLM]
 - 3) Rotary Embeddings [GPTNeo]
- Optimizer는 AdamW 사용 ($\beta_1 = 0.9$, $\beta_2 = 0.95$)



Approach

params	dimension	n heads	n layers	learning rate	batch size	n tokens
6.7B	4096	32	32	$3.0e^{-4}$	4M	1.0T
13.0B	5120	40	40	$3.0e^{-4}$	4M	1.0T
32.5B	6656	52	60	$1.5e^{-4}$	4M	1.4T
65.2B	8192	64	80	$1.5e^{-4}$	4M	1.4T

Table 2: **Model sizes, architectures, and optimization hyper-parameters.**

다음의 표는 모델 파라미터에 대한 간략한 정리임.
4개의 모델 사이즈가 있고 거기에 사용된 모델의 하이퍼 파라미터를 표로 정리함.

Approach

1) Pre-normalization [GPT3]

- 기존 transformer에서는 LayerNorm를 출력단에 적용하여 서브 레이어의 output을 정규화함
- LLaMA 에서는 RMSNorm 정규화 함수를 사용
 - > LayerNorm보다 가벼운 연산으로 메모리 효율성 증가
 - > LayerNorm보다 높은 gradient norm을 유지하여 Gradient vanishing 해결
- 각 transformer 서브 레이어의 입력을 정규화
 - > 학습 안정성 향상





Figure 1. (a) Post-LN Transformer layer; (b) Pre-LN Transformer layer.

2) SwiGLU activation function [PaLM](2020)

- 논문에서 사용한 것과 똑같은 하이퍼 파라미터를 똑같이 사용함
- ReLU non-linearity의 SwiGLU activation function으로 대체하였고, 이에 성능의 향상이 가능하였음.
- PaLM 논문에서는 Feed Forward Layer의 차원을 4배 확장한 반면, LLaMA에서는 메모리 효율성을 고려하여 약 2.67배 확장하는 방식을 사용하여 성능을 유지하면서도 메모리 사용량을 최적화




Approach

3) Rotary Embeddings [GPTNeo] (2021)

- 기존 Absolute positional embedding -> 시퀀스 길이의 제한 존재

[Solution] Rotary Embedding을 사용하여 해결

- 시퀀스 길이 제한 해결
=> 사전 정의된 길이를 초과하는 문장에서 일반화가 어려웠지만, RoPE는 단순한 회전 변환을 적용하여 긴 시퀀스에서도 자연스럽게 확장 가능
- relative distance 때문에 늘어나는 내부 시퀀스 의존성 줄임
=> 모델이 문장의 전체적인 위치뿐만 아니라, 단어 간 상대적 관계를 직접적으로 학습
- Linear self attention 할 수 있음
=> RoPE는 토큰 벡터 자체에 회전 변환을 적용하여 상대적 관계를 유지하기 때문에, Self-Attention 연산을 보다 효율적으로 수행



4) Efficient implementation

코드 구현시 효율적으로 구현한 방법

- Causal multi head attention을 사용하여 마스킹된 부분은 key, query score를 계산하지 않음
 - backward시 Pytorch의 autograd에 의존하지 않고 직접 구현함. 체크포인트 활용
 - Sequence parallelism 적용
- > 메모리 사용량 줄임
- > 시퀀스 길이가 길어져도 효율적으로 처리가 가능함

Main Results

1) Common Sense Reasoning

- Zero-shot과 few-shot tasks
20개의 benchmarks에서 testing 진행
- Common Sense Reasoning의 경우
기존의 모델과 LLaMA 모델이 있는데
=> 더 높은 score를 보이면서 훨씬 작은 파라미터를
사용하고 있음
- LLaMA의 경우 아래의 모델로 비교를 하는데
어떤 것은 성능이 좋고
BoolQ, WinGrande는 조금 뒤쳐지지만
좋은 성능을 보임

		BoolQ	PIQA	SIQA	HellaSwag	WinoGrande	ARC-e	ARC-c	OBQA
GPT-3	175B	60.5	81.0	-	78.9	70.2	68.8	51.4	57.6
Gopher	280B	79.3	81.8	50.6	79.2	70.1	-	-	-
Chinchilla	70B	83.7	81.8	51.3	80.8	74.9	-	-	-
PaLM	62B	84.8	80.5	-	79.7	77.0	75.2	52.5	50.4
PaLM-cont	62B	83.9	81.4	-	80.6	77.0	-	-	-
PaLM	540B	88.0	82.3	-	83.4	81.1	76.6	53.0	53.4
LLaMA	7B	76.5	79.8	48.9	76.1	70.1	72.8	47.6	57.2
	13B	78.1	80.1	50.4	79.2	73.0	74.8	52.7	56.4
	33B	83.1	82.3	50.4	82.8	76.0	80.0	57.8	58.6
	65B	85.3	82.8	52.3	84.2	77.0	78.9	56.0	60.2

Table 3: Zero-shot performance on Common Sense Reasoning tasks.

Main Results

2) Closed-book Question Answering

- 두 가지 벤치마크 데이터셋에서 다른 LLM 모델과 비교했을 때 좋은 성능을 보임으로써

기존 모델 스케일링을 통한 게 완전히 학습이 되지 않음을 보여줌

		0-shot	1-shot	5-shot	64-shot
GPT-3	175B	14.6	23.0	-	29.9
Gopher	280B	10.1	-	24.5	28.2
Chinchilla	70B	16.6	-	31.5	35.5
PaLM	8B	8.4	10.6	-	14.6
	62B	18.1	26.5	-	27.6
	540B	21.2	29.3	-	39.6
LLaMA	7B	16.8	18.7	22.0	26.1
	13B	20.1	23.4	28.1	31.9
	33B	24.9	28.3	32.9	36.0
	65B	23.8	31.0	35.0	39.9

Table 4: **NaturalQuestions**. Exact match performance.

		0-shot	1-shot	5-shot	64-shot
Gopher	280B	43.5	-	57.0	57.2
Chinchilla	70B	55.4	-	64.1	64.6
LLaMA	7B	50.0	53.4	56.3	57.6
	13B	56.6	60.5	63.1	64.0
	33B	65.1	67.9	69.9	70.4
	65B	68.2	71.6	72.6	73.0

Table 5: **TriviaQA**. Zero-shot and few-shot exact match performance on the filtered dev set.

Main Results

3) Reading Comprehension

- 중고등학교 영어 독해 시험에서 수집된 데이터셋인 RACE를 수행하는 task
- LLaMA-65B는 PaLM-540B와 경쟁력이 있으며, LLaMA-13B는 GPT-3를 몇 퍼센트 정도 능가

		RACE-middle	RACE-high
GPT-3	175B	58.4	45.5
	8B	57.9	42.3
	62B	64.3	47.5
PaLM	540B	68.1	49.1
	7B	61.1	46.9
LLaMA	13B	61.6	47.2
	33B	64.1	48.3
	65B	67.9	51.6

Table 6: **Reading Comprehension.** Zero-shot accuracy.

4) Mathematical reasoning

- 중고등학교 수학 문제로 구성된 데이터셋인 MATH, GSM8k 사용
- LLaMA 모델은 수학 데이터에 대해 fine-tuning을 하지 않았지만, PaLM과 Minerva와 비교하여 성능을 평가
- 특히, GSM8k 데이터셋에 majority voting을 적용한 결과, LLaMA-65B 모델은 Minerva-62B 모델을 초과한 성능을 보임

		MATH +maj1@k		GSM8k +maj1@k	
PaLM	8B	1.5	-	4.1	-
	62B	4.4	-	33.0	-
	540B	8.8	-	56.5	-
Minerva	8B	14.1	25.4	16.2	28.4
	62B	27.6	43.4	52.4	68.5
	540B	33.6	50.3	68.5	78.5
LLaMA	7B	2.9	6.9	11.0	18.1
	13B	3.9	8.8	17.8	29.3
	33B	7.1	15.2	35.6	53.1
	65B	10.6	20.5	50.9	69.7

Table 7: **Model performance on quantitative reasoning datasets.** For majority voting, we use the same setup as Minerva, with $k = 256$ samples for MATH and $k = 100$ for GSM8k (Minerva 540B uses $k = 64$ for MATH and $k = 40$ for GSM8k). LLaMA-65B outperforms Minerva 62B on GSM8k, although it has not been fine-tuned on mathematical data.

Main Results

5) Code-generation

- 모델의 코딩 능력을 평가하는 HumanEval과 MBPP 벤치마크 사용
- LLaMA 13B 모델은 LaMDA 137B를 두 가지 벤치마크에서 초과 성능을 보였고, LLaMA 65B는 PaLM 62B보다 더 나은 성능을 보임

pass@	Params	HumanEval		MBPP	
		@1	@100	@1	@80
LaMDA	137B	14.0	47.3	14.8	62.4
PaLM	8B	3.6*	18.7*	5.0*	35.7*
PaLM	62B	15.9	46.3*	21.4	63.2*
PaLM-cont	62B	23.7	-	31.2	-
PaLM	540B	26.2	76.2	36.8	75.0
LLaMA	7B	10.5	36.5	17.7	56.2
	13B	15.8	52.5	22.0	64.0
	33B	21.7	70.7	30.2	73.4
	65B	23.7	79.3	37.7	76.8

Table 8: **Model performance for code generation.** We report the pass@ score on HumanEval and MBPP. HumanEval generations are done in zero-shot and MBPP with 3-shot prompts similar to Austin et al. (2021). The values marked with * are read from figures in Chowdhery et al. (2022).

6) MMLU

- 인문학, 과학, 공학 등 다양한 지식 분야를 포함하는 객관식 질문으로 구성됨
- LLaMA-65B 모델은 평균적으로 Chinchilla-70B와 PaLM-540B 모델에 비해 몇 퍼센트 정도 뒤쳐짐
- > 사전 학습 데이터로 사용한 책과 학술 논문이 제한적이었다는 점

		Humanities	STEM	Social Sciences	Other	Average
GPT-NeoX	20B	29.8	34.9	33.7	37.7	33.6
GPT-3	175B	40.8	36.7	50.4	48.8	43.9
Gopher	280B	56.2	47.4	71.9	66.1	60.0
Chinchilla	70B	63.6	54.9	79.3	73.9	67.5
PaLM	8B	25.6	23.8	24.1	27.8	25.4
	62B	59.5	41.9	62.7	55.8	53.7
	540B	77.0	55.6	81.0	69.6	69.3
LLaMA	7B	34.0	30.5	38.3	38.1	35.1
	13B	45.0	35.8	53.8	53.3	46.9
	33B	55.8	46.0	66.7	63.4	57.8
	65B	61.8	51.7	72.9	67.4	63.4

Table 9: **Massive Multitask Language Understanding (MMLU).** Five-shot accuracy.

Main Results

Evolution of performance during training

- 벤치마크별 학습 성능 변화 그래프
- SIQA에서는 성능에 많은 변동이 나타나 이 벤치마크가 신뢰할 수 없다는 것을 나타낼 수 있음
- LLaMA-33B와 LLaMA-65B는 훈련 중에 비슷한 성능을 보임




Figure 2: Evolution of performance on question answering and common sense reasoning during training.

MMLU

- Massive Multitask Language Understanding
- Instruction data에 대해 소량의 fine-tuning만으로 MMLU에서 성능 개선
- LLaMA 65B는 기존의 모델들을 능가하지만, SOTA(77.4)와는 차이가 있음

OPT	30B	26.1
GLM	120B	44.8
PaLM	62B	55.1
PaLM-cont	62B	62.8
Chinchilla	70B	67.5
LLaMA	65B	63.4
OPT-IML-Max	30B	43.2
Flan-T5-XXL	11B	55.1
Flan-PaLM	62B	59.6
Flan-PaLM-cont	62B	66.1
LLaMA-I	65B	68.9

Table 10: **Instruction finetuning – MMLU (5-shot).** Comparison of models of moderate size with and without instruction finetuning on MMLU.

Experiments: Bias, Toxicity and Misinformation

RealToxicityPrompts

- 목적: Toxic expression
- Metric: PerspectiveAPI
- Results:
 - 점수가 높을수록 독성이 더 높은 생성
 - 모델 크기에 비례해서 Respectful 성능이 안 좋아지는 경향

CrowS-Pairs

- 목적: 9개의 카테고리에 대한 bias (즉, 고정관념 선호 정도 측정)
- Metric: Model perplexity
- Results:
 - 점수가 높을수록 높은 bias 생성
 - LLaMA가 평균적으로는 두 모델에 비해 유리한 결과이지만, 각 카테고리에 대해서는 높은 bias를 나타냄
 - -> LLaMA의 Pretraining dataset 의 큰 부분을 차지하는 CommonCrawl 데이터에서 비롯된 것이라고 주장

		Basic	Respectful
LLaMA	7B	0.106	0.081
	13B	0.104	0.095
	33B	0.107	0.087
	65B	0.128	0.141

Table 11: **RealToxicityPrompts**. We run a greedy decoder on the 100k prompts from this benchmark. The “respectful” versions are prompts starting with “Complete the following sentence in a polite, respectful, and unbiased manner:”, and “Basic” is without it. Scores were obtained using the PerplexityAPI, with higher score indicating more toxic generations.

	LLaMA	GPT3	OPT
Gender	70.6	62.6	65.7
Religion	79.0	73.3	68.6
Race/Color	57.0	64.7	68.6
Sexual orientation	81.0	76.2	78.6
Age	70.1	64.4	67.8
Nationality	64.2	61.6	62.9
Disability	66.7	76.7	76.7
Physical appearance	77.8	74.6	76.2
Socioeconomic status	71.5	73.8	76.2
Average	66.6	67.2	69.5

Table 12: **CrowS-Pairs**. We compare the level of biases contained in LLaMA-65B with OPT-175B and GPT3-175B. Higher score indicates higher bias.

Experiments: Bias, Toxicity and Misinformation

WinoGender

- 목적: Gender bias
 - 모델이 성별 대명사에 대해 수행을 잘 하는지 확인
- Metric: co-reference resolution accuracy
- Results: Gender bias가 나타남
 - “their/them/someone” 가 “her/her/she” 와 “his/him/he”에 비해 수행을 더 잘 해냄 (Gender bias 나타낼 가능성이 크다고 판단)

TruthfulQA

- 목적: 진실 식별 여부
 - 진실한 답변을 하는가 / 진실하면서도 유익한 정보까지 포함하는 답변을 하는가
- Results: GPT-3보다 높은 점수를 기록하지만, 여전히 모델의 정답률이 낮음

	7B	13B	33B	65B
All	66.0	64.7	69.0	77.5
her/her/she	65.0	66.7	66.7	78.8
his/him/he	60.8	62.5	62.1	72.1
their/them/someone	72.1	65.0	78.3	81.7
her/her/she (gotcha)	64.2	65.8	61.7	75.0
his/him/he (gotcha)	55.0	55.8	55.8	63.3

Table 13: **WinoGender**. Co-reference resolution accuracy for the LLaMA models, for different pronouns (“her/her/she” and “his/him/he”). We observe that our models obtain better performance on “their/them/someone” pronouns than on “her/her/she” and “his/him/he”, which is likely indicative of biases.

		Truthful	Truthful*Inf
GPT-3	1.3B	0.31	0.19
	6B	0.22	0.19
	175B	0.28	0.25
LLaMA	7B	0.33	0.29
	13B	0.47	0.41
	33B	0.52	0.48
	65B	0.57	0.53

Table 14: **TruthfulQA**. We report the fraction of truthful and truthful*informative answers, as scored by specially trained models via the OpenAI API. We follow the QA prompt style used in Ouyang et al. (2022), and report the performance of GPT-3 from the same paper.

Conclusion

- 두 가지 Scaling laws에 대한 흐름을 이해할 필요가 있음
- 이전의 연구들과는 달리, 공개된 데이터만을 사용하여 SOTA를 달성할 수 있음
- LLaMA-13B는 GPT-3(175B)를 능가하면서도 크기는 10배 이상 작고, LLaMA-65B는 Chinchilla-70B와 PaLM-540B와 경쟁할 수 있음
- Large Language model을 가속화할 수 있도록 오픈 소싱