

DeepLabv3

Encoder-Decoder with Atrous Separable Convolution for Semantic...

Spatial pyramid pooling module or encode-decoder structure are used in deep neural networks for semantic segmentation task. The former networks are able to encode multi-scale contextual...

 <https://arxiv.org/abs/1802.02611>



Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation

저자 : Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, Hartwig Adam


발행일 : 2018년 2월

0. Abstract

- Semantic segmentation을 위해 보통 두 가지 구조가 사용됨:
 - **Spatial Pyramid Pooling**: 다양한 크기의 receptive field로 **multi-scale context**를 반영
 - **Encoder-Decoder 구조**: 점진적으로 **공간 정보 복원** → 객체 경계 복원에 유리
- **DeepLabv3+**
 - 기존 DeepLabv3에 간단한 **decoder 모듈**을 추가해 **object boundary 복원 강화**
 - ASPP 모듈과 decoder에 **depthwise separable convolution** 적용 → **속도 향상 + 정확도 향상**
- **성능**
 - **PASCAL VOC 2012**: 89.0% mIOU
 - **Cityscapes**: 82.1% mIOU
 - 별도 후처리 없이 **SOTA 달성**

1. Introduction

- **Semantic segmentation**은 이미지의 모든 pixel에 semantic label을 할당하는 문제로, 딥러닝 기반 FCN(Fully Convolutional Network)이 큰 발전을 이룸
- 기존 접근 방식
 - **Spatial Pyramid Pooling 계열 (DeepLabv3, PSPNet)**
 - 다양한 스케일의 정보를 반영하지만 **경계 정보 손실**
 - **Encoder-Decoder 계열**
 - 경계는 잘 살리지만 **context 표현이 약함**
- 문제점
 - 풀링, stride로 인해 feature map 해상도가 낮아지고 경계 정보 손실
 - 특히 DeepLab 계열은 feature density를 높이기 위해 atrous convolution 사용
 - 하지만 너무 고해상도 feature를 만들면 계산량이 폭증함
- 해결 : DeepLabv3+



- DeepLabv3의 ASPP encoder + 간단하고 효율적인 decoder를 결합
- encoder는 **context 풍부한 feature** 추출
- decoder는 **세밀한 object boundary 복원**
- 추가 개선
 - **Xception 구조** 활용
 - **Depthwise separable convolution**을 ASPP와 decoder에 적용
 - 더 빠르고 정확한 네트워크 구성

3. Methods


3.1 Encoder-Decoder with Atrous Convolution

(1) Atrous Convolution (Hole/Dilated Convolution)

- 특징
 - 필터 사이에 간격을 두어 feature map의 해상도는 유지하면서 field-of-view를 넓힘
- 장점
 - multi-scale context 정보를 하나의 layer에서 효율적으로 추출
 - 해상도 조절이 가능 (rate = 1 → 일반 convolution)

(2) Depthwise Separable Convolution

DeepLabv3+: Encoder-Decoder with Atrous Separable Convolution



- 구성
 1. Depthwise Convolution: 각 채널마다 독립적으로 3×3 conv 수행
 2. Pointwise Convolution: 1×1 conv로 채널 간 정보 통합
- 효과:
 - 계산량 크게 절감
 - 성능은 그대로 or 향상
- 적용:
 - ASPP 모듈과 decoder 모듈에 함께 적용

(3) DeepLabv3 as Encoder

- 기반 구조: ResNet + ASPP
- Output stride (OS):
 - 입력 이미지 대비 feature map의 축소 배율
 - 분류 task → 일반적으로 OS=32
 - segmentation → OS=16 또는 8 사용
 - stride 제거 + atrous conv 적용으로 해상도 보존
- ASPP 모듈:
 - 서로 다른 rate의 atrous conv를 병렬 적용
 - image-level features를 결합해 풍부한 context 학습

(4) Proposed Decoder

- 기존 DeepLabv3는 단순 bilinear upsampling만 사용 → 경계 복원 한계
- DeepLabv3+ Decoder 구조:
 1. Encoder feature(OS=16) → 4배 bilinear upsampling
 2. ResNet의 **low-level feature (e.g., Conv2)**와 concat
 - 이때 low-level feature는 1×1 conv로 채널 수 감소
 3. 3×3 conv로 특징 정제
 4. 최종 4배 upsampling → 최종 segmentation 결과 생성

3.2 Modified Aligned Xception

DeepLabv3+에서는 기존 Xception 모델을 semantic segmentation에 맞게 수정하여 사용

주요 변경 사항

1. 더 깊은 Xception 구조 사용 (MSRA 팀의 Aligned Xception 기반)
 - 단, Entry Flow는 그대로 유지하여 연산 속도 + 메모리 효율 확보
2. Max Pooling → Strided Depthwise Separable Convolution으로 대체
 - 이로써 Atrous Separable Convolution을 자유롭게 적용 가능
3. 각 3×3 depthwise conv 뒤에 BatchNorm + ReLU 추가

→ MobileNet 스타일 구조 도입 → 안정적인 학습

4. Experimental Evaluation

4.1 Decoder Design Choices

- 기존 DeepLabv3는 bilinear upsampling만 사용 → 경계 복원 성능 부족
- 개선된 Decoder는 다음과 같은 구성으로 성능 향상:
 1. Conv2 (low-level feature)와 Encoder feature를 concat
 2. **1×1 conv** 로 Conv2 채널을 48로 축소
 3. 이어서 **3×3 conv, 256 filters** 2번 적용
- 더 깊은 Decoder 구조 (e.g. Conv3까지 포함하거나 conv 3회)는 성능 향상 미미
- 최종 구조는 간단하면서도 효과적인 skip + 2 conv 구조 선택

4.2 ResNet-101 as Network Backbone

Encoder		Decoder MS Flip	mIOU	Multiply-Adds
train OS	eval OS			
16	16		77.21%	81.02B
16	8		78.51%	276.18B
16	8	✓	79.45%	2435.37B
16	8	✓ ✓	79.77%	4870.59B
16	16	✓	78.85%	101.28B
16	16	✓ ✓	80.09%	898.69B
16	16	✓ ✓ ✓	80.22%	1797.23B
16	8	✓	79.35%	297.92B
16	8	✓ ✓	80.43%	2623.61B
16	8	✓ ✓ ✓	80.57%	5247.07B
32	32		75.43%	52.43B
32	32	✓	77.37%	74.20B
32	16	✓	77.80%	101.28B
32	8	✓	77.92%	297.92B

- ResNet-101 기반에서 다양한 설정 실험
 - output stride = 16이 성능과 연산 복잡도 간 가장 좋은 trade-off
 - stride = 8은 약간 더 정확하지만 계산량 ↑

- Multi-scale / Flip / Decoder 조합으로 최대 80.57% mIOU 도달
- Decoder 없이 stride=32로 학습하면 연산량 ↓지만 성능은 다소 낮음


4.3 Xception as Network Backbone

Encoder		Decoder	MS	Flip	SC	COCO	JFT	mIOU	Multiply-Adds
train OS	eval OS								
16	16							79.17%	68.00B
16	16		✓					80.57%	601.74B
16	16		✓	✓				80.79%	1203.34B
16	8							79.64%	240.85B
16	8		✓					81.15%	2149.91B
16	8		✓	✓				81.34%	4299.68B
16	16	✓						79.93%	89.76B
16	16	✓	✓					81.38%	790.12B
16	16	✓	✓	✓				81.44%	1580.10B
16	8	✓						80.22%	262.59B
16	8	✓	✓					81.60%	2338.15B
16	8	✓	✓	✓				81.63%	4676.16B
16	16	✓			✓			79.79%	54.17B
16	16	✓	✓	✓	✓			81.21%	928.81B
16	8	✓			✓			80.02%	177.10B
16	8	✓	✓	✓	✓			81.39%	3055.35B
16	16	✓			✓	✓		82.20%	54.17B
16	16	✓	✓	✓	✓	✓		83.34%	928.81B
16	8	✓			✓	✓		82.45%	177.10B
16	8	✓	✓	✓	✓	✓		83.58%	3055.35B
16	16	✓			✓	✓	✓	83.03%	54.17B
16	16	✓	✓	✓	✓	✓	✓	84.22%	928.81B
16	8	✓			✓	✓	✓	83.39%	177.10B
16	8	✓	✓	✓	✓	✓	✓	84.56%	3055.35B

- Aligned Xception 구조 채택 (Entry flow 제외 MSRA와 동일)
→ ResNet보다 약 2% 더 높은 정확도
- 추가 개선 사항
 - 모든 Max Pooling → Strided Depthwise Separable Conv로 대체
 - 모든 3×3 Depthwise Conv 뒤에 BatchNorm + ReLU 추가
- ASPP + Decoder에도 depthwise separable conv 적용 → 연산량 30~40% 절감
- Pretraining:

- ImageNet + COCO + JFT 사전학습 → 성능 최대 84.56% mIOU

4.4 Improvement along Object Boundaries



- Trimap 실험으로 경계 근처 성능 측정:
 - Decoder 사용 시 ResNet: +4.8%, Xception: +5.4% mIOU 향상
 - 특히 경계선이 얇을수록 효과 뚜렷
- Decoder가 단순한 bilinear upsampling보다 경계 복원에 탁월

4.5 Experimental Results on Cityscapes




Fig. 6. Visualization results on *val* set. The last row shows a failure mode.

Backbone	Decoder	ASPP	Image-Level	mIOU
X-65		✓	✓	77.33
X-65	✓	✓	✓	78.79
X-65	✓	✓		79.14
X-71	✓	✓		79.55

(a) *val* set results

Method	Coarse	mIOU
ResNet-38 [83]	✓	80.6
PSPNet [24]	✓	81.2
Mapillary [86]	✓	82.0
DeepLabv3	✓	81.3
DeepLabv3+	✓	82.1

(b) *test* set results

- Cityscapes dataset에서 DeepLabv3+ 평가
- Xception-65 + decoder → 77.3% → 78.79% (val)
- Image-level feature 제거 시 오히려 성능 ↑ → 79.14%
- Xception-71 (더 깊은 backbone) 사용 → 79.55% (val)
- coarse dataset 추가 학습 → test 성능 82.1% (SOTA) 달성

5. Conclusion

- 제안 모델 DeepLabv3+는
 - DeepLabv3 (Encoder) + 간단하고 효과적인 Decoder 구조를 결합한 Encoder-Decoder 방식
- Atrous Convolution을 통해 연산 자원에 맞게 해상도 조절 가능
- Xception 백본과 Atrous Separable Convolution을 활용해
 - 속도와 정확도 모두 향상
- 실험 결과:
 - PASCAL VOC 2012

- Cityscapes

두 데이터셋 모두에서 최선(state-of-the-art) 성능 달성