

DeepLabv3: Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation

📅 작성일시	@2025년 4월 3일
📍 강의 번호	BASE
📍 유형	논문리뷰
📎 자료	https://arxiv.org/abs/1802.02611
☑️ 복습	☐



1. 멀티 스케일 컨텍스트 정보(DeepLabv3)와 물체 경계 복원(Decoder)을 결합한 **DeepLabv3+** 모델을 제안했다.
2. **Atrous Convolution**으로 출력 해상도를 유연하게 조절하여 정확도와 계산량 사이의 트레이드오프를 극복했다.
3. **Depthwise Separable Convolution**(atrous separable)을 ASPP 및 Decoder에 적용해 연산량을 크게 줄였다.
4. PASCAL VOC 2012, Cityscapes 등 벤치마크에서 **최고 수준의 정확도**를 보이며 후처리 없이도 경계를 정교하게 복원했다.
5. TensorFlow 구현 코드를 공개함으로써 쉽게 재현 및 확장이 가능하도록 설계했다.

Abstract

• 연구 배경

일반적으로, 딥러닝 기반의 semantic segmentation(장면 분할) 모델들은 크게 두 가지 방식이 많이 쓰임. 첫째는 Spatial Pyramid Pooling을 활용하여 여러 스케일(다중해상도)의 맥락 정보를 포착하는 접근이고, 둘째는 Encoder-Decoder 구조로 점진적으로 세밀한 위치 정보를 복원하는 접근임

• 핵심 제안

이 논문에서 위 두 방식을 결합하여, DeepLabv3+ 라는 새로운 모델을 제안한다. DeepLabv3가 갖춘 다중 스케일 컨텍스트 추출(병렬 atrous convolution을 여러 rate로 적용하는 ASPP 기법)을 Encoder로 활용하고, 뒤에 단순하면서도 효과적인 Decoder 모듈을 붙여서 개체(객체)경계 부위를 더 정확하게 하도록 복원함.

• Atrous Separable Convolution

또한, Encoder모듈의 일부와 Decoder 모듈에 depthwise seperable convolution을 적용함으로써 계산량을 크게 줄이면서도 정확도를 향상시킴.

• 결과

제안된 모델 DeepLabv3+는 PASCAL VOC 2012와 Cityscapes라는 유명한 데이터셋에서 이전보다 높은 정확도(89.0%, 82.1% 등)를 달성하며, 복잡한 후처리(post-processing) 없이도 우수한 성능을 보임.

Introduction

- **Semantic Segmentation의 중요성과 배경**

이미지 내 각 픽셀마다 의미 있는 레이블(예: 사람, 자동차 등)을 할당하는 semantic segmentation 문제는 컴퓨터 비전에서 중요한 분야다. 최근에는 CNN 기반의 Fully Convolutional Network(FCN) 방식이 강력한 성능을 보여 다양한 후속 연구가 진행되어 왔다.

- **이전 접근 방법**

1. **Spatial Pyramid Pooling 기반(PSPNet, DeepLab 시리즈 등)**

- Atrous convolution 등으로 여러 스케일에서 특징을 추출(멀티스케일 맥락 정보를 획득)한다.
- 하지만, 해상도를 줄여서 추론하기 때문에 객체 경계 정보가 희미해지는 문제가 있었다.

2. **Encoder-Decoder 기반(U-Net, SegNet 등)**

- Encoder 부분에서 점진적으로 특징을 추출하고, Decoder 부분에서 고해상도로 되살리는 방식이다.
- 경계를 복원하는 데는 유리하지만, 넓은 맥락 정보를 적극적으로 활용하기가 상대적으로 쉽지 않다.

- **논문의 동기와 목적**

- 멀티스케일 맥락 정보를 풍부하게 처리하면서도, 경계 부분 역시 정확히 복원할 수 있는 방법을 찾는 것이 목표다.
- 이를 위해, DeepLabv3가 갖고 있는 ASPP(병렬 atrous convolution으로 멀티스케일 특징을 포착)와 Image-Level Feature pooling 기법을 **Encoder**로 쓰고, **단순한 Decoder** 모듈을 추가하여 객체 경계를 개선한다.

- **주요 기여**

1. DeepLabv3를 Encoder로 확장하고, **"simple yet effective"** Decoder를 설계해 경계를 정교하게 복원하는 구조를 제안한다.
2. Atrous convolution을 통해 출력 해상도(output stride)를 유연하게 조절할 수 있으므로, 계산 자원에 맞게 해상도를 정할 수 있다.
3. Xception 네트워크와 **depthwise separable convolution**(논문에서는 'atrous separable convolution')을 통해, 정확도 향상과 더불어 계산량 감소를 동시에 달성한다.
4. 실제 실험(PASCAL VOC 2012, Cityscapes)에서 당시 최고 수준의 정확도를 달성하며, 코드 구현(TensorFlow)도 공개하여 재현성을 높였다.

2. Related Work

FCN 기반 시맨틱 세그멘테이션

- 딥러닝 기반 **Fully Convolutional Network (FCN)** 구조가 도입된 이후, 기존의 손수 설계한 특징(Hand-crafted features)을 사용하는 방법보다 훨씬 우수한 성능을 보였다.
- FCN의 뒤를 잇는 여러 연구에서는 **다중 스케일 컨텍스트**(multi-scale context)나 확률 그래프 모델(DenseCRF 등) 등을 결합하여 정확도를 높이려 했다.

Spatial Pyramid Pooling 계열

- 대표적으로 **PSPNet**은 다양한 해상도에서의 풀링(Spatial Pyramid Pooling)을 수행해, 입력 이미지의 여러 스케일 정보를 반영한다.
- **DeepLab 시리즈**(특히 DeepLabv3)는 병렬로 atrous convolution(팽창합성곱)을 여러 가지 다른 dilation rate로 수행해 마찬가지로 다중 스케일 문맥 정보를 포착한다(ASPP 기법).
- 그러나 최종 feature가 해상도가 낮아, 객체 경계가 매끄럽게 복원되지 않는 단점이 있을 수 있다.

Encoder-Decoder 구조

- **Encoder-Decoder**는 Encoder에서 점진적으로 해상도를 낮추며 추상화된 특징을 뽑고, Decoder에서 이를 다시 고해상도로 복원해나가는 방식이다(U-Net, SegNet 등).
- 이 접근은 **객체 경계 복원** 측면에서 강점을 지닌다. 그러나 다중 스케일 문맥 정보를 활용하는 면에서는 추가적인 모듈·설계가 필요하다.

Depthwise Separable Convolution

- **Depthwise Separable Convolution**(또는 그룹 합성곱)은 일반 합성곱을 '채널별 공간 합성곱'(depthwise conv)과 '채널 결합 합성곱'(pointwise conv)으로 분해한 것으로, 연산량과 파라미터를 크게 줄일 수 있다.
- 최근 여러 모바일·실시간 처리용 네트워크(MobileNet, ShuffleNet, Xception 등)에서 활용되며, 계산 효율과 정확도의 균형을 맞추는 핵심 기법으로 주목받고 있다.

3. Proposed Method

본 논문에서는 DeepLabv3를 **Encoder**로 삼고, 단순하면서도 효과적인 **Decoder** 모듈을 붙인 'DeepLabv3+' 구조를 제안한다. 구체적으로는 다음과 같은 요소들로 구성된다.

3.1 Encoder-Decoder with Atrous Convolution

1. Atrous Convolution (팽창합성곱)

- 합성곱 과정에서 커널의 receptive field를 확장하는 기법으로, 해상도(output stride)와 필터의 필드 크기를 유연하게 조절할 수 있다.
- 이를 통해 추출되는 특징맵의 해상도를 높여 객체 경계를 개선하거나, 여러 dilation rate를 적용해 다양한 크기의 컨텍스트 정보를 얻을 수 있다.

2. DeepLabv3 as Encoder

- DeepLabv3는 **ASPP(Atrous Spatial Pyramid Pooling)**와 image-level feature를 활용해 다중 스케일 정보를 풍부하게 캡처한다.
- 논문에서는 DeepLabv3가 만들어낸 최종 특징(256 채널)을 Encoder의 출력으로 간주한다.
- 해상도는 하이퍼파라미터(예: output stride=16 또는 8)에 따라 달라지며, 계산량-정확도 간 트레이드오프를 조절 가능하다.

3. Decoder 구조

- Encoder에서 나온 특징맵을 단순히 16배나 8배로 업샘플링(bilinear upsampling)하는 대신, **Decoder** 모듈을 추가해 좀 더 정교한 복원을 수행한다.
- 구체적으로 **저해상도 Encoder 특징맵**을 한 번 4배 정도 업샘플링한 뒤, 백본(backbone)의 초기 레이어(예: Conv2 블록)에서 추출한 **저차원 특징**을 가볍게(채널 수를 48 등으로 줄인 뒤) 결합한다.
- 이후 3×3 합성곱 여러 번을 거쳐 경계를 세밀하게 복원하고, 최종적으로 다시 업샘플링해 완전한 해상도의 예측(마스크)을 만든다.

3.2 Modified Aligned Xception

- **Xception** 네트워크(Depthwise Separable Convolution 기반)를 세분화 작업(semantic segmentation)에 맞게 수정·활용한다.
- **Aligned Xception**(MSRA 팀의 버전)을 더 확장한 형태로,
 1. 맥스 풀링 대신 stride가 있는 depthwise separable conv로 대체,
 2. 레이어 중간에 Batch Normalization + ReLU를 추가,
 3. (필요하면) Atrous Convolution을 활용해 출력 해상도를 조절 등의 수정이 적용된다.
- 이를 통해 연산량을 줄이고도 정확도(성능) 향상을 노린다.

결론적으로, 이 구조는

1. DeepLabv3의 다중 스케일 맥락 정보를 Encoder로 사용,
2. Decoder로 경계를 보완,
3. Atrous Separable Convolution을 폭넓게 도입함으로써 계산 효율과 정확도를 동시에 달성하는 것을 목표로 한다.

4. Experimental Evaluation

4.1 PASCAL VOC 2012 실험

- **학습 프로토콜**
 - PASCAL VOC 2012 trainaug(10,582장)를 사용해 학습, 검증은 val(1,449장), 최종 평가는 test(1,456장)로 진행.
 - “poly” 러닝레이트 스케줄, 입력 크기 513×513 중심 크롭, 랜덤 스케일링 등 전형적인 세팅을 적용한다.
- **Decoder 유무에 따른 효과**
 - 기본적으로 DeepLabv3는 최종적으로 feature 맵을 단순 업샘플링(16배 등)하는 구조인데, 이 부분을 Decoder 모듈로 대체하면 객체 경계가 더 정확히 복원됨을 실험적으로 보여줌.
 - 예컨대, ResNet-101을 백본으로 쓴 경우, Decoder를 추가하면 약 1~2% 이상의 mIOU 개선.
- **ResNet-101 vs. Modified Xception**
 - 추가로, **네트워크 백본**을 더 강력한 “Aligned Xception”으로 바꾸고 atrous separable convolution을 폭넓게 적용하면, 같은 output stride(16, 8)에서 더 높은 정확도와 더 적은 계산량을 달성한다.
 - Xception을 사용할 경우, ImageNet 분류 정확도에서도 ResNet-101 대비 성능이 높음.
- **COCO, JFT 사전 학습**
 - MS COCO 데이터셋을 추가로 사전 학습(pretrain)하면, PASCAL VOC 2012 mIOU가 약 2% 가량 높아짐.
 - 여기에 Google의 대규모 JFT-300M 데이터셋까지 활용해 사전 학습을 더 해주면 성능이 한층 더 향상된다(최종 test set 기준 89.0% mIOU).
- **경계 근처 정확도(Trimap 실험)**
 - 객체 경계 인근 픽셀에 대해서도, Decoder 모듈이 있는 DeepLabv3+가 더 나은 성능을 보인다.
 - 즉, trimap 폭이 좁을수록(경계에 가까울수록) Decoder의 이점이 더욱 크게 드러난다.

4.2 Cityscapes 실험

- Cityscapes

- 고해상도(2048×1024) 이미지에 19개 클래스 라벨이 주어진 도시 장면 데이터셋.
- fine set(2,975장)으로 학습, val set(500장)으로 검증 후, 최종적으로 test set(1,525장)을 제출 평가한다.

- 결과

- DeepLabv3 기반에 Decoder를 붙이면 val set 성능이 1점 이상 mIOU가 상승.
 - 백본으로 수정된 Xception(더 깊은 Entry flow 사용) 등을 적용하면 test set에서 82.1% mIOU로, 당시 SOTA(최고 수준) 성능 달성.
-

5. Conclusion

- 요약

- 논문에서는 ****DeepLabv3+****라는 모델을 제안했다.
- DeepLabv3의 다중 스케일 맥락 정보를 활용하는 **Encoder**와, 경계를 좀 더 세밀하게 복원해주는 **단순·효과적인 Decoder** 구조를 결합했다.
- 출력 해상도는 atrous convolution을 통해 유연하게 조절할 수 있어, 정확도와 속도 트레이드오프에 대응이 가능하다.

- 의의

- **Atrous Separable Convolution**을 ASPP와 Decoder에 적용해 계산량을 줄이면서 성능을 유지하거나 높였다.
- PASCAL VOC 2012, Cityscapes 등에서 **기존 대비 높은 정확도를 기록**하며 후처리 없이도 우수한 결과를 보였다.
- TensorFlow 구현 코드를 공개하여 재현성 및 확장 가능성을 높였다.

- 결론

- 제안 기법은 객체 경계를 복원하면서, 멀티스케일 정보를 풍부하게 활용하는 모델이 될 수 있음을 입증했다.
- 향후 이 구조와 기법(Depthwise Separable, Atrous Convolution 등)은 다른 영상 처리/컴퓨터 비전 문제에도 활용할 수 있을 것으로 기대된다.