



DeepLabv3

이름	홍준기
대학교	동국대학교
학과	산업공학과
날짜	2025년

Abstract

DeepLabv3는 **semantic segmentation** 문제에서 **다중 스케일 객체**를 효과적으로 처리하고, **세밀한 공간 정보 보존**을 위해 Atrous Convolution (Dilated Convolution)을 재조명하여 활용한 모델임

Abstract

1. Introduction

제안 방식 및 기여

Atrous Convolution 활용 확대

다중 스케일 정보 처리 구조 설계

효과적인 학습 전략

2. Related Works

Image Pyramid

Encoder-Decoder 구조

Context Module

Spatial Pyramid Pooling

3. Methods

3.1. Dense Feature Extraction을 위한 Atrous Convolution

DeepLabv3의 접근:

3.2. Atrous Convolution을 활용한 깊이 있는 모듈 설계

Cascaded Atrous ResNet 구조

Multi-Grid 전략

3.3. ASPP (Atrous Spatial Pyramid Pooling) 모듈 개선

4. Experimental Evaluation

4.1. 데이터셋 및 평가 기준

4.2. Atrous Convolution 구조 실험

[ResNet-50 실험](#)

[ResNet-101 실험](#)

[Multi-grid 적용 실험](#)

[4.3. ASPP \(Atrous Spatial Pyramid Pooling\) 실험](#)

[4.4. ASPP \(Atrous Spatial Pyramid Pooling\) 실험](#)

[Test Set 성능 및 성능 개선 전략](#)

[4.5. 추가 실험](#)

[5. Conclusions](#)

1. Introduction

제안 방식 및 기여

Atrous Convolution 활용 확대

- 특징: 필터의 **field-of-view**를 조정하고 해상도 손실 없이 **feature map**을 추출 가능
- 적용: 기존 ImageNet 사전학습 모델에 적용할 수 있도록 downsampling layer 제거 후 atrous convolution 적용

다중 스케일 정보 처리 구조 설계

- **Cascade** 및 병렬 구조로 다양한 atrous rate를 가진 convolution layer들을 배치
- 대표 구조: **ASPP**
 - 여러 atrous rate를 병렬로 적용하여 다양한 스케일에서 context 정보를 포착
 - 이미지 전역 context를 반영하기 위해 **image-level feature** 추가
 - Atrous rate가 너무 크면 경계 효과로 1x1 convolution으로 퇴화하는 문제
 - 이를 보완하기 위해 ASPP에 **image-level feature**를 포함

효과적인 학습 전략

- **Batch Normalization**이 매우 중요한 역할을 함
- 드문 클래스나 정밀한 객체에 대해 성능을 높이기 위해 **bootstrap 학습 방법** 도입

- 별도 후처리 없이도 기존 DeepLab 버전보다 성능 향상
- PASCAL VOC 2012 데이터셋에서 **85.7% mIOU** 기록

2. Related Works

Image Pyramid

- 입력 이미지를 여러 해상도로 조정하여 각각 처리 후 결합.

Encoder-Decoder 구조

- 예시: U-Net, SegNet
- 낮은 해상도에서 context 정보 학습 → Decoder로 공간 해상도 복원.

Context Module

- DenseCRF 또는 별도 convolution 모듈을 이용해 **장거리 의존성** 반영.

Spatial Pyramid Pooling

- 여러 receptive field 크기를 가진 pooling을 통해 **다양한 스케일의 정보** 캡처

3. Methods

3.1. Dense Feature Extraction을 위한 Atrous Convolution

- **문제:** DCNN에서는 연속적인 풀링과 스트라이딩(striding)으로 인해 feature map의 해상도가 심각하게 줄어듦
- **기존 대안:** Deconvolution(Transpose Convolution) 사용하여 해상도 복원

DeepLabv3의 접근:

→ Atrous Convolution (또는 Dilated Convolution)을 사용해 해상도 손실 없이 더 **조밀한 feature map**을 추출 → 필터 내부에 'hole'을 삽입하여 receptive field를 넓힘

📌 **Atrous Rate (r)**: 필터 가중치 사이에 $r-1$ 개의 0을 삽입해 feature 추출 간격을 조절

📌 **Output Stride**: 입력 이미지 대비 출력 feature map의 해상도 비율

→ 예: Output Stride = 16이면, 마지막 다운샘플링 레이어 제거 + 이후 conv 레이어들을 atrous conv(rate=2)로 대체

3.2. Atrous Convolution을 활용한 깊이 있는 모듈 설계

Cascaded Atrous ResNet 구조

- 기존 ResNet의 마지막 블록(block4)을 복제하여 **block5~7까지 연속 배치 (cascade)**.
- 원래는 stride 2를 적용해 해상도를 계속 줄이지만, **세분화된 공간 정보를 보존하기 위해 atrous conv로 대체**.
- 출력 해상도(output stride)를 유지하면서 deeper하게 context 정보를 학습.

Multi-Grid 전략

- 각 블록 내의 3개의 conv 레이어에 **서로 다른 atrous rate** 적용
- 예: Multi Grid = (1, 2, 4), Output Stride = 16이면 → 실제 rate는 (2, 4, 8)
- 효과: 하나의 블록 안에서도 다양한 receptive field를 반영해 **다중 스케일 정보 포착** 가능

3.3. ASPP (Atrous Spatial Pyramid Pooling) 모듈 개선

- 기존 **ASPP**: 서로 다른 atrous rate (e.g., 6, 12, 18)을 가진 3x3 atrous conv를 병렬 적용하여 **다양한 스케일의 특징**을 동시에 포착.
- 개선점:
 - **Batch Normalization** 적용
 - **Image-level feature** 추가: Global Average Pooling → 1x1 conv(256채널) → Bilinear Upsample → ASPP와 concat

4. Experimental Evaluation

4.1. 데이터셋 및 평가 기준

- 데이터 셋: **ASCAL VOC 2012**: 20개 객체 클래스 + 1개 배경 클래스
- 평가 지표: **Mean Intersection-over-Union (mIoU)**

4.2. Atrous Convolution 구조 실험

ResNet-50 실험

- **Output stride**를 조절해가며 atrous conv 적용 실험
- *Output stride = 256 (즉, atrous 미적용)**인 경우 mIoU는 20.29%로 매우 낮음
- Atrous 적용 후 stride를 16 등으로 줄이면 **성능이 최대 75.18%까지 상승**, 세밀 정보가 복원됨

ResNet-101 실험

- ResNet-101을 사용하면 더 깊은 구조에서 성능 개선이 있음.
- 다만 블록이 너무 많아지면 성능 향상 폭은 줄어들

Multi-grid 적용 실험

- **block4~block7**에 Multi Grid = (1, 2, 1) 적용 → **성능 향상** 관찰.
- 너무 큰 rate 적용 (예: 2,2,2)은 오히려 효과 없음

다중 스케일 입력 + 좌우 반전 추가로 추가 성능 향상

4.3. ASPP (Atrous Spatial Pyramid Pooling) 실험

실험 요소	결과
ASPP 개선	BatchNorm 추가, Image-level feature 추가
Multi-grid + ASPP 조합	(1,2,4) → 최상의 성능 (77.21%)
추가 rate=24 브랜치 추가	오히려 성능 0.12% 감소
추론 시 Output stride = 8	성능 1.3% 향상
다중 스케일 + 좌우 반전 추가	추가로 1.26% 향상
최종 ASPP 모델 성능 (val)	79.77% (ASPP 기반이 cascade보다 더 좋음)

4.4. ASPP (Atrous Spatial Pyramid Pooling) 실험

Test Set 성능 및 성능 개선 전략

- Trainval 세트를 사용해 추가 파인튜닝 후 평가
- 출력 stride=8 유지, BatchNorm 파라미터는 고정
- Bootstrapping 전략:
 - 어려운 클래스(자전거, 의자, 테이블 등) 포함 이미지 중복 학습
 - 간단하지만 효과적인 rare class 성능 개선 기법

▶ 최종적으로 DenseCRF 없이도 85.7% mIoU 달성

4.5. 추가 실험

- MS-COCO 사전 학습 모델 활용 → 성능 82.7% (val)
- JFT-300M 사전 학습 모델로도 추가 실험 (성능 더 향상됨, 구체 수치는 일부 생략됨)

5. Conclusions

- DeepLabv3 모델은 Atrous Convolution을 이용해 조밀한 feature map을 추출하고, 장거리 문맥 정보를 효과적으로 포착함

- **다중 스케일 정보를 반영하기 위해**
 - **Cascaded Atrous 모듈**: atrous rate를 점진적으로 증가시키며 구성
 - **ASPP (Atrous Spatial Pyramid Pooling)**: 여러 atrous rate와 **image-level feature**를 병합하여 다양한 receptive field를 구성
- **성능 향상:**
 - 이전 DeepLab 버전 대비 크게 개선됨
 - PASCAL VOC 2012 기준으로 **SOTA에 근접하는 성능을 보임**