

1. 서론 (Introduction)

배경: GAN, VAE, Autoregressive 모델 등 다양한 생성 모델들이 발전하면서 고품질 샘플 생성이 가능해짐. 최근엔 score matching과 energy-based 모델도 주목받음.

기여 요약:

확산 모델(Diffusion Probabilistic Models)의 샘플 품질이 기존 모델 못지않다는 것을 입증.

역확산 과정이 Langevin Dynamics와 Denoising Score Matching과 연결됨.

새로운 가중된 변분 바운드를 제안해 학습 효율 향상.

생성 과정은 **점진적 손실 압축 (progressive lossy compression)**으로 해석될 수 있음.

2. 배경 이론 (Background)

확산 모델은 Markov 체인 기반 잠재 변수 모델.

정방향 과정 (forward process): 데이터에 점진적으로 Gaussian 노이즈를 추가 → 정보 소멸.

역방향 과정 (reverse process): 정방향 과정을 되돌려 노이즈를 제거하며 샘플 생성.

학습: 변분 추론을 통해 역과정의 조건부 확률을 학습함.

특징: 각 시간 단계에서 샘플링이 가능하고, training이 효율적이며, 단순한 파라미터 구조 사용.

3. 확산 모델과 Denoising Autoencoders의 연결 (Diffusion models and DAEs)

3.1 정방향 과정과 LT 항

β_t 는 일정한 값으로 고정하여 구현 단순화.

LT는 학습 중 상수로 간주 가능.

3.2 역과정과 $L_t: T-1$ 항

평균 μ_θ 는 forward posterior의 평균 $\hat{\mu}_t$ 를 예측하도록 학습하거나,

노이즈 ε 를 직접 예측하는 방식(ε -prediction)을 제안.

ε 예측 방식은 Langevin dynamics와 구조적으로 유사하고, denoising score matching과도 연결됨.

수식적으로 ε 예측 방식이 변분 바운드로 해석될 수 있음 → 샘플 품질 향상.

3.3 L_0 항 (데이터 복원)

데이터는 $[-1, 1]$ 로 스케일된 정수값으로 간주하고, 독립적인 디코더를 통해 복원.

마지막 확률은 Gaussian을 적분하여 discrete likelihood 계산.

3.4 단순화된 학습 목적함수

기존 변분 바운드 대신, 단순한 MSE 기반 목적함수 사용:

$$L_{simple}(\theta) = E_{t, x_0, \varepsilon} [||\varepsilon - \varepsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{(1 - \bar{\alpha}_t)}\varepsilon, t)||^2]$$

간단하면서도 고품질 샘플을 생성할 수 있음.

작은 t 에 대한 손실을 자연스럽게 낮춰, 어려운 노이즈 제거에 집중하게 함.

4. 실험 (Experiments)

4.1 샘플 품질

CIFAR-10: IS 9.46, FID 3.17 → 당시 최고 수준.

LSUN Church/Bedroom: ProgressiveGAN 수준의 고품질 샘플 생성.

4.2 역과정 파라미터와 학습 목표 비교

ε 예측 방식이 $\hat{\mu}$ 예측보다 샘플 품질이 더 뛰어남.

특히 단순화된 목적함수 L_{simple} 와 조합할 때 효과적.

역과정 분산을 학습시키는 방식은 훈련이 불안정하고 성능이 낮았음.

4.3 점진적 압축 (Progressive Coding)

확산 모델의 생성 과정을 압축 해석으로 이해할 수 있음.

각 단계에서 생성한 latent는 점진적으로 원본 정보를 복원함.

초기 단계는 큰 특징(예: 윤곽)을 복원하고, 마지막 단계는 세부 특징을 복원.

Rate-Distortion 분석:

많은 비트가 인간이 인지할 수 없는 세부사항을 묘사하는 데 사용됨.

이는 좋은 손실 압축기 inductive bias를 가지고 있음을 시사.

4.4 인터플레이션

두 이미지 사이의 latent를 선형 보간해 자연스러운 변화를 생성.

포즈, 표정, 배경 등 고수준 특징은 자연스럽게 변하지만, 안경 등은 유지됨.

5. 관련 연구 (Related Work)

확산 모델은 Flow나 VAE처럼 잠재 변수 모델 구조를 따르지만,

prior x_T 가 정보량이 거의 0에 수렴함.

학습은 variational inference 기반, 샘플링은 Langevin dynamics처럼 작동.

score matching, energy-based 모델과 밀접한 관계.

autoregressive 모델과도 연관: 일반적인 autoregressive decoding의 일반화 형태로 해석 가능.

6. 결론 및 사회적 영향 (Conclusion & Broader Impact)

결론: 확산 모델은 고품질 샘플을 생성하며, 다양한 생성 모델 개념들과 이론적으로 연결됨.

응용 가능성:

이미지 생성 외에도 압축, 표현 학습, 자율 학습 등에 사용 가능.

예술/사진/음악 등의 창작 분야에도 적용 가능.

위험 요소:

deepfake처럼 악용 가능성 있음.

데이터셋 편향이 강화될 우려 존재.