



Diffusion Model

Denoising Diffusion Probabilistic Models

저자 : Jonathan Ho, Ajay Jain, Pieter Abbeel

Denoising Diffusion Probabilistic Models

We present high quality image synthesis results using diffusion probabilistic models, a class of latent variable models inspired by considerations from nonequilibrium thermodynamics. Our

 <https://arxiv.org/abs/2006.11239>



1. Introduction

- 기존의 이미지 생성 모델(GAN, VAE, Autoregressive models 등)의 한계를 극복할 수 있는 새로운 접근법으로 Diffusion Probabilistic Models (DPMs)가 등장
- DPM은 Markov chain을 기반으로 데이터를 점진적으로 파괴하고, 이를 복원하는 구조를 가짐
- 특히 이 논문은 DDPM (Denoising Diffusion Probabilistic Model)이라는 형태를 제시하고, 이미지 생성에서 경쟁력 있는 품질을 입증함
- 핵심 기여
 - Gaussian 노이즈를 점진적으로 추가하는 forward process 정의
 - 그 역방향을 neural network로 학습하여 샘플 생성
 - denoising score matching, Langevin dynamics, VAE와의 연결 구조 수학적으로 해석




Figure 1: Generated samples on CelebA-HQ 256×256 (left) and unconditional CIFAR10 (right)

→ CelebA-HQ, CIFAR-10 등에서 생성된 고품질 샘플 이미지 예시

2. Background

- 확률적 생성 모델의 관점에서 DPM은 latent variable 모델로 구성됨
- Forward process

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) := \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}), \quad q(\mathbf{x}_t | \mathbf{x}_{t-1}) := \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

- Markov chain으로 data에 noise를 추가하는 과정
- Noise를 추가할 때 variance schedule $\beta_1, \dots, \beta_T$ 로 scaling을 한 후 더함
- Reverse process

$$p_\theta(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t), \quad p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) := \mathcal{N}(\mathbf{x}_{t-1}; \mu_\theta(\mathbf{x}_t, t), \Sigma_\theta(\mathbf{x}_t, t))$$

- Reverse process로 가우시안 노이즈를 사용하는 이유는 1994년 논문에 forward process가 가우시안이면 reverse process도 가우시안으로 쓰면 된다는 증명이 있다고 함
- 여기서 우리가 해야 할 것은 $\mathbf{x}_t$ 를 보고 $\mathbf{x}_{t-1}$ 의 평균 μ_θ 과 분산 Σ_θ 을 예측해내는 것

⇒ 직관적으로 보면, forward는 점점 노이즈를 추가하여 데이터를 파괴하고, reverse는 이를 되돌리는 이미지 복원 네트워크

- Loss Function L

- Diffusion 모델의 목적은 노이즈가 추가된 이미지 가 주어졌을 때, 점진적으로 노이즈를 제거해 원본 이미지 x_0 을 복원하는 것
- 즉, x_{t-1} 를 예측할 수 있다면 도 예측 가능
- 모델은 negative log-likelihood 을 최소화하는 방향으로 학습됨. 직접 계산이 어렵기 때문에 다음과 같은 Evidence Lower Bound (ELBO)를 최적화

$$\mathbb{E}[-\log p_{\theta}(\mathbf{x}_0)] \leq \mathbb{E}_q \left[-\log \frac{p_{\theta}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] = \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t>1} \log \frac{p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] =: L \quad (3)$$

- ELBO는 실제 데이터 분포 가 너무 복잡해 직접 접근하기 어려울 때, 접근 가능한 분포를 통해 대체하고 두 분포 간의 차이(KL divergence)를 최소화하는 방식임
- 결국, ELBO는 다음 세 가지 항의 합으로 정리

$$\mathbb{E}_q \left[\underbrace{D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p(\mathbf{x}_T))}_{L_T} + \sum_{t>1} \underbrace{D_{\text{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \parallel p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t))}_{L_{t-1}} - \log p_{\theta}(\mathbf{x}_0|\mathbf{x}_1) \right] \quad (5)$$

3. Diffusion models and denoising autoencoders

3.1 Forward process and L_T

- Forward process는 학습 대상은 아니지만, 노이즈 분산 계수 β_t 는 학습 가능
- 그러나 DDPM에서는 고정된 noise schedule로도 충분한 성능 확보 가능
 - 특히 isotropic Gaussian 분포 (모든 방향으로 균일한 분산)를 확보할 수 있음
- 따라서 L_T 는 고정된 prior 분포와의 KL divergence 항이며, 학습에서 무시 가능한 상수 항

3.2 Reverse process and $L_{(1:T-1)}$

Denoising Process Loss L_{T-1}

$$L_{t-1} = D_{KL} (q(x_{t-1} | x_t, x_0) \| p_{\theta}(x_{t-1} | x_t))$$

- $q(x_{t-1} | x_t, x_0) = N(x_{t-1}; \tilde{\mu}(x_t, x_0), \tilde{\beta}_t \mathbf{I})$
- $p_{\theta}(x_{t-1} | x_t) = \mathcal{N}(x_{t-1}; \mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t))$

$$\mu_{\theta}(\mathbf{x}_t, t) = \tilde{\mu}_t \left(\mathbf{x}_t, \frac{1}{\sqrt{\alpha_t}} (\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_{\theta}(\mathbf{x}_t)) \right) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) \quad (11)$$

- 역방향 확률 모델의 평균을 직접 예측하는 대신,
- 노이즈 ϵ 를 예측하고, 이를 통해 평균 μ_{θ} 를 재구성
- 왜? → 이미지 전체 패턴을 예측하는 것보다 노이즈만 예측하는 게 학습 안정성과 효율성에서 유리

3.3 Data scaling, reverse process decoder, and L_0

- $x_1 \rightarrow x_0, x_1 \rightarrow x_0$ 에서 discrete 픽셀 이미지를 복원해야 하므로 VAE-style decoder 사용
- log-likelihood 기반 손실로 계산

$$L_0 = -\log p_{\theta}(x_0 | x_1)$$

$$p_{\theta}(\mathbf{x}_0 | \mathbf{x}_1) = \prod_{i=1}^D \int_{\delta_{-}(x_0^i)}^{\delta_{+}(x_0^i)} \mathcal{N}(x; \mu_{\theta}^i(\mathbf{x}_1, 1), \sigma_1^2) dx$$

$$\delta_{+}(x) = \begin{cases} \infty & \text{if } x = 1 \\ x + \frac{1}{255} & \text{if } x < 1 \end{cases} \quad \delta_{-}(x) = \begin{cases} -\infty & \text{if } x = -1 \\ x - \frac{1}{255} & \text{if } x > -1 \end{cases}$$

3.4 Simplified training objective

- 복잡한 KL 기반 ELBO 대신, 간단한 MSE 기반 손실 함수를 사용
- 시간 단계 t 에 상관없이 모든 스텝을 고르게 학습하도록 유도함

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\left\| \epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right\|^2 \right] \quad (14)$$

- 과거에는 작은 t 에 더 큰 가중치를 부여했지만, DDPM에서는 가중치 제거 → 학습 균형 향상
- 결과적으로 고난이도 노이즈 제거 능력 향상 → 전체 성능 향상

4. Experiments

4.1 Sample quality

- 실험 데이터셋: CIFAR10, CelebA-HQ 등
- 평가 지표:
 - Inception Score (IS): 이미지의 다양성과 품질을 종합적으로 평가
 - FID Score (Fréchet Inception Distance): 생성 이미지와 실제 이미지 간의 분포 차이 측정
 - Negative Log Likelihood (NLL): 모델이 데이터를 얼마나 잘 설명하는지 측정
- DDPM은 Unconditional 모델로, 추가 조건 없이 pure image generation 수행
 - 그림에도 불구하고 FID 기준으로 기존 모델보다 우수한 성능을 보임
 - 단순한 loss function (MSE 기반)을 사용함에도 불구하고 복잡한 loss를 쓰는 모델보다 더 좋은 FID 성과



Figure 3: LSUN Church samples. FID=7.89




Figure 4: LSUN Bedroom samples. FID=4.90

4.2 Reverse process parameterization and training objective ablation

- 역방향 확률 모델에서의 두 가지 parameterization 방식 실험:
 1. u_0 : 평균 직접 예측 방식
 2. ϵ_θ : 노이즈 직접 예측 방식 (reparameterization)
- 결과
 - ϵ_θ 예측 방식이 더 높은 sample quality 보임
 - 단순화된 objective (MSE 기반 loss)를 사용할수록 성능 차이는 더 커짐

Table 2: Unconditional CIFAR10 reverse process parameterization and training objective ablation. Blank entries were unstable to train and generated poor samples with out-of-range scores.

Objective	IS	FID
$\tilde{\mu}$ prediction (baseline)		
L , learned diagonal Σ	7.28 ± 0.10	23.69
L , fixed isotropic Σ	8.06 ± 0.09	13.22
$\ \tilde{\mu} - \tilde{\mu}_\theta\ ^2$	—	—
ϵ prediction (ours)		
L , learned diagonal Σ	—	—
L , fixed isotropic Σ	7.67 ± 0.13	13.51
$\ \tilde{\epsilon} - \epsilon_\theta\ ^2 (L_{\text{simple}})$	9.46 ± 0.11	3.17

4.3 Progressive coding

- Diffusion 과정을 압축 관점에서 해석할 수 있음: 점진적으로 정보를 복원하는 구조

- 각 timestep은 점점 더 세부적인 정보를 추가하는 역할을 함
 - 초기 단계는 전반적인 형태 (전역 구조),
 - 후반 단계는 세밀한 디테일 (텍스처, 색감 등)을 담당
- 실험적으로 각 step에서의 RMSE(왜곡) 와 정보량 (비트)를 측정해 시각화함
 - 대부분의 정보는 마지막 단계에 몰려 있음




Figure 6: Unconditional CIFAR10 progressive generation ($\hat{x}_0$ over time, from left to right). Extended samples and sample quality metrics over time in the appendix (Figs. 10 and 14).



Figure 7: When conditioned on the same latent, CelebA-HQ 256×256 samples share high-level attributes. Bottom-right quadrants are x_t , and other quadrants are samples from $p_\theta(x_0|x_t)$.

4.4 Interpolation

- latent 공간에서 두 이미지의 노이즈 상태를 선형 보간해 생성하는 실험
- 결과: 두 이미지 간의 자연스럽게 부드러운 전이가 가능함



Figure 8: Interpolations of CelebA-HQ 256x256 images with 500 timesteps of diffusion.

5. Related Work

본 논문에서는 DDPM이 기존 생성 모델들과 어떤 관계를 가지는지 이론적으로 비교 분석함

- Autoregressive Models
 - 이미지 생성을 픽셀 단위로 순차적으로 수행 (예: PixelCNN)
 - 장점: 높은 샘플 품질
 - 단점: 느린 샘플링 속도, 복잡한 종속성 구조
- GANs
 - 경쟁 학습을 통해 고품질 샘플 생성
 - 단점: mode collapse, 학습 불안정성
- VAEs
 - 확률적 latent 공간 기반 생성
 - 단점: 생성 이미지가 blurry해지는 경향
- Score Matching & Langevin Dynamics
 - 본 논문은 denoising score matching과의 연결을 수식적으로 정리하며, diffusion 모델이 이론적으로 유도될 수 있음을 보임

⇒ DDPM은 이러한 기존 방식들의 장점을 유지하면서도 단점을 줄인 새로운 패러다임으로 해석 가능

6. Conclusion

- DDPM은 diffusion 기반 생성 모델로, 기존의 복잡한 학습 objective를 단순한 노이즈 예측(MSE) 방식으로 대체함

- GAN이나 autoregressive 모델보다 학습 안정성과 샘플 품질(FID 등)에서 우수한 성능을 보임
- 다양한 scale의 노이즈를 제거해 원본을 복원하는 구조로 Unconditional Image Generation에서도 탁월함
- 이후 DDIM, Latent Diffusion 등 많은 후속 연구에 기반이 되었으며, 생성 모델의 새로운 패러다임을 제시함

7. Broader Impact

- 본 연구는 생성 모델의 진보라는 측면에서 큰 의미를 가지지만, 동시에 잠재적인 윤리적 문제도 함께 내포함
- 우려되는 영향
 - 사실과 다른 이미지 생성을 통한 misinformation
 - deepfake와 같은 악용 사례로 이어질 가능성
- 긍정적 활용 가능성
 - 예술, 콘텐츠 제작, 압축 및 복원 기술 향상
 - 데이터 부족 문제를 해결하기 위한 synthetic data generation 등 다양한 응용 분야 존재

⇒ 따라서 향후 diffusion 모델의 활용에는 공정성, 프라이버시, 사회적 책임 등의 고려가 필수적임