

Denoising Diffusion Probabilistic Models

0. Abstract

- 고품질 이미지 생성을 위한 새로운 생성 모델 제안
- 확률론적 노이즈 추가 및 제거 과정을 통해 학습
- 기존 likelihood 기반 모델과 GAN 기반 모델의 장점 결합
- CIFAR10 등에서 우수한 샘플 품질 달성

1. Introduction

- 기존의 생성 모델들은 학습 안정성 또는 샘플 품질 측면에서 한계를 가짐
- DDPM은 노이즈 제거 과정을 학습함으로써 고품질 이미지 생성 가능
- 확률적 과정 기반의 생성 메커니즘을 소개하고 이론적으로 뒷받침
- 복잡한 사후 분포 없이 명확한 likelihood 목표로 학습

2. Background

- 확률적 생성 모델의 일반 개념 소개
- Variational autoencoders VAEs와 score matching과의 관계 설명
- 확률적 그래픽 모델과 마르코프 체인 개념이 기반
- 이미지 생성 시 사용되는 다양한 likelihood 기반 접근 방식 설명

3. Diffusion models and denoising autoencoders

서론

- DDPM은 데이터를 점진적으로 노이즈화하고 이를 복원하는 과정을 학습
- 마르코프 체인을 통해 점진적으로 가우시안 노이즈를 추가
- 학습 과정은 노이즈를 제거하며 원본을 복원하는 방향으로 진행

3.1 Forward process and L_T

- 정방향 과정은 데이터를 점진적으로 가우시안 노이즈화
- 각 단계는 마르코프 체인으로 구성되며 수학적으로 정확히 모델링
- 마지막 단계에서는 거의 완전한 노이즈가 된 상태로 변환됨
- L_T 는 마지막 단계에서 샘플링의 차이를 최소화하는 loss 항

3.2 Reverse process and $L_{1:T-1}$

- 역방향 과정은 노이즈로부터 점차 원본 이미지를 복원
- 확률적 역 마르코프 체인으로 모델링
- $L_{1:T-1}$ 은 각 단계의 복원 오류를 최소화하기 위한 loss
- 복원 과정은 단순한 조건부 가우시안 분포를 사용

3.3 Data scaling, reverse process decoder, and L_0

- 역과정에서 decoder와 decoder loss인 L_0 도입
- 데이터의 정규화 및 스케일 조정 필요
- 최종 loss는 $L_0 + L_{1:T-1} + L_T$ 로 구성

3.4 Simplified training objective

- 실제 학습에서는 loss를 단순화하여 효율적인 학습 가능
- 노이즈 예측 기반 objective로 변형하여 계산 효율 증가
- 이 접근 방식은 denoising score matching과 유사

4. Experiments

서론

- 다양한 생성 품질 실험을 통해 DDPM의 성능 검증
- 샘플 퀄리티 측정과 함께 다양한 ablation을 수행

4.1 Sample quality

- CIFAR10 LSUN 등에서 높은 FID 점수 기록
- GAN 수준의 샘플 품질 달성

- 학습된 모델로부터의 샘플은 다양하고 사실적인 특징 보임

4.2 Reverse process parameterization and training ablation

- 역방향 과정의 다양한 파라미터화 실험
- 시간별 가중치 설정과 모델 구조가 성능에 미치는 영향 분석

4.3 Progressive coding

- 점진적인 생성 구조를 통해 고해상도 이미지 생성 가능
- 각 단계의 생성물이 이전 단계의 조건이 됨
- 생성 과정이 안정적이고 직관적으로 해석 가능

4.4 Interpolation

- 노이즈 공간에서 두 샘플 사이의 선형 보간 수행
- 자연스럽게 의미 있는 중간 이미지 생성 가능
- 잠재 공간의 연속성과 표현력 입증

5. Related Work

- GAN VAE Flow-based 모델 등 기존 생성 모델과의 비교
- Score matching과 noise-conditional generative 모델과의 연관성
- DDPM은 학습 안정성과 샘플 품질을 모두 달성하는 새로운 계열로 분류됨

6. Conclusion

- DDPM은 간단한 구조로 고품질 생성이 가능한 확률적 생성 모델
- noise prediction 기반 학습 objective가 매우 효과적임을 입증
- 다양한 이미지 생성 작업에서 경쟁력 있는 성능을 보임
- 미래 연구는 고속 샘플링 고해상도 확장 등 방향으로 나아갈 수 있음