

DIFFUSION 논문 리뷰

1. 연구 배경 및 동기

이미지 생성 분야에서는 오랫동안 **GAN(Generative Adversarial Networks)**이 주류를 이뤄왔지만, 다음과 같은 문제점이 있었다:

- 훈련이 불안정하고 민감함 (모델 붕괴, mode collapse 등)
- 학습 제어가 어렵고, 다양성/퀄리티 간 trade-off 존재

이에 따라 **대체 가능한 안정적인 생성 모델로 Diffusion 모델**이 주목받게 되었으며, 이 논문은 **"노이즈를 점진적으로 제거하면서 이미지를 생성하는 새로운 확률적 모델"**을 제안한다.

2. 논문 주요 기여

1. 확률적 이미지 생성 모델로서의 Diffusion 모델 정식화
2. **Denoising autoencoder 기반 훈련 방식** 제안
3. GAN과 유사하거나 그 이상의 이미지 생성 품질 달성
4. 후속 연구 (Improved DDPM, Imagen, Stable Diffusion 등)의 기초가 됨

3. 핵심 아이디어: 정방향 & 역방향 확률 과정

Forward Process (노이즈 추가)

- 입력 이미지 x_0 에 **T step**에 걸쳐 점점 더 많은 노이즈를 추가하여 x_T 에 도달
- 각 단계는 아래 식에 따라 정의됨:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t\mathbf{I})$$

- 결국 x_T 는 거의 정규분포와 유사한 순수한 노이즈가 됨

Reverse Process (노이즈 제거)

- 생성 과정은 반대로 노이즈 $x_T \rightarrow$ 원본 이미지 x_0 로 복원
- 이상적으로는 각 단계의 역확률 $p_\theta(x_{t-1} | x_t)$ 를 모델링

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

- 실제 모델에서는 μ_θ 또는 노이즈 ϵ_θ 를 예측하는 구조로 바뀜

4. 모델 아키텍처

✓ 네트워크 구조

- 보통 **U-Net 기반** 구조 사용 (이미지 처리에 강한 구조)
- 입력: 노이즈 이미지 x_t + timestep (포지셔널 인코딩)
- 출력: 예측 노이즈 ϵ_θ 또는 역과정 평균 μ_θ

이후 Denoising Diffusion Implicit Models (DDIM), Latent Diffusion (LDM), Stable Diffusion 등에서 U-Net을 기본으로 채택

5. 훈련 방식

학습 목표

Diffusion 모델의 훈련은 실제로는 매우 간단함. 목표는 다음과 같음:

$$\min_{\theta} \mathbb{E}_{x_0, t, \epsilon \sim \mathcal{N}(0,1)} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$$

- x_t 는 x_0 에 t step만큼 노이즈를 추가한 것
- 모델은 이로부터 원래의 노이즈 ϵ 를 예측함

이 방식은 **Denoising Autoencoder의 일반화 버전**으로 볼 수 있다.

6. 실험 및 성능

- CIFAR-10, LSUN, ImageNet 등에서 비교 실험
- FID score 기준으로 GAN과 비교해 경쟁력 있는 성능 달성
- 생성된 이미지의 다양성도 우수함

모델	Dataset	FID ↓
BigGAN	ImageNet	4.3
DDPM	ImageNet	3.17

7. 주요 발전 방향 및 후속 논문

1. **Improved DDPM** (Nichol & Dhariwal, 2021)
→ 학습 스케줄 개선, 성능 향상
2. **DDIM** (Song et al., 2020)
→ deterministic한 역과정으로 더 빠른 생성 가능
3. **Latent Diffusion (LDM)** (Rombach et al., 2022)
→ 이미지 대신 **잠재 공간(latent space)**에서 diffusion 수행 → 속도/성능 균형
4. **Stable Diffusion**
→ LDM + 텍스트 조건 추가 → 고품질 텍스트-이미지 생성 가능
5. **Imagen** (Google)
→ 고성능 text-to-image diffusion 모델

8. 한계점

한계	설명
생성 속도 느림	수백~수천 단계 반복 연산 필요
계산 자원 소모 큼	GPU 메모리, 시간 많이 필요
조건부 생성 복잡	text-to-image 등에서 조건 반영이 어렵거나 불안정할 수 있음
노이즈 스케줄링 민감	β_t 스케줄에 따라 품질 크게 달라짐

9. 결론

DDPM은 간단한 확률적 원리에 기반한 강력한 이미지 생성 모델로, 학습 안정성, 다양성, 정제된 품질 등에서 GAN보다 우수한 특성을 보인다.

이 논문은 이후의 diffusion 모델 생태계(Stable Diffusion, Imagen 등)를 여는 핵심 기초가 되었으며, 최근에는 텍스트, 오디오, 비디오 생성 등 다양한 분야로 확장되고 있다.