

DiffusionModel: Denoising Diffusion Probabilistic Models

📅 작성일시	@2025년 4월 9일
📁 강의 번호	BASE
📁 유형	논문리뷰
📎 자료	https://arxiv.org/pdf/2006.11239
☑️ 복습	☐



• Diffusion 기반의 새로운 확률 모델 제안

- 데이터를 점진적으로 노이즈화(Forward)하고 이를 역으로 복구(Reverse)하는 구조의 **마코프 체인**을 통해 이미지를 생성하는 접근을 공식화했다.
- Reverse 과정은 변분 추론으로 학습되어, 분포를 고품질로 샘플링할 수 있게 된다.

• Denoising Score Matching과 Langevin Dynamics의 연결

- Reverse 프로세스를 노이즈 예측(ϵ -prediction) 형태로 파라미터화하면, 여러 단계의 Denoising Score Matching을 수행하는 것과 동가임을 보였다.
- 샘플링은 마치 Langevin Dynamics로 점진적으로 노이즈를 제거하는 과정과 유사해진다.

• 간단화된 학습 목표(Lsimple) 활용

- 진짜 변분 경계를 그대로 쓰기보다, 이를 ****단순화한 오차 항($\|\epsilon - \epsilon_\theta\|^2$)****을 이용해 학습해도 오히려 더 나은 이미지 품질을 얻는 결과를 보였다.
- 실험적으로 단순화된 목표가 SOTA(당시 최고 수준)의 결과로 이어졌다.

• 고화질 이미지 생성 성능 달성

- **CIFAR10**에서 Inception Score 9.46, FID 3.17을 기록하며, 많은 경쟁 모델을 상회하는 무조건부 (unconditional) 생성 성능을 확보했다.
- **LSUN** 등 고해상도(256×256) 이미지에서도 ProgressiveGAN 등에 버금가는 품질을 시연했다.

• 다양한 측면에서의 의미와 확장 가능성

- 모델 샘플링이 **autoregressive 모델**이나 **lossy compression**과도 밀접히 연관됨을 보였고, Energy-based Model과의 관계도 강조된다.
- 향후 이미지 외에 다른 데이터(오디오·영상·텍스트)나, 다른 생성 모델과의 결합, 부분적으로만 노이즈 제거를 하는 보간(interpolation) 등 폭넓은 확장 가능성을 제시한다.

Abstract

1. 새로운 확률적 모델

- “Diffusion Probabilistic Model”이라는 형태의 생성 모델을 제안한다.
- 데이터를 점차적으로 노이즈로 바꾸는 과정(Forward)과, 이를 역으로 복원하는 과정(Reverse)을 정의한다.

2. Denoising Score Matching과의 연결

- 제안된 모델을 학습하는 과정이 **Denoising Score Matching + Langevin Dynamics**와 밀접하게 연결됨을 보인다.
- 이렇게 해석하면, 여러 단계(스케일)의 노이즈를 한꺼번에 제거하는 과정으로 볼 수 있다.

3. 고품질 이미지 생성 성능

- CIFAR10에서 Inception Score 9.46, FID 3.17을 달성하는 등, 당시 기준으로 매우 좋은 성능을 보인다.
- 256×256 해상도의 LSUN 데이터셋에서도 다른 강력한 모델들과 견줄 만한 이미지를 생성한다.

4. 추가 의의

- 이 모델은 진행형(Progressive) 손실 압축 방식으로 해석 가능하며, 기존의 오토리그레시브(autoregressive) 방식과도 관련됨을 제시한다.
- 코드가 공개되어 있고, 추후 연구에 유용할 것으로 기대한다.

Introduction

1. 배경

- 최근 딥러닝 기반 생성 모델(GAN, Autoregressive, Flow, VAE 등)이 이미지를 비롯한 복잡한 데이터 분포를 잘 학습하게 됨.
- 하지만, 과거의 Diffusion 모델은 제대로 된 고품질 생성 사례가 많지 않았음.

2. Diffusion 모델의 아이디어

- **Forward Process:** 데이터에 점진적으로 노이즈를 추가해가면서 정보를 '제거'한다.
- **Reverse Process:** 위 과정을 거꾸로 해서 노이즈를 제거, 다시 데이터로 복원한다. 이를 신경망으로 학습해 샘플을 생성한다.

3. 연구 목표와 기여

- 실제로 Diffusion 모델이 높은 화질의 샘플을 만들 수 있음을 실험적으로 보여준다.
- **Denoising Score Matching**과 **Langevin Dynamics** 개념을 Diffusion 모델에 접목해, 모델 학습과 샘플 생성 과정을 단순하고도 효과적으로 설계한다.
- 결과적으로, 이전 세대의 모델들과 비교해서 훌륭한 생성 품질을 달성했다.

4. 결과 요약

- CIFAR10, LSUN, CelebA-HQ 등 다양한 이미지 데이터셋에서 비교적 단순한 방식으로도 우수한 샘플 품질을 얻는다.
- 또한, 로그우도(log-likelihood) 계산이나 마코프 체인 관점의 해석이 명확해, 추후 다양한 활용 가능성을 가진다.

Background

1. Diffusion Model 개념

- 일반적으로, 확률적 생성 모델은 데이터 x_0 를 **잠재 변수(latent variable)** $x_1, x_2, \dots$ 등을 통해 표현한다.
- 논문에서 제안된 **Diffusion Model**은, 데이터에 서서히 노이즈를 첨가하는 **Forward Process**(q)와, 이를 역으로 복구하는 **Reverse Process**(p_θ)의 곱으로 확률분포를 구성한다.
- Forward Process는 파라미터를 학습하지 않고, 미리 정의한 방법(점진적으로 노이즈 추가)으로 $x_0 \rightarrow x_1 \rightarrow \dots \rightarrow x_T$ 를 만든다.

2. Forward & Reverse의 구조

- **Forward (q):** x_0 에 작은 노이즈를 계속 더해, 결국엔 무질서(거의 순수 노이즈)에 가까운 상태 x_T 로 만든다.
- **Reverse (p_θ):** x_T 에서부터 거꾸로 진행해, 차례대로 노이즈를 제거함으로써 x_0 와 유사한 샘플을 복원한다.
- 이 Reverse 과정을 인공신경망(θ 파라미터)으로 학습해서, 최종적으로 샘플링할 때 x_T 에서 시작해 x_0 방향으로 진행하게 된다.

3. 변분 추론 (Variational Inference) 사용

- 데이터의 우도(확률)를 최대화하는 대신, 변분 추론으로 bound(상한)을 최소화하는 접근을 쓴다.
- Forward가 정해져 있으므로, Reverse를 잘 맞추면, 실제 데이터 분포에 가깝게 샘플링할 수 있다.

Diffusion models and denoising autoencoders

1. Reverse Process와 Denoising

- Reverse Process는 x_t 에서 x_{t-1} 을 추론해야 하므로, 네트워크가 '노이즈를 제거하는(denoising)' 기능을 배운다고 볼 수 있다.
- 여기서 단순히 평균(μ)을 예측하는 대신, ' **ϵ -예측 파라미터화(ϵ -prediction)**' 방식을 사용하면, Denoising Score Matching과 밀접하게 연결된다는 점을 발견했다.

2. Denoising Score Matching과의 유사성

- Score Matching**은, 데이터를 약간씩 오염시킨 뒤, 그 노이즈를 제거하는 방향(스코어)을 학습한다.
- Diffusion Model에서 Reverse 과정을 ϵ -예측으로 학습하면, 다중 스케일(여러 시간단계)에 걸쳐 수행되는 Denoising Score Matching과 사실상 동일한 목적 함수를 갖게 된다.

3. Langevin Dynamics 해석

- 샘플 생성 과정(Reverse)에서, 한 스텝씩 "노이즈 제거 + 랜덤 샘플링"을 반복하는 방식이, 통계물리학에서 말하는 **Langevin Dynamics**와 닮았다.
- 즉, 마치 확률적 경사 하강(gradient-based)으로 데이터 분포를 향해 천천히 이동하듯, 노이즈를 줄이는 과정을 거친다.

4. Training Objective 간소화

- 실제 변분 경계(VI objective) 대신, **Denoising Score Matching**에 더욱 가까운 단순화된 목표 함수(**Lsimple**)를 사용해도, 실제로는 더 좋은 생성 품질을 얻는다.
- 이는 구체적으로 $\|\epsilon - \epsilon_\theta(\cdot)\|^2$ 같은 형태로, 모델이 각 타임스텝마다 노이즈 벡터를 얼마나 잘 예측하는지를 측정한다.

Experiments

1. 실험 세팅

- 저자들은 CIFAR10, LSUN, CelebA-HQ 등 이미지 데이터셋에서 모델을 학습해 성능을 평가했다.
- 총 단계(T)는 1000으로 설정하여, Reverse(샘플링) 과정에서 신경망 추론을 1000번 수행한다.

2. 생성 품질

- CIFAR10**에서 Inception Score가 9.46, FID가 3.17이라는 **당시 기준 매우 좋은 결과**를 달성했다(비교 모델들과 견줄 수 있는 성능).
- LSUN 256×256**(예: 교회, 침실, 고양이) 등의 고해상도 이미지에서도, 이미지 퀄리티가 꽤 높으며, ProgressiveGAN 등 이전 강력 모델과 비슷한 수준을 보인다.

3. ϵ -예측 방식의 효과

- Reverse 과정에서 μ (평균) 대신 ϵ (노이즈)를 예측하도록 파라미터화한 것이 샘플 품질에 크게 기여했다.
- 변분 경계를 직접 최소화하는 대신, 이를 단순화한 Lsimple("노이즈 벡터와 예측값의 2차 오차")를 학습 목표로 써도, 더 좋은 이미지가 생성되는 것으로 나타났다.

4. Progressive Coding & Interpolation

- 모델은 "점진적(Progressive)으로" 노이즈를 제거하면서 이미지를 복원/생성한다.
- 실험에서, 노이즈 제거 단계를 중간중간 멈추거나(진행 중 이미지 확인), 중간 잠재 표현(x_t)을 이용해 여러 이미지를 **보간(Interpolation)** 할 수 있음을 시연한다.
- 보간 시, 얼굴 각도나 머리 색깔 같은 큰 속성부터 점진적으로 변하는 모습이 확인됨.

Related Work

1. 기존 생성 모델

- 생성 모델 분야에는 GAN, Autoregressive, Flow, VAE 등 다양한 방법이 활발히 연구되어 왔다.
- 이들 모델은 고품질 이미지를 만드는 데 성공했지만, Diffusion 모델은 그동안 제대로 활용되지 못했다.

2. Energy-based Model(EBM)·Score Matching

- 이미 **Score Matching**(특히 **Denoising Score Matching**) 기반 모델들이 있었는데, 이 연구는 역 과정(Reverse)을 명시적 확률모델로 학습해, 로그우도 등도 계산 가능하게 했다는 점이 특징이다.
- Annealed Langevin Dynamics 등과 유사점이 있지만, 여기서는 변분 추론으로 그 과정을 직접 학습하며, 전체 목표를 최적화해 높은 품질의 이미지를 만든다.

3. Autoregressive 모델과의 연관

- “Masking 노이즈로 progressive하게 특정 좌표를 채우는” 방식이 Autoregressive 모델로 해석될 수 있듯이, Gaussian 노이즈를 넣고 빼는 방식도 유사한 인덱티브 바이어스(데이터 구조화 방식)를 가진다.
- 즉, Diffusion은 ‘마스킹 대신 가우시안 노이즈’를 사용한 순차적 복원 과정이며, 이는 오토리그레시브 접근을 일반화한 것으로 해석 가능하다.

4. 의의 및 후속 활용

- 본 모델은 단순히 좋은 시각적 샘플 품질만이 아니라, 로그우도(또는 변분 경계) 계산, MCMC(Langevin) 해석, 에너지 기반 모델과의 연결 등 다양한 측면에서 의미가 크다.
- 향후 다른 모달리티(오디오, 동영상, 텍스트)에 적용하거나, 더욱 다양한 구조와 결합해볼 수도 있을 것으로 기대된다.

Conclusion

1. Diffusion 모델의 성공

- 논문은 Diffusion 모델이 실제로 **고품질의 이미지를 생성**할 수 있음을 실험적으로 입증했다.
- 변분 추론(Variational Inference)을 활용하여, 마코프 체인(Forward/Reverse) 구조를 명시적으로 학습하는 방식이 효과적임을 보여준다.

2. 다양한 방법론과의 연결

- **Denoising Score Matching**과 **Langevin Dynamics**: 노이즈를 단계적으로 제거하고 이미지를 복원하는 메커니즘이 이와 동일하게 해석될 수 있다.
- **Energy-based Model**: 위 Score Matching, Langevin 관점에서 에너지 기반 모델과도 연결점을 찾을 수 있다.
- **Autoregressive Model**: 점진적으로 이미지를 재구성한다는 면에서, 일정 부분 오토리그레시브 생성과 유사한 인덱티브 바이어스를 가진다.
- **Lossy Compression(손실 압축)**: 점차 노이즈를 넣고 빼는 과정이 이미지 특징을 점진적으로 저장/복원하는 압축 방식으로 볼 수도 있다.

3. 향후 전망

- 논문에서는 주로 이미지 생성 실험에 집중했지만, Diffusion 모델이 **이미지 외의 다른 데이터(텍스트, 오디오, 영상 등)**에도 유용할 가능성이 있다.
- 또, 다른 생성 모델(예: GAN, Autoregressive, VAEs)이나 기계학습 시스템과 **조합할 수 있는 잠재력**도 크다고 본다.