



ELMo 관련 연구 및 모델 구조 정리

1. 기존 Word Embedding 방식의 한계와 극복 시도

(1) Character-Based CNN

- 단어를 문자(character) 단위로 쪼개어 CNN을 적용하여 임베딩을 생성.
- N-gram 방식으로 단어를 부분 단위로 변환 후 Convolution 연산 수행.
- 어근이나 접미사 등의 단어 내부 특징을 학습하는 데 도움을 줄 수 있음.
- 그러나 **문맥 정보 부족**이라는 단점이 존재.

(2) Word2Vec + Clustering

- Word2Vec을 활용하여 각 문장을 문맥 벡터화하고, 이를 클러스터링하여 서로 다른 문맥에서 동일한 단어가 다른 벡터를 가지도록 시도.
- 실루엣 계수(Silhouette Coefficient)와 Elbow Method 등을 활용하여 최적의 클러스터 개수를 찾지만, **최적 개수를 설정하는 어려움**이 존재.

(3) Bi-directional LSTM (Bi-LSTM)

- 초창기 기계 번역 연구에서 사용된 양방향 LSTM을 활용.
- 기존 연구에서는 주로 소스-타겟 문장 쌍의 병렬 코퍼스를 이용하는 방식이었음.
- **Context2Vec**과 같은 방식은 단일 언어에서 학습하며 문맥을 반영하지만, 타겟 단어 주변으로만 한정된다는 한계가 있음.
- **ELMo**는 전체 문장을 대상으로 문맥을 반영하는 방식을 도입하여 문제를 해결.

2. ELMo의 모델 구조 (Architecture)

(1) Character-Based CNN

- 단어를 문자(character) 단위로 쪼개어 고정 차원의 벡터로 변환.
- 다양한 크기의 필터를 활용한 CNN 연산 수행 후 **Max Pooling** 적용.
- 초기 임베딩을 얻기 위해 2-layer Highway Network를 적용하여 불필요한 정보는 억제하고 중요한 정보만 전달.

(2) Bidirectional Language Model (BiLM)

- **Forward LM**: 현재 토큰을 기준으로 다음 토큰을 예측하는 모델.

- **Backward LM**: 현재 토큰을 기준으로 이전 토큰을 예측하는 모델.
- 두 방향에서 얻은 정보를 통합하여 **Bidirectional Language Model**을 형성.
- 학습 시, **양방향 Log likelihood**를 최대화하는 방식으로 최적화 수행.

(3) ELMo Embedding 생성

- BiLM을 거친 각 LSTM 층의 출력을 가중합하여 최종적인 ELMo 벡터를 생성.
- LSTM 층별 출력을 가중평균하며, 이때 가중치는 학습 가능한 파라미터로 조정 가능.
- 모델 최적화 과정에서 필요에 따라 적절한 크기의 벡터로 자동 조정됨.

(4) Task-Specific Layers

- 생성된 ELMo 벡터는 Downstream Task에서 활용됨.
- **입력(Input) 레이어**에 추가할 수도 있고, **출력(Output) 레이어**에 적용할 수도 있음.
- 적용 방식에 따라 감성 분석, 개체명 인식(NER), 문서 요약, QA 등 다양한 NLP 태스크에서 활용 가능.

3. ELMo의 성능 평가 (Evaluation)

ELMo는 여러 NLP 벤치마크 데이터셋에서 기존 SOTA(State-of-the-Art) 모델보다 높은 성능을 기록함.

- **SQuAD**: 질문 응답(Task).
- **SNLI**: 자연어 추론(Task).
- **SRL**: 의미역 분석(Task).
- **Coreference Resolution (Coref)**: 동일한 개체를 가리키는 명사구들을 연결(Task).
- **NER**: 개체명 인식(Task).
- **SST-5**: 감성 분석(Task, 긍정/부정 분류).

4. 분석 (Analysis)

(1) Layer Weighting Scheme (층별 가중치 조정)

- 기존 방식에서는 BiLM의 마지막 Layer만 활용하는 경우가 많았음.
- 실험 결과, **모든 Layer를 활용하는 것이 더 좋은 성능을 보임.**
- 각 층의 역할:
 - 저층(Lower Layers): 기본적인 구문, 문법적 정보 학습.
 - 고층(Higher Layers): 의미론적, 문맥적 고차원 정보 학습.
 - 층별 가중치(λ)를 조정하여 Task에 따라 최적화 가능.

(2) ELMo 적용 위치에 따른 성능 변화

- **Input Layer 적용:** SRL Task에서 성능 향상 (문맥을 활용한 역할 분석 효과).
- **Output Layer 적용:** SNLI, SRL Task에서 성능 향상 (문맥 반영 후 Attention 수행 효과).

(3) Sample Efficiency (데이터 효율성)

- ELMo 적용 모델은 기존 모델보다 훨씬 적은 Epoch에서도 높은 성능을 달성.
- 기존 모델이 486 Epoch에서 최고 성능을 기록한 반면, ELMo 모델은 **10 Epoch 만에 최고 성능** 도달.
- 훈련 데이터가 적을 때도 우수한 성능을 보임.

5. 결론 (Conclusion)

- BiLM을 활용한 Context 기반 Word Embedding을 통해 기존의 고정된 단어 벡터 방식의 한계를 극복.
- 다의어 처리 및 문맥 반영이 가능하여 보다 정밀한 자연어 이해가 가능.
- 특정 Task에 따라 **층별 가중치를 조정하여 최적의 성능을 달성할 수 있음**.
- 다양한 NLP Task에서 활용될 수 있는 **범용적인 모델로서의 가치가 높음**.