

ELMo Summary

1.1 ELMo(Embeddings from language Model)

▼ ELMo의 핵심 구조



- Bidirectional LSTM 기반 언어 모델 (입력된 문장을 앞(→)과 뒤(←)에서 동시에 읽음)
- 여러 층을 쌓아 깊이 있는 의미 정보 학습
- 최종 벡터는 LSTM의 여러 층의 출력을 조합한 결과

▼ ELMo 벡터 생성 과정

- 단어를 문맥 없이 기본적인 Character-level CNN으로 인코딩

▼ ? Character - level CNN ?

Character-level CNN (문자 기반 CNN)



Character-level CNN(문자 수준 합성곱 신경망)은 단어 단위가 아닌 개별 문자(characters) 단위로 입력을 받아 학습하는 임베딩 기법. 이는 언어적 특성이 다르거나, 단어 수준 임베딩이 부족한 경우 유용하게 활용됨

CNN 기반 특징 추출 단계

1. 1 문자 단위 입력 변환

예제: "hello"를 One-hot Encoding

만약 알파벳 a~z(26자) + 공백 + 특수문자 포함 총 30개의 문자 집합을 사용한다고 가정하면:

문자	a	b	c	...	h	e	l	o
원-핫 벡터	(1,0,0,...,0)	(0,1,0,...,0)	(0,0,1,...,0)	...	(0,0,0,...,1)	(0,0,0,...,1)	(0,0,0,...,1)	(0,0,0,...,1)

💡 "hello" → (h, e, l, l, o)의 원-핫 벡터로 변환됨

이제 각 문자들은 30차원의 벡터로 표현돼!

2. 1D 합성곱 적용 (다양한 크기의 필터를 사용하여 문자 패턴을 학습)

예제: 3-gram 필터 적용

"hello"에서 문자 3개씩 묶어서 특징을 추출한다고 가정하면:

3-gram 필터 적용 결과
"hel" → 벡터1
"ell" → 벡터2
"llo" → 벡터3

- 👉 "hel", "ell", "llo" 같은 부분 문자(ngram) 패턴을 학습할 수 있음!
- 👉 이를 통해 비슷한 철자 구조를 가진 단어들도 유사한 벡터로 변환 가능!

- 여러 크기의 1D 합성곱 필터를 사용하여, 연속된 문자들(예: "he", "el", "ll", "lo")에 대해 국소적인 특징(n-gram 패턴)을 추출합니다.
- 각 필터는 입력 문자 임베딩 행렬과 합성곱 연산을 수행하여 특징 맵(feature map)을 생성합니다.

3. 맥스 풀링 적용

→ 가장 중요한 특징을 선택하여 고정된 길이의 벡터로 변환. (만약 필터를 여러 개 사용했다면 최대값을 뽑아 중요한 특징만 남김)

👉 'hello' 길이가 5인 단어라도, 하나의 고정된 벡터로 변환 될 수 있음.

4. Fully Connected Layer (FC레이어)

→ 최종적으로 고정된 크기의 벡터를 얻어 단어 수준 임베딩 벡터로 변환

→ 이때 가중치(W)와 편향(b)가 적용되어 맥스 풀링의 벡터와는 다른 벡터로 변환 됨.

→ 다운스트림 태스크(언어 모델, 분류)에 따라 가중치가 달라지게 됨.

최종 결과:


💡 "hello" → CNN + Pooling → 최종 256차원 벡터 (예: $[-0.2, 0.5, \dots, 0.1]$)

▼ ELMo의 동작 과정

• CNN (맥스 풀링까지)

+


- RNN



1) 각 층의 출력값을 연결(concatenate)한다.




2) 각 층의 출력값 별로 가중치를 준다.



이 가중치를 여기서는 s_1, s_2, s_3 라고 합시다.

3) 각 층의 출력값을 모두 더한다.




4) 벡터의 크기를 결정하는 스칼라 매개변수를 곱한다.

$$\gamma \times \text{[red vector]} = \text{[red vector]}$$

→ 이렇게 완성된 벡터는 ELMo 표현 (representation이라고 함!)

→ 이 이후에는 fc layer이 없음



→ 위의 그림은 ELMo 표현이 기존의 GloVe 등과 같은 임베딩 벡터와 함께 NLP 태스크의 입력이 되는 것을 보여줌

왜 기존 임베딩과 합쳐서 사용할까?



ELMo가 문맥 정보를 반영하긴 하지만, **GloVe** 같은 고정된 임베딩이 가진 일반적인 언어 정보도 중요하기 때문

- **ELMo는 문맥을 반영하지만, 단어 자체의 일반적인 의미는 부족할 수 있음.**

예를 들어, 희귀 단어(rare words)나 도메인 특화 단어의 경우, 학습 데이터에 충분히 노출되지 않으면 좋은 표현을 제공하지 못할 수 있음.

- **GloVe 같은 고정 임베딩은 일반적인 언어 패턴을 잘 학습한 상태.**
 - GloVe는 대규모 코퍼스로 학습되었기 때문에, 단어 간의 유사성이거나 일반적인 의미 관계를 잘 캡처함