

DeepLabv3

<https://arxiv.org/pdf/1802.02611>

Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation

Abstract

DeepLabv3+는 의미론적 분할을 위한 딥러닝 모델로, 공간 피라미드 풀링과 인코더-디코더 구조를 결합하여 **객체 경계를 정밀하게 복원**하는 특징이 있다.

공간 피라미드 풀링을 사용하는 네트워크는 다양한 비율과 가시 영역에서 필터링 및 풀링 작업을 수행하여 다중 규모의 컨텍스트 정보를 인코딩할 수 있다. 반면 인코더-디코더 네트워크는 점진적으로 공간 정보를 복원하여 더욱 선명한 객체 경계를 포착할 수 있다. 본 연구에서는 이러한 두 방법의 장점을 결합한 모델을 제안한다.

1. Introduction

의미론적 분할(semantic segmentation)은 이미지의 모든 픽셀에 의미 있는 레이블을 할당하는 것으로, 컴퓨터 비전에서 중요한 주제이다. 기존의 핸드 크래프트(hand-crafted) 특징을 활용한 방법과 비교하여, 심층 합성곱 신경망(Deep Convolutional Neural Networks, CNN)은 분할 성능을 크게 향상시켰다.

이 연구에서는 의미론적 분할을 위한 두 가지 주요 접근 방식을 다룬다.

1. 공간 피라미드 풀링(SPP) 기반 네트워크:

- 여러 해상도에서 특징을 추출하여 풍부한 컨텍스트 정보를 확보할 수 있음.
- 그러나 객체 경계의 세부 정보가 손실될 가능성이 높음.

2. 인코더-디코더 네트워크:

- 객체의 경계를 더욱 명확하게 복원할 수 있음.
- 그러나 연산량이 많아질 경우 속도가 느려질 수 있음.

DeepLabv3+는 두 접근법의 장점을 결합하여, DeepLabv3의 인코더 모듈을 확장하고 단순하면서도 효과적인 디코더 모듈을 추가하여 객체 경계를 보다 정밀하게 복원한다. 또한, 최신 모델인 Xception을 활용하여 연산 속도를 높이고 성능을 향상시켰다.

결론:

- DeepLabv3를 강력한 인코더로 활용하고 효과적인 디코더를 추가한 **새로운 인코더-디코더 구조**를 제안.
- Atrous Convolution을 활용하여 **해상도와 연산 속도 간의 균형을 조절할 수 있도록 설계**함.
- Xception 모델을 **세그멘테이션(task) 용도로 최적화**하고, ASPP 및 디코더 모듈 모두에 **심층 분리 합성곱을 적용**하여 속도와 성능을 개선.
- PASCAL VOC 2012 및 Cityscapes 데이터셋에서 **새로운 최고 성능(State-of-the-Art, SOTA)** 기록 달성.
- TensorFlow 기반 **오픈소스 구현 제공**.

Related Work

2.1 공간 피라미드 풀링 (Spatial Pyramid Pooling, SPP)

- 대표적인 모델: PSPNet[24], DeepLab 시리즈[23,39]
- 주요 기법:
 - 다중 해상도 격자 (multi-grid scales)에서 공간 피라미드 풀링 수행
 - Atrous Spatial Pyramid Pooling (ASPP) 활용
 - 이미지 수준 풀링(image-level pooling)[52] 포함
- 장점: 여러 크기의 컨텍스트 정보를 효과적으로 활용 가능
- 단점: 경계 부분의 정밀도가 낮아지는 문제가 있음

2.2 인코더-디코더 구조 (Encoder-Decoder Architecture)

- 주요 활용 사례:
 - 사람의 자세 추정 (Human Pose Estimation)[53]
 - 객체 탐지 (Object Detection)[54-56]
 - 의미론적 이미지 분할 (Semantic Segmentation)[11,57,21,22,58-64]
- 구조

1. 인코더 (Encoder): 특징 맵(feature map)을 점진적으로 축소하면서 고수준의 의미 정보 학습
 2. 디코더 (Decoder): 축소된 공간 정보를 복원하여 세부적인 경계 복원
- DeepLabv3+의 차별점
 - 기존 DeepLabv3[23]를 인코더로 활용
 - 추가적으로 간단하지만 효과적인 디코더 모듈을 도입하여 경계 정밀도를 개선
-

2.3 깊이별 분리 합성곱 (Depthwise Separable Convolution)

- 기존의 연산 비용이 높은 일반 합성곱(convolution) 연산을 대체하는 기법
- 주요 모델: MobileNet[27,28], ResNeXt[7,65], Xception[26]
- 장점
 - 연산량 감소 및 모델 경량화
 - 성능 유지 또는 향상 가능
- 본 연구에서는 Xception 모델을 활용하여 성능과 속도를 모두 개선

3. Methods

3.1 Encoder-Decoder with Atrous Convolution

인코더-디코더와 팽창 합성곱

팽창 합성곱(Atrous Convolution)은 필터의 시야(Field-of-view)를 조정하여 다중 스케일 정보를 캡처할 수 있도록 하는 기법이다.

팽창율(r)이 클수록 더 넓은 범위를 볼 수 있지만, 연산량이 증가한다.

깊이별 분리 합성곱 (Depthwise Separable Convolution)

기존 합성곱을 깊이별 합성곱과 점별(1×1) 합성곱으로 분리하여 연산량을 크게 줄인다.

TensorFlow에서는 깊이별 합성곱에 팽창 합성곱을 적용하여 효율적인 연산을 수행한다.

DeepLabv3 인코더

DeepLabv3는 다양한 팽창율을 적용한 Atrous Spatial Pyramid Pooling(ASPP) 모듈을 통해 다중 스케일 특징을 추출한다.

이 모델의 출력 특성 맵(256 채널)은 리치한 의미 정보를 포함하고 있다.

제안된 디코더

DeepLabv3 인코더의 출력은 16배 업샘플링되지만, 이 방식은 경계 복원이 어렵다. 따라서 제안된 디코더는:

1. 출력 특성 맵을 4배 업샘플링
2. 네트워크의 저수준 특징(low-level features)과 결합
3. 1×1 합성곱을 통해 채널 수 감소
4. 3×3 합성곱을 적용하여 세부 정보 보완 후 다시 4배 업샘플링

이 방식은 속도와 정확도의 균형을 유지하면서 더 나은 세분화 결과를 제공한다.

3.2 Modified Aligned Xception

Xception 모델은 ImageNet에서 좋은 성능을 보이며, MSRA팀이 객체 검출에 최적화된 변형 모델(Aligned Xception)을 개발했다.

본 연구에서는 이를 기반으로 다음과 같은 수정 사항을 적용:

1. 더 깊은 Xception 네트워크 사용
2. 최대 풀링을 깊이별 분리 합성곱(strided depthwise convolution)으로 대체하여 임의 해상도에서 특성 맵 추출 가능
3. 모든 3×3 깊이별 합성곱 후 배치 정규화(Batch Normalization)와 ReLU 활성화 추가

이러한 수정은 MobileNet 구조와 유사하며, 연산 효율성을 유지하면서도 성능을 향상시킨다.

4. Experimental Evaluation

4.1 Decoder Design Choices

기본적인 DeepLabv3 구조

- DeepLabv3 특징 맵: Atrous Spatial Pyramid Pooling(ASPP) 및 이미지 수준 특징 포함
- 기본 디코더: 단순한 bilinear upsampling(16배 업샘플링) 사용
- 기본 디코더 성능: mIoU 77.21% (PASCAL VOC 2012 검증 세트)

DeepLabv3+ 디코더 개선 사항

- 기존 naive decoder(단순 bilinear upsampling)보다 더 정교한 디코더 모듈 추가
- 개선된 디코더 모듈의 핵심 요소:
 1. 1×1 합성곱: 인코더의 저수준(low-level) 특징 맵의 채널 수를 줄이기 위해 사용
 2. 3×3 합성곱: 더 정밀한 세그멘테이션 결과를 위해 추가
 3. 어떤 인코더 저수준 특징을 사용할지 선택

디코더 모듈의 실험 결과

- 1×1 합성곱의 채널 수를 48 또는 32로 줄이면 성능 향상 → 최종적으로 [1×1, 48] 설정 선택
- 3×3 합성곱 개수 실험:
 - 3×3 합성곱 2개(256개 필터) 사용 시 성능이 가장 좋음
 - 1개 또는 3개 사용 시 성능 저하
 - 필터 수를 128로 줄이거나, 커널 크기를 1×1로 변경 시 성능 저하

추가 실험 및 최종 선택

- Conv2 및 Conv3를 모두 활용하는 U-Net/SegNet 방식도 실험했으나 큰 개선이 없었음
- 따라서 Conv2 특징 맵과 DeepLabv3 특징 맵을 연결(concatenation)한 후, 3×3 합성곱 두 개 적용하는 간단한 구조 채택
- 최종 모델의 output stride = 4 (더 작은 stride는 GPU 자원 부족으로 미실험)

결론:

- DeepLabv3+는 기존 DeepLabv3의 단순 업샘플링 방식보다 정교한 디코더 모듈을 추가하여 성능을 향상
- PASCAL VOC 2012 데이터셋을 이용하여 실험 진행, mIoU 성능 기준으로 평가
- 디코더 설계에서 1×1 및 3×3 합성곱 개수, 필터 수 등을 실험하여 최적의 조합(1×1, 48 및 3×3, 256 두 개) 선택
- U-Net/SegNet 스타일의 다단계 디코더 설계를 실험했으나, 단순한 구조가 더 효과적이었음
- 최종적으로 output stride = 4를 사용하여 최적 성능 달성