

Faster R-CNN

Faster R-CNN 논문 요약

Shaoqing Ren, Kaiming He, Ross Girshick, Jian Sun
CVPR 2015

[논문 링크](#)

1. Introduction

- 기존의 R-CNN 계열은 Region Proposal 단계(Selective Search 등)에서 병목 발생
 - **Faster R-CNN**은 Region Proposal을 CNN으로 대체한 **Region Proposal Network (RPN)** 제안.
- RPN은 detection network와 convolutional layer를 공유하여 속도와 정확도 개선.
- 전체 네트워크는 단일, 통합 구조 (**single, unified network**)로 구성됨.

2. Method: Faster R-CNN

2.1 Architecture Overview

Faster R-CNN 구조도 (RPN + Fast R-CNN)

- Conv feature map 위에 RPN 슬라이딩 적용 → 객체성(objectness) + box regression 동시 예측
- RoI pooling → Fast R-CNN 분류기로 연결
- 전체 파이프라인은 End-to-End 학습 가능

2.2 Region Proposal Network (RPN)

****Baseline Architecture**

- 작은 $n \times n$ 윈도우(기본 3×3)를 conv feature map 위에 슬라이딩하며 proposal 생성
- 각 위치마다 k개의 **anchor box**를 기준으로:
 - 2k개의 objectness score
 - 4k개의 box regression 좌표 예측
- 기본 anchor 설정:
 - 3 scales (128^2 , 256^2 , 512^2)
 - 3 aspect ratios (1:1, 1:2, 2:1) → 총 9 anchors per location

Loss Function

- Binary classification (object / not object) + box regression (Smooth L1 loss)
 - Positive anchor: $\text{IoU} \geq 0.7$ 또는 GT와 최고 IoU
 - Negative anchor: $\text{IoU} \leq 0.3$
 - Loss 구성: $L = L_{\text{cls}} + \lambda * L_{\text{reg}}$
($\lambda = 10$ 사용, 성능 민감도 낮음)
-

2.3 Training Scheme

- RPN과 Fast R-CNN의 conv layer 공유 → 4-step alternating training 사용
1. RPN 학습 (ImageNet pretrain 기반)
 2. Fast R-CNN 학습 (RPN proposal 사용)
 3. RPN 미세조정 (shared conv 고정)
 4. Fast R-CNN 미세조정 (shared conv 고정)
- 추후에는 **approximate joint training** 방식도 도입 (속도 향상)
-

PASCAL VOC 2007/2012

- RPN + Fast R-CNN (VGG-16, 300 proposals):

- VOC 2007: 69.9% mAP (SS보다 높음)
- VOC 2012: 70.4% mAP

Speed

구성	Conv	Proposal	Region-wise	총 시간	FPS
SS + Fast R-CNN (VGG)	146	1510	174	1830	0.5 fps
RPN + Fast R-CNN (VGG)	141	10	47	198	5 fps
RPN + Fast R-CNN (ZF)	31	3	25	59	17 fps

4. MS COCO 결과

- COCO test-dev 기준:
- Faster R-CNN (VGG-16): 42.1% @0.5 IoU, 21.5% mAP
- Faster R-CNN (ResNet-101): 48.4% / 27.2%
- COCO+VOC 조합 학습 시 VOC에서 최고의 성능 도출 (VOC07 test: 78.8%)

5. 분석 및 추가 결과

- One-stage 방식 (e.g. OverFeat)보다 두 단계 방식(RPN → classifier)이 정확도 높음
- Anchor 개수 조절 실험: 3 scales + 3 ratios 조합이 best
- λ 값 변화, IoU threshold 변화에 대한 성능 변화 적음 → robust한 설계

6. Conclusion

- Faster R-CNN은 region proposal을 CNN으로 통합하여 속도 병목을 제거
- 실시간 근접 속도 + 최고 정확도 → 실제 시스템에 적용 가능
- 이후 Mask R-CNN, RetinaNet 등의 기반이 되는 핵심 논문

7. YOLO vs Faster R-CNN: 장단점 비교

둘은 속도와 정확성 면에서 trade-off 가 존재. 만약 realtime이 중요하다면 YOLO 쓸 듯 ..

YOLO (You Only Look Once)

- 장점:
 - 속도: 매우 빠름. 실시간 객체 탐지에 적합.
 - 단일 통합 아키텍처: 한 번의 네트워크 실행으로 전체 이미지 추론 가능.
 - 단순한 구조: 쉽게 이해하고 구현 가능.
- 단점:
 - 정확도: 작은 객체나 복잡한 이미지에서의 정확도가 낮을 수 있음.
 - 위치 정확성: Region proposal 방식에 비해 박스 위치 정확도가 떨어질 수 있음.

Faster R-CNN

- 장점:
 - 정확도: 높은 객체 탐지 정확도. 특히 작은 객체에서도 우수한 성능.
 - 정밀한 위치 예측: RPN을 통해 정확한 위치를 예측할 수 있음.
 - 유연성: 다양한 구조의 객체 탐지에 잘 작동.
 - 단점:
 - 속도: 상대적으로 느림. 실시간 탐지에는 부적합.
 - 복잡한 구조: 구현과 최적화가 어려울 수 있음.
-