



Faster R-CNN

이름	홍준기
대학교	동국대학교
학과	산업공학과
날짜	2025년

Abstract

실시간 객체 탐지를 향한 Region Proposal Network을 제안함

Abstract

1. Introduction

기존 문제 제기

제안 방식(Faster R-CNN)

2. Faster R-CNN

2.1. Region Proposal Network (RPN)

2.2. RPN & Fast R-CNN's Feature Sharing

교차 학습(Alternating Training)

근사적 공동 학습(Approximate Joint Training)

정확한 공동 학습(Non-approximate)

2.3. Implementation Details

3. Experiments

3.1. PASCAL VOC

3.1.1 Dataset 및 실험 설계 Network

3.1.2 성능 지표(mAP)

3.1.3 Ablation Study

1) 공유된 Conv Layer의 Effectiveness

2) RPN의 proposal만 바꾸기

3) RPN의 cls or reg 계층 제거

4) VGG- 16 사용시 성능

5) Anchor 구성 분석

6) One-stage vs. Two-stage

3.2. MS COCO

3.2.1 Dataset 및 실험 설계 Network

3.2.2 평가 Metric

3.2.3 성능 결과 (COCO test-dev 기준)

3.2.4 COCO에서 VOC로 전이 학습 (Transfer Learning)

4. Conclusion

Results

1. Introduction

기존 문제 제기

- 기존 객체 탐지 시스템(R-CNN, Fast R-CNN 등)은 객체가 있을 법한 영역(Region Proposals)을 먼저 찾아야 하는데, 이 과정이 매우 느림
 - 전체 파이프라인 중 **region proposal**이 병목 현상이 됨(Selective Search)

제안 방식(Faster R-CNN)

- Region Proposal Network (RPN)
 - CNN 기반으로 region을 예측
 - 기존의 검출 네트워크(Fast R-CNN)와 합쳐서 하나의 네트워크로 통합
 - CNN의 **feature map**을 공유하므로, 별도의 연산 없이 거의 바로 후보 생성 가능

2. Faster R-CNN

2.1. Region Proposal Network (RPN)

- 원리 및 과정
 - RPN은 입력 이미지에서 객체가 있을 법한 영역(박스)과 그에 대한 "objectness" score를 예측
 - 슬라이딩 윈도우 방식으로 CNN feature map 위를 움직이며, **3x3 크기의 윈도우**를 통해 예측을 수행함

- 각 위치마다 두 개의 sibling layer가 있음
 - Reg: 경계 박스 좌표 예측
 - cls: 객체일 확률 예측
-  Anchors box (앵커 박스)
 - 각 위치마다 여러 크기와 비율의 기준 박스(anchor)를 기준으로 예측
 - 예측된 박스와 실제 정답(ground truth)의 **IoU가 높으면 positive**, 낮으면 negative
 - 학습은 classification (객체/비객체) + regression (좌표 보정) **멀티태스크 손실 함수**로 진행

2.2. RPN & Fast R-CNN's Feature Sharing

- 3가지의 학습 방식이 존재함

교차 학습(Alternating Training)

- RPN 학습 → proposal 생성 → Fast R-CNN 학습 → 다시 RPN 학습 → 반복
- 논문에서 주로 활용하는 방식

근사적 공동 학습(Approximate Joint Training)

- RPN과 Fast R-CNN을 하나의 네트워크로 병합해 학습
- 학습 속도가 빠르고 구현 간단하지만, 박스 좌표에 대한 gradient는 무시

정확한 공동 학습(Non-approximate)

- RoI pooling을 박스 좌표까지 미분 가능한 구조로 바꾸어 정확히 학습
- 구현의 복잡성 증대

2.3. Implementation Details

- 이미지는 짧은 변 기준으로 600픽셀로 리사이즈
- 이미지 피라미드 불사용, 고정 크기(3x3) feature로 다양한 객체 크기 대응

- 사용 anchor: 3 스케일 (128^2 , 256^2 , 512^2) × 3 비율 (1:1, 1:2, 2:1) = 9개
- 경계 넘는 anchor는 학습 시 무시, 테스트 시에는 이미지 경계로 클리핑

3. Experiments

3.1. PASCAL VOC

3.1.1 Dataset 및 실험 설계 Network

- **PASCAL VOC 2007**: 약 5,000장의 trainval 이미지와 5,000장의 test 이미지 (20개 객체 클래스)
- **ZF Net** (간단한 모델): conv 5개, FC 3개
- **VGG-16** (깊은 모델): conv 13개, FC 3개
- 사전학습: ImageNet

3.1.2 성능 지표(mAP)

- RPN이 다른 Selective Search+Fast R-CNN, EdgeBoxes+ Fast R-CNN, 방법론에 비해서 더 빠르고 정확도도 더 높음
- 제안 영역 수가 적어져 (300개 proposal) region-wise 연산량 감

3.1.3 Ablation Study

1) 공유된 Conv Layer의 Effectiveness

- RPN과 Fast R-CNN이 conv layer를 공유하지 않으면 mAP(58.7%)
- 공유하여 학습 시 더 나은 성능 (59.9%)

2) RPN의 proposal만 바꾸기

- SS로 학습된 Fast R-CNN에서 테스트 시 SS 대신 RPN proposal 사용
 - 6,000개 proposal(NMS 제거) → 55.2%
 - 300개 proposal → 56.8%, 100개 proposal → 55.1%
- 상위 proposal만으로도 성능이 괜찮음, NMS 제거해도 크게 떨어지지 않음

3) RPN의 cls or reg 계층 제거

- cls는 순위 예측에, reg는 정확한 박스 위치에 핵심 역할
 - cls 제거: 성능 급락(44.6%), reg 제거: anchor만 사용할 경우 mAP 52.1%

4) VGG-16 사용시 성능

- RPN은 학습이 가능하기 때문에 더 깊은 네트워크로 제안 품질이 **향상됨**
- SS처럼 고정된 방법보다 RPN이 데이터와 네트워크에 따라 성능 향상 가능

5) Anchor 구성 분석

- 3개 스케일 × 3개 비율 → 총 9개 anchor 사용
- anchor 개수 줄이면 성능 3~4% 감소
- 스케일과 비율 둘 다 고려하는 것이 효과적

6) One-stage vs. Two-stage

- One Stage: Fast R-CNN+ Sliding Window
- Two-Stage: Faster R-CNN(RPN+ Fast R-CNN) → 두 단계 구조가 더 명확, 정확한 성능 및 빠른 속

3.2. MS COCO

3.2.1 Dataset 및 실험 설계 Network

- 카테고리: 80개 객체 클래스
- 데이터셋 구성:
 - Train: 80,000장
 - Val: 40,000장
 - Test-dev: 20,000장

3.2.2 평가 Metric

- **mAP@[.5, .95]** : COCO의 공식 평가 지표 (IoU 0.5~0.95 평균)
- **mAP@0.5** : VOC 방식과 동일
- 결과:
 - TCN은 receptive field 내에서는 정확한 예측 가능
 - 하지만, Bi-LSTM은 시간이 지연됨에 따라 성능이 빠르게 하락

3.2.3 성능 결과 (COCO test-dev 기준)

- **Faster R-CNN**이 Fast R-CNN보다 정확도가 높음
 - 특히 높은 IoU 구간에서 localization 성능 향상
- 여전히 이미지당 200ms 이내의 속도로 동작
- RPN은 ResNet 같은 더 강력한 피처에서도 효과적으로 작동, 다른 고성능 모델들과도 잘 결합됨

3.2.4 COCO에서 VOC로 전이 학습 (Transfer Learning)

실험 1: VOC 학습 없이 COCO 모델 그대로 평가

- VOC를 학습하지 않아도 COCO 모델이 더 높은 성능

→ 대규모 데이터 학습이 강력한 표현력 제공

실험 2: COCO 모델을 초기화로 사용하여 VOC에서 Fine-tuning

- 기존 ImageNet pretrain보다 **+5.6% 향상**

→ **COCO+VOC 모델이 모든 클래스에서 최고 성능기록**

4. Conclusion

Results

- RPN을 도입하여 region proposal을 거의 비용 없이 생성 가능
- Fast R-CNN과 conv layer를 공유함으로써 전체 객체 탐지 파이프라인을 통합 네트워크로 구현
- 제안 품질 향상 → 최종 탐지 정확도도 향상

- 실시간 수준의 속도 + 높은 정확도 → 실용적 객체 탐지 시스템 달성