

Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks

0. Abstract

Faster R-CNN은 실시간 객체 탐지를 위해 제안된 프레임워크로 Region Proposal Network(RPN)을 도입해 region proposal 과정을 신경망 내부로 통합함

기존의 두 단계 탐지 방식에서 region proposal 과 classification 단계를 통합해 전체 파이프라인을 end-to-end로 훈련 가능하게 함

RPN은 피라미드 구조 없이도 효율적으로 proposal을 생성하며 Fast R-CNN과 feature map을 공유하여 연산 속도와 정확도 모두를 향상시킴

1. Introduction

기존의 객체 탐지 모델들은 proposal 생성과 분류를 별개로 수행하여 느렸음

Selective Search 같은 기존 proposal 기법은 느리고 정확도가 낮았음

Faster R-CNN은 RPN을 통해 proposal 생성 과정을 CNN으로 통합해 실시간 탐지를 가능하게 함

공통 feature를 사용하여 속도와 성능 모두 향상시킴

3. Faster R-CNN

3.1 Region Proposal Networks

RPN은 입력 이미지에서 anchor box 기반으로 물체가 존재할 가능성이 있는 영역을 예측 슬라이딩 윈도우 방식으로 feature map 위에서 box 좌표와 objectness score를 동시에 출력

다양한 스케일과 종횡비의 anchor를 사용해 다양한 크기와 형태의 객체를 탐지

3.2 Sharing Features for RPN and Fast R-CNN

RPN과 Fast R-CNN은 동일한 backbone CNN의 feature map을 공유함

연산량을 줄이고 전체 네트워크를 end-to-end로 훈련 가능하게 함

alternating training 또는 joint training 방식을 사용하여 두 네트워크를 효과적으로 학습

3.3 Implementation Details

ImageNet으로 사전 학습된 VGG-16을 backbone으로 사용

anchor는 3개의 스케일과 3개의 종횡비를 조합해 총 9개 사용

훈련 시 mini-batch로 256개의 anchor 사용하며 positive과 negative 예제를 균형 있게 구성

proposal 수는 훈련 시 2000개, 테스트 시 300개로 제한

4. Experiments

4.1 Experiments on PASCAL VOC

PASCAL VOC 2007과 2012에서 실험 수행

Faster R-CNN은 기존 SOTA 방법들보다 높은 mAP을 달성하며 연산 속도에서도 우위

RPN만으로도 기존의 Selective Search보다 뛰어난 제안 품질을 보임

4.2 Experiments on MS COCO

복잡하고 객체 수가 많은 COCO 데이터셋에서도 높은 성능을 기록

특히 작은 객체 탐지에서 좋은 결과를 보임

anchor 설정이 COCO처럼 다양한 객체 크기를 가지는 경우에 적합하게 작동함

4.3 From MS COCO to PASCAL VOC

COCO에서 학습한 모델을 VOC에 fine-tune 없이 직접 적용했을 때도 좋은 일반화 성능을 보임

대규모 데이터셋에서의 학습이 소규모 데이터셋에 대한 성능 향상으로 이어질 수 있음

5. Conclusion

Faster R-CNN은 RPN을 통해 객체 탐지에서 proposal과 classification을 통합한 최초의 end-to-end 프레임워크임

proposal을 deep learning 기반으로 생성함으로써 탐지 속도와 정확도 모두를 크게 향상
시킴

Faster R-CNN은 이후 객체 탐지 연구의 새로운 패러다임을 제시함