

Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks

📅 작성일시	@2025년 3월 25일
📍 강의 번호	BASE
📄 유형	논문리뷰
📎 자료	https://arxiv.org/pdf/1506.01497
☑️ 복습	☐



1. 객체 검출에서 느렸던 후보영역 검출 단계를 "Region Proposal Network(RPN)"으로 대체하여 속도를 크게 높임
2. RPN과 Fast R-CNN을 합성곱 계층을 공유하는 형태로 통합해, 후보영역 추출에 추가 연산이 거의 들지 않음
3. 다양한 크기 및 비율의 anchor box를 사용해, 한 번의 CNN 연산으로 여러 종류의 객체 후보를 효과적으로 찾음
4. PASCAL VOC, MS COCO 등에서 최고 수준 정확도를 달성하면서도, GPU기준 초당 5프레임 수준의 실시간에 가까운 속도를 보임
5. 후보영역 추출과 검출을 단일 깊은 신경망으로 묶어버린 접근으로, 이후 객체 검출 및 분할 분야의 기반이 되었음

Abstract

- 기존의 객체 탐지 시스템들은 먼저 "이 구역에 물체가 있을 거야"라고 후보 구역(region proposals)을 추정한 뒤, 그 안에 어떤 물체가 있는지를 분류함.
- Fast R-CNN 같은 방법은 인식 속도는 빨라졌지만, 후보 구역을 만드는 과정은 여전히 느림(예: Selective Search 1~2초 걸림)
- 이 논문에서는 RPN(Region Proposal Network)를 제안함. 이걸 CNN을 이용해서 물체 후보 영역을 거의 공짜로 뽑을 수 있는 방법임
- RPN은 CNN에서 얻은 특징 맵 위에서 바로 물체 후보 영역을 예측하는 완전한 convolutional 네트워크임.
- 그리고 RPN과 Fast R-CNN을 하나의 통합된 네트워크로 만들어서, 특징 맵을 같이 쓰게 만들었음.
- 그 결과, 속도는 GPU에서 초당 5프레임, 성능은 VOC, COCO등 다양한 데이터셋에서 최고 성능을 기록함

INTRODUCTION

1) 기존 방식의 문제점

- R-CNN 계열의 방법들은 후보 영역을 뽑는 데 시간이 너무 오래 걸림
- 예: Selective Search는 CPU에서 이미지 하나 처리하는 데 2초 정도 걸림.
- 전체 탐지 시스템에서 후보 영역 생성이 병목 됨

2) 직관적인 해결책

- 후보 영역 생성도 GPU로 옮기면 속도는 빨라질 수 있음
- 근데 detection 네트워크랑 따로 계산하니까 연산 낭비가 생김

3) 이 논문의 핵심 아이디어

- 후보 영역도 CNN이 알아서 뽑게 하자
- Fast R-CNN에서 쓰던 특징 맵을 그대로 이용해서 RPN을 구성함.
- 이건 image pyramid, filter pyramid처럼 복잡하게 안 해도 되니까 빠르고 효율적임.

4) 기술적인 핵심

- 각 위치에서 다양한 크기와 비율의 anchor box를 미리 정의해 놓고,
- 그 위치에 물체가 있는지, 박스는 어떻게 조정해야 할 지를 예측함
- 이건 image pyramid, filter pyramid 처럼 복잡하게 안 해도 되니까 빠르고 효율적임

5) 결과

- 성능도 좋고, 속도도 빠름
- 대회에서 1등함

RELATED WORK

1) 객체 후보영역 (Object Proposals) 생성 연구

- 객체 후보 영역은 "이미지에서 어디에 물체가 있을 가능성이 높을까?"를 빠르게 찍어주는 방법을 의미함
- Selective Search(SS)
 - Superpixel을 병합하면서 "이곳이 물체 구별일 것 같다"고 추정하는 전형적인 알고리즘
 - 저해상도 특성만을 써서 구현하기는 쉽지만, CPU에서 동작 시 1~2초 정도 걸리므로, 빠른 검출 시스템을 짤 때 병목이 되어 왔음
- EdgeBoxes(EB)
 - 물체의 외곽선을 분석해서 후보 영역을 뽑음. SS보다 빠르지만, 여전히 0.2초 정도로 결코 무시 못 할 시간이 듦.
- 그 외 MCG, CPMC 같은 여러 기법들이 있지만, 공통적으로 이들은 "객체 후보 영역을 먼저 생성하고, 이후에 CNN으로 분류"하는 전형적인 2단계 구조에서 후보영역 부분을 담당했음

2) 딥러닝 기반의 객체 검출(Detection)

- R-CNN
 - CNN(합성곱 신경망)으로 후보영역을 분류하는 방법을 제안한 초기 연구.
 - 후보 영역은 Selective Search 등 전통 알고리즘이 뽑고, 그 영역을 CNN으로 분류해 정확도를 크게 올림
 - 다만 모든 후보 영역에 대해 CNN을 매번 돌려야 해서 느림
- SPPNet, Fast R-CNN
 - 공유 합성곱(convolution) 연산을 쓰는 방법이 제안되면서 속도가 개선되었음.
 - 이미지 전체를 한 번만 CNN으로 처리한 후, ROI(Region of Interest) Pooling 등을 이용해 후보 영역의 특징을 효율적으로 뽑도록 함.
 - 그래도 여전히 후보영역 자체를 생성하는 단계가 느렸음.(Selective Search 등.)
- OverFeat, MultiBox
 - 후보 영역을 미리 고정 (Sliding window 형태)해놓고 CNN으로 그 위치의 객체 여부나 경계상자 (bounding box)를 직접 추정하는 시도.
 - OverFeat는 단일 객체에 대한 위치 추정에서 확장; MultiBox는 여러 박스를 한 번에 추정.
 - 다만 이미지 피라미드나 다양한 스케일을 적용해야 하므로 시간이 많이 들거나, 네트워크 파라미터가 커지기도 했음

3) 특징 공유(Shared Computation)

- Fast R-CNN 이전에도 “이미지 전체를 한 번만 CNN으로 돌린 뒤, 필요한 후보 위치만 뽑아내는”식의 공유 합성곱 아이디어가 존재했음.
- Fully Convolutional Network 개념도 등장해, 픽셀 단위 분할 등에서 CNN을 전 이미지에 슬라이딩 형태로 적용하면서, 여러 위치의 출력을 함께 얻을 수 있음을 보여줬음.
- Faster R-CNN의 핵심은, 후보영역을 뽑는 단계까지 이 공유합성곱 위에서 한번에 처리하자는 것

Fast R-CNN

Faster R-CNN은 크게 두 단계(모듈)로 구성되는데, 이 두 단계가 하나의 통합된 신경망 안에서 동시에 학습되고, 합성곱 연산을 공유함.

1) Region Proposal Network(RPN)

- 후보 영역을 뽑는 전용 작은 네트워크
- 입력 이미지에서 CNN으로 특징 맵을 만든 뒤(이 특징 맵은 이후 Fast R-CNN 단계와 공유), 해당 특징 맵의 각 위치에서 “이 위치에 물체가 있을지” (objectness score)와 박스 좌표를 예측
- 예측의 중심 개념: anchor box
 - 어떤 위치에서 3가지 스케일 x 3가지 비율 등을 미리 정의해둔 박스를 여러 개 놓아 둠(기본 9개)
 - 각각에 대해 “물체 여부”와 “어떻게 미세 조정해야 하는가”를 CNN으로 추정함
- 이렇게 하면 별도의 Selective Search 없이, CNN 한 번의 피쳐맵 계산으로 후보 영역을 빠르게 얻을 수 있음

2) Fast R-CNN Detector

- RPN이 뽑아준 후보영역(ROI)들이 들어오면, 그 영역에 어떤 물체가 있는지 (클래스)와 좌표를 다시 정밀하게 검출
- 구체적으로는 Fast R-CNN과 똑같이 ROI Pooling → 분류 + 박스 보정을 수행

3) 통합된 학습 과정

- 이미지에 대한 CNN 합성곱을 한 번만 수행 → 이것을 RPN과 Fast R-CNN이 같이 활용
- 단계별 학습 방식:
 1. RPN 먼저 학습 (이미지넷 초기 가중치로 시작)
 2. RPN이 만든 후보영역으로 Fast R-CNN을 학습
 3. 여기서 학습한 detector(분류기)로 다시 RPN를 미세조정
 4. 마지막으로 Fast R-CNN쪽도 다시 미세조정
- 결과적으로 하나의 CNN(합성곱 층) + RPN 층 + Fast R-CNN 층이 합쳐진형태가 됨

4) 장점

- 속도 : 한 장의 이미지에 대해 CNN 합성곱을 여러 번 돌릴 필요없이, 한 번만 계산해도 RPN과 Detector가 동시에 활용함
 - 결과적으로 후보영역 생성이 거의 추가 비용이 10ms 내외로 매우 적음
 - VGG-16 기반으로도 약 5fps 정도의 속도를 낼 수 있음
- 성능 : VOC, COCO 대회에서 매우 높은 정확도 달성
 - RPN이 학습을 통해 물체가 있을 가능성이 높은 영역을 더 잘 뽑아주므로, 최종 검출 성능도 높아짐.

4. Experiments (실험 결과 요약)

(1) 실험 환경 및 평가 지표

- 데이터셋: 주로 PASCAL VOC 2007, 2012 그리고 MS COCO를 사용.
- 평가 지표:
 - PASCAL VOC: mAP(mean Average Precision; IoU=0.5 기준)
 - COCO: mAP@[0.5:0.95] (다양한 IoU 기준 평균)와 mAP@0.5 (VOC와 동일 기준)

(2) PASCAL VOC 2007 실험

1. Selective Search(SS) vs. RPN

- 기존에 많이 쓰인 후보영역 생성 기법인 SS와 비교했을 때, RPN 기반 Faster R-CNN이 비슷하거나 더 나은 성능을 보임.
- 동시에 RPN은 합성곱 계층을 Detector(Fast R-CNN)와 공유하므로, 후보영역 생성 속도가 훨씬 빨라져 전체 시스템 속도를 크게 개선.

2. VGG vs. ZF 모델

- ZF(Zeiler & Fergus) 계열 네트워크: 약 5개 합성곱 계층; 대략 17fps까지 빠름(약간 더 가벼운 모델).
- VGG-16: 합성곱 계층이 13개로 더 깊고 정확도가 더 좋지만, 여전히 5fps 정도 처리 가능.
- 두 모델 모두 SS 대비 빠르면서도 높은 정확도(mAP) 달성.

3. 스케일(anchor 설정) 등 세부 하이퍼파라미터

- 3가지 크기(128^2 , 256^2 , 512^2) × 3가지 비율(1:1, 1:2, 2:1)의 anchor를 사용했을 때 성능이 가장 좋음.
- λ 등 손실 가중치도 폭넓은 값에서 안정적인 결과.

(3) PASCAL VOC 2012 실험

- VOC 2012에서도 비슷한 성능 향상 확인.
- RPN + Fast R-CNN(shared convolution) 사용 시, Selective Search 기반 대비 mAP가 더 높거나 유사하면서 훨씬 빠름.

(4) MS COCO 실험

- MS COCO는 객체 범주도 80종류로 많고, 이미지 수(훈련: 80k, 검증: 40k 등)가 큼.
- Faster R-CNN(VGG-16)으로 ****mAP@[0.5:0.95] ~21%****대 성능 달성 (당시 기준 매우 우수).
- COCO의 넓은 데이터로 학습하면, 이후에 PASCAL VOC에서 성능을 더 높일 수 있음(Transfer Learning 효과).

(5) COCO로 학습해서 VOC에 적용

- COCO에서 학습한 모델을 PASCAL VOC에 직접 적용하면, 별도의 VOC 데이터 없이도 높은 mAP를 얻음.
- COCO로 학습한 모델을 VOC 데이터로 **추가 파인튜닝(fine-tuning)**하면, VOC에서의 성능이 더 크게 상승 (예: VOC 2007은 78%+ mAP).

(6) 속도 측면 정리

- Selective Search 등 기존 기법을 쓰면 후보영역 계산에 CPU기준 1~2초 필요.
- RPN은 합성곱 층을 Detector와 공유하므로, 후보영역을 **추가 10ms 내외**로 예측 가능.
- 최종적으로 **VGG-16을 써도 약 5fps**, ZF 모델이면 **17fps** 정도 달성.

5. Conclusion (결론 요약)

- 이 논문에서 제안한 **Faster R-CNN**은 **RPN**(Region Proposal Network)이라는 작은 네트워크를 사용해, 객체 후보영역을 효율적이면서도 정확하게 추출할 수 있음을 보임.
- RPN과 최종 Detector(Fast R-CNN)가 **하나의 통합된 신경망**으로 구성되어, **합성곱(Convolution) 연산을 공유함으로써 추가 계산량이 거의 들지 않는 후보영역 생성**을 구현.
- 결과적으로:
 - **실시간에 가까운**(약 5fps 수준) 객체 탐지 가능.
 - PASCAL VOC, MS COCO 등 다양한 데이터셋에서 **최고 수준의 검출 정확도** 달성.
 - 깊은 네트워크(예: VGG-16, ResNet-101)와 결합 시, 큰 데이터셋(COCO 등)에서도 뛰어난 성능 보임.
- “후보영역 추출 + 물체 검출” 과정을 하나로 묶어버림으로써, **CNN에 기반한 완전 통합 객체 검출**의 길을 열었고, 이후 이 기법이 다양한 최신 연구(예: Mask R-CNN 등)로 확장·활용되는 기반이 되었다.