



FCN(Fully Convolutional Networks)

이름	홍준기
대학교	동국대학교
학과	산업공학과
날짜	2025년

Abstract

Abstract

1. Introduction

기존 문제 제기

제안 방식(FCN)

2. Fully Convolutional Networks

2.0. 기본 요소

2.1. Adapting classifiers for dense prediction

2.2. Shift-and-Stitch 기법

2.3. Upsampling: (Deconvolution)

2.4. Patchwise 학습 vs. 전체 이미지 학습

3. Segmentation Architecture

3.1. Dataset & Results

PASCAL VOC 2011 용

3.2. 분류기 → FCN 변환

3.3. 의미 정보 + 위치 정보 결합 (Skip Architecture)

4. Results & Conclusions

합성곱 신경망은 강력한 시각 모델로, 계층적인 특징들을 생성함. 이러한 합성곱 신경망만으로, 처음부터 끝까지 (end-to-end) 학습하고, 픽셀 단위의 입력을 픽셀 단위의 출력으로 변환하여, 의미론적 분할(Semantic Segmentation)에서 기존의 최고 성능을 능가할 수 있음을 보여주는 논문임. 기존의 분류 네트워크를 활용하되, 완전 합성곱 네트워크로 변환하고, 의미론적 분할 작업에 이들 네트워크의 학습된 표현을 미세 조정(fine-tuning)하여 전이 학습함. 그후, 우리는 깊고 거친 계층에서의 의미 정보와 얇고 정밀한 계층에서의 외형 정보를 결합하여, 정확하고 세부적인 분할 결과를 만들어내는 새로운 구조를 제안

1. Introduction

기존 문제 제기

- 각 픽셀 단위로 예측하는 이전의 여러 연구들은 각 픽셀을 해당 객체나 영역의 클래스로 분류하는 의미론적 분할(Semantic Segmentation)을 위해 ConvNet을 사용함
 - 이는 여러 한계점이 존재하였음

제안 방식(FCN)

- 픽셀 단위 예측을 위한 end-to-end 학습

- pretrained 모델로부터의 전이 학습
- 기존 분류 네트워크를 **FCN으로 재구성**하고, 그 학습된 표현을 의미론적 분할 작업에 fine-tuning
 - FCN은 임의 크기의 입력에 대해 밀집 출력(dense output)을 생성하며, 전체 이미지를 대상으로 하는 feedforward 연산과 backpropagation으로 학습과 추론 진행
 - 네트워크 내부에 업샘플링 계층을 도입함으로써, 풀링으로 인해 다운샘플링된 feature map에서도 **픽셀 단위의 예측과 학습**이 가능해짐
 - 이는 기존 연구들의 superpixel, proposal, random field, local classifier 같은 전처리/후처리 기법을 사용의 필요를 없

2. Fully Convolutional Networks

2.0. 기본 요소

- ConvNet의 기본 구성요소(합성곱, 풀링, 활성화 함수 등)는 **지역적인 연산**을 수행하고, 상대적인 위치에만 의존.
 - 따라서 입력 크기에 관계없이 연속적으로 계층을 쌓아도 이 구조는 유지
- FCN에 손실 함수를 결합하면 특정 태스크를 정의할 수 있음
 - 손실 함수가 마지막 계층의 공간 위치들에 대한 합이라면, 전체 이미지 단위로 연산하는 것이 patch 단위보다 훨씬 효율

2.1. Adapting classifiers for dense prediction

- 기존의 분류 네트워크(AlexNet, VGG, GoogLeNet 등)는 고정된 크기의 입력을 받아 비공간적인 결과(예: 클래스 라벨)를 출력함
- FCN의 경우, **입력 크기에 상관없이 작동하며, 분류 heatmap**을 출력
 - pooling과 stride 때문에 출력은 입력보다 해상도가 낮아짐
- 실시간 속도가 높음

2.2. Shift-and-Stitch 기법

- **OverFeat**에서 제안한 트릭으로, coarse한 출력을 shifting과 interlacing을 통해 밀집하게 만드는 방식
- 이 방식은 필터를 희소하게 만들고 stride를 줄이는 방식으로 **동일한 효과**를 가짐
- 하지만 계산량이 많고 세밀한 정보 포착하지 못함 → 본 논문 사용X

2.3. Upsampling: (Deconvolution)

- 다운샘플된 출력을 다시 픽셀 수준의 밀집 출력을 얻기 위해 **업샘플링 필요**
- 단순한 **선형 보간(bilinear interpolation)** 대신, deconvolution(또는 transposed convolution) 사용해 학습 가능한 업샘플링 수행
 - 네트워크 내부에서 이 연산을 통해 **end-to-end로 학습 가능**
 - 다층의 deconvolution + 비선형 활성화를 통해 **비선형 업샘플링도 학습**

2.4. Patchwise 학습 vs. 전체 이미지 학습

- 기존 연구들은 patch 단위 학습을 주로 사용했지만, FCN은 전체 이미지 단위 학습이 가능
 - 전체 이미지 학습은 patchwise 학습과 **동일한 데이터 분포를 학습**할 수 있고, 계산적으로 더 효율적
 - class imbalance 조절, 공간 상관성 완화 등도 patchwise에서 중요하지만, FCN에서는 **loss weighting**과 **sampling**으로 해결 가능

3. Segmentation Architecture

3.1. Dataset & Results

PASCAL VOC 2011 용

- 기존 분류기(AlexNet, VGG16, GoogLeNet)를 **FCN(Fully Convolutional Network)** 구조로 변환하고, **in-network upsampling**과 픽셀 단위 손실(pixelwise loss)을 추가해 의미론적 분할(semantic segmentation)에 적용
- 핵심 아이디어: 깊은 계층 Semantic 정보와 얇은 계층의 세밀한 위치정보(appearance)를 skip-connection으로 결합하여 예측을 정교하게 만드는 것

3.2. 분류기→ FCN 변환

- 기존 분류 네트워크(AlexNet, VGG16, GoogLeNet)의 fully connected layer를 **1×1 convolution**으로 변환하고, 클래스 수만큼 채널을 갖는 마지막 convolution layer 추가
- **업샘플링(deconvolution)** 계층을 추가해 coarse한 출력을 원본 이미지 해상도로 보간
- GoogLeNet은 성능이 낮았으며, 성능 차이는 주로 네트워크 구조와 업샘플링 효과 때문

3.3. 의미 정보 + 위치 정보 결합 (Skip Architecture)

- Why?
 - 일반적인 FCN은 출력 stride가 32픽셀로 **출력이 너무 coarse**함 → finer한 예측이 필요함
- 해결방법
 - **FCN-16s**: 마지막 conv7(conv된 fc7) 출력(stride 32)과 pool4 출력(stride 16)을 결합 → 2x 업샘플링 후 더함 → 최종 출력으로 업샘플링
 - **FCN-8s**: 위 결과에 pool3(stride 8) 출력까지 추가 결합 → 약간의 성능 향상 (→ 62.7)
- skip 구조는 **전역 구조를 유지하면서 지역 예측의 정확도를 높임**
- stride를 줄이는 방식(pool5 stride=1 등)은 계산량 증가 및 학습 어려움 때문에 비효율적

4. Results & Conclusions

- **FCN은 분류 ConvNet의 일반화된 형태로**, 의미론적 분할을 위해 매우 적합한 구조임.
- 기존 분류 모델을 FCN으로 확장하고, 다중 해상도 계층을 결합(skip connection)함으로 써:
 - 성능을 **극적으로 향상**하고
 - 복잡한 후처리 없이 **간단하고 빠르게 학습 및 추론** 가능하게 함
- FCN은 단일 태스크뿐 아니라 **멀티모달 입력(RGB+D)**, 멀티태스크 출력(semantic + geometry)에도 잘 작동함을 확인

