

FCN

Fully Convolutional Networks for Semantic Segmentation

Convolutional networks are powerful visual models that yield hierarchies of features. We show that convolutional networks by themselves, trained end-to-end, pixels-to-pixels, exceed the...

 <https://arxiv.org/abs/1411.4038>



Fully Convolutional Networks for Semantic Segmentation

저자 : Jonathan Long, Evan Shelhamer, Trevor Darrell

발행일 : 2014년 11월

0. Abstract

- Convolutional Network는 hierarchical한 feature를 추출할 수 있는 강력한 시각 모델
- End-to-end, Pixel-to-pixel 학습 → Semantic segmentation에서 최첨단 성능 능가
 - End-to-end: segmentation을 위한 filter들이 **learnable**, 하나의 CNN 모델만 사용 (cascade 방식 아님)
 - Pixel-to-pixel: 이미지의 각 pixel에 대해 classification, 모든 pixel을 label하는 dense prediction task 수행
- Fully Convolutional Network (FCN)
 - 입력 크기에 제약 없이 arbitrary-sized input 처리 가능
 - upsampling layer를 통해 subsampled feature → pixel-level output 복원
- Deep semantic info + Shallow appearance info 결합
 - Deep, coarse layer → 의미 중심 정보
 - Shallow, fine layer → 위치와 외관 중심 정보
 - 두 정보를 결합한 skip architecture로 정밀한 segmentation 달성

1. Introduction

Convolutional Network의 발전

- CNN은 전체 이미지 분류뿐 아니라, 구조적(local) 출력이 필요한 과제들에서도 성과를 냄
 - Bounding box 기반 객체 탐지
 - Keypoint (부위) 예측
 - Local correspondence (픽셀 간 매칭)
- 다음 단계: Coarse → Fine → Pixel-level 예측
 - 더 세밀한 단위인 pixel-level prediction, 즉 semantic segmentation으로 확장 필요
 - Semantic segmentation:
 - 이미지의 모든 pixel에 대해 객체 클래스 라벨을 부여
 - 기존 접근법들 존재했지만, 여전히 다음과 같은 한계점 존재

기존 접근 방식의 한계

- 대부분은 Patchwise 방식 사용
 - 작은 이미지 조각(Patch)을 CNN에 넣고 중심 pixel만 예측
 - 계산 비효율 + 중복 많음
- Pre/Post-processing이 복잡함
 - superpixel, region proposal, CRF 등의 처리 필요
 - 모델 구성 복잡해짐
- 작은 convnet 사용 + supervised pre-training 없음

FCN(Fully Convolutional Network)의 제안

- End-to-end, Pixel-to-pixel 학습 구조로 FCN 최초 제안
 1. 모든 pixel을 동시에 예측

2. 기존 분류 CNN (AlexNet, VGG, GoogLeNet) → FCN 형태로 전환
→ Supervised pre-training된 가중치 활용하여 fine-tuning 수행

- FCN의 특징:
 - Arbitrary input size 처리 가능
 - Dense output 생성
 - 전체 이미지를 한 번에 처리:
 - 학습(learning) & 추론(inference) 모두 dense feedforward + backpropagation으로 수행
 - In-network upsampling layer → subsampled feature → pixelwise 복원 가능
 - 추가적인 장치 없이도 state-of-the-art 성능 달성

Semantic vs. Appearance 정보의 결합 필요

- Semantic segmentation은 본질적으로 "무엇"과 "어디"를 함께 예측해야 함
 - Global (semantic) 정보: → 무엇인지 파악
 - Local (appearance) 정보: → 어디에 있는지 파악
- CNN의 deep layer와 shallow layer는 각각 역할이 다름:
 - Deep, coarse layer → 의미 중심 정보 (semantic)
 - Shallow, fine layer → 외관 중심 정보 (appearance)

⇒ 이를 결합하기 위해 "Skip architecture"를 제안

3. Fully convolutional networks

3.0. FCN 기본 개념

- CNN의 각 layer는 3D 텐서: $h \times w \times d$
 - h, w : 공간 정보, d : 채널 (특징맵)
- 각 위치는 입력 이미지 상의 특정 receptive field와 연결되어 있음

- CNN은 translation invariant 구조
→ Conv, Pooling, Activation 등은 지역적 연산이며, 상대적 위치만 고려
- 각 layer의 출력

$$y_{ij} = f_{ks}(\{x_{si+\delta i, sj+\delta j}\}_{0 \leq \delta i, \delta j \leq k})$$

- **k**: kernel size, **s**: stride, **f**: 레이어 타입(convolution, pooling 등)
- 여러 layer를 합성하면 nonlinear 필터 구조가 되어
→ 이를 deep filter = Fully Convolutional Network (FCN)라고 정의

장점


- 입력 크기 제한 없음 → arbitrary-sized input 가능
 - 출력도 입력 크기에 맞는 spatial output 생성
 - pixelwise loss 적용 가능:
→ 예: 모든 출력 pixel에 대해 loss 계산,
→ 전체 이미지 단위로 학습해도 patch-wise와 동일한 SGD 효과
- ⇒ 따라서 patch-wise로 하나씩 돌리는 방식보다 훨씬 효율적

3.1. Adapting classifiers for dense prediction

기존 분류 네트워크의 한계

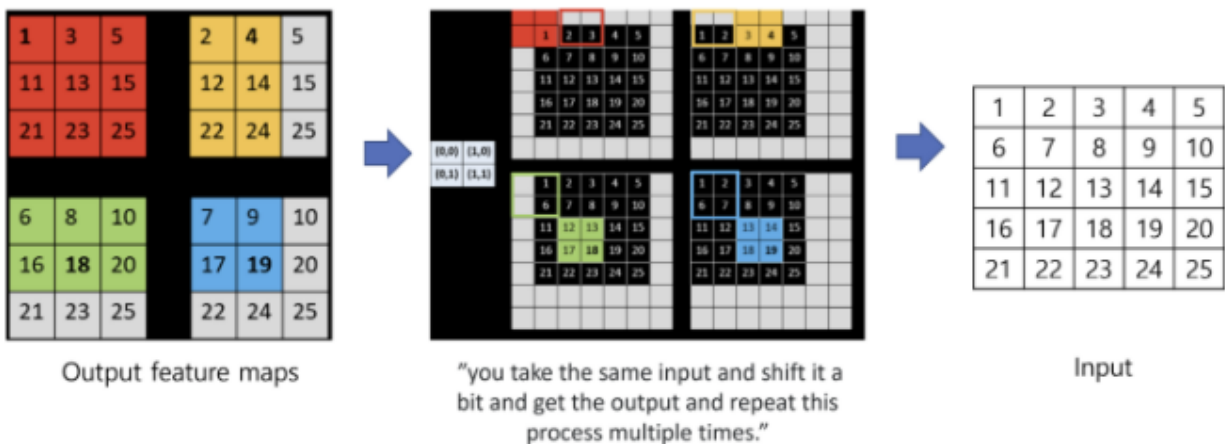
- LeNet, AlexNet, VGG 등은 고정된 입력 크기 요구
- 마지막 fully connected layer는 공간 정보 버림 → 비공간적 출력

해결 방법: Fully Connected → Convolution으로 변환



- Fully connected layer는 전체 영역을 덮는 1x1 conv처럼 간주 가능
- 변환하면:
 - 분류 모델을 heatmap 생성기로 변환 가능
 - 모든 위치에 대한 분류 결과 출력 가능 (dense output)
- 출력 크기 감소 이슈
 - 기존 분류 모델은 연산량을 줄이기 위해 subsampling 사용 (pooling, stride 등)
 - 출력이 입력보다 작아짐(coarse)
 - 이 문제를 해결하기 위한 방법은 3.2 / 3.3에서 제안

3.2. Shift-and-stitch is filter rarefaction



Shift-and-Stitch (OverFeat에서 도입)

- 문제: CNN은 stride와 pooling 때문에 출력이 downsampled (coarse)됨
 - pixel-level prediction이 어려움

- 해결 방법 (Trick)
 - 입력을 다양한 위치로 shift (x, y 방향)하면서 여러 번 CNN에 통과시킴
 - 각 결과(output)를 interlace 하여 dense output map 재구성

같은 결과를 필터 희소화로 재현 가능

- CNN 구조의 stride만 1로 바꾸고, 필터를 희소화(rarefy) 하면 동일 결과 가능
 - 필터의 일부 위치만 값을 갖고, 나머지는 0으로 설정
 - 반복적으로 모든 layer에 적용해야 완전한 shift-and-stitch 재현 가능

Shift-and-Stitch의 한계

- Receptive field 크기는 유지되지만, finer한 정보는 못 씀
- 연산량 증가 → 따라서 **본 논문에서는 사용하지 않음**

3.3. Upsampling is backwards strided convolution

Upsampling = Deconvolution

- 간단한 보간법 (예: bilinear interpolation)은 고정된 방식
- 대안: Deconvolution layer (Transposed Convolution)
 - 입력 stride의 역방향 → 출력 stride를 이용해 dense output 생성
 - 학습 가능한 필터로 구성 가능 (bilinear 고정 아님)

장점

- 네트워크 안에 포함되어 end-to-end 학습 가능
- 역전파로 pixelwise loss까지 연결 가능
- 여러 개의 deconv layer + activation function 조합 → 비선형 upsampling도 가능

결과

- 본 논문에서는 in-network upsampling (deconv layer)을 사용함
 - 더 효율적이고 효과적
 - 이후 Section 4.2에서 skip 구조와 결합하여 정밀도 향상

3.4. Patchwise training is loss sampling

- Patchwise 학습과 Fully Convolutional 학습은 본질적으로 같은 목적을 가짐
 - Fully convolutional 학습은 하나의 이미지에서 모든 receptive field를 사용해 학습하는 방식
- Patchwise 학습의 특징
 - 이미지의 일부분(patch)만 사용하여 gradient 계산
 - 다양한 patch 조합으로 batch 구성 가능
 - 클래스 불균형 완화 및 공간 상관성 감소에 유리함
- Fully Convolutional 학습에서도 동일한 효과 가능
 - Loss sampling 또는 DropConnect 방식으로 일부 위치만 loss 계산에 포함
 - 클래스 가중치 적용 등으로 class imbalance 조절 가능
- 결론
 - 논문 실험에서는 loss sampling을 사용해도 성능이나 학습 속도에서 특별한 이점 없음
 - 따라서 전체 이미지를 사용하는 학습 방식이 더 효율적이고 효과적임

4. Segmentation Architecture

개요

- 기존 ILSVRC 분류 모델(AlexNet, VGG, GoogLeNet)을 FCN 구조로 변환하여 segmentation에 활용
- In-network upsampling과 pixelwise loss를 결합해 dense prediction 수행
- 이후, skip architecture를 추가해 coarse(semantic) 정보 + fine(appearance) 정보를 결합 → 정밀도 향상

학습 설정

- Dataset: PASCAL VOC 2011
- Loss: pixel 단위 다항 로지스틱 손실 (multinomial logistic loss)
- 평가지표: Mean IU
- 주의점: GT에서 애매하거나 어려운 pixel은 무시

4.1. From classifier to dense FCN

사용된 분류 모델

- AlexNet (ILSVRC 2012 우승) / VGG-16 (ILSVRC 2014 참가) / GoogLeNet (ILSVRC 2014 상위권)
- 변환 과정
 - 마지막 분류기(fully connected layer) 제거
 - FC layer → convolution layer로 변환
 - 마지막에 1×1 convolution (채널 수 = 21) 추가
→ PASCAL VOC 클래스 수 (20개 클래스 + 배경)
 - 이후 deconvolution layer를 통해 coarse output을 pixel-level output으로 bilinear upsampling

실험 결과

- Fine-tuning만으로도 각 네트워크가 준수한 segmentation 성능 달성
- 가장 낮은 성능의 모델도 기존 state-of-the-art의 약 75% 성능 도달
- FCN-VGG16: 56.0 mean IU (기존 52.6 [16]보다 우수)
 - 추가 학습 데이터 사용 시: 59.4 mean IU까지 향상
- GoogLeNet은 segmentation 성능이 낮았음, 분류 성능과는 무관

4.2. Combining what and where

기존 FCN의 한계

- 4.1에서 만든 FCN(FCN-32s)은 출력 stride가 32 pixels
→ 업샘플링 결과가 너무 coarse하고 디테일 부족 (자세한 경계 표현 어려움)
- 해결 방법: **Skip Architecture (정보 결합 구조)**
- 상위 레이어(conv7)의 **semantic 정보(what)**+ 하위 레이어(pool4, pool3)의 **appearance 정보(when)**
⇒ 두 정보를 결합(fusion)해 더 정밀한 segmentation 수행

네트워크 확장 구조

- FCN-32s: 기본 FCN (stride 32) : mean IU 59.4
- FCN-16s:
 - pool4에서 1x1 conv로 예측
 - conv7 결과(FCN-32s)를 2배 업샘플링 후 pool4 예측과 합산
→ stride 16 결과 얻음
 - 성능 향상: mean IU 59.4 → 62.4
- FCN-8s:
 - pool3 예측 추가 → pool4 + conv7 fusion 결과를 다시 2배 업샘플링 후 pool3와 합산
→ stride 8 결과
 - 성능 약간 향상: mean IU 62.7

4.3. Experimental framework

학습 설정

- Optimizer: SGD + Momentum(0.9), Minibatch size: 20

- Learning rate:
 - FCN-AlexNet: $1e-3$
 - FCN-VGG16: $1e-4$
 - FCN-GoogLeNet: $5e-5$
- Class scoring layer (1×1 conv): 0으로 초기화
- Dropout: 기존 분류 모델 설정 유지

Fine-tuning 전략

- 전체 레이어 end-to-end fine-tuning
- 마지막 레이어만 학습 시 전체 성능의 70%만 도달
- 학습 시간:
 - FCN-32s: 약 3일
 - FCN-16s / FCN-8s: 각 1일 추가

Patch Sampling 실험

- 일부 픽셀만 loss에 반영하는 sampling 방식 실험
 - 수렴 속도나 성능에 큰 영향 없음
 - 전체 이미지 학습이 더 효율적이라 본 실험에서는 sampling 미사용

Dense Prediction 방식

- Deconvolution으로 업샘플링
 - 최종 레이어: bilinear 고정
 - 중간 레이어: bilinear 초기화 후 학습 가능
- Shift-and-stitch 방식은 사용하지 않음

데이터 증강

- 좌우 반전, 최대 32픽셀 위치 이동(jittering) 시도
→ 성능 향상 없음

추가 학습 데이터 사용 효과

- VOC 2011 (1,112장) → 기본 학습셋
- SDS 확장셋 (8,498장) 추가 시
 - VGG16 성능: mean IU 56.0 → 59.4 (+3.4)

실행 환경

- 프레임워크: Caffe
- GPU: NVIDIA Tesla K40c (단일 GPU)

5. Results

평가 지표 (Metrics)

- **Pixel Accuracy**: 전체 픽셀 중 맞춘 비율
- **Mean Accuracy**: 클래스별 정확도의 평균
- **Mean IU**: 클래스별 IoU의 평균
- **Freq. Weighted IU**: 클래스 출현 빈도를 고려한 IoU

PASCAL VOC (Object Segmentation)

- FCN-8s가 기존 최고 성능(SDS, R-CNN) 대비 20% 상대 향상
- Mean IU (VOC 2012):
 - SDS: 51.6
 - FCN-8s: 62.2
- 추론 속도:

- SDS: ~50초
- FCN-8s: ~175ms (약 286배 빠름)

NYUDv2 (RGB-D Scene Segmentation)

- RGB-D 입력과 다양한 depth 표현 방식(HHA 등) 실험
- 가장 좋은 성능은 RGB + HHA late fusion + FCN-16s
- Mean IU:
 - Gupta et al. (기존 SOTA): 28.6
 - FCN-16s RGB-HHA: 34.0

SIFT Flow (Scene + Geometry Segmentation)

- 33개 semantic 클래스 + 3개 geometric 클래스
- 두 가지 출력(semantic + geometric)을 동시에 학습하는 multi-task FCN-16s 구성
- 기존 모델들과 비교해 두 과제 모두 SOTA 달성
- Semantic Mean IU:
 - Farabet et al.: 29.6
 - FCN-16s: 39.5
- Geometric Accuracy:
 - Tighe: 90.8
 - FCN-16s: 94.3

시각적 성능 (Figure 6 요약)

- FCN-8s는 기존 시스템보다 더 세밀한 구조 표현 가능
- 인접 객체 분리, 가림(occlusion)에 대한 강건함
- 일부 오분류 사례 존재

6. Conclusion

- Fully Convolutional Networks (FCNs)는 기존 분류용 CNN보다 더 일반적인 모델 구조이며,
기존 분류 CNN은 FCN의 특수한 형태에 불과함
- 본 논문은
 1. 기존 분류 CNN을 segmentation 용 FCN으로 확장
 2. *다중 해상도 계층(skip architecture)**을 결합해 성능 향상
 3. 학습과 추론을 더 단순하고 빠르게 만듦
- 결과적으로, FCN은 성능과 효율성(속도, 구조 간결성)을 동시에 달성함.