

Abstract

완전 합성곱 네트워크(FCN)를 설계하여 의미론적 분할에서 기존 기술을 능가하는 성능을 달성했으며, 깊고 거친 계층의 의미론적 정보와 얇고 세밀한 계층의 외형 정보를 결합해 정확하고 빠른 분할을 수행한다. 이를 통해 PASCAL VOC(2012)에서 62.2% mIoU를 기록하며, 기존 대비 20% 성능 향상을 이루었다.

1. Introduction




Figure 1. Fully convolutional networks can efficiently learn to make dense predictions for per-pixel tasks like semantic segmentation.

완전 합성곱 네트워크(FCN)를 설계하여 의미론적 분할에서 기존 최신 기술을 능가하는 성능을 달성했다. FCN은 픽셀 단위 예측을 위해 끝에서 끝까지(end-to-end) 학습되며, 기존 분류 네트워크를 변환해 밀집 예측을 수행한다. 네트워크 내 업샘플링 계층을 활용해 효율적인 학습과 추론이 가능하며, 패치 기반 학습보다 성능과 효율성이 뛰어나다. 또한, 기존 연구들과 달리 초픽셀(superpixel)이나 후처리 없이 정밀한 분할을 수행한다. 마지막으로, 깊은 계층의 의미론적 정보와 얇은 계층의 외형 정보를 결합하는 "스킵(skip)" 구조를 도입하여 정확도를 향상시켰다.

2. Related Work

접근 방식은 딥러닝 기반 이미지 분류와 전이 학습을 활용하여 완전 합성곱 네트워크 (FCN)를 재구성하고, 의미론적 분할을 위한 직접적이고 밀집한 예측을 수행하도록 미세 조정한다. 기존 연구들은 패치 기반 학습, 후처리, 다중 스케일 처리 등을 활용했지만, 우리는 이를 배제하고도 효율적으로 학습한다. FCN은 기존 분류 네트워크를 변환하여 전체 이미지 입력을 기반으로 픽셀 단위 예측을 수행하며, 네트워크 내 업샘플링을 활용해 성능을 극대화한다. 기존 하이브리드 제안-분류 방식과 달리, 저자는 FCN은 **끝에서 끝까지 (end-to-end) 학습**되며, 의미론적 분할에서 최신 성능(state-of-the-art)을 달성한다. 이를 통해 PASCAL VOC 및 NYUDv2 데이터셋에서 기존 방법들과 직접 비교하며 우수한 결과를 보인다.

3. Fully convolutional networks

합성곱 신경망(ConvNet)의 각 층은 ****공간적 차원(h×w)과 채널 차원(d)****을 가진 3D 배열로 구성되며, 상위 층의 위치는 입력 이미지의 특정 영역(수용 영역)과 연결된다. ConvNet은 ****평행 이동 불변성(translation invariance)****을 바탕으로 작동하며, 합성곱, 풀링, 활성화 함수 등의 연산을 통해 비선형 필터를 구성한다. 완전 합성곱 네트워크(FCN)는 입력 크기에 관계없이 작동하며, 픽셀 단위 예측을 위해 coarse한 출력을 원본 해상도로 되돌려야 한다. 이를 위해 OverFeat에서 제안한 기법을 활용하거나, 보다 효율적인 **디컨볼루션(upsampling) 레이어**를 도입한다. 또한, 패치 기반 학습 대신 전체 이미지를 사용하는 학습 방식이 속도와 성능 면에서 효과적임을 실험적으로 증명한다.

3.1. Adapting classifiers for dense prediction




Figure 2. Transforming fully connected layers into convolution layers enables a classification net to output a heatmap. Adding layers and a spatial loss (as in Figure 1) produces an efficient machine for end-to-end dense learning.

기존 인식 신경망(LeNet, AlexNet 등)은 고정 크기 입력을 받아 비공간적 출력을 생성하지만, 완전 연결 층을 전역 합성곱(kernel 크기가 입력 전체인 합성곱)으로 변환하면 완전 합성곱 네트워크(FCN)로 변형할 수 있다. 이를 통해 입력 크기에 관계없이 분류 맵을 생성할 수 있으며, 겹치는 영역을 활용해 계산 속도를 획기적으로 향상시킨다. 예를 들어, AlexNet을 FCN으로 변환하면 **500×500 이미지에서 10×10 출력 맵을 5배 이상 빠르게 생성할 수 있다.** 이러한 공간적 출력 맵은 **의미론적 분할과 같은 밀집 예측(dense prediction) 문제에 적합하며,** 앞/뒤 전파 과정에서도 높은 계산 효율을 유지한다. 다만, 원본 분류 네트워크의 다운샘플링 구조로 인해 출력 해상도는 입력보다 낮아지는 경향이 있다.

3.2. Shift-and-stitch is filter rarefaction

OverFeat에서 제안한 **Shift-and-Stitch 기법**은 입력을 여러 번 시프트한 후 출력을 교차 결합(interlacing)하여 다운샘플링 없이 밀집 예측을 수행하는 방법이다. 필터 크기와 층의 스트라이드를 조정하면 동일한 효과를 낼 수 있지만, 이는 계산 비용과 수용 영역 크기의 트레이드오프를 발생시킨다. 저자는 **업샘플링 기반 학습이 더 효과적이고 효율적**이라고 판단하여, 이 기법 대신 업샘플링과 스킵 연결(skip connection)을 활용한다.

3.3 Upsampling is backwards strided convolution

업샘플링은 보통 보간(interpolation)을 사용하지만, 역합성곱(deconvolution, transposed convolution)을 활용하면 네트워크 내부에서 학습 가능한 업샘플링이 가능하다. 저자는 이를 통해 픽셀 단위 손실을 활용한 엔드투엔드 학습을 수행하며, 실험 결과 이 방법이 빠르고 효과적인 밀집 예측을 가능하게 함을 확인했다.

3.4 Patchwise training is loss sampling

확률적 최적화에서, **전체 이미지 완전 합성곱 훈련은 패치 기반 훈련보다 더 효율적이며,** 각 배치는 이미지의 모든 수용 필드로 구성된다. **랜덤 패치 샘플링**을 통해 클래스 불균형을 해결할 수 있지만, 전체 이미지 훈련이 더 빠르고 효과적인 수렴을 보여준다. 실험 결과, **샘플링을 통한 훈련**은 밀집 예측에서 더 나은 성능을 보이지 않는다.

4. Segmentation Architecture

저자는 **ILSVC 분류기**를 **FCN**으로 변환하고, **업샘플링**과 **픽셀 단위 손실**을 추가하여 밀집 예측을 수행한다. **스킵 아키텍처**를 통해 **세부적인 예측 정제**를 하며, **PASCAL VOC 2011** 데이터셋을 사용해 훈련하고 검증한다.

4.1 From classifier to dense FCN

저자는 **VGG 16** 및 **GoogLeNet**을 **FCN**으로 변환하여 **PASCAL VOC** 세분화 작업을 수행했으며, **VGG 16**은 **56.0 mean IU**를 기록하여 최신 성능에 근접한 결과를 얻었다.

GoogLeNet은 유사한 분류 정확도를 보였으나 세분화 성능은 떨어졌다

4.2 Combining what and where

	FCN-AlexNet	FCN-VGG16	FCN-GoogLeNet ⁴
mean IU	39.8	56.0	42.5
forward time	50 ms	210 ms	59 ms
conv. layers	8	16	22
parameters	57M	134M	6M
rf size	355	404	907
max stride	32	32	32

저자는 새로운 FCN(fully convolutional network)을 정의하여, 세분화된 출력을 위해 피쳐 계층을 결합하고 공간 정밀도를 개선했다. 기존의 FCN 분류기를 세분화에 맞게 미세 조정 한 후, 그 출력이 지나치게 거칠다는 문제를 해결하기 위해 예측 계층과 더 작은 스트라이드를 가진 낮은 계층을 결합하는 링크를 추가했다. 이로써 저자는 FCN-16s 네트워크를 만들었고, 이 네트워크는 출력 성능을 향상시켰다. 추가적인 예측 계층 결합을 통해 FCN-8s 네트워크를 만들었고, 세부적인 구조와 품질을 개선했다. 더 나은 예측을 위해 풀링 계층의 스트라이드를 줄이거나, shift-and-stitch 기법을 사용할 수 있지만, 저자는 레이어 결합이 더 효율적이라고 판단했다.

6. Conclusion

완전 합성곱 신경망(Fully Convolutional Networks, FCN)은 다양한 모델 클래스 중 하나로, 현대의 분류용 합성곱 신경망(convnets)은 그 특별한 사례에 해당한다. 이러한 분류용 신경망을 세분화 작업에 확장하고, 다중 해상도 계층 결합을 통해 아키텍처를 개선함으로써, 최신 기술 수준을 크게 향상시키면서도 학습과 추론을 단순화하고 가속화할 수 있다.