

Generative Adversarial **Networks** (GAN) 정리

생성 모델은 실존하지 않지만 있을 법한 데이터를 생성하는 머신러닝 모델이다. 이미지 데이터의 분포를 근사하는 모델 G를 학습하여 원본 데이터의 분포를 효과적으로 모델링하는 것이 목표이다. 대표적인 생성 모델로는 다음과 같은 방법들이 있다.

- Boltzmann Machine
- Auto-Encoder (AE)
- Generative Adversarial Network (GAN)

GAN은 Auto-Encoder의 개념을 확장하여 Discriminator(판별자)를 추가한 형태로, 두 개의 네트워크가 서로 경쟁하며 학습하는 방식이다.

GAN은 Generator(생성자)와 Discriminator(판별자)로 구성된 신경망으로, 두 네트워크가 서로 경쟁하면서 데이터를 생성하는 모델이다.

GAN의 학습 과정

1. 랜덤한 Noise를 입력으로 받음
2. Generator가 Noise를 기반으로 가짜 이미지를 생성
3. Discriminator가 가짜 이미지와 실제 이미지를 구분
 - 생성된 데이터에 대해 $D(G(z)) = 0$ 을 출력
4. Discriminator가 학습을 통해 진짜/가짜를 더 잘 구별하도록 개선
5. Generator는 Discriminator를 속이도록 더 정교한 가짜 데이터를 생성
6. 궁극적으로 Generator가 Discriminator를 완전히 속이게 되면 학습이 종료됨

GAN의 특성

- Generator는 비지도 학습(Unsupervised Learning)을 통해 실제와 유사한 데이터를 생성
- Discriminator는 지도 학습(Supervised Learning)을 통해 입력 데이터를 분류
- GAN은 지도 학습과 비지도 학습이 함께 존재하는 구조

GAN의 수식

GAN의 목적 함수는 다음과 같이 정의된다.

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

- **Discriminator Loss:** 실제 데이터에 대해 높은 확률을 부여하고, 가짜 데이터에는 낮은 확률을 부여하는 방향으로 학습

$$L_D = -[\log D(x) + \log(1 - D(G(z)))]$$

- **Generator Loss:** Discriminator를 속이도록 학습

$$L_G = -\log D(G(z))$$

- Discriminator는 Binary Cross-Entropy를 사용하여 손실을 계산하고, Generator는 Discriminator의 가중치를 이용하여 학습을 진행

GAN의 한계

- GAN의 성능을 수치화하여 객관적으로 평가하는 방법이 부족함
- 생성된 데이터가 새롭기 때문에 기존 데이터와 직접 비교하기 어려움

학습 불안정성

- GAN은 min-max 최적화 문제를 풀어야 하므로 학습이 불안정함
- Discriminator가 지나치게 강해지면 Generator의 학습이 어려워짐

이러한 한계를 해결하기 위해 다양한 변형 모델이 등장하였다.

GAN의 종류: DCGAN (Deep Convolutional GAN)

DCGAN은 기존 GAN의 MLP(다층 퍼셉트론) 대신 합성곱 신경망(CNN)을 사용하여 안정적인 학습을 가능하게 만든 모델이다.

DCGAN의 특징

Generator: 전치 합성곱(Transposed Convolution, Deconvolution)을 사용하여 이미지를 생성

Discriminator: 합성곱 신경망(CNN) 구조를 사용하여 이미지의 진위 여부를 판별

안정적인 학습 기법 적용

- Batch Normalization 사용
- Fully Connected Layer 제거 → 학습 안정성 및 성능 향상
- Discriminator에서 Leaky ReLU 활성화 함수 사용

DCGAN은 기존의 Vanilla GAN보다 고해상도의 이미지를 생성할 수 있으며, 학습이 더 안정적으로 진행된다는 장점이 있다.

결론

GAN은 생성 모델 중에서 가장 강력한 기술 중 하나로, 이미지 생성, 데이터 보강, 스타일 변환 등 다양한 분야에서 활용되고 있다. 그러나 학습의 불안정성과 평가의 어려움과 같은 문제를 해결하기 위해 다양한 변형 모델들이 제안되었으며, DCGAN은 그 중에서 대표적인 개선 모델이다.

향후 연구는 보다 안정적인 학습 방법과 평가 지표의 개선에 초점을 맞출 필요가 있다.