

BERT

1. 연구 배경 및 필요성

- 기존 언어 모델들은 좌→우 또는 우→좌의 단방향 특성으로 인해 문맥 정보가 충분히 반영되지 못함.
- ELMo처럼 양방향 정보를 활용하려는 시도와, GPT와 같이 fine-tuning을 활용하는 방식의 한계 극복 필요성이 대두됨.

2. BERT 모델의 핵심 개념

- **양방향 학습 (Bidirectional Self-Attention):**

문장 전체를 동시에 고려하여 더 풍부한 문맥 정보를 학습.

- **입력 표현:**

- *Token Embedding:* WordPiece 방식을 사용하여 어휘 크기를 줄이고, OOV 문제 해결.
- *Segment Embedding:* 문장 A와 문장 B 구분.
- *Position Embedding:* 단순 숫자 기반의 위치 정보로 문장 내 단어 순서 파악.
- 특수 토큰 [CLS]와 [SEP]를 활용해 분류 및 문장 쌍 처리 가능.

3. 사전 학습 (Pre-training) 전략

- **Masked Language Model (MLM):**

전체 단어 중 15%를 선택해 80%는 [MASK], 10%는 무작위, 10%는 그대로 유지하여 학습.

- **Next Sentence Prediction (NSP):**

두 문장이 실제로 이어지는지를 50:50 비율로 학습하여 문장 간 관계를 이해.

4. Fine-tuning 접근법 및 실험 결과

- 사전 학습된 파라미터를 기반으로 각 downstream task에 맞게 모델 전체를 미세 조정.
- GLUE, SQuAD, SWAG 등 다양한 NLP 태스크에서 SOTA 성능 달성.
- Ablation Studies를 통해 사전 학습 방식과 모델 크기의 효과 분석.

5. 결론

- 대규모 unlabeled 데이터를 활용한 사전 학습과, 이를 각 작업에 맞게 fine-tuning하는 접근법이 NLP 태스크의 성능 향상에 크게 기여함을 입증.

GPT-1

1. 연구 배경 및 문제의식

- 대량의 unlabeled 텍스트 데이터를 활용해 언어 모델을 학습하는 것이 중요하며, 라벨링 비용 문제를 해결할 필요가 있었음.
- 기존 RNN/LSTM의 장기 의존성 문제와 한계 극복이 주요 과제였음.

2. GPT-1의 접근 방식

- **Unsupervised Pre-training:**

- Transformer의 Decoder 구조를 사용하여, 언어 모델로서 다음 토큰 예측을 위해 대규모 unlabeled 데이터를 학습.
- Autoregressive 방식으로 문맥에 맞는 단어 생성.

- **Supervised Fine-tuning:**

- 사전 학습된 모델을 각 특정 태스크에 맞게 미세 조정.
- Task-specific input transformation을 통해 분류, NLI, QA 등 다양한 문제에 적용.

3. 모델 구조와 학습 원리

- **Transformer Decoder 사용:**

- Cross Attention 없이 단독으로 사용해 간결한 구조와 연산 효율 확보.
- Masking을 통해 미래 단어에 대한 정보 노출 방지하며 순차적 토큰 예측 수행.

- **목적 함수 및 학습 전략:**

- Unsupervised objective와 supervised objective를 동시에 고려하여, 모델이 언어의 특성을 풍부하게 학습하도록 함.
- Auxiliary objectives (예: Denoising, NSP 등)도 언급하며, 이를 통해 일반화 능력과 표현력을 강화.

4. 실험 및 평가

- BooksCorpus 등 대규모 데이터셋을 활용하여 언어 모델의 perplexity를 낮춤으로써 높은 생성 능력 입증.
- 다양한 downstream task (NLI, QA, Semantic Similarity, 분류 등)에서 fine-tuning 후 SOTA 성능 달성.
- 모델의 전이 학습 능력과 zero-shot 성능 평가를 통해, 단일 모델이 여러 태스크에 적용 가능함을 확인.

5. 결론

- GPT-1은 대규모 비지도 학습을 통해 사전 학습된 언어 표현이 downstream 태스크에서 뛰어난 성능으로 이어질 수 있음을 보여줌.
- Transformer Decoder를 활용한 간결한 모델 구조와, unsupervised pre-training + supervised fine-tuning 전략이 효과적임을 증명.