

GPT-1

Improving Language Understanding by Generative Pre-Training

https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf

0. Abstract

자연어 이해(NLU)에는 다양한 과제가 포함되지만, 대부분의 과제는 레이블이 부족하여 학습이 어렵다. 이를 해결하기 위해 우리는 대규모 비지도 사전 학습 후, 특정 과제에 대한 지도 학습을 수행하는 방식을 제안한다. 기존 방법과 달리, 최소한의 모델 변경으로 효과적인 전이를 가능하게 하는 task-aware input transformations를 활용한다.

1. Introduction

자연어 처리는 대부분 지도 학습에 의존하지만, 레이블이 부족한 경우가 많아 적용이 어렵다. 따라서 비지도 학습을 활용하여 더 나은 표현을 학습하는 것이 중요하다. 기존 연구는 단어 임베딩과 다양한 최적화 목표(언어 모델링, 기계 번역 등)를 활용했으나, 최적 방식에 대한 합의가 부족하다. 연구에서는 변형이 거의 필요 없는 사전 학습된 언어 모델을 제안하며, Transformer를 사용하여 장기 의존성을 효과적으로 처리한다. 해 모델은 4가지 자연어 이해 과제에서 기존 모델을 능가하며, 사전 학습된 모델이 다양한 다운스트림 작업에서 유용한 언어적 지식을 습득할 수 있음을 보여준다.

+) 4가지 자연어 이해 과제

1. **자연어 추론(NLI)** - 두 개의 문장이 주어졌을 때, 두 문장이 참/거짓/중립 관계인지 판단
2. **질의응답(QA)** - 질문에 대한 정답을 문서에서 찾거나 생성
3. **의미적 유사도(Semantic Similarity)** - 두 문장이 얼마나 비슷한 의미를 가지는지 측정
4. **문서 분류(Text Classification)** - 텍스트를 특정 카테고리(긍정/부정, 뉴스 주제 등)로 분류

→ 4가지 과제를 해결하기 위해 사전학습한 언어 모델을 활용하고, 파인튜닝 진행하면 성능 향상할 것

2. Related Work

- **Semi-supervised learning for NLP**

- 라벨이 부족한 자연어처리 데이터에서 일부는 지도학습, 일부는 비지도학습 방식을 사용
- 과거에는 단어/구 단위 통계 정보를 활용해 지도 모델의 입력 피처로 사용했음
- 최근에는 워드 임베딩 기법을 사용해 NLP 성능을 향상시켰지만, 이는 단어 수준 정보만 전달
- 본 연구는 문장 수준 이상의 의미를 학습하는 것에 집중

- **Unsupervised Pre-training**

- 지도학습 모델의 초기 가중치를 효과적으로 설정하는 방식
- 과거에는 이미지 분류, 음성 인식 등에 적용됨
- 최근 연구에서는 언어 모델 사전학습 후, 지도학습으로 파인튜닝 하는 방식 사용
- 기존 연구(Dai et al. & Howard and Ruder)는 LSTM 기반 모델을 활용했지만, LSTM의 단기 의존성 문제가 있음
- 본 연구는 Transformer 모델을 사용하여 장기 의존성을 효과적으로 학습

- **Auxiliary Training Objectives (보조 학습 목표)**

- 보조적인 비지도 학습 목표를 추가하여 성능을 향상하는 방법
- 품사 태깅, 개체명 인식, 문장 구조 분석 등의 NLP 태스크 활용
- Rei(2017) 연구에서는 언어 모델링을 보조 목표로 추가하여 성능을 개선
- 본 연구에서도 비지도 사전학습만으로도 충분히 다양한 언어적 특징을 학습할 수 있음을 실험적으로 증명

3. Framework

3.1 비지도 사전 훈련

- 대규모 텍스트 코퍼스를 사용하여 언어 모델을 학습한다.
- Transformer 기반 디코더를 활용하여 문맥 내 토큰의 확률을 예측한다.
- self-attention와 position encoding을 사용하여 토큰의 표현을 학습한다.

3.2 지도 미세 조정

- 훈련된 언어 모델을 지도 학습 태스크(분류 등)에 맞춰 조정한다.
- 입력 토큰을 변환하여 최종 Transformer 레이어의 출력을 선형 계층(softmax)으로 전달해 예측한다.
- 언어 모델링을 보조 목표로 포함하여 모델의 일반화 성능과 학습 속도를 개선한다.




Figure 1: (left) Transformer architecture and training objectives used in this work. (right) Input transformations for fine-tuning on different tasks. We convert all structured inputs into to sequences to be processed by our pre-trained model, followed by a linear+softmax layer.

3.3 Task-specific input transformations

For some tasks, like text classification, we can directly fine-tune our model as described ab

원: 트랜스포머 아키텍처 및 훈련 목표

- 입력 임베딩(텍스트 + 위치 정보)을 받아 multi-head self-attention 및 feed forward 레이어를 반복적으로 거침
- 텍스트 예측 또는 테스트 분류 수행

오: 태스크별 입력 변환 방식

- 모든 태스크의 입력을 토큰 시퀀스 형태로 변환한 후, 사전 훈련된 트랜스포머 모델을 거쳐 선형 계층으로 출력
 - **텍스트 분류(Classification):** 시작 토큰 → 입력 텍스트 → Transformer → Linear
 - **텍스트 함의(Entailment):** 전제(Premise) + 가설(Hypothesis) 사이에 구분자 추가

- **유사도(Similarity)**: 두 문장을 다른 순서로 배치한 후 Transformer에 개별적으로 입력 → 두 출력을 더한 후 Linear 적용
- **질문 응답(QA) 및 다중 선택(Multiple Choice)**: 문맥 + 질문 + 각 정답 후보를 각각 독립적으로 Transformer에 입력 후 softmax로 정답 선택

3.3 태스크별 입력 변환

- 텍스트 분류: 기존 방식 그대로 fine-tuning 수행
- 텍스트 함의(Entailment): 전제(p)와 가설(h)을 구분자(\$)로 연결
- 문장 유사도: 두 문장의 모든 순서를 고려하여 처리 후 합산
- 질문 응답(QA) 및 상식 추론: 문맥(z), 질문(q), 후보 정답(ak)을 구분자(\$)로 연결 후 각각 독립적으로 처리하여 softmax로 정답을 예측

4. Experiments

- 비지도 학습: BooksCorpus 데이터셋을 사용함. 이 데이터셋은 7,000권 이상의 책에서 추출된 텍스트로, 긴 텍스트를 기반으로 학습하여 장기적인 정보를 처리할 수 있음. 모델은 18.4의 낮은 perplexity를 기록함.
- 모델 사양: 12-layer 디코더 기반 트랜스포머 모델로, 768 차원의 상태와 12개의 attention 헤드를 사용함. 학습은 Adam 최적화 방법을 사용하고, 학습률은 초기 2000번 업데이트 후 선형 증가하고 cosine 스케줄로 감소함.
- 파인튜닝: 파인튜닝 시 학습률은 $6.25e-5$, 3번의 에포크

- GLUE 벤치마크 성능 비교
 - +) 자연어 이해 작업을 평가하는 벤치마크로, 모델이 여러 가지 언어 처리 작업을 얼마나 잘 수행하는지 확인

주요 결과:

- 최고 점수를 초과, 성능 부분에서는 다른 최신 모델 능가하거나 비슷한 성과를 보임

- 자연어 추론(NLI) 성능 비교

주요 결과:

- **MNLI**: 해당 모델은 90.8%의 정확도를 기록하며 이전 최고 모델을 초과함

- **SNLI**: 성능이 이전 최고 성과와 비슷하거나 조금 더 향상됨
- **RTE**: 해당 모델은 0.5% 향상
- 질문 응답(QA) 성능 비교
주요 결과:
 - **RACE**: 해당 모델은 90.3%의 정확도로 우수한 성과를 보였으며, 이전 모델을 초과함.
 - **Story Cloze Test**: 91.8%의 정확도를 기록하며, 이전 최고 성과를 뛰어넘음.
- 문장 유사성 성능 비교
주요 결과:
 - **STS-B**: **92.2**의 Pearson 상관계수를 기록하며 최고 성과를 보임.
 - **QQP**: **4.2%** 향상된 성과를 보였고, **MRPC**는 89.1%의 정확도를 기록하며 이전 최고 성과를 초과함.
- 감정 분석 성능 비교
주요 결과:
 - **SST-2**: 91.3%의 정확도로 이전 최고 성과를 능가함.
 - **CoLA**: **60.8**의 성과를 기록하며, 기존 최고 성과를 뛰어넘음.

5. Analysis

모델 성능 분석

- 전이 학습 - 전이된 레이어 수가 증가할수록 성능 향상됨
- 제로샷 성능 (레이블이 없는 데이터만으로 성능 보여주는 능력) - Transformer > LSTM
- 사전 학습 없는 Transformer - 14.8% 감소함 ⇒ 사전 학습이 성능 향상에 매우 중요함

6. Conclusion

- generative pre-training + discriminative fine-tuning 으로 자연어 이해 달성하는 프레임워크 소개
- 비지도 학습을 활용하여 판별적 작업의 성능 향상 시킬 수 있음

- models (Transformers) and data sets (text with long range dependencies)가 중요한 역할 수행