



GPT-1

Improving Language Understanding by Generative Pre-Training

저자 : Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever (OpenAI)

발행일 : 2018년 6월

0. Abstract

- unlabeled text data는 엄청나게 많은 반면, labeled text data는 적기 때문에 지도학습을 기반으로 한 모델들은 충분한 성능을 내기 어렵다.
- 따라서 본 논문에서는 **generative pre-training**를 통해 언어 모델을 대규모의 **unlabeled** 텍스트 코퍼스에서 먼저 학습시키고, 이후 각 특정 작업별로 지도학습을 활용한 미세 조정을 진행하면서 성능을 향상시킨다.
- 이를 통해 완성된 모델은 기존의 특정 task만을 위해 만들어진 모델들보다 뛰어난 성능을 보였으며, 12개의 작업 중 9개의 작업에서 성능이 더 우수했다.

1. Introduction

대부분의 딥러닝 기법은 대량의 수작업으로 라벨링된 데이터가 필요하지만, 주석이 달린 데이터가 부족하여 적용이 제한된다. 이러한 상황에서 라벨링되지 않은 데이터로부터 언어적 정보를 얻어낼 수 있는 모델은 지도학습의 훌륭한 대안이 되기도 한다.

1. unlabeled text를 이용한 모델 학습이 어려운 이유

- 어떤 최적화 목표(objective)가 텍스트 표현 학습에 가장 효과적인지 명확하지 않다.
 - Language Modeling, Machine Translation, Discourse Coherence 등

- 각각의 방법이 특정 NLP task에서 성능이 뛰어나지만 모든 task에서 최적의 방법은 아직 불명확함
 - 학습된 representation을 target task로 transfer시키는 가장 효과적인 방법에 대한 합의가 없다.
- 이러한 불 확실성으로 인해 NLP에서 효과적인 semi-supervised learning 접근법을 개발하는 것이 어려운 과제임

2. 논문의 연구 방식

따라서, 이 논문에서는 비지도 사전 학습(unsupervised pre-training)과 지도 미세 조정(supervised fine-tuning)을 결합한 반지도 학습 방법을 연구

- 첫 번째는 unlabeled data에 language modeling objective를 사용하여 초기 파라미터들을 학습
- 두 번째는 labeled data를 사용하여 이 초기 파라미터들을 주어진 목표 작업에 맞게 조금 수정

→ 비라벨 데이터와 태스크별 데이터가 동일한 도메인일 필요 없음

3. 사용한 모델 구조

Transformer사용

- 순환 신경망(RNN)보다 장기 의존성(long-term dependencies)을 더 효과적으로 처리 가능
- 다양한 태스크에서 최소한의 fine-tuning을 통해 transfer가 가능

2. Related Work

1. Semi-supervised learning for NLP

- 초기 접근 방식들은 라벨이 없는 데이터를 활용하여 단어 수준 또는 구 수준의 통계를 계산하고, 이를 지도학습 모델의 특징으로 사용하는 방식

- 최근 연구들은 unlabeled data에서 학습한 단어 임베딩이 다양한 NLP task의 성능을 향상시키는 데 효과적이라는 점을 입증함

→ 그러나 기존 연구들은 대부분 단어 단위의 정보를 학습했고, 본 연구에서는 더 높은 수준의 의미를 포착하는 것을 목표로 함

2. Unsupervised pre-training

- 비지도 사전 학습은 반지도 학습의 한 형태로, 지도학습 목표를 직접 변경하는 것이 아니라 모델을 위한 좋은 초기 가중치를 찾는 방식 (objective를 직접적으로 최적화하지 않음)
- 초기 연구들은 이미지 분류 및 회귀 task에서 사전 학습 기법을 탐색
- 이후 연구들은 사전 학습이 일종의 정규화 역할을 하여 신경망의 일반화 성능을 향상시킨다는 점을 발견

3. Auxiliary training objectives

- auxiliary unsupervised training objectives를 추가하는 것은 semi-supervised learning의 대안에 가까움
- 초기 연구에는 다양한 보조 NLP task를 추가하여 의미 역할 라벨링(semantic role labeling) 성능을 향상시킴
- 최근 연구에서는 보조 학습 목표로 언어 모델링(Language Modeling) 목표를 추가하여 시퀀스 라벨링(sequence labeling) 성능을 향상시킴

→ 본 논문도 auxiliary objective를 사용하지만, 실험 결과를 통해 unsupervised pre-training 자체가 이미 target task와 관련된 몇 가지 언어적 지식을 효과적으로 학습할 수 있음을 입증함

3. Framework

훈련 과정은 크게 두 가지 stage로 나뉜다.

(1) Language Model을 대용량 Corpus에서 Unsupervised pre-training

(2) Labeld data를 사용하여 Pre-train 된 Language Model을 Supervised fine-tuning

3.1. Unsupervised pre-training

token의 비지도 말뭉치 $U = \{u_1, \dots, u_n\}$ 이 주어질 때, standard language model 목적 함수를 사용하여 다음 가능도를 최대화하도록 학습을 진행한다.

k : size of context window (다음 단어를 예측할 때 참고할 이전 단어들의 개수)

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

- 조건부확률 P 는 parameter가 Θ 인 신경망을 사용하도록 설계된다
- 이는 확률적 경사 하강법(SGD)에 의해 학습

모델 구조

GPT는 언어 모델로 Transformer의 변형인 **multi-layer Transformer decoder** 사용

트랜스포머 디코더는 입력된 문맥 토큰들을 처리하여 다음 단어의 확률 분포를 생성

입력 벡터 생성 → 입력 문맥 token에 multi-headed self-attention을 적용 → position-wise feedforward layer를 적용하여 token에 대한 출력 분포를 얻음

$$\begin{aligned} h_0 &= UW_e + W_p \\ h_l &= \text{transformer_block}(h_{l-1}) \forall i \in [1, n] \\ P(u) &= \text{softmax}(h_n W_e^T) \end{aligned}$$

- U : token의 문맥 벡터
- k : layer의 수
- W_e : token embedding matrix (단어를 고유한 벡터로 변환)
- W_p : positional embedding matrix (문장 내에서 각 단어의 위치 정보를 반영하기 위해 사용)

3.2. Supervised fine-tuning

$$P(y|x^1, \dots, x^m) = \text{softmax}(h_l^m W_y).$$

input sequence : $x_1, x_2, \dots, x_m$ / 출력 라벨 : y

- 입력 데이터를 사전 학습된 모델에 통과
- 최종 트랜스포머 블록의 activation의 활성화 값 h_l^m 을 얻음
- Softmax 함수를 적용하여 각 가능한 라벨 y 에 대한 확률 분포를 생성

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y|x^1, \dots, x^m).$$

- 데이터셋 $\mathcal{C}$ 에서 모든 샘플 (x,y) 에 대해 로그 가능도를 최대화

$$L_3(\mathcal{C}) = L_2(\mathcal{C}) + \lambda * L_1(\mathcal{C})$$

- 일반화 성능을 높이고 학습을 빠르게 하기 위해 사용
- $L_2(\mathcal{C})$: 지도 학습의 손실
- $L_1(\mathcal{C})$: 언어 모델링 손실
- λ : 언어 모델링 손실의 가중치

→ 지도학습을 수행하면서도 언어 모델링의 효과를 유지하여 성능을 높일 수 있음


3.3. Task-specific input transformations

텍스트 분류와 같은 일부 task는 위 설명대로 모델을 직접 fine-tuning할 수 있다.

그러나 Q-A(Question and Answering) 혹은 textual entailment 같은 특정 다른 task에는 순서가 지정된 문장 쌍, 문서 혹은 질문과 답변처럼 구조화된 inputs가 존재한다. pre-trained

model은 연속된 text sequence에 대해 학습되었기 때문에, 이를 특정 task에 적용하기 위해 몇 가지 수정이 필요하다.

본 연구는 구조화된 입력을 사전 훈련된 모델이 처리할 수 있는 순서로 변환하는 **traversal-style approach**를 사용한다. 이를 통해 작업 전반에 걸친 아키텍처를 광범위하게 변경하는 것을 피할 수 있다.



모든 transformation에는 시작 및 종료 토큰(<s> & <e>)를 추가하는 작업이 포함 된다.

Textual entailment

텍스트 함의란 주어진 전제가 가설을 논리적으로 함의하는지 여부를 판단하는 task

전제(p)와 가설(h)를 연결하여 하나의 입력 시퀀스로 변환

중간에 구분자 토큰을 추가하여 두 문장을 구분함

Similarity

유사도 분석이란 두 개의 문장이 의미적으로 유사한지 여부를 판단하는 task

어느 문장이 먼저 와도 결과가 같아야함

두 가지 문장 순서를 모두 포함하여 두 개의 입력 시퀀스를 생성 → 각각 독립적으로 처리 → 두 결과를 요소별로 더한 후 최종 예측 수행

Question Answering and Commonsense Reasoning

질의 응답이란 주어진 문서와 질문을 기반으로 올바른 답변을 선택하는 task

상식 추론은 기본적인 상식을 바탕으로 적절한 답변을 찾는 문제

문맥(z)과 질문(q)를 연결한 후 각각 가능한 답변을 하나씩 추가하여 입력 시퀀스 생성 → 구분자 토큰을 추가하여 문맥과 답변 분리 → 각각 입력 시퀀스를 독립적으로 처리한 후 softmax로 확률 계산

4. Experiments

4.1. Setup

Unsupervised Pre-training

- BooksCorpus 사용
 - 다양한 장르의 7000권 이상의 미공개 책으로 구성된 대규모 텍스트 코퍼스
 - 장기 의존성 학습 가능

Task	Datasets
Natural language inference	SNLI [5], MultiNLI [66], Question NLI [64], RTE [4], SciTail [25]
Question Answering	RACE [30], Story Cloze [40]
Sentence similarity	MSR Paraphrase Corpus [14], Quora Question Pairs [9], STS Benchmark [6]
Classification	Stanford Sentiment Treebank-2 [54], CoLA [65]

Model Specifications

- Transformer 기반 12 layer 디코더 전용 모델 사용 (768차원 hidden state, 12개 어텐션 헤드)
- Adam 옵티마이저 (최대 학습률 2.5e-4, 2,000 스텝 warm-up 후 cosine 스케줄)
- 100 에포크(epoch), 배치 크기 64, 각 샘플 512 토큰 사용
- BPE 단어 사전(40,000 단어), GELU 활성화 함수 적용, LayerNorm 사용
- Dropout= 0.1, L2 정규화 적용

- BooksCorpus 데이터셋 전처리(ftfy + spaCy tokenizer 사용)

Fine-tuning Details

- 비지도 학습과 동일한 하이퍼파라미터 유지
- 분류기(classifier)에 dropout = 0.1 추가
- 학습률 = 6.25e-5, 배치 크기 = 32
- 대부분의 태스크에서 3 에포크만으로 충분
- 학습률 스케줄: 선형 감소(linear decay), 0.2% 훈련 동안 warm-up
- 보조 학습 목표(λ) = 0.5 설정

4.2. Supervised fine-tuning

자연어 추론(NLI), 질의응답(Question Answering), 의미적 유사도(Semantic Similarity), 텍스트 분류(Text Classification) 등의 다양한 지도 학습 task에서 실험을 수행

Natural Language Inference

자연어 추론은 주어진 문장 쌍을 읽고 그 관계를 "함의(entailment)", "모순(contradiction)", "중립(neutral)" 중 하나로 분류하는 task

Method	MNLI-m	MNLI-mm	SNLI	SciTail	QNLI	RTE
ESIM + ELMo [44] (5x)	-	-	<u>89.3</u>	-	-	-
CAFE [58] (5x)	80.2	79.0	<u>89.3</u>	-	-	-
Stochastic Answer Network [35] (3x)	<u>80.6</u>	<u>80.1</u>	-	-	-	-
CAFE [58]	78.7	77.9	88.5	<u>83.3</u>		
GenSen [64]	71.4	71.3	-	-	<u>82.3</u>	59.2
Multi-task BiLSTM + Attn [64]	72.2	72.1	-	-	82.1	61.7
Finetuned Transformer LM (ours)	82.1	81.4	89.9	88.3	88.1	56.0

→ 본 논문에서 제안한 모델이 5개 중 4개의 데이터셋에서 기존 모델을 능가하며 성능 향상을 보임

→ 이때, RTE는 비교적 작은 데이터셋으로 논문의 방법에서 정확도가 더 낮게 나옴. 다중 task 학습을 수행하면 성능이 향상될 가능성이 있음

Question answering and commonsense reasoning

질의응답(QA) 태스크는 단일 문장 및 다중 문장 추론이 필요한 문제

- RACE 데이터셋
 - 중학교 및 고등학교 시험 지문(passage)과 관련된 질문이 포함된 데이터셋
 - 다른 QA 데이터셋(SQuAD, CNN)보다 논리적 추론(logical reasoning)이 필요한 질문이 많음
- Story Cloze Test
 - 주어진 이야기(story)에서 두 개의 엔딩 후보 중 올바른 엔딩을 선택하는 task

Method	Story Cloze	RACE-m	RACE-h	RACE
val-LS-skip [55]	76.5	-	-	-
Hidden Coherence Model [7]	<u>77.6</u>	-	-	-
Dynamic Fusion Net [67] (9x)	-	55.6	49.4	51.2
BiAttention MRU [59] (9x)	-	<u>60.2</u>	<u>50.3</u>	<u>53.3</u>
Finetuned Transformer LM (ours)	86.5	62.9	57.4	59.0

→ 이전 최적 모델 대비 Story Cloze에서 8.9% 증가 / RACE에서 5.7% 증가

→ 긴 문맥(long-range context)을 효과적으로 처리하는 모델의 능력을 입증

Semantic Similarity

두 문장이 의미적으로 동등한지를 판단하는 task

의미 재구성 감지, 부정 이해, 구문적 모호성 등으로 인해 어려움

- **MRPC (뉴스 데이터 기반 패러프레이징) / QQP (Quora 질문 쌍 데이터셋) / STS-B (Semantic Textual Similarity Benchmark)**

→ STS-B에서 1.0점 절대 향상(absolute gain)

→ QQP에서 4.2% 절대 향상

Classification

문서 분류(Classification) task 2개 평가

- CoLA (Corpus of Linguistic Acceptability) → 문장이 문법적으로 올바른지 판단
- SST-2 (Stanford Sentiment Treebank) → 긍정/부정 감정 분석

Method	Classification		Semantic Similarity			GLUE
	CoLA (mc)	SST2 (acc)	MRPC (F1)	STSB (pc)	QQP (F1)	
Sparse byte mLSTM [16]	-	93.2	-	-	-	-
TF-KLD [23]	-	-	86.0	-	-	-
ECNU (mixed ensemble) [60]	-	-	-	<u>81.0</u>	-	-
Single-task BiLSTM + ELMo + Attn [64]	<u>35.0</u>	90.2	80.2	55.5	<u>66.1</u>	64.8
Multi-task BiLSTM + ELMo + Attn [64]	18.9	91.6	83.5	72.8	63.3	<u>68.9</u>
Finetuned Transformer LM (ours)	45.4	91.3	82.3	82.0	70.3	72.8

→ CoLA에서 45.4점으로 기존 최고 모델(35.0) 대비 큰 향상


→ SST-2에서 91.3% 정확도로 최첨단 성능과 경쟁 가능

→ GLUE 벤치마크 총점 72.8 획득 (이전 최고 모델: 68.9)

5. Analysis

1. Impact of number of layers transferred

비지도 사전학습에서 지도학습 task로 전이되는 레이어의 수가 성능에 미치는 영향을 관찰
MultiNLI와 RACE task에서 전이된 레이어 수에 따른 성능 변화를 시각화




- 일반적으로 사전 학습된 임베딩을 전이하면 성능이 향상됨
- 각 Transformer layer를 추가로 전이할수록 성능이 더 개선
- MultiNLI의 경우 모든 레이어를 전이했을 때 성능이 최대 9% 증가

⇒ 사전 학습된 모델의 각 레이어가 지도 학습 task를 해결하는 데 유용한 기능을 포함하고 있음을 시사함

2. Zero-shot Behaviors

Transformer 기반 언어 모델이 사전 학습(pre-training) 과정에서 여러 NLP 태스크를 자연스럽게 학습하는 이유를 분석하고자 함

- **CoLA (문법성 판별)** → 모델이 할당한 **토큰 로그 확률 평균**을 기준으로 문장을 평가하고 임계값(threshold)으로 예측 수행
- **SST-2 (감정 분석)** → 문장 끝에 ****"very"****를 추가 후, 모델이 **"positive"** 와 **"negative"** 중 더 높은 확률을 할당한 단어를 정답으로 선택
- **RACE (질의응답)** → 문맥과 질문을 주어진 후, **각 선택지 중 모델이 가장 높은 평균 토큰 로그 확률을 할당한 답을 정답으로 예측**
- **Winograd Schema (DPRD) [46]** → 대명사(pronoun)를 가능한 두 개의 참조 단어(referents)로 대체한 후, **교체된 문장의 나머지 부분에서 생성 모델이 더 높은 확률을 할당한 경우를 정답으로 선택**



→ 사전 학습이 진행될수록, 지도 학습 없이도(unsupervised fine-tuning 없이) 특정 NLP 태스크 수행 능력이 향상됨

→ LSTM은 변동성이 크지만, Transformer는 안정적으로 성능이 증가

3. Ablation studies

3가지 소거 실험을 수행하여 Transormer 모델의 성능을 분석

(1) 보조 언어 모델링 목표 (Auxiliary LM Objective) 제거

- 보조 학습 목표(auxiliary objective)가 자연어 추론(NLI) 및 QQP 태스크에서 성능 향상에 기여
- 대형 데이터셋(large datasets)에서는 성능 개선 효과가 크지만, 작은 데이터셋(small datasets)에서는 효과가 크지 않음

(2) Transformer vs. LSTM 비교

- Transformer 대신 단층(single-layer) 2048-unit LSTM을 사용하면 평균 성능이 5.6점 감소
- LSTM이 Transformer보다 높은 성능을 보인 데이터셋은 MRPC 하나뿐

(3) 사전 학습 없이 Transformer를 직접 지도 학습 (No Pre-training)

- 사전 학습 없이 지도 학습(target task)만 수행하면 모든 태스크에서 성능이 저하됨
- 사전 학습이 없는 경우, 전체 모델 대비 성능이 14.8% 감소

⇒ 결론적으로, Auxiliary LM Objective는 대형 데이터셋 성능 향상에 기여하며, Transformer가 긴 문맥 이해가 필요한 task에서 높은 성능을 보이고, 사전 학습이 모델 성능에 필수적임

6. Conclusion

- Generative Pre-training + Discriminative Fine-tuning 기법으로 강력한 자연어 이해 (NLU) 모델 구축
- 사전 학습을 통해 세계 지식과 긴 문맥 처리 능력을 습득, 다양한 NLP 태스크에 효과적으로 전이
- 12개 중 9개 데이터셋에서 기존 SOTA 성능 초월
- 비지도 학습이 지도 학습 성능 향상에 기여함을 입증
- Transformer와 긴 문맥 텍스트 데이터가 특히 효과적