



GPT-1

이름	홍준기
대학교	동국대학교
학과	산업공학과
날짜	2025년

Abstract

Abstract

1. Introduction

기존 NLP Model의 problem

기존 연구와의 Differentiation

Main Contribution

2. Model Architecture (Frameworks)

2.1. Unsupervised Pre-training

2.2. Supervised Fine-tuning

2.3. 보조 언어 모델 손실 추가 (Auxiliary LM Objective):

3. Experiments

3.1. Unsupervised pre-training

3.2. Fine-tuning

4. Results

5. Analysis, Ablation studies

5.1. 사전 훈련된 레이어 수가 미세 조정 성능에 미치는 영향

5.2. 제로샷(Zero-shot) 성능 분석

5.3. Ablation Studies

6. Conclusions

라벨이 없는 대규모 텍스트 데이터는 풍부하지만, 특정 태스크를 학습하는데 필요한

라벨링 데이터는 부족하여 기존 지도 학습 모델이 충분한 성능을 내기 어렵다는 점을 언급하며,

다양한 비라벨링 텍스트 코퍼스를 이용해

언어 모델을 먼저 학습하고, 사전 훈련된 모델을 각 태스크에 맞게 미세 조정하는 과정을 거쳐 모델 구조 변경을 최소화하면서 전이 학습 효과를 극대화하였음을 언급

1. Introduction

기존 NLP Model의 problem

- 규모 라벨링 데이터가 필요하지만, **라벨이 없는(unlabeled) 데이터가 훨씬 풍부함**
 - 기존 지도 학습 기반 모델은 라벨 데이터 부족으로 **적용 가능한 범위가 제한적이었음**
- 위 문제를 해결하기 위한 비지도 학습(Unsupervised Learning)과 전이 학습(Transfer Learning) 활용이 제안됨

기존 연구와의 Differentiation

- 주로 Word Embedding 사용하여 단어 수준에서 전이 학습을 수행함

- 위 방법은 단어 수준에서만 의미를 학습하며, 문장이나 문서 단위의 semantic 한 의미를 학습하기 어려움
- 위 논문은, 비지도 학습(Pre-training) + 지도 학습(Fine-tuning) 기반의 새로운 방법을 제안하여, 기존 모델보다 뛰어난 전이 학습 성능을 가짐

Main Contribution

- 언어 모델을 대규모 비라벨링 데이터에 대해 사전 훈련하였으며 이를 다양한 자연어 이해(NLU) 태스크에 쉽게 전이할 수 있도록 설계하였음
- Transformer 구조를 가지고 와서, Transformer가 기존 RNN보다 **장기 의존성(Long-range Dependencies)**을 효과적으로 처리함을 이용함
- 입력을 일관된 시퀀스로 변환하여, 동일한 모델 구조를 유지하면서 다양한 태스크에 적용 가능하도록 하였음

2. Model Architecture (Frameworks)

2.1. Unsupervised Pre-training

- 대규모 비라벨링 데이터에서 언어 모델을 사전 훈련
- 이를 위해 Transformer 기반의 디코더(Decoder)-only 구조 사용

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

- 다중 헤드어텐션(Masked Multi head Self-attention) 및 위치 임베딩(Position Embedding) , 피드포워드 신경망(Position-wise FFN) 적용
 - 이때 k는 context window의 크기임
- 자세한 학습 과정
 1. 임베딩 단계:
 - 토큰 임베딩(Token Embedding, W_e)과 위치 임베딩(Position Embedding, W_p)을 합쳐 벡터 표현으로 변환

2. Transformer Block을 통한 context 정보 학습:

- n개의 Transformer 블록을 거치며, Self-Attention을 통해 문맥을 반영한 벡터를 생성


3. 출력 확률 계산:

- 마지막 Transformer 블록의 출력을 소프트맥스(Softmax)를 통해 다음 단어의 확률 분포로 변환

$$\begin{aligned}h_0 &= UW_e + W_p \\h_l &= \text{transformer_block}(h_{l-1}) \forall i \in [1, n] \\P(u) &= \text{softmax}(h_n W_e^T)\end{aligned}$$

2.2. Supervised Fine-tuning

- 학습된 언어 모델을 특정 태스크(예: 질의응답, 자연어 추론, 문서 분류)에 맞게 미세 조정함
 - 텍스트 분류(Text Classification) 같은 일부 태스크는 **별도의 변환 없이** 미세 조정이 가능함
- 이때 별도의 변환이 필요한 태스크 별로 **입력 변환(Task-specific Input Transformations)** 기법을 활용하여, 모델 구조 변경 없이 적용 가능
 - 주요 입력 변환 방식:
 - NLI: "문장1 [SEP] 문장2 "형식으로 변환
→ 모델이 두 문장이 서로 어떤 관계인지 학습할 수 있도록 도움, 전제 문장과 가설 문장을 하나의 시퀀스로 변환
 - QA: 문맥, 질문, 정답을 하나의 시퀀스로 변환
→ 각 정답 후보를 **독립적으로 처리한 후**, softmax를 적용하여 가장 가능성이 높은 답을 선택
 - Semantic Similarity: 두 개의 문장을 각각 독립적으로 처리 후 비교
→ 두 문장 간의 유사도를 평가하는 태스크로, **문장 순서에 의미가 없기 때문에 양쪽 순서를 모두 고려**



- 이때의 학습 목표:
 - 다음과 같은 로그 확률을 최대

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y|x^1, \dots, x^m).$$

- 자세한 학습 과정:
 1. 라벨이 있는 데이터셋을 사용함
 - 각 샘플은 토큰 시퀀스 $(x_1, \dots, x_m)$ 과 라벨 y 로 구성
 2. 사전 훈련된 모델을 거친 후, 최종 레이어 추가
 - 입력 $(x_1, \dots, x_m)$ 을 Transformer 모델에 통과시켜 최종 출력 벡터를 도출함
 - 이 벡터를 new linear layer에 입력해 라벨 y 예측

$$P(y|x^1, \dots, x^m) = \text{softmax}(h_l^m W_y).$$

3. 모델이 예측한 확률을 최대화 하는 방식으로 학습하며 손실함수를 위의 L2사용

2.3. 보조 언어 모델 손실 추가 (Auxiliary LM Objective):

- L1과 L2를 동시에 최적화하면 일반화 성능 및 학습 속도 향상을 이뤄낼 수 있다고 함

$$L_3(\mathcal{C}) = L_2(\mathcal{C}) + \lambda * L_1(\mathcal{C})$$

3. Experiments

3.1. Unsupervised pre-training

- **BooksCorpus** (약 7,000권의 책)
 - 긴 문맥을 포함하는 데이터셋으로, 모델이 **장기 의존성(Long-range Dependency)**을 학습하는 데 유리하다고 함
 - cf) **1B Word Benchmark**는 문장을 단위로 섞어서 사용했기 때문에 문맥 학습이 어려움
- 모델 설정:
 - **Transformer 기반 12-layer 디코더(Decoder)-only 모델** 사용 (768차원, 12개의 어텐션 헤드)
 - **토큰 임베딩(Token Embedding)** 및 **위치 임베딩(Position Embedding)** 적용
 - **Byte-Pair Encoding (BPE)** 기반의 **40,000개 단어 사전** 사용
 - Adam 옵티마이저(Cosine schedule 적용)
 - 100 epoch (batch size: 64, sequence length: 512)

3.2. Fine-tuning

- Pre-training과 동일한 설정 유지 (dropout: 0.1).
 - 미세 조정 시 , **batch size: 32, 3 epochs** 만으로도 충분한 성능 도달
 - 학습률은 **warm-up** 후 **선형 감소 (linear decay schedule)** 적용

4. Results

- 자연어 추론 (Natural Language Inference, NLI):
 - **GPT 모델이 5개 중 4개 데이터셋에서 기존 최고 성능을 경신함**
- 질의응답 (Question Answering, QA)
 - 긴 문맥을 이해하는 데 강점을 보이며, 기존 모델보다 뛰어난 성능을 달성함
- 문장 유사도 (Semantic Similarity)
 - 유사도 태스크에서도 GPT가 최고 성능을 달성함
- 텍스트 분류 (Text Classification)
 - 문법적 판단(CoLA)에서 큰 성능 향상을 거둠

5. Analysis, Ablation studies

5.1. 사전 훈련된 레이어 수가 미세 조정 성능에 미치는 영향

- 실험 목표:
 - **비지도 학습(Pre-training)된 Transformer 레이어를 얼마나 많이 전이(Transfer)하는 것이 효과적인지를 탐구하는 실험**
- 실험 결과:
 - **임베딩(Embedding)만 전이해도 성능이 향상됨** → 사전 훈련의 효과를 확인함
 - Transformer 레이어를 추가로 전이할수록 성능이 지속적으로 증가함
 - 든 레이어를 전이할 경우 MultiNLI 태스크에서 최대 +9% 성능 향상을 이뤄냄
 - 각 Transformer 레이어가 유용한 기능을 학습하고 있으며, 이를 유지할수록 성능이 좋아진다는 방증임
 - 사전 훈련된 레이어를 많이 활용할수록 전이 학습(Transfer Learning) 성능이 향상

5.2. 제로샷(Zero-shot) 성능 분석

- 실험 목표:
 - 왜 사전 훈련이 효과적인지, Transformer가 LSTM보다 효과적인 이유를 탐구함

- 가설: GPT 모델은 언어 모델 학습 중에 다양한 NLP 태스크를 자연스럽게 학습할 가능성이 있고 이때 Transformer구조가 전이 학습에 유리하다는 가설을 세
- 실험 방법:
 - 사전 훈련된 모델을 별도 미세 조정(Fine-tuning) 없이 NLP 태스크에 직접 적용 (Zero-shot 학습)함
- 실험 결과:
 - **Transformer 기반 모델은 Zero-shot에서도 성능이 점진적으로 향상됨**
 - **LSTM 기반 모델은 Zero-shot 성능이 불안정하고 변동성이 큼** → Transformer가 더 강력한 전이 학습 능력을 보유함

5.3. Ablation Studies

- 모델의 각 요소가 얼마나 중요한지 검증하기 위해 **소거 실험(Ablation Study)** 수행
1. 보조 언어 모델 학습 목표(Auxiliary LM Objective) 제거
 - a. 대규모 데이터에서 성능 향상에 위 Auxiliary LM objective가 기여함
 2. Transformer 대신 LSTM 사용
 - a. Transformer가 전이 학습 성능이 뛰어남
 3. 사전 훈련 없이 바로 지도 학습 수행
 - a. 성능 크게 저하됨

6. Conclusions

- 비지도 사전 훈련+ 지도 학습 기반 미세 조정 접근법을 제안함
- Transformer 기반 모델을 대규모 코퍼스에서 사전 훈련하면, 강력한 전이 학습 성능을 발휘함
- 긴 문맥을 포함한 데이터가 있는 경우, 성능이 더욱 향상됨
- 9개 태스크에서 기존 최고 성능(SOTA)을 경신함