

Improving Language Understanding by Generative Pre-Training

0. Abstract

- 대량의 텍스트 데이터에 대해 비지도 사전 학습(unsupervised pre-training) 을 수행한 후, 지도 학습(supervised fine-tuning) 을 적용하는 접근 방식을 제안
- 사전 학습된 언어 모델을 다양한 자연어 처리(NLP) 작업에 적용하여 성능 향상을 확인
- 기존 방식 대비 적은 레이블 데이터로도 뛰어난 성능 을 달성할 수 있음을 보임

1. Introduction

- 기존의 NLP 모델은 지도 학습(supervised learning) 에 크게 의존하여 대량의 레이블 데이터가 필요
- 하지만 레이블 데이터를 확보하는 것은 비용이 많이 들고 확장성이 떨어짐
- 이를 해결하기 위해 비지도 사전 학습(unsupervised pre-training) + 지도 미세 조정(supervised fine-tuning) 방식을 제안
- 이 접근 방식은 다양한 NLP 태스크에서 성능 향상 을 가져옴

2. Related Work

- Semi-supervised learning for NLP
 - 기존의 반지도 학습(semi-supervised learning)은 레이블이 부족한 문제를 해결하기 위해 소량의 레이블 데이터 + 대량의 비레이블 데이터를 활용
 - 하지만, 기존 연구는 특정 태스크에 최적화된 모델을 훈련하는 방식이었음
- Unsupervised pre-training
 - 대량의 비레이블 데이터를 활용하여 언어 모델을 사전 학습하는 방법
 - 이전 연구에서는 단순한 언어 모델(language modeling) 훈련 또는 분산 표현(distributed representation) 학습 에 그쳤음

- Auxiliary training objectives
 - 보조적인 학습 목표를 설정하여 모델의 일반화 성능을 높이는 방법
 - 다중 작업 학습(Multi-task Learning)과 트랜스퍼 러닝(Transfer Learning) 접근 방식과 유사

3. Framework

3.1 Unsupervised pre-training

- 대량의 비지도 텍스트 데이터를 이용하여 Transformer 기반의 언어 모델을 학습
- 목표: 주어진 문맥에서 다음 단어를 예측하는 언어 모델링(Language Modeling) 훈련
- 이를 통해 문법적 구조와 의미적 정보를 효과적으로 학습

3.2 Supervised fine-tuning

- 사전 학습된 언어 모델을 특정 NLP 태스크에 맞게 미세 조정
- 모델이 태스크별 데이터 분포에 적응하도록 학습
- 기존의 랜덤 초기화된 모델 대비 적은 데이터로도 더 나은 성능을 발휘

3.3 Task-specific input transformations

- NLP 태스크에 맞게 입력을 변환하여 적용
- 예를 들어, 질의응답(QA) 태스크에서는 입력을 질문 + 문맥 형식으로 구성

4. Experiments

4.1 Setup

- 실험에 사용한 모델 아키텍처, 하이퍼파라미터, 데이터셋 설명
- GLUE Benchmark를 포함한 다양한 NLP 태스크에서 평가 진행

4.2 Supervised fine-tuning

- 사전 학습 모델을 지도 학습을 통해 특정 태스크에 최적화
- 여러 NLP 태스크에서 기존 모델 대비 우수한 성능을 보였으며, 특히 소량의 레이블 데이터에서도 좋은 결과를 기록

5. Analysis

- 사전 학습이 얼마나 효과적인지 분석
- 태스크별 성능 비교 및 모델의 일반화 성능 평가
- Pre-training이 없는 모델과의 성능 차이를 수치적으로 분석

6. Conclusion

- 비지도 사전 학습이 NLP 태스크에서 강력한 사전 지식을 제공 하여 성능을 향상
- 지도 미세 조정을 통해 각 태스크에 맞춰 쉽게 적응 가능
- 향후 연구 방향: 더 큰 데이터셋, 더 깊은 모델, 더 다양한 태스크로 확장