

GPT-1 : Improving Language understanding by Generative Pre-Training

📅 작성일 시	@2025년 3월 12일
📍 강의 번호	BASE
📍 유형	논문리뷰
📎 자료	https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf
☑️ 복습	☐

자연어 처리 분야는 지난 수년 동안 놀라운 발전을 이루어왔는데, 그 중심에는 GPT-1 같은 혁신적인 모델이 있었음. 이번 글에서는 GPT-1의 근본적인 구조와 기능, 그리고 그것이 어떻게 다양한 자연어 처리 작업에서 뛰어난 성능을 발휘하는 지에 대해 깊이 있게 알아보았음.

첫 번째 섹션에서는 기존의 자연어 처리 방법들과 주요한 문제점을 논의

→ GPT와 같은 새로운 모델의 등장을 촉발한 주요한 요인

- 기존 모델들의 제한된 문맥 이해와 처리 능력, 복잡한 작업에 대한 어려움
 - 자연어 처리 작업의 효율성과 정확성을 제한하며, 해결하기 위한 새로운 접근 방법의 필요성을 높임.

두 번째 섹션에서는 GPT-1의 핵심인 모델 구성과 학습 방법에 대해서 설명함. GPT-1이 어떻게 다음 단어를 예측하는 방법을 통해 효과적으로 학습되는지, 그리고 이를 다양한 자연어 처리 작업에 어떻게 적용하는지에 대한 설명이 포함되어 있음. 이 부분은 GPT-1의 기본적인 작동 원리를 이해하는데 중요함. 세부적인 모델 구조와 학습 전략을 통해, 이 모델이 어떻게 고급 자연어 처리 기능을 실현하는지에 대한 근본적인 이해를 얻을 수 있음.

세 번째와 네 번째 섹션에서는 GPT-1의 실험 결과와 분석 실험에 대해 소개함. 이를 통해 GPT-1의 성능과 그 한계를 실제로 확인할 수 있음. 여러 가지 자연어 처리 작업에서의 GPT-1의 성능을 실제 데이터와 결과를 통해 살펴봄. 이 과정에서 GPT-1의 강력한 성능과 동시에 그것의 한계와 제약사항도 분명히 이해할 수 있음.

다섯 번째 섹션에서는 GPT-1의 장단점을 살펴봄. 모델의 강점과 약점을 이해함으로써, GPT-1이 실제 작업에 어떻게 적용될 수 있는지에 대한 통찰을 얻을 수 있음. GPT-1을 실제 작업에 적용할 때 중요한 고려사항임. GPT-1의 성능과 효율성, 그리고 그것의 한계와 제약사항에 대한 균형 잡힌 이해를 통해, 이 모델을 최대한 효과적으로 활용하는 방법을 살펴봄.

마지막 섹션에서는 GPT-1의 의의에 대해 논의함. GPT-1이 자연어 처리 분야에 어떤 영향을 미치고 있는지, 그리고 앞으로 어떤 발전이 기대되는지에 대한 내용을 다룸. 이는 GPT-1의 장기적인 영향과 가치를 이해하는 데 도움이 됨. GPT-1의 혁신적인 접근 방법과 성과를 통해, 자연어 처리 분야의 미래 발전 방향에 대한 통찰을 얻을 수 있음.

1. 기존 방법의 문제점

언어 모델을 위한 데이터 구성을 생각해 보면 Labeled Data의 양은 많지 않음. 이러한 데이터는 사람의 Labeling 작업이 필요하고, 따라서 확보하기가 어려움. 반면 Unlabeled Data는 쉽게 다량으로 확보할 수 있음.

문제는 기존 언어모델에서 다량의 Unlabeled Data를 충분히 활용할 수 있는 방법이 없다는 것임. Labeled Data를 사용한 Supervised Learning 방법에 많이 의존하고 있었음. 이에 GPT-1에서는 Unlabeled Data를 사용한 Generative Pre-Training을 효과적으로 활용할 수 있는 방법을 고민하고, 이에 초점을 맞춰 모델을 개발함.

2. GPT-1 제안 방법

GPT-1은 어떻게 Generative Pre-Training의 효과를 누릴 수 있었는지 살펴봄. GPT-1의 전체 Architecture를 살펴본 후 Unsupervised Pre-Training 방법과 Supervised Fine Tuning 방법을 차례대로 살펴봄. 마지막으로 Task별 Input 구성 방법에 대해서도 살펴봄.

2-1 Architecture

먼저 GPT-1 Architecture를 살펴봄. GPT-1은 Transformer에서 Encoder는 제외하고 Decoder만을 가져와서 사용함. Transformer와 GPT-1의 Architecture를 비교함.




그림1. GPT-1 Architecture

GPT-1에서는 Transformer의 Decoder 부분만을 사용, 이때 Cross Self Attention 부분은 제거한 모습을 볼 수 있음. Transformer에서 Cross Self Attention은 Encoder의 입력과 Decoder의 입력을 Cross Attention하는 역할을 함. 하지만 GPT-1에서는 Encoder 없이 Decoder 단독으로 구성되어 Cross Attention 기능이 필요 없어 졌기 때문임.

그러면 왜 GPT-1에서는 왜 Encoder를 제외하고 Decoder만을 사용했을까?

→ 학습원리와 간결성의 이점을 얻기 위함.

- GPT-1은 다음 단어를 예측하는 방법을 사용하여 학습함. 이는 Decoder가 수행하기에 적합한 문제임. 이와 정 확히 반대 이유로 BERT에서는 Transformer의 Encoder만을 사용함.
- Decoder만을 사용하면 모델 구조를 더 간결하게 만들 수 있고 이로 인해 연산량이 줄어드는 장점이 있음.

GPT-1에서는 이렇게 Decoder 12개를 쌓아올린 구조를 하고 있음. Decoder의 최종 Output에 Linear Layer와 Softmax를 이어주어 최종 Output Probability를 출력하는 구조임.

2-2 Unsupervised Pre-Training

GPT-1 부터 시작해서 GPT-2,GPT-3,Instruct GPT, Chat GPT까지 GPT시리즈의 공통된 학습철학임. BERT등 다른 LLM과 차별화된 방법이며 근본적인 성능차이를 가져오는 원인 중 하나라고 할 수 있음.

GPT-1은 다음 단어를 맞추도록 학습함. 논문에서는 Next Word Prediction이라고 표현함.

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

전체 데이터셋은 아주 많은 문장으로 구성되어 있음. 이 데이터셋을 우선 문장별로 나누어줌. 그리고 각 문장을 GPT-1에 입력해 주는데, 문장을 잘라서 주고 그 다음에 나올 단어를 예측하도록 학습함. 예를 들어 "나는 오늘 학교에 가서 수업을 듣는다"라는 문장이 있다고 가정하면, GPT-1에게 "나는 오늘 학교에"라는 문장을 입력해 주고, 다음에 나올 단어를 예측하도록 학습함.

2-3 Next Word Prediction의 효과

GPT 시리즈는 모두 다음 단어를 예측하는 방식으로 학습함. 다음 단어를 예측하는 학습 방법은 왜 효과적일까?

1. 언어 구조를 학습하게 되기 때문

→ 모델은 다음 단어를 예측하며 문장 내에서 단어가 어떻게 배치되는지, 어떠한 단어가 다른 단어 뒤에 올 확률이 높은지를 학습함. 이를 통해 모델은 언어의 기본적인 구조와 문법을 이해하게 됨.

2. 문맥을 이해하려 노력하게 되기 때문

→ 다음 단어를 예측하려면 반드시 문맥을 이해하고 있어야 함. 앞의 내용을 이해해야 다음 단어를 예측할 수 있기 때문. 따라서 다음 단어를 예측하는 과정을 통해 모델은 문맥 이해 능력을 향상하게 됨.

3. 다양한 언어 패턴을 학습하게 되기 때문

→ Unlabeled Dataset을 아주 다량의 언어 데이터로 구성되어 있음. 따라서 다양한 종류의 언어와 다양한 패턴, 특성을 포함하고 있음. 이러한 데이터에서 다음 단어를 예측하도록 학습함으로써 모델은 다양한 언어와 다양한 특성, 패턴을 학습하게 되고 이 덕분에 인간과 유사한 언어 능력을 얻었다고 할 수 있음.

4. 전이 학습의 유용함임

→ Pre-Training을 완료한 모델은 모든 학습을 끝낸 것이 아닌, 최종 문제에 맞는 Fine Tuning 작업을 해야함. 따라서 Pre-Training 작업은 반드시 다양한 Task의 Fine Tuning에 적합한 형태여야 함. 다음 단어를 예측하는 작업은 특정 문제에 특화된 문제를 학습하기 전에 일반적인 능력을 향상시키는 Pre-Training방법으로 적합하다고 할 수 있음.

2-4 Supervised Fine Tuning

이렇게 Pre-Training을 마친 모델은 최종 성능 측정을 하기에 앞서 각 Task에 맞추어 재학습을 함. 이 과정을 Fine Tuning이라고 함. 이러한 Fine Tuning은 앞선 Pre-Training과 달리 Supervised Learning 방법으로 이루어짐.

Fine Tuning을 위한 데이터셋은 Labeled Dataset으로 구성되어 있기 때문임. 따라서 Loss함수는 다음과 같이 간단하게 표현됨.


$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y|x^1, \dots, x^m).$$

이때 Pre-Training Loss도 추가하여 같이 학습해줌. 최종 Loss함수는 다음과 같음.

$$L_3(\mathcal{C}) = L_2(\mathcal{C}) + \lambda * L_1(\mathcal{C})$$

2-5 Task Specific Input Transformations

Task 별로 Fine Tuning을 할 때 Input Data는 어떻게 구성해줄까? 예를 들어 하나의 문장의 종류를 구분하는 Classification 문제와 두 개의 문장을 입력받아 유사도를 측정하는 Similarity 문제에서의 Input Data 구성은 분명 달라야함. Task 별 Input Transformation 방법은 아래 그림과 같음.



먼저 Classification 문제는 입력받은 Text를 분류하는 문제임. 가장 대표적으로 스팸 메일 분류 문제가 있음. 메일 내용 전체를 입력으로 주고 모델은 이 메일이 스팸인지 아닌지를 구분하는 문제임. 이때는 단순히 문장 전체를 모델에 입력으로 넣어주면 됨.

다음은 Textual Entailment 문제로 이는 2개의 문장을 입력받아 두 문장의 관계를 classification하는 문제임. 보통 세 가지로 분류함. Entailment(함축), Contradiction(모순), Neutral(중립)임. 이 경우 문장 2개를 구분해서 입력받아야함. 따라서 위의 그림과 같이 첫 번째 문장인 Premise를 넣고, Delim(구분)과 두 번째 문장인 Hypothesis를 구성해줌.

세 번째는 Similarity 문제로 이는 두 개의 문장을 입력받아 두 문장이 얼마나 유사한지를 측정하는 문제임. 따라서 입력으로 두 개의 문장을 받아야 하고 출력은 0~1사이 값을 내야함. 위 그림을 보면 첫 번째 입력은 Text1, Text2 순서로 구성하고, 두 번째 입력은 Text2, Text1 순서로 구성하고 있음. 이 두 문장을 각각 모델에 입력한 뒤 나온 Representation을 Elementwise Addition 한 뒤 Linear와 Activation 함수를 거쳐 최종 유사도 값을 출력하는 구조임.

네 번째는 Multiple Choice 문제로 구체적으로는 Question Answering and Commonsense Reasoning 문제가 있음. 이 문제는 Context와 Answer로 구성되어 있음. 예를 들어 Context는 "서울은 대한민국의 수도입니다."

이 도시는 한강을 중심으로 확장되어 있다. 대한민국의 수도는 어디입니까?” 이에 대한 Answer은 “서울”임. 모델은 Context를 입력으로 받아 그에 맞는 Answer를 출력하도록 학습함.

3. 실험 결과

3-1 Natural Language Inference

Table 2: Experimental results on natural language inference tasks, comparing our model with current state-of-the-art methods. 5x indicates an ensemble of 5 models. All datasets use accuracy as the evaluation metric.

Method	MNLI-m	MNLI-mm	SNLI	SciTail	QNLI	RTE
ESIM + ELMo [44] (5x)	-	-	89.3	-	-	-
CAFE [58] (5x)	80.2	79.0	89.3	-	-	-
Stochastic Answer Network [35] (3x)	80.6	80.1	-	-	-	-
CAFE [58]	78.7	77.9	88.5	83.3		
GenSen [64]	71.4	71.3	-	-	82.3	59.2
Multi-task BiLSTM + Attn [64]	72.2	72.1	-	-	82.1	61.7
Finetuned Transformer LM (ours)	82.1	81.4	89.9	88.3	88.1	56.0

모든 데이터셋에서 기존 방법들보다 성능이 좋은 모습을 볼 수 있음

3-2 Question Answering and Commonsense Reasoning

Table 3: Results on question answering and commonsense reasoning, comparing our model with current state-of-the-art methods.. 9x means an ensemble of 9 models.

Method	Story Cloze	RACE-m	RACE-h	RACE
val-LS-skip [55]	76.5	-	-	-
Hidden Coherence Model [7]	77.6	-	-	-
Dynamic Fusion Net [67] (9x)	-	55.6	49.4	51.2
BiAttention MRU [59] (9x)	-	60.2	50.3	53.3
Finetuned Transformer LM (ours)	86.5	62.9	57.4	59.0

모든 데이터셋에서 기존 방법들 대비 가장 좋은 성능을 확인할 수 있음

3-3 Semantic Similarity & Classification

Table 4: Semantic similarity and classification results, comparing our model with current state-of-the-art methods. All task evaluations in this table were done using the GLUE benchmark. (*mc*= Mathews correlation, *acc*=Accuracy, *pc*=Pearson correlation)

Method	Classification		Semantic Similarity			GLUE
	CoLA (mc)	SST2 (acc)	MRPC (F1)	STSB (pc)	QQP (F1)	
Sparse byte mLSTM [16]	-	93.2	-	-	-	-
TF-KLD [23]	-	-	86.0	-	-	-
ECNU (mixed ensemble) [60]	-	-	-	81.0	-	-
Single-task BiLSTM + ELMo + Attn [64]	35.0	90.2	80.2	55.5	66.1	64.8
Multi-task BiLSTM + ELMo + Attn [64]	18.9	91.6	83.5	72.8	63.3	68.9
Finetuned Transformer LM (ours)	45.4	91.3	82.3	82.0	70.3	72.8

대체로 좋은 성능을 보여주고 있음

4. 분석

4-1 Impact of Number of Layers Transferred & Zero Shot Behaviors




Figure 2: (left) Effect of transferring increasing number of layers from the pre-trained language model on RACE and MultiNLI. (right) Plot showing the evolution of zero-shot performance on different tasks as a function of LM pre-training updates. Performance per task is normalized between a random guess baseline and the current state-of-the-art with a single model.

왼쪽 그래프는 Transfer에 사용한 Layer 개수에 다른 성능을 측정한 그래프임. 사용한 Layer의 개수가 많을수록 성능이 좋아지는 모습임. 이는 Pretrained 정보를 많이 사용할 수록 Fine Tuning 했을 때의 성능이 좋다는 의미임. 결과적으로 Pretrained Model은 Down Stream Task를 해결하기에 유용한 정보를 많이 가지고 있다는 것을 알 수 있음. 즉, GPT-1에서 제안하는 다음 단어 예측하기 학습 방법은 대부분의 Down Stream Task에 적합하다고 결론 내릴 수 있음.

오른쪽 그래프는 Zero Shot 성능을 측정한 그래프임. X축은 Pre-Training을 진행한 정도를 의미함. 또한 실선 Transformer를 사용한 성능을, 점선은 LSTM을 사용한 성능을 나타냄. 결과를 해석해보면 대부분의 Task에서 Pre-Training을 많이 진행했수록 성능이 좋으므로, Pre-Training 과정의 대부분의 Down Stream Task에 적합함을 알 수 있음. 또한 Transformer 구조가 LSTM보다 탁월함을 알 수 있음.

5-2 Ablations

Table 5: Analysis of various model ablations on different tasks. Avg. score is a unweighted average of all the results. (*mc*= Mathews correlation, *acc*=Accuracy, *pc*=Pearson correlation)

Method	Avg. Score	CoLA (mc)	SST2 (acc)	MRPC (F1)	STS _B (pc)	QQP (F1)	MNLI (acc)	QNLI (acc)	RTE (acc)
Transformer w/ aux LM (full)	74.7	45.4	91.3	82.3	82.0	70.3	81.8	88.1	56.0
Transformer w/o pre-training	59.9	18.9	84.0	79.4	30.9	65.5	75.7	71.2	53.8
Transformer w/o aux LM	75.0	47.9	92.0	84.9	83.2	69.8	81.1	86.9	54.4
LSTM w/ aux LM	69.1	30.3	90.5	83.2	71.8	68.1	73.7	81.1	54.6

위 표는 Ablation 실험 결과를 보여주고 있음. 이를 통해 세 가지 교훈을 얻을 수 있음.

첫 번째는 L1 Auxiliary Objective의 효과임. Fine Tuning과정에서 Loss 함수를 Pre-training loss와 같이 구성할 수 있음. 이러한 방법을 L1 Auxiliary Objective라고 표현함. 결과를 보면 NLI, QQP 등 큰 데이터셋에서는 도움이 되고 작은 데이터셋에서는 도움이 안되는 모습을 볼 수 있음.

두 번째는 LSTM과의 비교임. 전체적으로 LSTM을 사용할 경우 성능이 크게 하락하는 모습을 볼 수 있음. 이를 통해 Transformer구조가 LSTM을 사용하는 구조보다 우수함을 알 수 있음.

세 번째는 Pre-Training의 효과임. Pre-Training을 생략할 경우 아주 크게 성능이 하락하는 모습을 볼 수 있음. 이를 통해 GPT-1에서 제안하는 Pre-training방식이 효과적이며, 성능에 아주 큰 영향을 준다는 사실을 알 수 있음.

5. 장단점

5-1 장점

첫 번째 장점은 전이 학습의 효율성을 높인 방법이라는 것. 즉 강력한 Pre-Training 방법을 제안한 것이라고도 표현할 수 있음. 실험 결과를 통해 살펴봤듯이 GPT-1의 Pre-Training 효과는 아주 강력하다는 것을 알 수 있음. Pre-Training 없이 Fine Tuning만 진행했을때 성능이 크게 하락하는 모습을 통해 확인할 수 있음. 이렇게 강력한 Pre-Training 덕분에 Task별 Fine Tuning으로 모델은 아주 좋은 성능을 가질 수 있었음.

두 번째 장점은 Task 별 최소한의 엔지니어링이 필요하다는 것임. 앞서 언급한 것 처럼 GPT-1의 Pretraining은 아주 강력한 효과를 발휘함. Fine Tuning 과정 또한 모델의 구조를 크게 변경하지 않고 진행할 수 있기에 이러한 강력한 Pretraining 효과를 그대로 사용할 수 있음.

세 번째 장점은 강력한 성능임. 앞서 실험 결과를 통해 살펴본 것처럼 Pretraining과 Fine Tuning을 거친 GPT-1의 성능은 대부분의 데이터셋에서 SOTA를 기록했음.

5-2 단점

첫 번째는 너무 많은 계산량에서 야기되는 비싼 계산 비용임. 물론 뒤에 나올 LLM 등에 비하면 작은 연산량이지만 이 당시에는 가장 큰 연산량을 요구하는 방법이었음.

두 번째는 Task 별 Fine Tuning의 어려움임. 뒤에 발표된 모델들은 Fine Tuning 의 단점을 없애기 위해 Fine Tuning 없이 사용하는 방법을 사용함. 이와 비교했을때 GPT-1은 직접 Fine Tuning을 진행해야 하므로 일반화 능력을 잃어버리는 등의 한계가 존재함.

6. 의의

GPT는 언어 모델의 새로운 패러다임을 제시함. 기존 방법과 달리 Pretraining 방법을 제시하며 새로운 접근 방법을 제안함. 또한 자연어 처리의 미래를 예측하는 중요한 단서를 제공함.