

# Improving Language Understanding by Generative Pre-Training

24기 분석 조희선

## 1. 연구 배경 및 목적

### ✓ 배경

- 자연어 이해(Natural Language Understanding, NLU)는 다양한 작업(텍스트 분류, 질문 응답, 의미 유사성 평가 등)을 포함함.
- 기존 딥러닝 방식은 대부분 대량의 라벨 데이터(annotated data)에 의존 → 라벨 데이터 수집은 시간과 비용이 많이 듦.
- 반면, 라벨이 없는 텍스트 데이터는 풍부하지만, 이를 효과적으로 활용하는 방법은 미흡했음.

### ✓ 연구 목적

- 라벨이 없는(unlabeled) 대규모 텍스트 데이터를 활용하여 사전 학습(pre-training)하고, 이후 각 작업에 맞게 지도 학습(supervised fine-tuning)을 통해 다양한 자연어 이해 작업에서 성능을 높이는 방법 제안.
- 기존 태스크별 맞춤형 아키텍처 없이 하나의 범용 모델로 다양한 작업을 처리하는 것이 목표.

## 2. 기존 연구 및 한계점

- 기존 방식들은 주로 단어 수준의 임베딩(word embedding, 예: Word2Vec, GloVe)을 이용해 일부 개선을 이루었지만, 더 높은 수준의 문맥 정보를 반영하기는 어려웠음.
- ELMo, ULMFiT 등도 비슷한 접근을 했지만, 대부분 LSTM 기반 모델 → 장기 의존성(long-range dependency) 처리에 한계 존재.
- 태스크별 맞춤 아키텍처가 필요했기에 범용성, 확장성에 제한이 있었음.

## 3. 제안하는 방법

### ✓ 기본 아이디어

- 생성 기반 사전 학습(Generative Pre-Training, GPT) + 지도 학습 기반 미세 조정(Discriminative Fine-Tuning)
- Transformer 아키텍처를 기반으로 함.

## 4. 모델 아키텍처 및 학습 과정

### ✓ 전체 과정

[사전 학습(Pre-training)]

- BooksCorpus 데이터셋 사용 (약 7천 권 이상의 책)
- 순차적 언어 모델링(Language Modeling) → 이전 문맥을 고려하여 다음 단어 예측
- Transformer 기반 디코더 구조 사용 (12-layer, masked self-attention, 768 차원)

hidden state)

[미세 조정(Fine-tuning)]

- 각 태스크에 맞게 소량의 라벨 데이터를 이용해 지도 학습
- 입력 형식에 소규모 변형(task-specific input transformation)을 적용하여 태스크를 변환함
- 입력 데이터를 토큰 시퀀스로 변환하여 Transformer로 처리

태스크 예시

문장 유사도(Similarity) → 문장 쌍을 양방향으로 처리하고 벡터를 더한 후 예측

질문 응답(Question Answering) → 문서+질문+답변 후보를 연결한 시퀀스를 각각 처리하고 softmax로 정답 예측

텍스트 분류(Classification) → 문장 전체를 입력으로 사용하여 분류 수행

## 5. 주요 기법 설명

✓ Transformer 사용 이유

- 기존 LSTM에 비해 병렬 처리 가능
- 장기 문맥(long-range context) 처리에 강함
- 자기-어텐션(Self-Attention)을 통해 문맥 정보를 효과적으로 통합

✓ 학습 세부사항

- 토큰 임베딩 + 위치 임베딩(learned position embeddings) 사용
- Byte Pair Encoding(BPE)로 어휘 구성 (40,000개 토큰)
- Adam Optimizer 사용 (학습률 스케줄 포함)
- dropout, GELU 활성화 함수 적용
- Auxiliary Language Modeling Objective 추가하여 일반화 성능 향상

## 6. 실험 결과

### ✓ 실험 데이터셋

| 작업 유형                   | 데이터셋                              |
|-------------------------|-----------------------------------|
| 자연어 추론 (NLI)            | SNLI, MNLI, QNLI, RTE, SciTail    |
| 질문 응답 (QA)              | RACE, Story Cloze Test            |
| 문장 유사도 (Similarity)     | MRPC, Quora Question Pairs, STS-B |
| 텍스트 분류 (Classification) | SST-2, CoLA                       |

### ✓ 주요 결과

| 작업                  | 기존 최고 성능 | GPT-1 성능     | 향상폭   |
|---------------------|----------|--------------|-------|
| Story Cloze (상식 추론) | 77.6%    | <b>86.5%</b> | +8.9% |
| RACE QA (고난도 독해)    | 53.3%    | <b>59.0%</b> | +5.7% |
| MNLI (추론)           | 80.6%    | <b>82.1%</b> | +1.5% |
| GLUE 벤치마크           | 68.9점    | <b>72.8점</b> | +3.9점 |

## 7. 분석 및 논의

### ✓ 전이 학습 효과 분석

Transformer의 각 레이어가 유용한 정보를 포함

사전 학습 후 레이어 수가 많을수록 전이 학습 성능이 향상

### ✓ 제로샷(Zero-shot) 테스트

추가 미세 조정 없이도 기본적인 작업을 수행 가능

예) 문장 문법성(CoLA), 감정 분류(SST-2), 질문 응답(RACE)

### ✓ 어블레이션(Ablation) 스터디

사전 학습 없이 학습 시 성능 저하 (-14.8%)

보조 언어 모델링 제거 시 일부 태스크에서 성능 하락

Transformer가 LSTM보다 일관되고 강력한 전이 학습 능력을 가짐