

Abstract

문제 상황 : 방대한 양의 라벨이 없는 텍스트 코퍼스가 존재하지만, 이러한 특정 작업을 학습하기 위한 라벨이 지정된 데이터는 부족하며, 판별적으로 훈련된 모델이 적절한 성능을 내기 어려움

제안 : 언어 모델을 비라벨링 텍스트 코퍼스에서 생성적으로 사전 훈련한 후 각 특정 작업에 대한 판별적 미세 조정을 함. 기존 접근 방식과 달리 미세 조정 과정에서 take-aware 입력 변환을 사용하여 효과적인 전이를 이루면서도 모델 아키텍처 변경을 최소화

1. Introduction

비라벨링 데이터로부터 언어적 정보를 활용할 수 있는 모델은 시간적 비용적 측면에서 유용..

문제 상황 : 비라벨링 텍스트에서 단어 수준 이상의 정보를 활용 하는 것은 어려움

1. 어떤 유형의 최적화 목표가 가장 효과적?
2. 학습된 표현을 목표 작업으로 전이하는 가장 효과적인 방법에 대한 합의 x
➔ 이러한 불확실성으로 인해 자연어 처리를 효과적인 반지도 학습 접근 방식을 개발하는 것이 어려운 상황'

비지도 사전 훈련 + 지도 미세 조정을 결합한 반지도 학습 접근 방식을 활용할 것

두 단계 학습 절차

1. 비라벨링 데이터에 대해 언어 모델링 목표를 사용하여 신경망 모델의 초기 파라미터 학습
2. 지도 학습 목표를 적용하여 해당 파라미터를 목표 작업에 맞게 조정

모델 아키텍처로는 Transformer 사용 전이 과정에서는 작업별 입력 변환을 활용

평가 1. 자연어 추론, 2. 질의 응답 3. 의미 유사도, 4. 텍스트 분류

2. Related Work

Semi-supervised learning for NLP

Unsupervised pre-training

Auxiliary training objectives

3. Framework

훈련 절차

1. 대규모 텍스트 코퍼스를 사용하여 고용량 언어 모델을 학습
2. 미세 조정 단계를 통해 모델을 라벨링된 데이터를 활용한 판별적 작업에 적응

3.1. Unsupervised pre-training

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

he context window, and the conditional probability P is modeled using parameters Θ . These parameters are trained using stochastic gradient descent.

use a multi-layer *Transformer decoder* [34] for the language modeling task [62]. This model applies a multi-headed self-attention operation followed by position-wise feedforward layers to produce an output d

$$\begin{aligned} h_0 &= UW_e + W_p \\ h_l &= \text{transformer_block}(h_{l-1}) \forall l \in [1, n] \\ P(u) &= \text{softmax}(h_n W_e^T) \end{aligned}$$

K : 컨텍스트 윈도우의 크기

P : 조건부 확률로 파라미터 세타를 갖는 신경망을 사용하여 모델링

파라미터는 경사하강법을 통해 학습

3.2. Supervised fine-tuning


목표로 학습한 후, 파라미터를 지도 학습 목표 작업에 맞게 적응

$$P(y|x_1, \dots, x_m) = \text{softmax}(h_m W_y).$$

$$L_2(C) = (x, y) \sum \log P(y|x_1, \dots, x_m). \quad \leftarrow \text{목표를 최대화}$$

$$L3(C) = L2(C) + \lambda \times L1(C).$$

구조



3.3 Task-specific input transformations

언어 이해 작업을 위한 반지도 학습 접근 방식을 제안

사전 훈련된 모델을 사용해 다양한 작업에 맞춰 적응하며, 구조화된 입력에 대해서는 순차 처리 방식으로 모델링을 수정. 텍스트 함의, 유사도, 질문 응답, 상식 추론 작업에 대해 구분자 토큰을 추가하고, 입력 시퀀스를 적절히 변환하여 모델이 처리할 수 있도록 한다. 이러한 방식은 모델 아키텍처에 최소한의 변경만으로 다양한 작업에 적용 가능

4. Experiments

4.1 Setup

사용 데이터 : BooksCorpus 데이터셋

모델은 12층의 디코더-only 트랜스포머로, 768차원 상태와 12개의 주목 헤드를 사용하며, 학습률은 $2.5e-4$ 로 설정했다. 사전 훈련은 100 에포크 동안 512 토큰 시퀀스를 사용하여 진행되며, BPE 어휘와 GELU 활성화 함수를 사용했다. 미세 조정 시, 분류기에 0.1 비율의 드롭아웃을 적용하고, 학습률은 $6.25e-5$ 로 설정하여 3 에포크만으로 대부분의 작업에서 충분히 훈련된다. 또한, 선형 학습률 감소와 0.5의 λ 값을 사용하여 성능을 최적화

4.2 Supervised fine-tuning

Method	MNLI-m	MNLI-mm	SNLI	SciTail	QNLI	RTE
ESIM + ELMo [44] (5x)	-	-	<u>89.3</u>	-	-	-
CAFE [58] (5x)	80.2	79.0	<u>89.3</u>	-	-	-
Stochastic Answer Network [35] (3x)	<u>80.6</u>	<u>80.1</u>	-	-	-	-
CAFE [58]	78.7	77.9	88.5	<u>83.3</u>		
GenSen [64]	71.4	71.3	-	-	<u>82.3</u>	59.2
Multi-task BiLSTM + Attn [64]	72.2	72.1	-	-	82.1	61.7
Finetuned Transformer LM (ours)	82.1	81.4	89.9	88.3	88.1	56.0

Table 3: Results on question answering and commonsense reasoning, comparing our model with current state-of-the-art methods.. 9x means an ensemble of 9 models.

Method	Story Cloze	RACE-m	RACE-h	RACE
val-LS-skip [55]	76.5	-	-	-
Hidden Coherence Model [7]	<u>77.6</u>	-	-	-
Dynamic Fusion Net [67] (9x)	-	55.6	49.4	51.2
BiAttention MRU [59] (9x)	-	<u>60.2</u>	<u>50.3</u>	<u>53.3</u>
Finetuned Transformer LM (ours)	86.5	62.9	57.4	59.0

자연어 추론, 질문 답변, 의미 유사성, 텍스트 분류 등 다양한 지도 학습 작업에 대해 실험을 수행. 일부 작업은 최근에 출시된 GLUE 다중 작업 벤치마크에서 제공되는 작업을 포함한다. 자연어 추론(NLI) 작업은 두 문장을 읽고 그들 간의 관계를 추론하는 과제로, 다양한 현상이 존재해 여전히 도전적인 작업. 우리는 다섯 개의 데이터셋에서 실험을 진행했으며, 우리의 모델은 대부분의 데이터셋에서 이전 최첨단 모델보다 성능이 향상됨

질문 답변 및 상식 추론 작업에서는 RACE 데이터셋과 Story Cloze Test에서 이전 최상의 결과를 능가하는 성능을 보였다. 의미 유사성 작업에서는 MRPC, QQP, STS-B 데이터셋에서 최첨단 결과를 달성하였다. 마지막으로 텍스트 분류 작업에서는 CoLA와 SST-2에서 뛰어난 성과를 보였으며, GLUE 벤치마크에서 이전 최고 점수인 68.9를 넘어선 72.8점을 기록

5. Analysis

Impact of number of layers transferred




Figure 2: **(left)** Effect of transferring increasing number of layers from the pre-trained language model on RACE and MultiNLI. **(right)** Plot showing the evolution of zero-shot performance on different tasks as a function of LM pre-training updates. Performance per task is normalized between a random guess baseline and the current state-of-the-art with a single model.

Zero-shot Behaviors

트랜스포머의 생성적 사전 학습이 효과적인 이유를 이해하기 위해 여러 작업을 수행하는 휴리스틱 솔루션을 설계하고 실험을 진행한다. 이 과정에서 트랜스포머는 LSTM에 비해 더 안정적이고 성능이 꾸준히 증가하는 경향을 보인다. 예를 들어, CoLA에서는 생성 모델이 할당하는 평균 토큰 로그 확률을 기준으로 평가하고, SST-2에서는 "positive"와 "negative" 단어만 출력하도록 제한하여 예측한다. RACE에서는 문서와 질문에 조건을 걸어 답을 선택하고, DPRD에서는 참조어를 대체하여 생성 모델의 확률을 기반으로 해석을 예측한다.

Ablation studies

Method	Avg. Score	CoLA (mc)	SST2 (acc)	MRPC (F1)	STSB (pc)	QQP (F1)	MNLI (acc)	QNLI (acc)	RTE (acc)
Transformer w/ aux LM (full)	74.7	45.4	91.3	82.3	82.0	70.3	81.8	88.1	56.0
Transformer w/o pre-training	59.9	18.9	84.0	79.4	30.9	65.5	75.7	71.2	53.8
Transformer w/o aux LM	75.0	47.9	92.0	84.9	83.2	69.8	81.1	86.9	54.4
LSTM w/ aux LM	69.1	30.3	90.5	83.2	71.8	68.1	73.7	81.1	54.6

6. Conclusion

이 연구의 **의의**는 비지도 학습을 통해 자연어 이해 성능을 획기적으로 향상시킬 수 있다는 점이다. 연구는 생성적 사전 학습과 판별적 미세 조정을 통해 하나의 모델로 다양한 자연어 처리 과제를 해결할 수 있음을 입증했다. 이 방식은 특히 긴 범위의 의존성을 처리할 수 있는 능력을 기반으로, 기존의 모델들이 한정된 범위의 의존성만을 처리한 것과 차별화된다.

기존과의 차별점:

1. 기존 모델들은 주로 단일 작업에 맞춰 훈련되었으나, 이 연구는 하나의 작업 불가지론 모델을 통해 다양한 과제를 해결할 수 있음을 보여주었다.
2. 기존의 LSTM 기반 모델들보다, 트랜스포머 모델이 긴 범위의 의존성을 효과적으로 처리하고, 더 낮은 변동성을 보이며 제로샷 성능을 발휘하는 점에서 차별화된다.
3. 또한, 기존의 연구들은 각각 다른 데이터셋과 과제에 특화된 모델을 훈련했으나, 이 연구는 다양한 데이터셋을 통해 생성적 사전 학습의 효과를 증명하며, 트랜스포머와 긴 텍스트 의존성을 학습한 데이터셋이 이 방식에 최적화된다는 점을 강조했다.