

1. 개요 (Abstract)

- **LLaMA**(Large Language Model Meta AI)는 **7B에서 65B 개의 매개변수를 가진 언어 모델** 시리즈로 구성됨.
 - 기존 GPT-3(175B)보다 작은 모델(LLaMA-13B)이 더 나은 성능을 보여줌.
 - **모든 데이터는 공개적으로 사용 가능한 소스에서 가져옴** (GPT-3, PaLM 등은 비공개 데이터 사용).
 - 연구 커뮤니티를 위해 모든 모델을 공개하여 **대규모 언어 모델(LLM)의 접근성을 향상**하는 것이 목표.
-

2. 연구 배경 (Introduction)

- LLM(대규모 언어 모델)은 인간의 피드백 없이도 다양한 작업을 수행할 수 있는 능력을 보유.
 - 그러나, **매개변수 수가 많을수록 성능이 향상된다는 기존 가설**(Kaplan et al., 2020)은 최근 연구(Hoffmann et al., 2022)에서 수정됨.
 - 즉, **더 작은 모델을 더 많은 데이터로 훈련하는 것이 더 효율적**이라는 결과가 나옴.
 - 본 연구는 **다양한 추론 비용에 맞춘 최적의 모델을 개발하는 것을 목표로 함**.
-

3. LLaMA 모델 학습 방법

3.1 사전 학습 데이터 (Pre-training Data)

- **공개적으로 사용 가능한 데이터만 사용하여 LLaMA를 학습**.
- 데이터 출처 및 비율:
 - **CommonCrawl (67%)**: 웹에서 수집한 방대한 텍스트 데이터.
 - **C4 (15%)**: 기존 CommonCrawl 데이터 정제 버전.
 - **Github (4.5%)**: 오픈소스 코드 포함.
 - **Wikipedia (4.5%)**: 다국어 백과사전 데이터.
 - **Books (4.5%)**: Gutenberg 프로젝트 및 Books3 데이터.

- o arXiv 논문 (2.5%): 과학 논문 데이터.
 - o StackExchange (2.0%): 질문-응답 형식의 데이터.
 - 총 1.4조 개의 토큰(Token) 사용하여 모델을 훈련.
-

3.2 아키텍처 (Architecture)

- Transformer 기반 모델이며, 기존 모델 대비 여러 최적화 적용:
 - o Pre-normalization (GPT-3 방식): 층 출력이 아닌 입력을 정규화하여 학습 안정성 향상.
 - o SwiGLU 활성화 함수 (PaLM 방식): ReLU 대신 SwiGLU 사용으로 성능 개선.
 - o Rotary Embeddings (GPT-Neo 방식): 기존 절대 위치 임베딩 대신 사용하여 문맥 학습 향상.
 - 모델 크기:
 - o LLaMA-7B (7B 파라미터)
 - o LLaMA-13B (13B 파라미터)
 - o LLaMA-33B (33B 파라미터)
 - o LLaMA-65B (65B 파라미터)
-

3.3 최적화 및 학습 기법

- AdamW 옵티마이저 사용($\beta_1=0.9$, $\beta_2=0.95$)
 - 코사인 스케줄러(Cosine Decay)로 학습률 조정
 - 효율적인 다중 GPU 병렬 처리 적용하여 훈련 속도 개선
 - LLaMA-65B의 경우 2048개의 A100 GPU로 21일간 학습
-

4. 실험 결과 (Experiments)

4.1 비교 모델

- LLaMA는 다음과 같은 모델들과 성능을 비교:
 - GPT-3 (175B)
 - Chinchilla (70B)
 - PaLM (62B, 540B)
 - Gopher (280B)
 - OPT (175B)
 - GPT-NeoX (20B)

4.2 성능 평가

(1) 일반 상식 추론 (Common Sense Reasoning)

- LLaMA-13B가 GPT-3(175B)를 능가
- LLaMA-65B가 Chinchilla-70B와 비슷한 성능
- 특히 HellaSwag, ARC Challenge 등에서 높은 성능을 기록.

(2) 폐쇄형 질문 응답 (Closed-book QA)

- TriviaQA 및 Natural Questions 벤치마크에서 LLaMA-65B가 SOTA 달성
- LLaMA-13B도 GPT-3와 동등한 성능을 보이며, 크기 대비 효율성 입증.

(3) 독해 능력 평가 (Reading Comprehension)

- RACE 데이터셋 기준으로 LLaMA-65B가 GPT-3보다 6% 이상 성능 향상.

(4) 수학적 추론 (Mathematical Reasoning)

- LLaMA-65B는 Minerva-62B(수학 특화 모델)보다 성능이 낮지만, 기본 LLM 중에서는 최고 성능.

(5) 코드 생성 (Code Generation)

- HumanEval 및 MBPP 벤치마크에서 LLaMA-65B가 PaLM-62B를 초월.
- LLaMA-13B 모델도 LaMDA-137B보다 높은 코드 생성 성능을 보임.

5. 모델 활용 및 공개

- LLaMA는 연구 커뮤니티에 공개되어 누구나 연구 및 실험 가능.
 - GPT-3 등과 달리 완전한 오픈소스 데이터로 훈련되어 데이터 접근성 문제 해결.
-

6. 모델의 한계 및 문제점

- **편향(Bias) 문제:** 특정 인종, 성별, 종교에 대한 편향이 존재할 가능성이 있음.
 - **독해 성능:** 학습 데이터의 한계로 인해 MMLU 벤치마크에서 일부 성능 저하.
 - **사실성(Factual Accuracy) 문제:** TruthfulQA 평가에서 잘못된 정보 생성 가능성 확인.
-

7. 결론 및 향후 연구 방향

- LLaMA-13B는 GPT-3(175B)보다 성능이 우수하며, 크기가 10배 더 작음.
- LLaMA-65B는 Chinchilla-70B, PaLM-540B와 경쟁할 수 있음.
- 완전한 공개 데이터로 학습된 최초의 고성능 LLM.
- 향후 연구에서는 지속적인 학습 데이터 확대 및 모델 개선이 필요.