

LLaMA와 TCN 정리본

24기 정현서

1. LLaMA (Large Language Model Meta AI)

1.1 개요

LLaMA는 기존의 GPT-3와 같은 대형 언어모델(LLM)에 비해 크기가 현저히 작으면서도 경쟁 가능한 성능을 보여준 모델이다. 특히 GPT-3 모델 대비 10배 더 작은 규모로 효율적인 학습과 성능 달성을 목표로 하였다.

1.2 데이터 및 접근법

LLaMA는 데이터를 선정할 때 공개적으로 접근 가능한 데이터만을 사용하여 구축되었으며, 문서화된 데이터에 중점을 두었다. 데이터셋은 총 1.4T 토큰으로 구성되어 있고, 이 중에서 Wikipedia와 책과 같은 특정 데이터는 추가적인 반복 학습(2 epochs)을 진행하여 모델이 중요한 정보들을 충분히 학습할 수 있도록 했다. 또한, Byte Pair Encoding(BPE)을 사용하여 토큰화를 진행함으로써 언어 모델의 효율성을 향상시켰다.

1.3 아키텍처 특징

LLaMA는 Transformer의 디코더 구조를 기본으로 채택하였으며, GPT-3가 사용하는 Pre-normalization 접근 방식을 유지하면서도 다음과 같은 개선점을 적용하였다.

- 기존 Transformer 모델의 Layer Normalization 대신 RMSNorm을 사용하여 연산의 가벼움과 메모리 효율성을 증대시켰다. 이를 통해 Gradient Vanishing 문제를 완화하고 안정적인 학습 환경을 제공했다.
- 활성화 함수로 SwiGLU를 선택하여 ReLU보다 우수한 성능을 달성하였다. 메모리 효율성 측면에서 Feed Forward Layer의 차원 확장을 PaLM 모델의 4배에서 약 2.67배로 낮추면서도 성능은 유지했다.
- Rotary Embeddings (RoPE)을 도입하여 기존 절대 위치 임베딩의 시퀀스 길이 제한 문제를 극복하고 긴 시퀀스에 대해서도 자연스럽게 일반화가 가능한 모델을 만들었다.
- 효율적 코드 구현을 위해 Causal Multi-head Attention과 Sequence Parallelism을 적용하여 연산 속도를 향상시키고 메모리 소모를 최소화하였다.

1.4 성능 평가

- Common Sense Reasoning 및 Reading Comprehension에서 GPT-3, PaLM과 같은 기존 모델 대비 경쟁력 있는 성능을 나타냈다.
- 수학적 추론(MATH, GSM8k) 및 코드 생성(HumanEval, MBPP)에서도 우수한 성능을 보였다.
- MMLU 및 TruthfulQA에서 여전히 개선의 여지는 있지만, 상대적으로 뛰어난 성과를 기록하였다.

1.5 결론 및 의의

LLaMA는 공개 데이터만으로 효율적이고 우수한 성능을 달성할 수 있다는 점을 입증했다. 규모의 경제를 넘어서며 오픈소스 환경에서 강력한 경쟁력을 보여주었다.

2. TCN (Temporal Convolutional Networks)

2.1 개요

TCN은 기존의 순환 신경망(RNN)을 대체할 수 있는 효과적인 시계열 데이터 모델링을 위한 합성곱 신경망(CNN) 기반 아키텍처이다.

2.2 기존 모델과의 비교

기존의 RNN 계열 모델은 시퀀스 데이터에서 Gradient Vanishing이나 Gradient Exploding 문제로 인해 장기적인 의존성을 잘 학습하지 못한다는 한계가 있다. 이에 반해 TCN은 CNN 기반의 구조를 이용하여 이러한 문제를 효과적으로 해결하였다.

2.3 TCN의 구조 및 특징

TCN은 다음과 같은 구조적 특징을 가진다.

- 기존 CNN에서 사용되는 Pooling 방식을 대신하여 Dilated Convolution(팽창 컨볼루션)을 도입하였다. 이 방식을 통해 입력 시퀀스의 크기 제한 없이 가변적 길이의 시퀀스를 처리할 수 있다.
- Residual Connection을 사용하여 계층이 깊어짐에 따른 Gradient Vanishing 문제를 방지하였다. 이를 통해 모델이 긴 시퀀스에서 발생하는 복잡한 패턴을 효과적으로 학습할 수 있게 되었다.
- Dilated Convolution의 효과로 인해 시퀀스 데이터의 넓은 범위를 효율적으로 학습할 수 있고, CNN의 구조상 병렬 처리가 가능하여 RNN 대비 연산 속도에서 강

점을 가진다.

- 입력과 출력의 크기를 유사하게 유지할 수 있도록 구조를 설계하여 다양한 시계열 예측 및 연속 데이터 처리 분야에서 높은 호환성을 제공한다.

2.4 성능 평가

- 다양한 시퀀스 모델링 Task에서 RNN보다 더 우수하거나 최소한 유사한 성능을 나타냈다.
- NLP 분야(예: 자연어 처리, 번역, 감정 분석 등) 및 음악 데이터 모델링에서 TCN이 RNN의 성능을 뛰어넘는 결과를 보여주었다.

2.5 결론 및 의의

TCN은 RNN의 주요 한계를 극복하고, 긴 시퀀스 데이터에 대해 보다 안정적이고 효율적인 학습을 가능케 했다. 이는 시계열 예측, 자연어 처리, 음악 생성 등 다양한 응용 분야에서 널리 활용될 수 있는 가능성을 입증하였다.