



Llama

LLaMA: Open and Efficient Foundation Language Models

We introduce LLaMA, a collection of foundation language models ranging from 7B to 65B parameters. We train our models on trillions of tokens, and show that it is possible to train state-

 <https://arxiv.org/abs/2302.13971>



LLaMA: Open and Efficient Foundation Language Models

저자 : Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurelien Rodriguez, Armand Joulin, Edouard Grave, Guillaume Lample

발행일 : 2023년 2월

0. Abstrct

LLaMA(Large Language Model Meta AI)는 7B~65B 규모의 파라미터를 가진 대형 언어 모델로, 공개된 데이터만을 사용하여 학습되었다. 이때, LLaMA-13B는 GPT-3(175B)보다 대부분의 벤치마크에서 더 높은 성능을 보이며, LLaMA-65B는 Chinchilla-70B 및 PaLM-540B와 비슷한 성능을 보였다.

1. Introduction

대형 언어 모델은 Few-shot learning을 통해 새로운 작업을 학습하지 않고도 문제 해결할 수 있다. 기존 연구들은 모델 크기를 키우면 성능이 향상된다는 가정하에 확장되었지만, 최근 연구는 단순한 모델 크기 증가보다 더 많은 데이터를 활용하여 작은 모델을 학습하는 것이 더 효과적임을 보여주었다.

따라서, LLaMA는 더 적은 파라미터로 최상의 성능을 내는 모델을 개발하는 것을 목표로 함

- 공개 데이터만 사용하여 학습됨
- 다양한 크기의 모델을 제공하여 추론 속도와 비용을 최적화
- LLaMA-13B는 GPT-3(175B)보다 성능이 우수하며, LLaMA-65B는 Chinchilla-70B 및 PaLM-540B와 경쟁 가능

2. Approach

2.1. Pre-training data

LLaMA 모델의 학습 데이터는 완전히 공개된 데이터셋만으로 구성

Dataset	Sampling prop.	Epochs	Disk size
CommonCrawl	67.0%	1.10	3.3 TB
C4	15.0%	1.06	783 GB
Github	4.5%	0.64	328 GB
Wikipedia	4.5%	2.45	83 GB
Books	4.5%	2.23	85 GB
ArXiv	2.5%	1.06	92 GB
StackExchange	2.0%	1.03	78 GB

- **English CommonCrawl (67%)**: CCNet pipeline을 활용하여 전처리. 웹에서 수집된 텍스트 데이터를 중복 제거하고 언어를 식별한 후, 품질이 낮은 콘텐츠를 필터링함.
- **C4 (15%)**: T5에서 사용된 Colossal Clean Crawled Corpus (C4) 활용. heuristic 기반 품질 필터링 적용.
- **GitHub (4.5%)**: Google BigQuery에서 공개된 깃허브 데이터셋 사용. MIT, Apache, BSD 라이선스의 프로젝트만 포함하며, 중복 코드 제거 및 품질 필터링을 수행함.
- **Wikipedia (4.5%)**: 2022년 6~8월 데이터 활용, 20개 언어 포함 (bg, ca, cs, da, de, en, es, fr, hr, hu, it, nl, pl, pt, ro, ru, sl, sr, sv, uk).
- **Gutenberg & Books3 (4.5%)**: 공공 도서(Gutenberg Project) 및 Books3 데이터 포함. 유사한 책은 중복 제거함.
- **ArXiv (2.5%)**: 과학 논문 데이터를 포함하기 위해 사용. LaTeX 파일을 전처리하여 참고문헌 및 메타데이터 제거.

- **Stack Exchange (2%):** 질의응답(QA) 데이터를 포함하기 위해 Stack Exchange에서 28개의 주요 웹사이트 데이터를 사용.

2.2. Architecture

LLaMA는 Transformer 아키텍처를 기반으로 하며, 기존 연구의 개선점을 반영하여 학습 안정성과 성능을 향상시킴

params	dimension	n heads	n layers	learning rate	batch size	n tokens
6.7B	4096	32	32	$3.0e^{-4}$	4M	1.0T
13.0B	5120	40	40	$3.0e^{-4}$	4M	1.0T
32.5B	6656	52	60	$1.5e^{-4}$	4M	1.4T
65.2B	8192	64	80	$1.5e^{-4}$	4M	1.4T

Table 2: Model sizes, architectures, and optimization hyper-parameters.

- Pre-normalization [GPT-3] - 각 서브 레이어의 출력을 정규화하는 대신 입력을 정규화하여 학습 안정성을 개선 (RMSNorm 적용)
- SwiGLU Activation [PaLM] - ReLU 대신 SwiGLU를 사용하여 성능 향상 및 연산 효율 개선
- RoPE Positional Embeddings [GPTNeo] - 기존 절대 위치 임베딩을 제거하고, 상대적 위치 정보를 학습할 수 있도록 RoPE 적용

2.3. Optimizer

LLaMA 모델은 AdamW 옵티마이저(Loshchilov & Hutter, 2017)를 사용하여 학습됨

- $\beta_1 = 0.9$, $\beta_2 = 0.95$
- Cosine learning rate schedule: 최종 학습률은 최대 학습률의 10%
- Weight decay = 0.1, Gradient clipping = 1.0
- Warmup steps = 2,000
- 모델 크기에 따라 학습률과 배치 크기 조정

2.4. Efficient implementation

- xformers 라이브러리를 활용하여 메모리 사용량과 연산 속도를 최적화
- Activation Checkpointing 기법을 개선하여 비싼 연산만 저장하고 나머지는 재계산하여 메모리를 절약
- 모델 및 시퀀스 병렬 처리를 적용하고 GPU 연산과 통신을 최적화하여 65B 모델을 2048 개 A100 GPU에서 21일 만에 학습

3. Main results

LaMA는 zero-shot 및 few-shot 성능을 평가하기 위해 총 20개 벤치마크에서 테스트

- Zero-shot: 모델이 텍스트 설명과 테스트 예제만 보고 정답을 생성하거나 선택하는 방식
- Few-shot: 모델이 1~64개의 예제 학습 후 테스트 예제에 답을 생성하는 방식

3.1. Common Sense Reasoning

LLaMA는 BoolQ, PIQA, SIQA, HellaSwag, WinoGrande, ARC-e, ARC-c, OpenBookQA 등 8개의 일반 상식 벤치마크에서 평가됨

		BoolQ	PIQA	SIQA	HellaSwag	WinoGrande	ARC-e	ARC-c	OBQA
GPT-3	175B	60.5	81.0	-	78.9	70.2	68.8	51.4	57.6
Gopher	280B	79.3	81.8	50.6	79.2	70.1	-	-	-
Chinchilla	70B	83.7	81.8	51.3	80.8	74.9	-	-	-
PaLM	62B	84.8	80.5	-	79.7	77.0	75.2	52.5	50.4
PaLM-cont	62B	83.9	81.4	-	80.6	77.0	-	-	-
PaLM	540B	88.0	82.3	-	83.4	81.1	76.6	53.0	53.4
LLaMA	7B	76.5	79.8	48.9	76.1	70.1	72.8	47.6	57.2
	13B	78.1	80.1	50.4	79.2	73.0	74.8	52.7	56.4
	33B	83.1	82.3	50.4	82.8	76.0	80.0	57.8	58.6
	65B	85.3	82.8	52.3	84.2	77.0	78.9	56.0	60.2

Table 3: Zero-shot performance on Common Sense Reasoning tasks.

- LLaMA-65B는 Chinchilla-70B보다 대부분의 벤치마크에서 높은 성능을 보였으며, PaLM-540B도 일부 벤치마크에서 초월
- LLaMA-13B는 GPT-3보다 10배 작음에도 불구하고 대부분의 벤치마크에서 더 높은 성능을 기록

3.2. Closed-book Question Answering

LLaMA는 Natural Questions, TriviaQA에서 문서를 참조하지 않고 질문에 답하는 closed-book setting으로 평가됨

		0-shot	1-shot	5-shot	64-shot
Gopher	280B	43.5	-	57.0	57.2
Chinchilla	70B	55.4	-	64.1	64.6
LLaMA	7B	50.0	53.4	56.3	57.6
	13B	56.6	60.5	63.1	64.0
	33B	65.1	67.9	69.9	70.4
	65B	68.2	71.6	72.6	73.0

Table 5: **TriviaQA.** Zero-shot and few-shot exact match performance on the filtered dev set.

- LLaMA-65B는 zero-shot 및 few-shot에서 SOTA 성능을 달성
- LLaMA-13B도 GPT-3 및 Chinchilla와 경쟁할 수준의 성능을 보이며, V100 GPU 하나로 추론 가능
- LLaMA-65B는 Chinchilla-70B보다 높은 정확도를 기록하며, 규모 대비 효율적인 성능을 입증

3.3. Reading Comprehension

LLaMA는 RACE 데이터셋을 활용하여 독해 능력을 평가받았으며, 이는 중·고등학생 대상 영어 독해 시험에서 수집된 데이터

		RACE-middle	RACE-high
GPT-3	175B	58.4	45.5
PaLM	8B	57.9	42.3
	62B	64.3	47.5
	540B	68.1	49.1
LLaMA	7B	61.1	46.9
	13B	61.6	47.2
	33B	64.1	48.3
	65B	67.9	51.6

Table 6: **Reading Comprehension.** Zero-shot accuracy.

- LLaMA-65B는 PaLM-540B와 경쟁할 만한 성능을 보임
- LLaMA-13B는 GPT-3보다 몇 퍼센트 높은 정확도를 기록

3.4. Mathematical reasoning

LLaMA는 수학적 추론 능력을 평가하기 위해 MATH와 GSM8k 데이터셋에서 테스트됨

		MATH +maj1@k		GSM8k +maj1@k	
PaLM	8B	1.5	-	4.1	-
	62B	4.4	-	33.0	-
	540B	8.8	-	56.5	-
Minerva	8B	14.1	25.4	16.2	28.4
	62B	27.6	43.4	52.4	68.5
	540B	33.6	50.3	68.5	78.5
LLaMA	7B	2.9	6.9	11.0	18.1
	13B	3.9	8.8	17.8	29.3
	33B	7.1	15.2	35.6	53.1
	65B	10.6	20.5	50.9	69.7

- MATH는 LaTeX으로 작성된 중·고등학교 수학 문제 12K개로 구성됨
- GSM8k는 중학생 수준의 수학 문제를 포함
- Minerva는 PaLM을 수학 데이터로 추가 학습한 모델이지만, LLaMA는 수학 데이터로 파인튜닝되지 않았음에도 불구하고 LLaMA-65B가 Minerva-62B를 초과하는 성능을 보임

3.5. Code generation

HumanEval과 MBPP 데이터셋을 사용하여 코드 생성 능력을 평가받았으며, 자연어로 주어진 프로그램 설명과 입출력 예시에 맞는 Python 코드를 생성해야 함

pass@	Params	HumanEval		MBPP	
		@1	@100	@1	@80
LaMDA	137B	14.0	47.3	14.8	62.4
PaLM	8B	3.6*	18.7*	5.0*	35.7*
PaLM	62B	15.9	46.3*	21.4	63.2*
PaLM-cont	62B	23.7	-	31.2	-
PaLM	540B	26.2	76.2	36.8	75.0
LLaMA	7B	10.5	36.5	17.7	56.2
	13B	15.8	52.5	22.0	64.0
	33B	21.7	70.7	30.2	73.4
	65B	23.7	79.3	37.7	76.8

- LLaMA는 코드에 특화된 파인튜닝 없이도 PaLM 및 LaMDA와 같은 기존 모델보다 높은 성능을 기록
- LLaMA-13B는 LaMDA-137B를 초과하는 성능을 보였으며, LLaMA-65B는 PaLM-62B보다 우수한 성능을 나타냄
- 코드에 특화된 파인튜닝(PaLM-Coder 등)을 적용하면 성능이 더욱 향상될 수 있으나, 본 연구에서는 다루지 않음

3.6. Massive Multitask Language Understanding

- LLaMA-65B는 MMLU 벤치마크에서 Chinchilla-70B와 PaLM-540B보다 낮은 성능을 기록함
- 이는 LLaMA의 학습 데이터에서 책과 학술 논문이 부족했기 때문으로 추정됨

3.7. Evolution of performance during training

- 대부분의 벤치마크에서 perplexity가 감소할수록 성능이 향상되었음
- 그러나 SIQA는 변동이 심하고 WinoGrande는 모델 크기에 따른 성능 차이가 크지 않았음

4. Bias, Toxicity and Misinformation

LLaMA는 웹 데이터를 대량으로 학습했기 때문에 편향, 독성(유해성), 허위 정보 생성 가능성을 평가하는 것이 중요함

이를 위해 여러 벤치마크에서 LLaMA-65B의 유해성 위험성을 분석했지만, 현재의 평가 방법 만으로는 모델의 모든 위험성을 완전히 이해하기 어렵다고 언급됨

5.1. RealToxicityPrompts

LLaMA는 RealToxicityPrompts 벤치마크를 사용하여 독성 콘텐츠 생성 가능성을 평가함

- 모델 크기가 커질수록 toxicity score 증가, 특히 "정중한(respectful)" 프롬프트에서도 독성이 증가하는 경향을 보임
- LLaMA-65B는 0.128(기본), 0.141(정중한) 점수를 기록하며, 기존 연구에서 관찰된 결과와 유사함
- Chinchilla와 Gopher에서는 모델 크기에 따른 독성 증가가 명확하지 않았으나, LLaMA에서는 더 큰 모델이 독성을 더 많이 생성하는 경향이 확인됨

5.2. CrowS-Pairs

LLaMA는 CrowS-Pairs 벤치마크를 통해

성별, 인종, 종교, 연령 등 9가지 사회적 편향을 평가받음

	LLaMA	GPT3	OPT
Gender	70.6	62.6	65.7
Religion	79.0	73.3	68.6
Race/Color	57.0	64.7	68.6
Sexual orientation	81.0	76.2	78.6
Age	70.1	64.4	67.8
Nationality	64.2	61.6	62.9
Disability	66.7	76.7	76.7
Physical appearance	77.8	74.6	76.2
Socioeconomic status	71.5	73.8	76.2
Average	66.6	67.2	69.5

- LLaMA는 GPT-3, OPT-175B보다 평균적으로 편향이 적지만, 종교, 연령, 성별에서 더 큰 편향을 보임
- CommonCrawl 데이터에 기인한 것으로 추정됨

5.3. WinoGender

LLaMA는 WinoGender 벤치마크에서 성별 편향에 따른 공동 참조 해석(co-reference resolution) 성능을 분석함

	7B	13B	33B	65B
All	66.0	64.7	69.0	77.5
her/her/she	65.0	66.7	66.7	78.8
his/him/he	60.8	62.5	62.1	72.1
their/them/someone	72.1	65.0	78.3	81.7
her/her/she (gotcha)	64.2	65.8	61.7	75.0
his/him/he (gotcha)	55.0	55.8	55.8	63.3

- 독립적 대명사(their/them/someone)에 대한 성능이 높고, 남성(his/him/he)과 여성(her/her/she) 대명사에서는 낮음
- 직업과 성별의 일반적 연관성을 반영한 결과로, 사회적 편향을 포함하고 있음을 시사함
- 특히, 직업과 대명사가 일치하지 않는 "gotcha" 사례에서 오류율이 증가, 성별에 따른 고정관념을 학습한 것으로 보임

5.4. TruthfulQA

TruthfulQA 벤치마크를 통해 LLaMA의 사실 검증 능력과 허위 정보 생성 가능성을 평가함

		Truthful	Truthful*Inf
GPT-3	1.3B	0.31	0.19
	6B	0.22	0.19
	175B	0.28	0.25
LLaMA	7B	0.33	0.29
	13B	0.47	0.41
	33B	0.52	0.48
	65B	0.57	0.53

- LLaMA는 GPT-3보다 더 높은 진실성 점수를 기록했지만, 여전히 허위 정보를 생성할 가능성이 존재
- 모델 크기가 커질수록 사실적인 응답 비율이 증가하지만, 완벽하지 않음

5. Carbon footprint

- LLaMA 모델 학습에는 막대한 에너지가 소비되었으며, 상당한 탄소 배출량이 발생함
- 이를 평가하기 위해 GPU 사용 시간, 전력 소비량, 전력 사용 효율을 고려하여 총 에너지 소비와 탄소 배출량을 추정함

6. Conclusion

LLaMA는 공개적으로 배포된 언어 모델 시리즈로, 기존 SOTA 모델과 경쟁할 수 있는 성능을 갖춤

- LLaMA-13B는 GPT-3보다 작지만 더 높은 성능, LLaMA-65B는 Chinchilla-70B 및 PaLM-540B와 유사한 성능을 보임
- 모든 학습 데이터를 공개 데이터만 사용하여도 최첨단 성능을 달성할 수 있음을 입증
- 모델 공개를 통해 연구 커뮤니티가 LLM 개발을 가속화하고, 편향·독성 문제 해결에 기여할 것으로 기대
- 향후 더 큰 데이터셋을 활용한 모델을 개발하고, instruction finetuning을 추가 연구할 계획