



Llama

이름	홍준기
대학교	동국대학교
학과	산업공학과
날짜	2025년

Abstract

LLaMA는 7B에서 65B개의 파라미터를 가진 여러 모델로 구성되며, 모든 모델은 공개된 데이터만을 사용하여 훈련되었다. 이는 기존 대형 언어 모델 (GPT-3, PaLM 등)이 비공개 데이터에 의존하는 문제를 해결하고, 연구 커뮤니티에 개방적으로 제공될 수 있도록 하기 위한 접근 방식임

Abstract

1. Introduction

연구 Background:

2. Training with Architecture

2.1. Train dataset

2.2. 모델 아키텍처 및 최적화

2.3. Brief Summary of Results

3. Specific Results(1)

3.1. Common Sense Reasoning

3.2. Closed-book Question Answering

3.3. Reading Comprehension

3.4. Mathematical Reasoning

3.5. Code Generation

3.6. Massive Multitask Language Understanding, MMLU

3.7. Performance Evolution During Training

3.8. Instruction Finetuning

4. Specific Results(2)

4.1. RealToxicityPrompts(유해 콘텐츠 평가)

4.2. CrowS-Pairs(사회적 편향 평가)

4.3. WinoGender(성별 편향 평가)

5. Conclusions

1. Introduction

연구 Background:

- 대규모 언어 모델은 더 큰 모델이 더 좋은 성능을 보일 것이라는 가정하에 연구가 진행됨
- 그러나 **Hoffmann et al. (2022)의 연구**에 따르면, 컴퓨팅 자원이 제한된 상황에서는 단순히 모델 크기를 키우는 것보다 더 많은 데이터를 학습시키는 것이 성능 향상에 효과적이라는 것이 밝혀짐
- 따라서, 본 연구에서는 특정 컴퓨팅 예산 내에서 **최적의 성능을 내는 모델을 개발하는 것**에 초점을 맞추었음

2. Training with Architecture

2.1. Train dataset

LLaMA는 다양한 공개 데이터 소스로부터 데이터를 수집하여 훈련됨. 주요 데이터 출처 및 비율은 다음과 같다.

- **CommonCrawl (67%)**: 인터넷에서 수집한 대규모 텍스트 데이터 (2017~2020년)
- **C4 (15%)**: 기존 CommonCrawl을 필터링한 고품질 데이터셋
- **GitHub (4.5%)**: 오픈소스 코드 저장소 (Apache, BSD, MIT 라이선스만 사용)
- **Wikipedia (4.5%)**: 20개 언어의 최신 위키백과 덤프
- **Gutenberg 및 Books3 (4.5%)**: 공공 도서 데이터셋
- **arXiv (2.5%)**: 과학 논문 데이터 (수식 및 불필요한 부분 제거)
- **Stack Exchange (2%)**: 다양한 주제의 Q&A 데이터

2.2. 모델 아키텍처 및 최적화

- **Transformer 기반 아키텍처**를 사용하지만 여러 개선점을 적용
 - **Pre-normalization (GPT-3에서 적용됨)**: 안정적인 학습을 위해 서브 레이어 입력을 정규화.
 - **SwiGLU 활성화 함수 (PaLM에서 적용됨)**: 성능 향상을 위해 ReLU 대신 SwiGLU 사용.
 - **Rotary Embeddings (GPT-Neo에서 적용됨)**: 기존 절대 위치 임베딩 대신 RoPE 방식 사용
- 훈련 최적화를 위해 AdamW 옵티마이저 및 다양한 기법 적용
 - **Cosine 학습률 스케줄링** 사용.
 - **모델 병렬화 및 체크포인팅**으로 메모리 사용량 절감.
 - **GPU 연산 최적화**로 2048개 A100 GPU에서 초당 380 토큰 처리
 - **문장 하나 또는 두 개를 입력으로 받을 수 있도록** 설계되었음

2.3. Brief Summary of Results

- LLaMA-13B 모델은 **GPT-3(175B)보다 우수한 성능**을 보이며, LLaMA-65B는 **Chinchilla-70B 및 PaLM-540B와 경쟁할 수 있는 수준**임을 확인함
- 특히 LLaMA 모델은 **소형 모델에서도 우수한 성능**을 보이며, **단일 GPU에서도 실행 가능**하다는 점에서 연구 및 실용성 측면에서 강점

3. Specific Results(1)

3.1. Common Sense Reasoning

- LLaMA-65B 모델이 **Chinchilla-70B 모델보다 모든 벤치마크에서 우수한 성능**을 보였으나, BoolQ에서는 Chinchilla에 미치지 못함
- **LLaMA-13B 모델이 GPT-3보다도 뛰어난 성능**을 기록, 특히 모델 크기가 10배 작음에도 불구하고 성능이 우수함

3.2. Closed-book Question Answering

- Pre-training과 동일한 설정 유지 (dropout: 0.1).
 - 미세 조정 시 , **batch size: 32, 3 epochs** 만으로도 충분한 성능 도달
 - 학습률은 **warm-up** 후 선형 감소 (linear decay schedule) 적용

3.3. Reading Comprehension

- LLaMA-65B는 **PaLM-540B**와 거의 유사한 성능을 보이며, **GPT-3**보다 우수한 성능을 기록

3.4. Mathematical Reasoning

- LaMA-65B는 **Minerva-62B** 모델보다 **GSM8k**에서 더 높은 성능을 보였으며, 수학 데이터로 추가 미세 조정(finetuning) 없이도 경쟁력 있는 성능을 보임

3.5. Code Generation

- 모델이 자연어로 주어진 프로그램 설명을 기반으로 **Python** 코드 생성
- 코드 전용으로 추가 학습을 하지 않았음에도 불구하고 높은 코드 생성 성능을 보임.

3.6. Massive Multitask Language Understanding, MMLU

- LLaMA-65B는 **Chinchilla-70B** 및 **PaLM-540B**보다 다소 낮은 성능을 보임.
- GPT-3보다 성능이 뛰어나지만, **훈련 데이터에서 학술 서적 및 논문이 적은 양(177GB)**만 사용된 것이 성능 차이의 원인으로 분석

3.7. Performance Evolution During Training

- 여러 질문 답변 및 상식 추론 벤치마크에서 모델의 훈련 중 성능 변화를 추적함
- 대부분의 벤치마크에서 성능이 지속적으로 향상되었으며, **훈련 손실(perplexity)**과 성능 간의 강한 상관관계를 보임

3.8. Instruction Finetuning

- 명령어 데이터로 소량 미세 조정(finetuning)하면 **MMLU** 성능이 빠르게 향상됨

- 실험 결과, LLaMA-I(Instruction-tuned LLaMA)는 기존의 일부 명령어 학습 모델 (OPT-IML, Flan-PaLM)보다 우수한 성능을 보임

4. Specific Results(2)

4.1. RealToxicityPrompts(유해 콘텐츠 평가)

- 100,000개의 프롬프트를 모델이 완성한 후, **PerspectiveAPI**를 이용해 생성된 문장의 유해성(0~1 사이 값)을 측정
- 기존 연구에서 모델 크기가 증가할수록 유해 콘텐츠 생성 가능성이 높아지는 경향이 보고됨
- 실험 결과, LLaMA 모델에서도 모델 크기가 클수록 유해성 점수가 증가하는 경향을 보임

4.2. CrowS-Pairs(사회적 편향 평가)

- 9가지 카테고리(성별, 종교, 인종, 성적 지향, 연령, 국적, 장애, 외모, 사회경제적 지위)에서 편향 측정
 - 각 예제는 편향적인 문장(스테레오타입)과 비편향적인 문장(안티-스테레오타입)으로 구성, 모델이 어떤 문장을 선호하는지 평가
 - 편향 점수가 높을수록 특정 스테레오타입을 더 강하게 반영
- LLaMA-65B는 GPT-3, OPT-175B보다 편향성이 약간 낮은 편.
- 그러나 종교(10% 더 높음), 연령, 성별 카테고리에서 상대적으로 높은 편향을 보임.

4.3. WinoGender(성별 편향 평가)

- 성별을 포함한 대명사의 상관관계 분석을 수행하여 모델이 사회적 성별 편향을 학습했는지 확인.
- 모델은 문장에서 대명사가 누구를 지칭하는지 예측해야 하며, 이를 통해 직업과 성별 간의 연관성을 측정
- LaMA-65B는 성별 중립적인 대명사("their/them/someone")에서 가장 높은 정확도를 기록
- 그러나 "her/her/she" 및 "his/him/he" 대명사에서는 상대적으로 낮은 성능을 보임

5. Conclusions

5.1. 사전 학습 태스크의 효과 (Effect of Pre-training Tasks)

- 실험 결과, LLaMA는 기존 최첨단 모델들과 경쟁할 수 있는 성능을 보여주었으며, 특히 **LLaMA-13B는 GPT-3보다 우수한 성능을 보이면서도 10배 이상 작은 크기를 유지하였다.** 또한, **LLaMA-65B는 Chinchilla-70B 및 PaLM-540B와 비슷한 성능을 기록하며,** 대형 언어 모델의 새로운 대안이 될 수 있음을 입증

1. 공개 데이터만을 사용하여 최첨단 성능을 달성
2. 연구 커뮤니티에 개방하여 언어 모델 연구 가속화
3. 명령어 미세 조정(Finetuning)이 성능을 크게 향상

→ LLaMA는 공개 데이터만으로도 **GPT-3 이상의 성능을 달성할 수 있음을 보여준 최초의 대형 언어 모델**