

LLaMA: Open and Efficient Foundation Language Models

📅 작성일시	@2025년 3월 18일
📍 강의 번호	BASE
📍 유형	논문리뷰
📎 자료	https://arxiv.org/pdf/2302.13971
☑️ 복습	☐

ABSTRACT

LLaMA는 7억부터 65억의 파라미터를 갖는 Foundation Language Model임.

! Foundation Language Model이란?

일반적으로 대규모 텍스트(또는 멀티모달) 데이터로 사전에 학습되어, 다양한 자연어 처리 작업에 광범위하게 활용될 수 있는 대형 언어 모델을 가리키는 용어임.

1. 대규모 사전 학습(Pre-training)

인터넷 등에서 수집된 방대한 텍스트 데이터를 기반으로, 문맥 파악, 문장 생성, 요약, 추론 등의 능력을 학습함.

2. 범용성(Generalizability)

한 번 대규모 학습을 마치면, 다양한 과제(질의응답, 감정 분석, 텍스트 분류, 요약 등)에 맞춰 미세 조정 혹은 프롬프트 엔지니어링 과정을 통해 쉽게 적용할 수 있음

즉, Foundation :Language Model은 대규모 사전 학습과 높은 범용성을 바탕으로, 여러가지 자연어 처리 업무의 기초 혹은 토대가 되는 모델

모델은 수 조개의 토큰으로 학습하고 공개적으로 이용 가능한 데이터셋을 사용하여 SOTA모델을 학습하는 것이 가능하다는 것을 보임.

대부분의 벤치마크에서 LLaMA-13B는 GPT-3를 능가하고 LLaMA-65B는 Chinchilla70B, PaLM-540B와 견줄 만 함.

INTRODUCTION

모델을 확장시키려는 노력이 계속되면서 더 좋은 성능을 위해서 더 많은 파라미터가 필요하다는 가정이 기초가 되었음. 하지만 최근 연구에 따르면 주어진 컴퓨팅 예산 내에서 더 좋은 성능을 달성하는 것은 큰 모델이 아니라 **더 많은 데이터로 학습된 더 작은 모델**임. 목표 수준의 성능이 주어질 때, 더 작은 모델이 학습에 더 오래 걸릴지라도 궁극적으로 추론에 더 비용이 적게 들기 때문에 더 작은 모델이 선호됨.

본 논문에서는 더 많은 토큰을 학습시켜 최고의 성능을 달성하는 적절한 크기의 언어모델을 추구함. 이렇게 생성된 LLaMA는 7억~65억 파라미터로 기존의 초거대 언어모델인 SOTA들과 비교하여 경쟁력 있는 성능을 보임.

LLaMA는 기존 모델과 달리 공개적으로 이용 가능한 데이터만 사용하므로 오픈 소싱과 호환됨.

APPROACH

Pre-training Data

학습 데이터 세트는 Table1에 나와있는 것처럼 다양한 도메인을 포괄하는 여러 소스가 혼합되어 있고 대부분 공개 데이터임.

Byte-Pair Encoding(BPE) Algorithm을 이용해 토큰나이징하여 약 1.4조개의 토큰을 생성하였음.

Dataset	Sampling prop.	Epochs	Disk size
CommonCrawl	67.0%	1.10	3.3 TB
C4	15.0%	1.06	783 GB
Github	4.5%	0.64	328 GB
Wikipedia	4.5%	2.45	83 GB
Books	4.5%	2.23	85 GB
ArXiv	2.5%	1.06	92 GB
StackExchange	2.0%	1.03	78 GB

Table 1: **Pre-training data.** Data mixtures used for pre-training, for each subset we list the sampling proportion, number of epochs performed on the subset when training on 1.4T tokens, and disk size. The pre-training runs on 1T tokens have the same sampling proportion.

BPE - 텍스트 데이터를 가변 길이 바이트 쌍으로 표현하여, 빈도가 높은 문자열을 짧은 바이트 쌍으로 나타내는 방식

Architecture

트랜스포머 아키텍처 기반 모델로 구현함.

Pre-normalization(GPT3): 훈련 안정성을 향상시키기 위해 출력 대신 각 트랜스포머 하위 계층의 입력을 RMSNorm정규화 하였음.

SwiGLU activation function(PaLM): 활성화 함수로 ReLU 대신 SwiGLU사용, PaLM의 4d 대신 (2/3)4d 차원을 사용함.

Rotary Embeddings(GPTNeo): Absolute positional embeddings 대신 Rotary positional embeddings 사용,

! SwiGLU 란?

구글이 발표한 대규모 언어모델인 PaLM에서 사용된 게이트 기반 피드포워드 아키텍처의 일종으로, 기존의 GeLU나 ReLU 대신 Swish 함수를 활용하는 것이 핵심.

즉, 입력을 두 갈래로 나눠 한 쪽은 선형 변환, 다른 한 쪽은 Swish 활성화를 적용한 뒤에 이 둘을 요소별로 곱을 취해 게이트처럼 동작시킴.

GLU는 입력 텐서를 두 부분으로 나누고, 한 부분은 그대로 선형 변환을 수행하며, 다른 한 부분은 이를 게이트처럼 통제하기 위해 시그모이드 등을 취한 뒤 서로 곱해 최종 출력을 얻음.

$$\text{GLU}(X) = (XW_1) \otimes \sigma(XW_2)$$

$$\text{SwiGLU}(X) = (XW_1) \otimes \text{Swish}(XW_2)$$

σ 는 시그모이드 함수인데 SwiGLU는 Swish함수로 대체하여 입력의 유효범위를 좀 더 부드럽게 제어함.

PaLM 등의 모델은 SwiGLU를 트랜스포머 블록의 피드포워드 신경망 부분에서 사용해, 학습 안정성과 표현력 측면에서 이점을 얻었다고 알려져 있음.

그러면 왜 SwiGLU가 주목받을까?

1. ReLU 대비 부드러운 활성화 : Swish는 음수 구간에서도 완전히 0이 되지 않고 연속적으로 활성화가 변하여, 기울기 소실이나 특정 축을 경직되게 만들지 않는 장점이 있음.
2. 게이트 효과 : 단순히 하나의 활성화 함수를 쓰는 대신, 두 갈래 분기에 의해 학습되는 게이트구조가 모델 표현력 향상에 도움이 됨.
3. 성능 향상 : 실제로 PaLM과 같은 대규모 모델에서 SwiGLU를 적용하면, 기존 GeLU 중심 구조 대비 소폭이나마 좋은 성능과 수렴 안정성을 보이는 것으로 보고 되었음.

Optimizer

AdamW 옵티마이저 사용 (하이퍼파라미터 $\beta_1 = 0.9, \beta_2 = 0.95$)

Cosine Learning Rate Schedule 사용

weight decay = 0.1 gradient clipping 1.0 , 2000 warm up step

params	dimension	n heads	n layers	learning rate	batch size	n tokens
6.7B	4096	32	32	$3.0e^{-4}$	4M	1.0T
13.0B	5120	40	40	$3.0e^{-4}$	4M	1.0T
32.5B	6656	52	60	$1.5e^{-4}$	4M	1.4T
65.2B	8192	64	80	$1.5e^{-4}$	4M	1.4T

Table 2: Model sizes, architectures, and optimization hyper-parameters.

Efficient Implementation

메모리 사용과 런타임을 줄이기 위해 Causal multi-head attention 사용 (xformers 라이브러리)

→ attention weight 정렬, key/query 점수 계산을 하지 않음

계산하기 비싼 activation 저장하여 많은 양의 다시 계산되는 activation을 줄임

→ 모델, 시퀀스 병렬 처리를 통해서 메모리 사용을 줄여야 함.

Main Results

Common Sense Reasoning

8개의 standard common sense reasoning benchmarks(BoolQ, PIQA, SIQA, HellaSwag, WinoGrande, ARC easy and challenge, OpenBookQA)에 대해 zero-shot 설정으로 진행

		BoolQ	PIQA	SIQA	HellaSwag	WinoGrande	ARC-e	ARC-c	OBQA
GPT-3	175B	60.5	81.0	-	78.9	70.2	68.8	51.4	57.6
Gopher	280B	79.3	81.8	50.6	79.2	70.1	-	-	-
Chinchilla	70B	83.7	81.8	51.3	80.8	74.9	-	-	-
PaLM	62B	84.8	80.5	-	79.7	77.0	75.2	52.5	50.4
PaLM-cont	62B	83.9	81.4	-	80.6	77.0	-	-	-
PaLM	540B	88.0	82.3	-	83.4	81.1	76.6	53.0	53.4
LLaMA	7B	76.5	79.8	48.9	76.1	70.1	72.8	47.6	57.2
	13B	78.1	80.1	50.4	79.2	73.0	74.8	52.7	56.4
	33B	83.1	82.3	50.4	82.8	76.0	80.0	57.8	58.6
	65B	85.3	82.8	52.3	84.2	77.0	78.9	56.0	60.2

Table 3: Zero-shot performance on Common Sense Reasoning tasks.

LLaMA-65B는 BoolQ를 제외한 모든 벤치마크에서 Chinchilla-70B를 능가했고, BoolQ와 WinoGrande를 제외하고는 PaLM-540B를 넘어섰음.

LLaMA-13B는 10배는 더 작은 크기임에도 불구하고 대부분의 벤치마크에서 GPT-3를 넘어섰음.

Closed-book Question Answering

		0-shot	1-shot	5-shot	64-shot
GPT-3	175B	14.6	23.0	-	29.9
Gopher	280B	10.1	-	24.5	28.2
Chinchilla	70B	16.6	-	31.5	35.5
PaLM	8B	8.4	10.6	-	14.6
	62B	18.1	26.5	-	27.6
	540B	21.2	29.3	-	39.6
LLaMA	7B	16.8	18.7	22.0	26.1
	13B	20.1	23.4	28.1	31.9
	33B	24.9	28.3	32.9	36.0
	65B	23.8	31.0	35.0	39.9

Table 4: NaturalQuestions. Exact match performance.

		0-shot	1-shot	5-shot	64-shot
Gopher	280B	43.5	-	57.0	57.2
Chinchilla	70B	55.4	-	64.1	64.6
LLaMA	7B	50.0	53.4	56.3	57.6
	13B	56.6	60.5	63.1	64.0
	33B	65.1	67.9	69.9	70.4
	65B	68.2	71.6	72.6	73.0

Table 5: TriviaQA. Zero-shot and few-shot exact match performance on the filtered dev set.

Reading Comprehension

		RACE-middle	RACE-high
GPT-3	175B	58.4	45.5
PaLM	8B	57.9	42.3
	62B	64.3	47.5
	540B	68.1	49.1
LLaMA	7B	61.1	46.9
	13B	61.6	47.2
	33B	64.1	48.3
	65B	67.9	51.6

Table 6: **Reading Comprehension.** Zero-shot accuracy.

Mathematical Reasoning

		MATH +maj1@k	GSM8k +maj1@k
PaLM	8B	1.5	-
	62B	4.4	-
	540B	8.8	-
Minerva	8B	14.1	25.4
	62B	27.6	43.4
	540B	33.6	50.3
LLaMA	7B	2.9	6.9
	13B	3.9	8.8
	33B	7.1	15.2
	65B	10.6	20.5

Table 7: **Model performance on quantitative reasoning datasets.** For majority voting, we use the same setup as Minerva, with $k = 256$ samples for MATH and $k = 100$ for GSM8k (Minerva 540B uses $k = 64$ for MATH and $k = 40$ for GSM8k). LLaMA-65B outperforms Minerva 62B on GSM8k, although it has not been fine-tuned on mathematical data.

Code Generation

pass@	Params	HumanEval		MBPP	
		@1	@100	@1	@80
LaMDA	137B	14.0	47.3	14.8	62.4
PaLM	8B	3.6*	18.7*	5.0*	35.7*
PaLM	62B	15.9	46.3*	21.4	63.2*
PaLM-cont	62B	23.7	-	31.2	-
PaLM	540B	26.2	76.2	36.8	75.0
LLaMA	7B	10.5	36.5	17.7	56.2
	13B	15.8	52.5	22.0	64.0
	33B	21.7	70.7	30.2	73.4
	65B	23.7	79.3	37.7	76.8

Table 8: **Model performance for code generation.** We report the pass@ score on HumanEval and MBPP. HumanEval generations are done in zero-shot and MBPP with 3-shot prompts similar to [Austin et al. \(2021\)](#). The values marked with * are read from figures in [Chowdhery et al. \(2022\)](#).

Massive Multitask Language Understanding

		Humanities	STEM	Social Sciences	Other	Average
GPT-NeoX	20B	29.8	34.9	33.7	37.7	33.6
GPT-3	175B	40.8	36.7	50.4	48.8	43.9
Gopher	280B	56.2	47.4	71.9	66.1	60.0
Chinchilla	70B	63.6	54.9	79.3	73.9	67.5
PaLM	8B	25.6	23.8	24.1	27.8	25.4
	62B	59.5	41.9	62.7	55.8	53.7
	540B	77.0	55.6	81.0	69.6	69.3
LLaMA	7B	34.0	30.5	38.3	38.1	35.1
	13B	45.0	35.8	53.8	53.3	46.9
	33B	55.8	46.0	66.7	63.4	57.8
	65B	61.8	51.7	72.9	67.4	63.4

Table 9: Massive Multitask Language Understanding (MMLU). Five-shot accuracy.

Evolution of performance during Training

학습을 진행할 수록 성능은 향상되었고, 학습 perplexity(불안성) 과의 상관관계도 나타났음.




Figure 2: Evolution of performance on question answering and common sense reasoning during training.

Bias, Toxicity and Misinformation

모델 크기가 커질수록 Toxic Prompt를 생성할 확률이 높아짐을 확인

편향성은 GPT, OPT 대비 LLaMA가 적음

Truthful 정도도 GPT 보다 크게 나옴

CONCLUSION

LLaMA-13B는 GPT-3보다 10배 이상 작으면서도 성능이 뛰어나며, LLaMA-65B는 chinchilla-70B 및 PaLM-540B와도 경쟁력이 있음

이전 연구와 달리 공개적으로 사용 가능한 데이터로만 훈련하여 최첨단 성능을 달성할 수 있다는 것을 입증

데이터 규모를 키우면서 성능이 향상되는 것을 확인했기 때문에 향후에는 더 큰 코퍼스로 훈련된 모델을 출시할 계획.