

LLaMa 논문 리뷰

1. 서론

대규모 언어 모델(LLM)의 발전은 모델의 크기를 키우는 방향으로 진행되어 왔다. 하지만 최근 연구에서는 동일한 계산 자원 내에서 더 나은 성능을 달성하려면 단순히 모델 크기를 키우기보다는 더 많은 데이터를 활용하는 것이 효과적임을 시사한다. 이는 작은 모델이더라도 충분한 데이터를 학습하면 추론 비용을 절감하면서도 높은 성능을 낼 수 있다는 점에서 실용적인 이점을 갖는다.

LLaMA는 이러한 접근 방식을 기반으로 설계된 모델로, 7B에서 65B까지 다양한 크기의 모델을 제공하며, 공개된 데이터만을 활용하여 기존의 최고 성능 LLM과 경쟁력 있는 결과를 보였다.

2. 접근 방법

2.1 사전 학습 데이터

LLaMA의 학습 데이터는 여러 공개 소스를 결합하여 구성되었다. 이를 통해 품질 높은 대규모 데이터셋을 확보하였다.

- **CommonCrawl (2017~2020)**: 언어 인식, 중복 제거, 저품질 콘텐츠 필터링을 수행하여 고품질 데이터만을 남김.
- **C4 데이터셋**: CommonCrawl에서 가공된 데이터셋으로 휴리스틱을 이용한 품질 필터링 적용.
- **GitHub 데이터**: Google BigQuery에서 수집한 공개 GitHub 저장소 데이터로, 저품질 파일 및 중복 제거 수행.
- **Wikipedia**: 20개 언어의 2022년 덤프를 사용하며, 보일러플레이트 및 하이퍼링크 제거.
- **Gutenberg & Books3**: 추가적인 책 말뭉치를 포함하여 중복을 제거함.
- **arXiv**: 과학 논문 데이터를 활용하되, 참고문헌 및 불필요한 메타데이터를 제거함.
- **Stack Exchange**: 높은 품질의 질의응답 데이터를 활용하여 HTML 태그 및 불필요한 내용을 정리.

LLaMA는 Byte-Pair Encoding (BPE) 방식을 사용하여 텍스트를 토큰화하였으며, 최종적으로 약 1.4조 개의 토큰을 생성하였다.

2.2 모델 아키텍처

LLaMA는 Transformer 기반 모델이지만, 몇 가지 차별점을 가진다.

- **Pre-normalization:** 학습 안정성을 위해 각 Transformer 서브 레이어 입력에 RMSNorm 적용 (GPT-3 방식).
- **SwiGLU 활성화 함수:** 기존 ReLU 대신 SwiGLU를 사용하고, PaLM에서 제안된 4d 대신 (2/3)4d 차원 적용.
- **Rotary Embeddings (RoPE):** 절대 위치 임베딩 대신 RoPE를 적용하여 위치 정보 표현 향상.

2.3 최적화 기법

- **AdamW 옵티마이저** ($\beta_1 = 0.9$, $\beta_2 = 0.95$) 사용.
- **Cosine Learning Rate Scheduler** 적용.
- **Weight Decay = 0.1, Gradient Clipping = 1.0, 2000 Step Warmup** 설정.

2.4 효율적 구현

- **Causal Multi-Head Attention:** Xformers 라이브러리를 활용하여 Key/Query 점수 계산을 줄임.
- **Activation 저장 기법:** 비싼 연산을 줄이기 위해 PyTorch Autograd를 사용하지 않고 Backward Function을 수동 구현.
- **모델 및 시퀀스 병렬화:** 메모리 사용량을 줄이고 계산 효율성을 증가시킴.

3. 주요 성능 평가

3.1 상식 추론

8개 일반 상식 추론 벤치마크(BoolQ, PIQA, SIQA 등)에서 LLaMA-65B는 BoolQ를 제외한 모든 벤치마크에서 Chinchilla-70B를 능가했다. 또한 LLaMA-13B는 10배 작은 크기임에도 GPT-3보다 높은 성능을 보였다.

3.2 폐쇄형 질의응답

LLaMA-65B는 Natural Questions, TriviaQA 벤치마크에서 zero-shot 및 few-shot 설정에서 SOTA 성능을 기록했으며, LLaMA-13B 역시 GPT-3 및 Chinchilla와 경쟁력 있는 성능을 보였다.

3.3 독해 능력

RACE 벤치마크에서 LLaMA-65B는 PaLM-540B와 유사한 성능을 기록했으며, LLaMA-13B는 GPT-3를 소폭 상회하는 결과를 보였다.

3.4 수학적 추론

MATH, GSM8K 벤치마크에서 평가한 결과, LLaMA-65B는 파인튜닝되지 않은 상태에서 Minerva-62B를 능가하였다.

3.5 코드 생성

HumanEval, MBPP 벤치마크에서 LLaMA는 코드 데이터에 대한 파인튜닝 없이도 PaLM 및 LaMDA 대비 우수한 성능을 보였다.

3.6 다중 태스크 이해

MMLU 벤치마크 5-shot 설정에서 LLaMA-65B는 Chinchilla-70B 및 PaLM-540B와 유사한 성능을 기록했지만, 학습 데이터에 포함된 책과 학술 논문의 제한적 사용이 성능에 영향을 미친 것으로 보인다.

3.7 학습 과정에서의 성능 변화




Figure 1: Training loss over train tokens for the 7B, 13B, 33B, and 65 models. LLaMA-33B and LLaMA-

훈련이 진행될수록 성능이 꾸준히 향상되었으며, Perplexity(모델의 불확실성)와도 상관관계를 보였다.

4. 지시형 미세 조정 (Instruction Finetuning)

MMLU 벤치마크에서 소량의 미세 조정만으로도 성능이 향상되었다. Instruction Finetuned 모델인 LLaMA-I는 68.9%의 정확도를 기록하며 기존 대부분의 Instruction

Finetuned 모델을 능가했지만, GPT (code-davinci-002)에는 미치지 못했다.

5. 편향, 독성 및 허위 정보

웹 데이터를 활용한 대규모 학습은 모델이 유해한 콘텐츠를 학습할 가능성이 높다는 점을 고려해야 한다.

5.1 RealToxicityPrompts

모델 크기가 증가할수록 독성이 증가하는 경향을 보였으며, 이는 동일한 모델 계열 내에서만 적용될 가능성이 있다.

5.2 CrowS-Pairs

9개 카테고리에서 고정관념 편향을 평가한 결과, LLaMA는 GPT-3 및 OPT-175B와 유사한 수준의 편향을 보였으며, 특히 지역(Category) 관련 편향이 더 강하게 나타났다.

5.3 WinoGender

공동참조 결정을 평가한 결과, LLaMA는 무성 대명사(their)에 대해 유성 대명사(her, his)보다 더 정확한 예측을 수행했으나, 특정 직업과 성별을 연관 짓는 경향이 발견되었다.

5.4 TruthfulQA

진실성 평가에서는 LLaMA가 일부 측면에서 GPT-3보다 높은 점수를 기록했지만, 전반적으로 정답률이 낮았다.

6. 결론

LLaMA는 기존 모델 대비 작은 크기임에도 불구하고 공개 데이터만을 활용하여 높은 성능을 기록했다. 또한, 효율적인 학습 및 최적화 기법을 적용하여 계산 비용을 절감하면서도 추론 성능을 극대화하였다. 다만, 편향 및 독성 문제를 완화하기 위한 추가적인 연구가 필요하다.