

Introduction

- 대형 언어 모델(LLM)은 인간처럼 다양한 작업(번역, 질의응답 등)을 수행할 수 있음.
- 기존 모델은 매우 큰 크기와 폐쇄된 데이터로 학습해 공개 연구가 어려움.

LLaMA는:

- 7B, 13B, 33B, 65B 크기의 모델을 제공.
- 공개 데이터만 사용. (책, 논문, GitHub 코드, StackExchange 등)
- 소규모 모델도 고성능을 보여줌.

예시:

LLaMA 13B → GPT-3보다 성능 좋음 (GPT-3는 175B)

LLaMA 65B → Chinchilla(70B), PaLM(540B)과 경쟁 가능

Approach (방법론)

학습데이터

데이터 출처	비율	특징
CommonCrawl	67%	웹사이트 텍스트, 저품질 제거 및 정제
C4	15%	Google에서 만든 웹 텍스트 데이터
Github	4.5%	오픈소스 코드 데이터
Wikipedia	4.5%	여러 언어의 백과사전 데이터
Books (Gutenberg & Books3)	4.5%	퍼블릭 도메인 책
ArXiv	2.5%	과학 논문
StackExchange	2%	질문/답변 커뮤니티

토큰나이징(BPE 방식): 텍스트를 숫자로 변환해 처리 (SentencePiece 사용)

모델 구조 (아키텍처)

개선 방식	설명
Pre-normalization	층의 입력값을 먼저 정규화 → 안정성 증가 (GPT-3 방식)
SwiGLU 활성화 함수	기존 ReLU보다 더 나은 성능 (PaLM에서 사용한 함수)
Rotary Embedding (RoPE)	위치 정보 표현 방식 개선 (GPT-Neo에서 사용)

최적화 방법 (Optimizer)

AdamW 옵티마이저 사용

Cosine learning rate 스케줄

가중치 감소, 그래디언트 클리핑 추가 → 과적합 방지, 안정적 학습

모델 크기와 학습량

모델 크기	파라미터 수	토큰 수 (학습량)
7B	70억	1조
13B	130억	1조
33B	330억	1.4조
65B	650억	1.4조

Main Results (주요 결과)

✓ 공통 상식 이해(Common Sense Reasoning)

여러 벤치마크에서 GPT-3, PaLM보다 더 나은 성능

특히 13B 모델이 GPT-3(175B)를 능가함

✓ 질문 응답(Closed-book QA)

TriviaQA, NaturalQuestions에서 PaLM 및 Chinchilla와 비슷하거나 더 좋은 성능

LLaMA 13B는 GPU 한 개에서도 실행 가능 (V100 기준)

✓ 수학적 추론 및 코드 생성

수학 문제, 코드 생성에서도 좋은 결과

특히 수학적/코드 데이터로 추가 학습 안 했음에도 높은 정확도

✓ 다중 작업 처리(MMLU)

65B 모델은 63.4% 정확도 → PaLM, Chinchilla보다 조금 낮지만 준수한 성능

Instruction Finetuning (명령어 파인튜닝)

간단한 파인튜닝만으로 명령어 이해 성능이 크게 향상

LLaMA-I (Instruction finetuned)는 Flan-PaLM보다 더 높은 정확도

Bias, Toxicity, Misinformation (편향, 유해성, 거짓 정보)

RealToxicityPrompts: 크기가 클수록 유해한 내용 생성 가능성 증가

CrowS-Pairs: 종교, 성별 등 편향 존재 확인

WinoGender: 성별 편향으로 직업 예측 편향 발생

TruthfulQA: GPT-3보다 거짓 정보 덜 생성, 하지만 여전히 개선 필요

탄소 발자국 (Carbon Footprint)

훈련 과정에서 전기 사용량과 탄소 배출량 공개

LLaMA는 효율적이라 13B는 23톤 CO₂eq, 65B는 173톤 정도 배출 (다른 모델보다 적음)

결론

LLaMA는 공개 데이터만으로도 최첨단 성능 가능성을 보여줌

연구자 누구나 접근 가능하여 LLM 연구를 민주화하는 데 기여

향후 더 큰 데이터셋과 모델 공개 예정